UNIVERSITÉ DE NAMUR

Econométrie

Variable Dépendante Binaire : MPL, Logit et Probit

Jérémy Do Nascimento Miguel
Université de Namur
19/10/2026

Rappel du cours précédent

- Régression sur discontinuité (RDD) : exploiter une règle d'assignation au traitement
- Jusqu'ici, la variable que l'on cherche à expliquer, Y, était ***continue*** : score en maths, taux de mortalité, emploi par établissement, salaire...



Rappel du cours précédent

- Régression sur discontinuité (RDD) : exploiter une règle d'assignation au traitement
- Jusqu'ici, la variable que l'on cherche à expliquer, Y, était ***continue*** : score en maths, taux de mortalité, emploi par établissement, salaire...

Aujourd'hui : *variable dépendante binaire*

- Que faire lorsque Y ne prend que deux valeurs : ***0*** ou ***1*** ?
- Pourquoi les ***MCO*** (OLS) posent-ils des problèmes dans ce cas ?
- Trois modèles : le ***modèle de probabilité linéaire (MPL)***, le ***logit*** et le ***probit***
- *Applications empiriques* : participation des femmes au marché du travail et refus de prêts hypothécaires (données de packages `R`)



La variable dépendante binaire

Qu'est-ce qu'une variable binaire ?

> ***Variable binaire*** (ou ***dummy***, ***indicatrice***, ***dichotomique***) : variable qui ne prend que ***deux valeurs***, codées 0 et 1.

Qu'est-ce qu'une variable binaire ?

> ***Variable binaire*** (ou ***dummy***, ***indicatrice***, ***dichotomique***) : variable qui ne prend que ***deux valeurs***, codées 0 et 1.

$$Y_i = \begin{cases} 1 \text{ si l'événement d'intérêt se réalise pour l'individu } i \\ 0 \text{ sinon} \end{cases}$$

Qu'est-ce qu'une variable binaire ?

> ***Variable binaire*** (ou ***dummy***, ***indicatrice***, ***dichotomique***) : variable qui ne prend que ***deux valeurs***, codées 0 et 1.

$$Y_i = \begin{cases} 1 \text{ si l'événement d'intérêt se réalise pour l'individu } i \\ 0 \text{ sinon} \end{cases}$$

- Par convention, $Y = 1$ correspond à l'***événement d'intérêt*** (le « succès »).
- Le codage $0/1$ n'est pas anodin : il donne à la moyenne de Y une interprétation très simple (voir plus loin).

Qu'est-ce qu'une variable binaire ?

> ***Variable binaire*** (ou ***dummy***, ***indicatrice***, ***dichotomique***) : variable qui ne prend que ***deux valeurs***, codées 0 et 1.

$$Y_i = \begin{cases} 1 \text{ si l'événement d'intérêt se réalise pour l'individu } i \\ 0 \text{ sinon} \end{cases}$$

- Par convention, $Y = 1$ correspond à l'***événement d'intérêt*** (le « succès »).
- Le codage $0/1$ n'est pas anodin : il donne à la moyenne de Y une interprétation très simple (voir plus loin).
- Les deux modalités sont ***mutuellement exclusives*** : un individu est soit dans la catégorie 1, soit dans la catégorie 0.



Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui* / *non* » :

Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui* / *non* » :

- Une femme *participe-t-elle* au marché du travail ?



Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui / non* » :

- Une femme *participe-t-elle* au marché du travail ?
- Un ménage *achète-t-il* un logement ? Un client *souscrit-il* à un produit ?

Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui / non* » :

- Une femme *participe-t-elle* au marché du travail ?
- Un ménage *achète-t-il* un logement ? Un client *souscrit-il* à un produit ?
- Une demande de prêt est-elle *refusée* ? Un emprunteur *fait-il défaut* ?



Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui / non* » :

- Une femme *participe-t-elle* au marché du travail ?
- Un ménage *achète-t-il* un logement ? Un client *souscrit-il* à un produit ?
- Une demande de prêt est-elle *refusée* ? Un emprunteur *fait-il défaut* ?
- Un étudiant *obtient-il* son diplôme ? Un individu est-il *au chômage* ?



Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui / non* » :

- Une femme *participe-t-elle* au marché du travail ?
- Un ménage *achète-t-il* un logement ? Un client *souscrit-il* à un produit ?
- Une demande de prêt est-elle *refusée* ? Un emprunteur *fait-il défaut* ?
- Un étudiant *obtient-il* son diplôme ? Un individu est-il *au chômage* ?
- Une entreprise *exporte-t-elle* ? Une personne *vote-t-elle* ?



Des exemples en économie

Beaucoup de questions économiques sont des questions de type « *oui / non* » :

- Une femme *participe-t-elle* au marché du travail ?
- Un ménage *achète-t-il* un logement ? Un client *souscrit-il* à un produit ?
- Une demande de prêt est-elle *refusée* ? Un emprunteur *fait-il défaut* ?
- Un étudiant *obtient-il* son diplôme ? Un individu est-il *au chômage* ?
- Une entreprise *exporte-t-elle* ? Une personne *vote-t-elle* ?

⚠️ Il s'agit d'une ***variable dépendante*** binaire, à ne pas confondre avec les variables explicatives binaires (dummies) que nous avons déjà utilisées comme régresseurs.



Variable binaire : explicative ou dépendante ?

Dummy comme variable explicative (déjà vu)

$$Y_i = \beta_0 + \beta_1 D_i + \varepsilon_i$$

- Y est continue.
- β_1 = différence de moyenne de Y entre les groupes $D = 1$ et $D = 0$.
- Les MCO fonctionnent très bien (RCT, DiD, RDD...).

Variable binaire : explicative ou dépendante ?

Dummy comme variable explicative (déjà vu)

$$Y_i = \beta_0 + \beta_1 D_i + \varepsilon_i$$

- Y est continue.
- β_1 = différence de moyenne de Y entre les groupes $D = 1$ et $D = 0$.
- Les MCO fonctionnent très bien (RCT, DiD, RDD…).

Dummy comme variable dépendante (aujourd'hui)

$$D_i = \beta_0 + \beta_1 X_i + \varepsilon_i \text{ ???}$$

- $Y \in \{0, 1\}$ n'est pas continue.
- Que signifie « prédire » un 0 ou un 1 ?
- Les MCO sont-ils encore appropriés ?

Propriétés d'une variable binaire

Soit Y une variable binaire et $p = \mathbb{P}(Y = 1)$.

Propriétés d'une variable binaire

Soit Y une variable binaire et $p = \mathbb{P}(Y = 1)$.

- ***Espérance*** : la moyenne d'une variable binaire est la ***proportion*** de 1 :

$$\mathbb{E}(Y) = 1 \times \mathbb{P}(Y = 1) + 0 \times \mathbb{P}(Y = 0) = p$$



Propriétés d'une variable binaire

Soit Y une variable binaire et $p = \mathbb{P}(Y = 1)$.

- ***Espérance*** : la moyenne d'une variable binaire est la ***proportion*** de 1 :

$$\mathbb{E}(Y) = 1 \times \mathbb{P}(Y = 1) + 0 \times \mathbb{P}(Y = 0) = p$$

- ***Variance*** : elle est entièrement déterminée par la moyenne :

$$\mathbb{V}(Y) = p(1 - p)$$



Propriétés d'une variable binaire

Soit Y une variable binaire et $p = \mathbb{P}(Y = 1)$.

- ***Espérance*** : la moyenne d'une variable binaire est la ***proportion*** de 1 :

$$\mathbb{E}(Y) = 1 \times \mathbb{P}(Y = 1) + 0 \times \mathbb{P}(Y = 0) = p$$

- ***Variance*** : elle est entièrement déterminée par la moyenne :

$$\mathbb{V}(Y) = p(1 - p)$$

- Conséquence : *modéliser l'espérance conditionnelle* de Y revient à modéliser la ***probabilité conditionnelle*** que $Y = 1$:

$$\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$$

Propriétés d'une variable binaire

Soit Y une variable binaire et $p = \mathbb{P}(Y = 1)$.

- ***Espérance*** : la moyenne d'une variable binaire est la ***proportion*** de 1 :

$$\mathbb{E}(Y) = 1 \times \mathbb{P}(Y = 1) + 0 \times \mathbb{P}(Y = 0) = p$$

- ***Variance*** : elle est entièrement déterminée par la moyenne :

$$\mathbb{V}(Y) = p(1 - p)$$

- Conséquence : *modéliser l'espérance conditionnelle* de Y revient à modéliser la ***probabilité conditionnelle*** que $Y = 1$:

$$\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$$

$\rightarrow$ Notre objectif : comprendre comment la ***probabilité*** que l'événement se réalise ***varie avec*** X.



Premier exemple : participation des femmes au marché du travail

- Données de Mroz (1987) : 753 femmes mariées, données de panel américain (PSID) de 1975.
- Disponibles dans le package `R` `wooldridge`, jeu de données `mroz`.

Premier exemple : participation des femmes au marché du travail

- Données de Mroz (1987) : 753 femmes mariées, données de panel américain (PSID) de 1975.
- Disponibles dans le package `R wooldridge`, jeu de données `mroz`.

```
# installer le package (une seule fois)
install.packages("wooldridge")

# charger les données
data("mroz", package = "wooldridge")
```



Premier exemple : participation des femmes au marché du travail

- Données de Mroz (1987) : 753 femmes mariées, données de panel américain (PSID) de 1975.
- Disponibles dans le package `R` `wooldridge`, jeu de données `mroz`.

```
# installer le package (une seule fois)
install.packages("wooldridge")

# charger les données
data("mroz", package = "wooldridge")
```

```
mroz %>%
  select(inlf, educ, exper, age, kidslt6, nwifeinc) %>
  head()
```

```
##   inlf educ exper age kidslt6  nwifeinc
## 1    1   12    14  32       1 10.910060
## 2    1   12     5  30       0 19.499981
## 3    1   12    15  35       1 12.039910
## 4    1   12     6  34       0  6.799996
## 5    1   14     7  31       1 20.100058
## 6    1   12    33  54       0  9.859054
```



Les variables de `mroz`

Variable	Définition
`inlf`	*Variable dépendante* : 1 si la femme a travaillé en 1975, 0 sinon
`educ`	Années d'éducation
`exper`	Années d'expérience sur le marché du travail
`age`	Âge de la femme (en années)
`kidslt6`	Nombre d'enfants de moins de 6 ans
`kidsge6`	Nombre d'enfants de 6 à 18 ans
`nwifeinc`	Revenu du ménage hors revenu de la femme (en milliers de dollars)



Les variables de `mroz`

Variable	Définition
`inlf`	*Variable dépendante* : 1 si la femme a travaillé en 1975, 0 sinon
`educ`	Années d'éducation
`exper`	Années d'expérience sur le marché du travail
`age`	Âge de la femme (en années)
`kidslt6`	Nombre d'enfants de moins de 6 ans
`kidsge6`	Nombre d'enfants de 6 à 18 ans
`nwifeinc`	Revenu du ménage hors revenu de la femme (en milliers de dollars)

Question : que pensez-vous de l'effet attendu de chaque variable sur la probabilité de travailler ?



La variable `inlf` : proportion de femmes actives

```
table(mroz$inlf)
```

```
##
##   0   1
## 325 428
```

```
mean(mroz$inlf)
```

```
## [1] 0.5683931
```

La moyenne de `inlf` est la ***proportion*** de femmes qui ont travaillé : 56.8 %.



La variable `inlf` : proportion de femmes actives

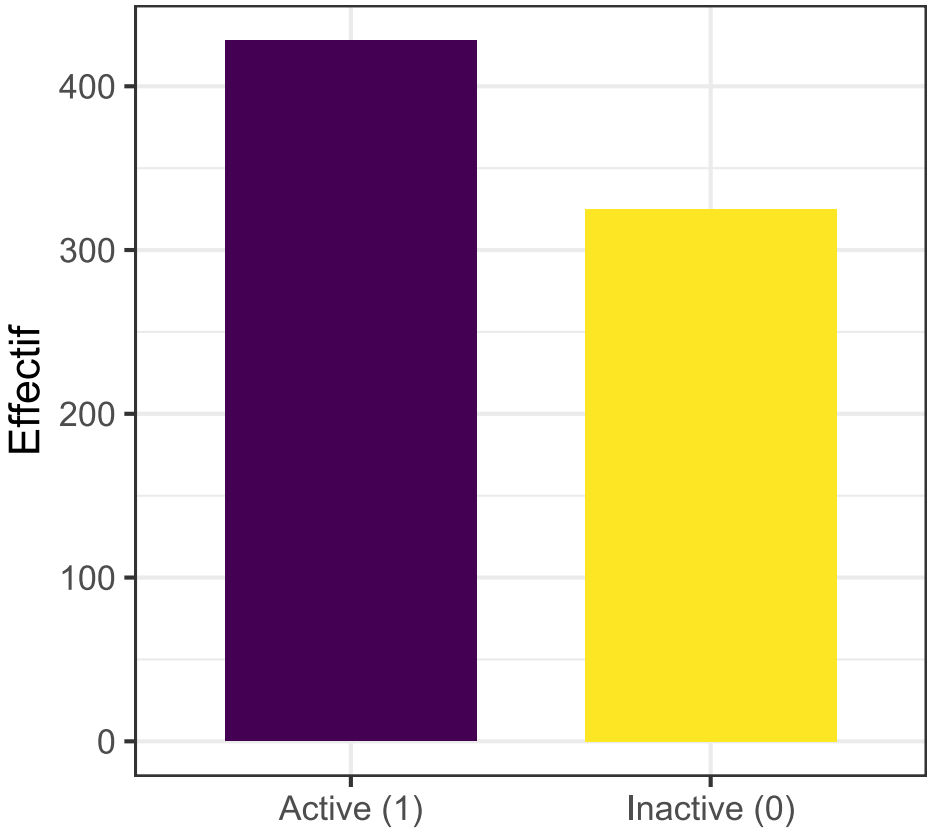
```
table(mroz$inlf)
```

```
##
##   0   1
## 325 428
```

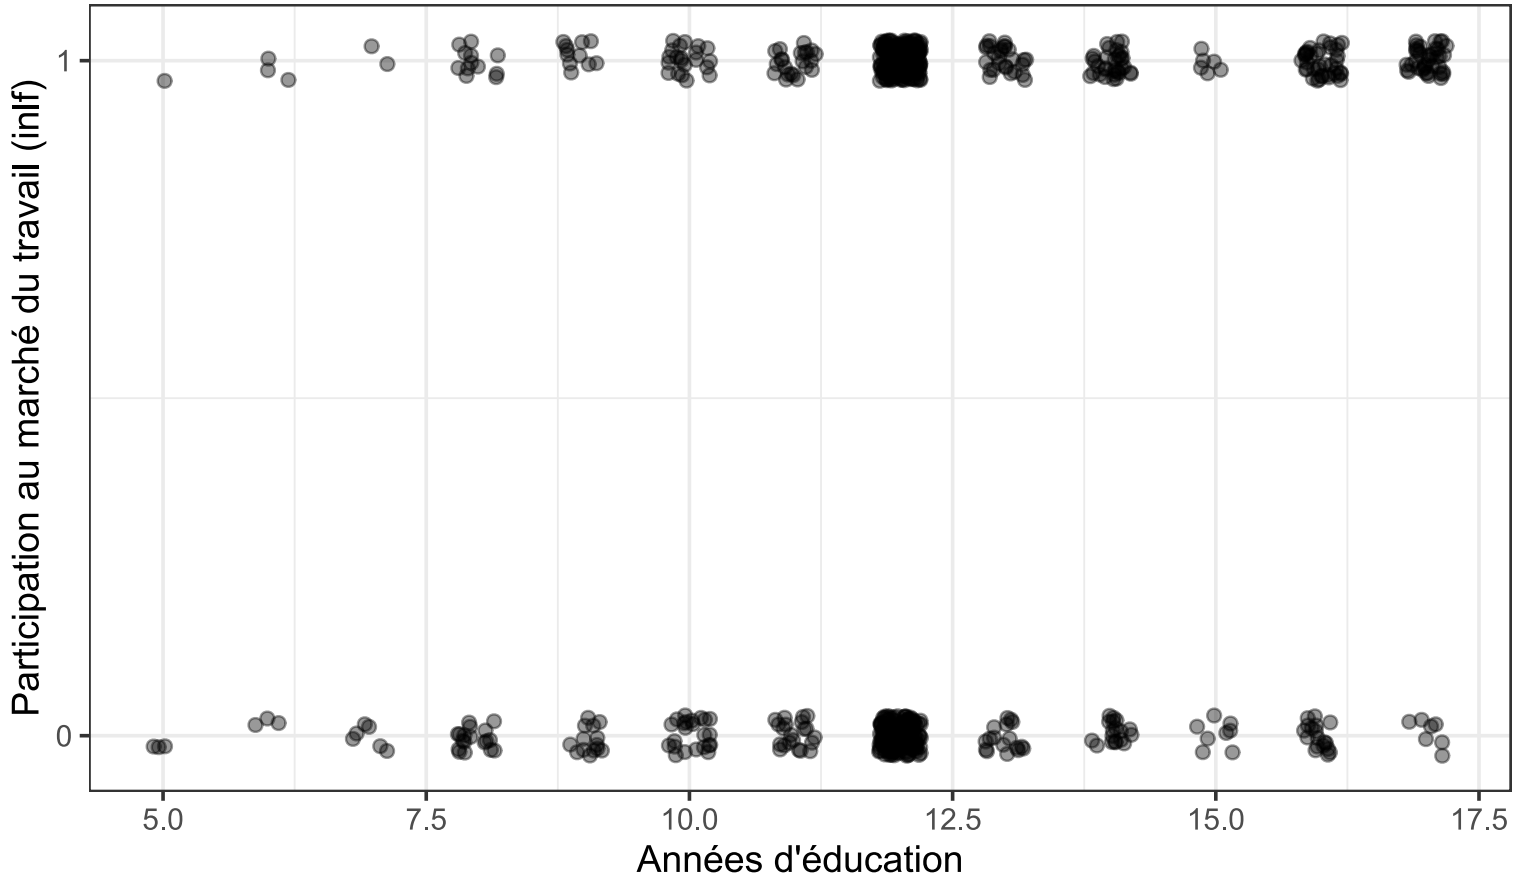
```
mean(mroz$inlf)
```

```
## [1] 0.5683931
```

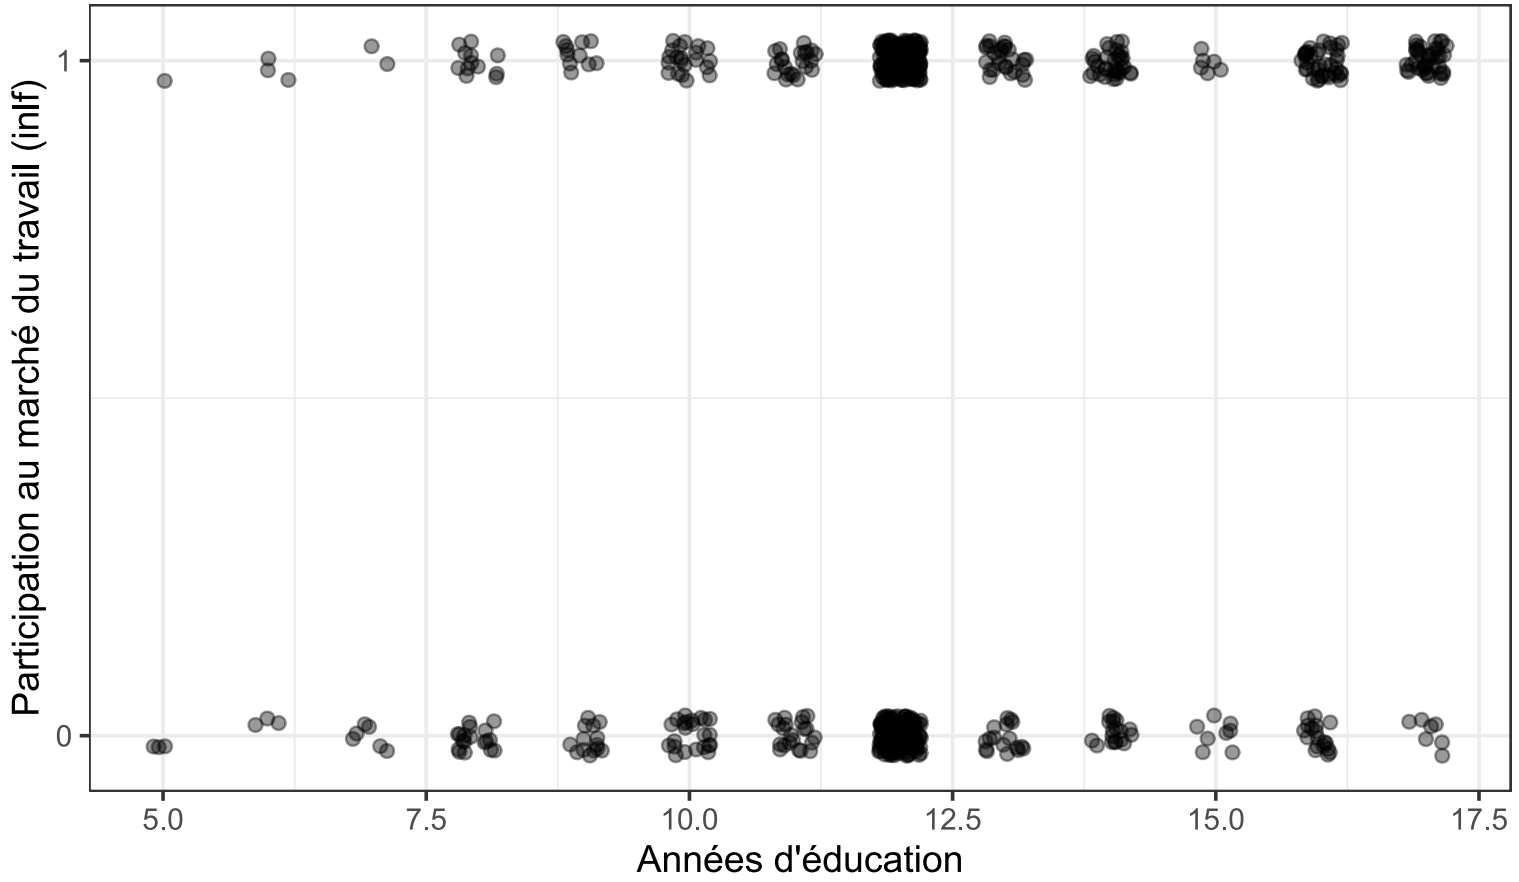
La moyenne de `inlf` est la ***proportion*** de femmes qui ont travaillé : 56.8 %.



Que voulons-nous modéliser ?



Que voulons-nous modéliser ?



Les points se répartissent sur ***deux lignes*** (0 et 1). On veut décrire comment la ***probabilité*** d'être sur la ligne 1 évolue avec l'éducation.

Le modèle de probabilité linéaire (MPL)

Point de départ : retour aux MCO

- Modèle de régression linéaire multiple, estimé par ***MCO*** :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + u_i$$

Point de départ : retour aux MCO

- Modèle de régression linéaire multiple, estimé par ***MCO*** :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + u_i$$

- Lorsque Y est ***continue***, on interprète β_j comme la ***variation de*** Y associée à une variation d'une unité de X_j, toutes choses égales par ailleurs :

$$\beta_j = \frac{\Delta Y}{\Delta X_j}$$

Point de départ : retour aux MCO

- Modèle de régression linéaire multiple, estimé par ***MCO*** :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + u_i$$

- Lorsque Y est ***continue***, on interprète β_j comme la ***variation de*** Y associée à une variation d'une unité de X_j, toutes choses égales par ailleurs :

$$\beta_j = \frac{\Delta Y}{\Delta X_j}$$

- Lorsque Y est ***binaire***, cette interprétation n'a plus de sens : Y ne peut valoir que 0 ou 1, donc elle ne peut pas varier de « β_j unités » de façon continue.

Point de départ : retour aux MCO

- Modèle de régression linéaire multiple, estimé par ***MCO*** :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + u_i$$

- Lorsque Y est ***continue***, on interprète β_j comme la ***variation de*** Y associée à une variation d'une unité de X_j, toutes choses égales par ailleurs :

$$\beta_j = \frac{\Delta Y}{\Delta X_j}$$

- Lorsque Y est ***binaire***, cette interprétation n'a plus de sens : Y ne peut valoir que 0 ou 1, donc elle ne peut pas varier de « β_j unités » de façon continue.

- Mais l'interprétation reste possible si l'hypothèse ***MLR.4*** (*moyenne conditionnelle nulle*) est vérifiée :

$$\mathbb{E}(u_i | X_{1i}, \ldots, X_{ki}) = 0$$



- Mais l'interprétation reste possible si l'hypothèse ***MLR.4*** (*moyenne conditionnelle nulle*) est vérifiée :

$$\mathbb{E}(u_i|X_{1i},\ldots,X_{ki}) = 0$$

- Dans ce cas, $\mathbb{E}(Y_i|X_i) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki}$: β_j mesure la variation de l'***espérance conditionnelle*** de Y, et non de Y lui-même. Or, pour une variable binaire, l'espérance de Y est une ***probabilité***.

Le modèle de probabilité linéaire (MPL)

- L'idée la plus simple : appliquer les ***MCO*** directement à la variable binaire.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

Le modèle de probabilité linéaire (MPL)

- L'idée la plus simple : appliquer les ***MCO*** directement à la variable binaire.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

- Comme $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$, on obtient :

$$\mathbb{P}(Y_i = 1|X_i) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki}$$

Le modèle de probabilité linéaire (MPL)

- L'idée la plus simple : appliquer les ***MCO*** directement à la variable binaire.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

- Comme $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$, on obtient :

$$\mathbb{P}(Y_i = 1|X_i) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki}$$

- Ce modèle est appelé ***modèle de probabilité linéaire*** (MPL, ou *LPM* en anglais) car la probabilité est une fonction ***linéaire*** des variables explicatives.

Le modèle de probabilité linéaire (MPL)

- L'idée la plus simple : appliquer les ***MCO*** directement à la variable binaire.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

- Comme $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$, on obtient :

$$\mathbb{P}(Y_i = 1|X_i) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki}$$

- Ce modèle est appelé ***modèle de probabilité linéaire*** (MPL, ou *LPM* en anglais) car la probabilité est une fonction ***linéaire*** des variables explicatives.

- ***Interprétation de*** β_j : une augmentation d'une unité de X_j est associée à une variation de la probabilité que $Y = 1$ de β_j, soit $100 \times \beta_j$ ***points de pourcentage***, toutes choses égales par ailleurs.

MPL : estimation avec `lm()`

Régression simple de la participation sur l'éducation :

$$inlf_i = \beta_0 + \beta_1 educ_i + \varepsilon_i$$

```
lpm_simple <- lm(inlf ~ educ, data = mroz)

library(broom)
tidy(lpm_simple)
```

```
## # A tibble: 2 × 5
##   term        estimate std.error statistic     p.value
##   <chr>          <dbl>     <dbl>     <dbl>       <dbl>
## 1 (Intercept)   0.0680   0.0974      0.699 0.485
## 2 educ          0.0407   0.00779     5.23  0.000000224
```



MPL : estimation avec `lm()`

Régression simple de la participation sur l'éducation :

$$inlf_i = \beta_0 + \beta_1 educ_i + \varepsilon_i$$

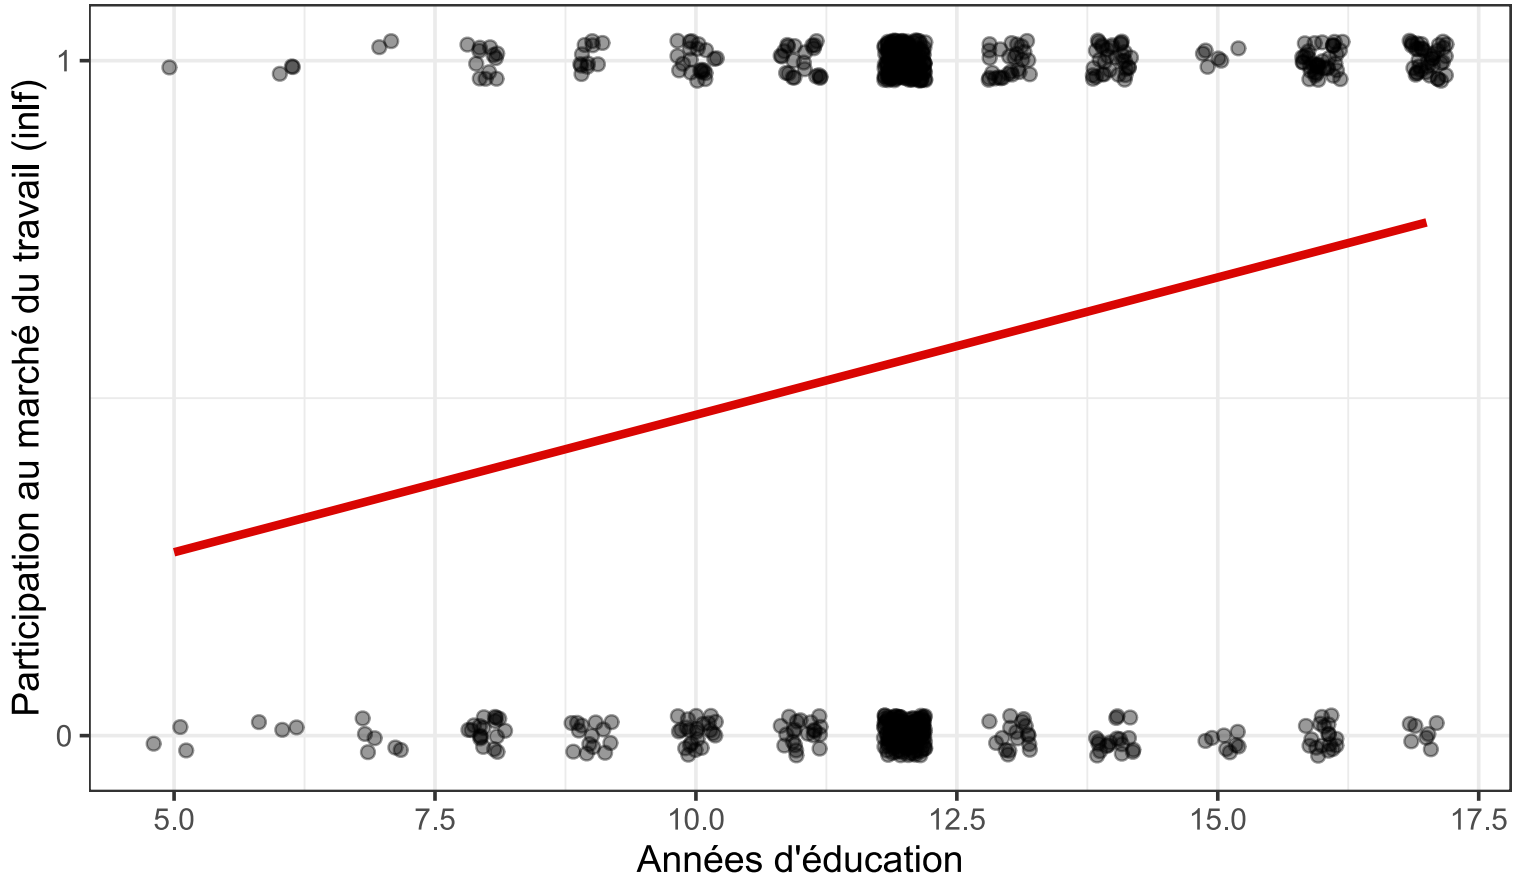
```
lpm_simple <- lm(inlf ~ educ, data = mroz)

library(broom)
tidy(lpm_simple)
```

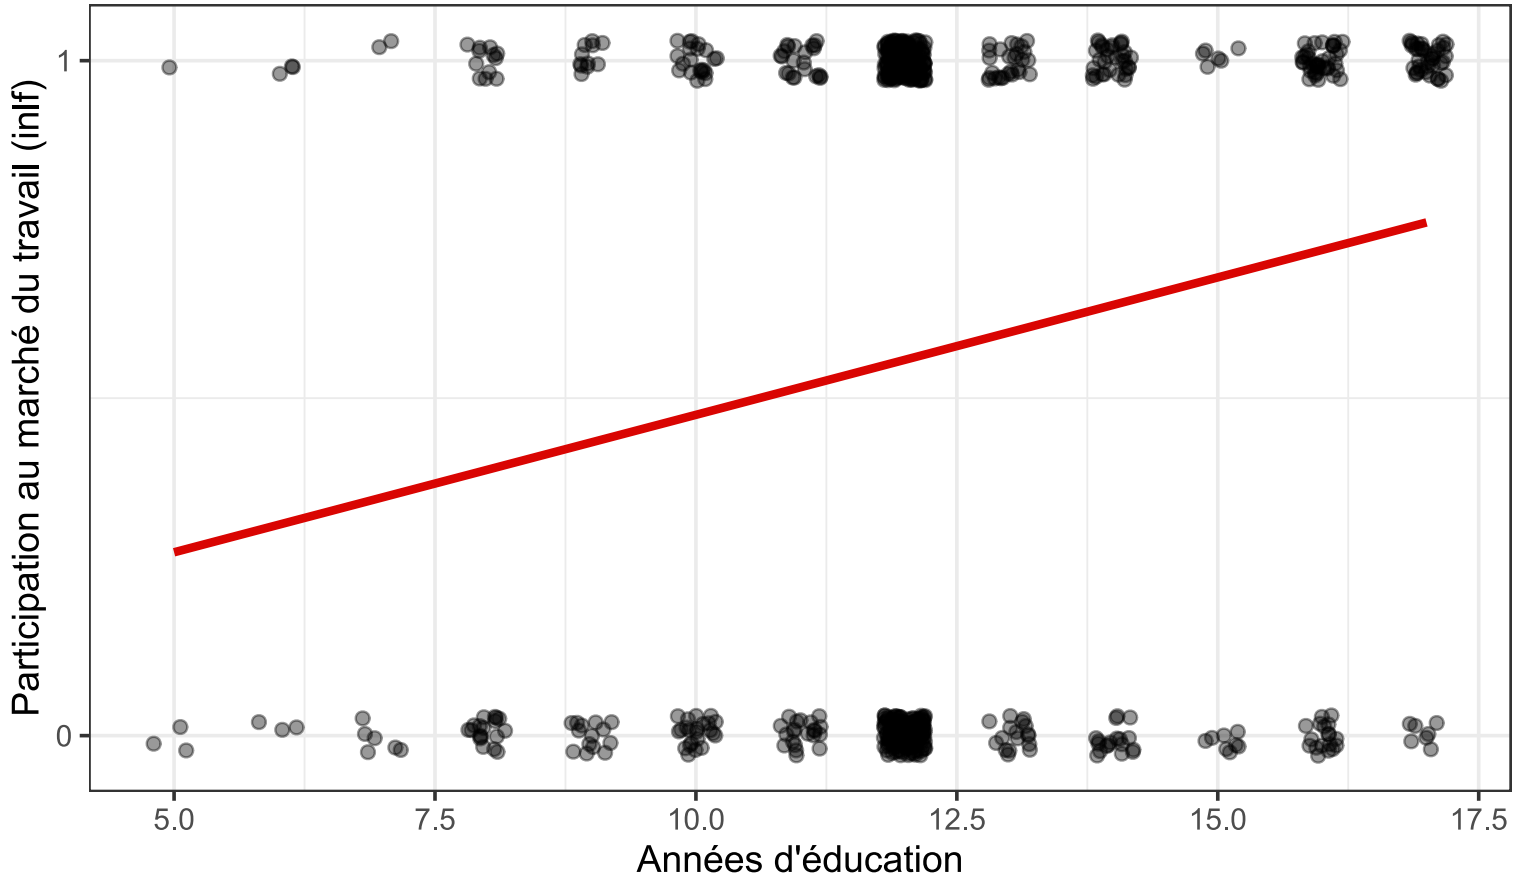
```
## # A tibble: 2 × 5
##   term        estimate std.error statistic     p.value
##   <chr>          <dbl>     <dbl>     <dbl>       <dbl>
## 1 (Intercept)   0.0680   0.0974      0.699 0.485
## 2 educ          0.0407   0.00779     5.23  0.000000224
```

Interprétation : une année d'éducation supplémentaire est associée à une hausse de la probabilité de travailler de 4.1 points de pourcentage en moyenne.

MPL : représentation graphique



MPL : représentation graphique



La droite de régression donne, pour chaque niveau d'éducation, la ***probabilité prédite*** de travailler.

MPL : régression multiple

On ajoute des variables de contrôle :

```
lpm <- lm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
          data = mroz)
tidy(lpm)
```

```
## # A tibble: 7 × 5
##   term        estimate std.error statistic p.value
##   <chr>          <dbl>     <dbl>     <dbl>   <dbl>
## 1 (Intercept)   0.707     0.150      4.70   0
## 2 educ          0.0398    0.0074     5.38   0
## 3 exper         0.0226    0.0022    10.4    0
## 4 age          -0.0177    0.0024    -7.23   0
## 5 kidslt6      -0.272     0.0336    -8.10   0
## 6 kidsge6       0.0125    0.0133     0.944  0.346
## 7 nwifeinc     -0.0033    0.0015    -2.28   0.0227
```



MPL : régression multiple

On ajoute des variables de contrôle :

```
lpm <- lm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
          data = mroz)
tidy(lpm)
```

```
## # A tibble: 7 × 5
##   term        estimate std.error statistic p.value
##   <chr>          <dbl>     <dbl>     <dbl>   <dbl>
## 1 (Intercept)   0.707     0.150      4.70   0
## 2 educ          0.0398    0.0074     5.38   0
## 3 exper         0.0226    0.0022    10.4    0
## 4 age          -0.0177    0.0024    -7.23   0
## 5 kidslt6      -0.272     0.0336    -8.10   0
## 6 kidsge6       0.0125    0.0133     0.944  0.346
## 7 nwifeinc     -0.0033    0.0015    -2.28   0.0227
```

- Un enfant de moins de 6 ans supplémentaire est associé à une ***baisse*** de la probabilité de travailler de 27.2 points de pourcentage.



Exercice 1 : le MPL sur `mroz`

10:00

1. Chargez les données avec `data("mroz", package = "wooldridge")`. Quelle proportion des femmes de l'échantillon a travaillé en 1975 ?

2. Estimez le modèle de probabilité linéaire : `inlf` sur `educ`, `exper`, `age`, `kidslt6`, `kidsge6` et `nwifeinc`. Interprétez les coefficients de `educ` et de `kidslt6`.

3. Calculez les probabilités prédites avec `fitted(lpm)`. Quelles sont les valeurs minimale et maximale ? Que remarquez-vous ?

4. Combien de probabilités prédites sont inférieures à 0 ou supérieures à 1 ?



Problème n°1 : des « probabilités » hors de $[0, 1]$

- Une probabilité est comprise entre 0 et 1. Or une droite est ***non bornée*** : tôt ou tard elle sort de l'intervalle.



Problème n°1 : des « probabilités » hors de $[0, 1]$

- Une probabilité est comprise entre 0 et 1. Or une droite est ***non bornée*** : tôt ou tard elle sort de l'intervalle.

```
p_hat <- fitted(lpm)

range(p_hat)
```

```
## [1] -0.3042662  1.1386752
```

```
sum(p_hat < 0 | p_hat > 1)
```

```
## [1] 34
```



Problème n°1 : des « probabilités » hors de $[0, 1]$

- Une probabilité est comprise entre 0 et 1. Or une droite est ***non bornée*** : tôt ou tard elle sort de l'intervalle.

```
p_hat <- fitted(lpm)

range(p_hat)
```

```
## [1] -0.3042662  1.1386752
```

```
sum(p_hat < 0 | p_hat > 1)
```

```
## [1] 34
```

Pour `mroz`, 34 des 753 femmes (soit 4.5 %) ont une « probabilité » prédite ***en dehors de*** $[0, 1]$.



Problème n°1 : des « probabilités » hors de $[0, 1]$

- Une probabilité est comprise entre 0 et 1. Or une droite est ***non bornée*** : tôt ou tard elle sort de l'intervalle.

```
p_hat <- fitted(lpm)

range(p_hat)
```

```
## [1] -0.3042662  1.1386752
```

```
sum(p_hat < 0 | p_hat > 1)
```

```
## [1] 34
```

Pour `mroz`, 34 des 753 femmes (soit 4.5 %) ont une « probabilité » prédite ***en dehors de*** $[0, 1]$.

- Que signifie une probabilité de travailler de -0.15 ou de 1.2 ? Ces prédictions n'ont ***aucun sens***.



Illustration avec des données simulées

Imaginons que la ***vraie*** probabilité suive une courbe en « S » (courbe logistique) :

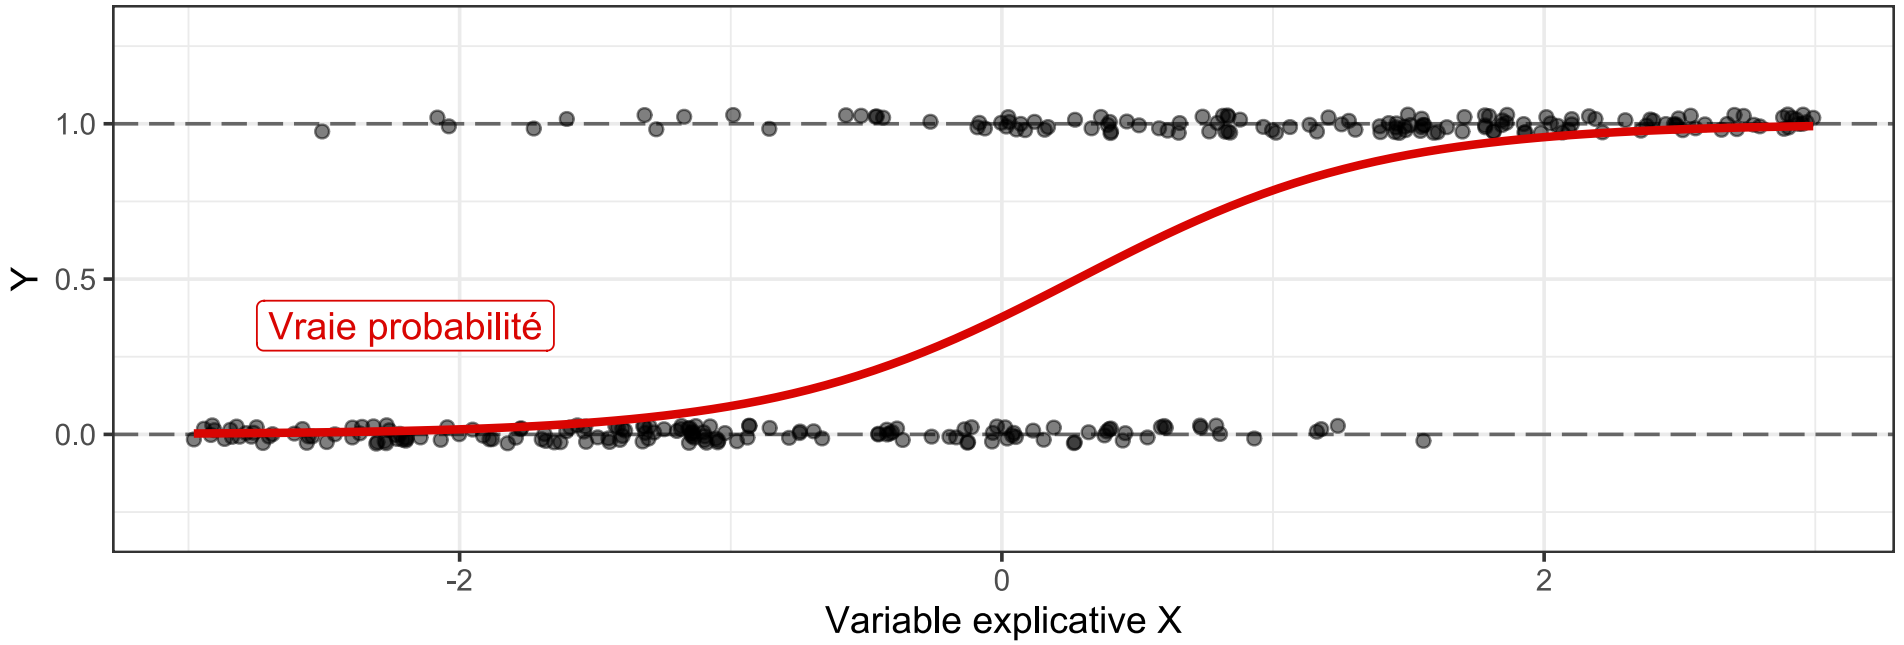


Illustration avec des données simulées

Imaginons que la ***vraie*** probabilité suive une courbe en « S » (courbe logistique) :

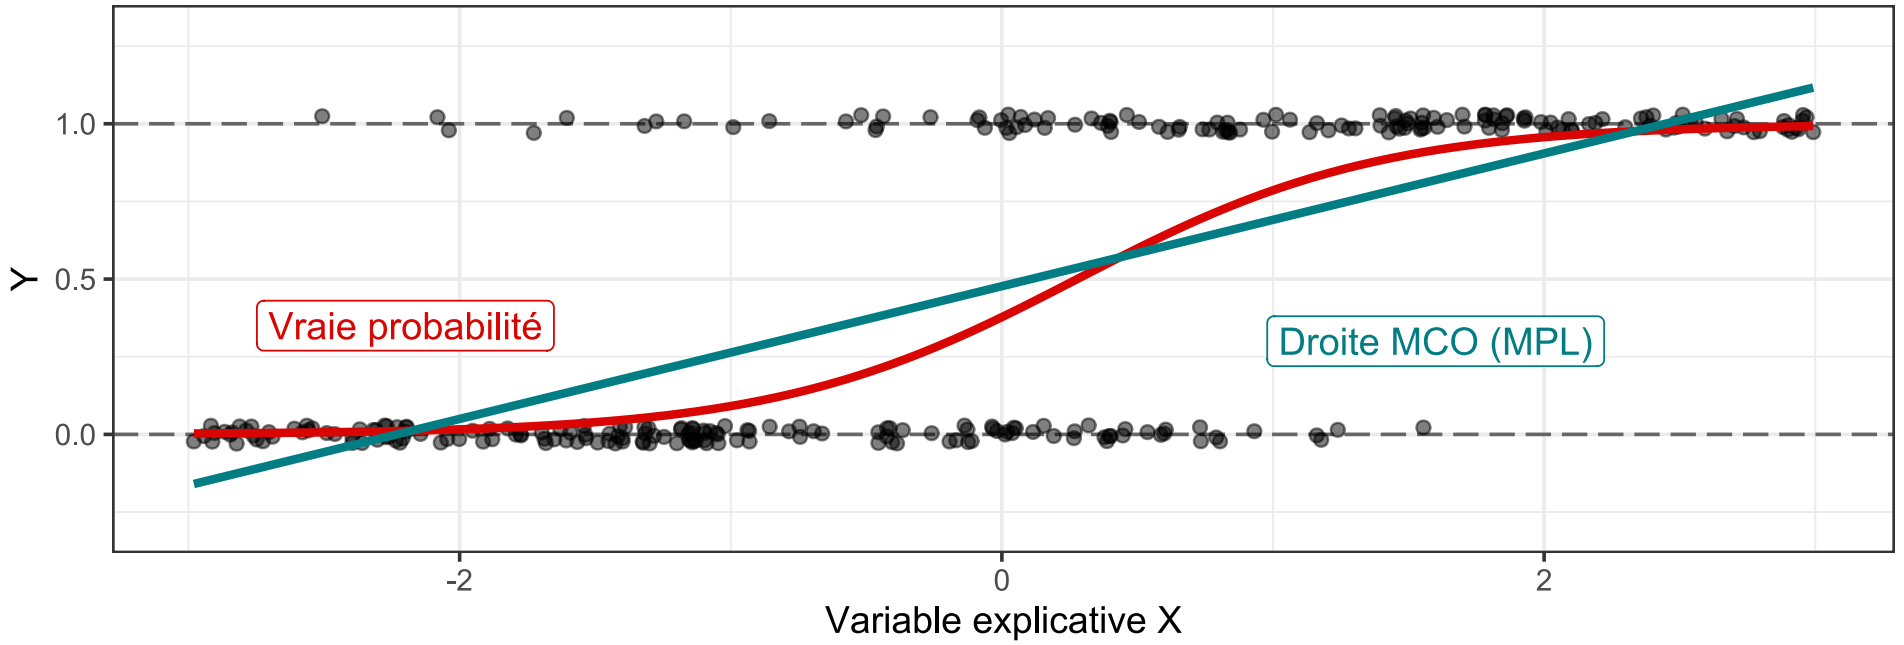
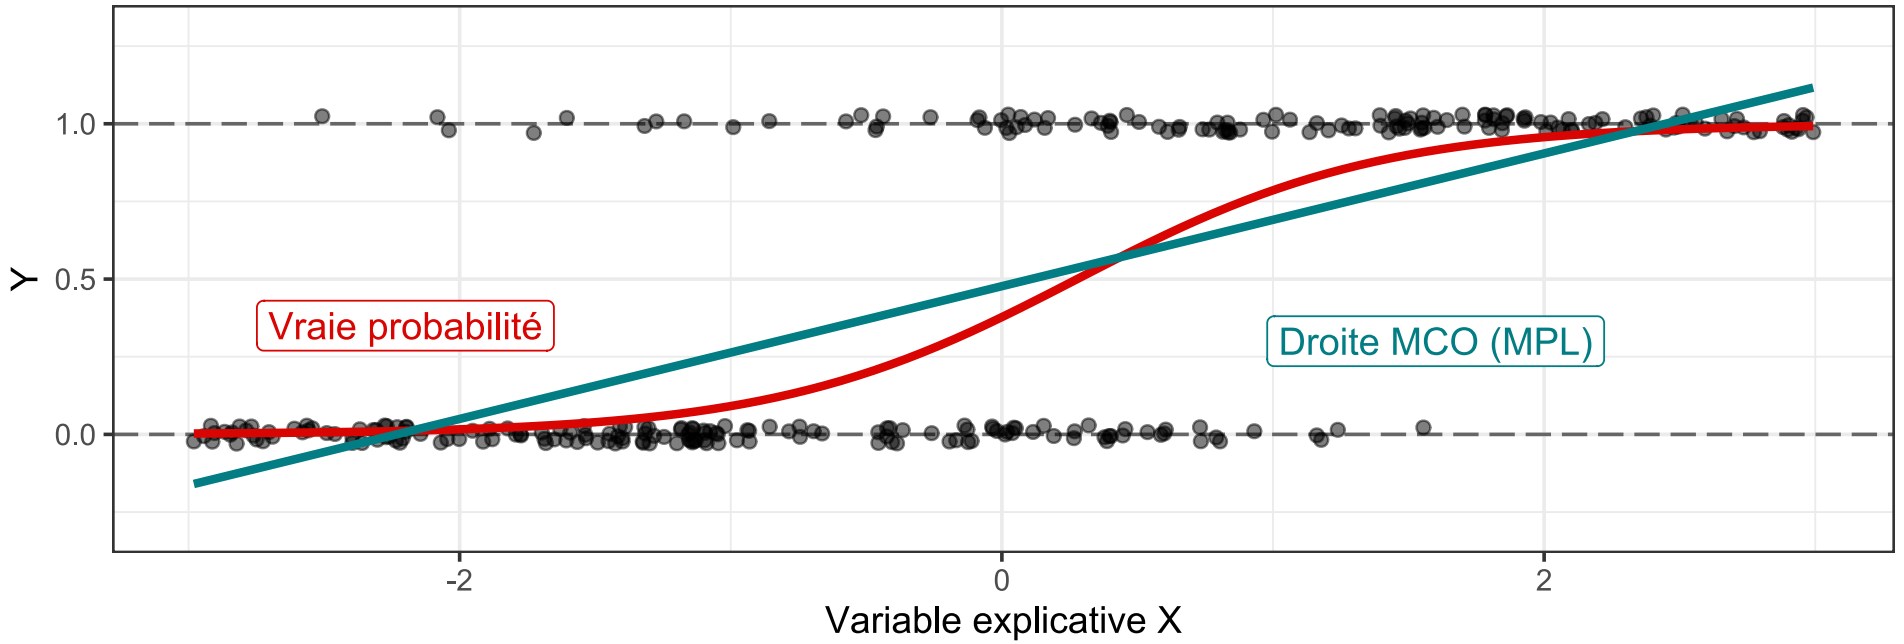


Illustration avec des données simulées

Imaginons que la ***vraie*** probabilité suive une courbe en « S » (courbe logistique) :



La droite MCO ***dépasse*** 1 et passe sous 0, et elle ***s'éloigne de la vraie probabilité*** aux extrémités : la forme linéaire est une mauvaise approximation.

Problème n°2 : l'effet marginal est constant

- Dans le MPL, l'effet d'une unité de X est ***toujours le même*** : β_1, quel que soit le niveau de X

Problème n°2 : l'effet marginal est constant

- Dans le MPL, l'effet d'une unité de X est ***toujours le même*** : β_1, quel que soit le niveau de X
- Est-ce réaliste ?
  - Passer de 0.50 à 0.55 de probabilité de travailler : plausible.
  - Mais passer de 0.98 à 1.03 ? Impossible : la probabilité est bornée par 1.

Problème n°2 : l'effet marginal est constant

- Dans le MPL, l'effet d'une unité de X est ***toujours le même*** : β_1, quel que soit le niveau de X
- Est-ce réaliste ?
  - Passer de 0.50 à 0.55 de probabilité de travailler : plausible.
  - Mais passer de 0.98 à 1.03 ? Impossible : la probabilité est bornée par 1.
- Quand la probabilité est proche de 0 ou de 1, on s'attend à ce que l'effet de X ***s'atténue*** (on « sature »).

Problème n°2 : l'effet marginal est constant

- Dans le MPL, l'effet d'une unité de X est ***toujours le même*** : β_1, quel que soit le niveau de X
- Est-ce réaliste ?
  - Passer de 0.50 à 0.55 de probabilité de travailler : plausible.
  - Mais passer de 0.98 à 1.03 ? Impossible : la probabilité est bornée par 1.
- Quand la probabilité est proche de 0 ou de 1, on s'attend à ce que l'effet de X ***s'atténue*** (on « sature »).

$\rightarrow$ Si la vraie relation est non linéaire, les effets marginaux estimés par le MPL ne sont qu'une ***approximation*** de la réalité, de moins en moins bonne loin du « centre » des données.

Problème n°3 : la forme des erreurs

Comme $Y \in \{0, 1\}$, le terme d'erreur $\varepsilon_i = Y_i - \mathbb{P}(Y_i = 1|X_i)$ ne peut prendre que ***deux valeurs***. Notons $p_i = \mathbb{P}(Y_i = 1|X_i)$:

Problème n°3 : la forme des erreurs

Comme $Y \in \{0, 1\}$, le terme d'erreur $\varepsilon_i = Y_i - \mathbb{P}(Y_i = 1|X_i)$ ne peut prendre que ***deux valeurs***. Notons $p_i = \mathbb{P}(Y_i = 1|X_i)$:

$$\varepsilon_i = \begin{cases} 1 - p_i \text{ avec une probabilité } p_i \\ -p_i \text{ avec une probabilité } 1 - p_i \end{cases}$$

Problème n°3 : la forme des erreurs

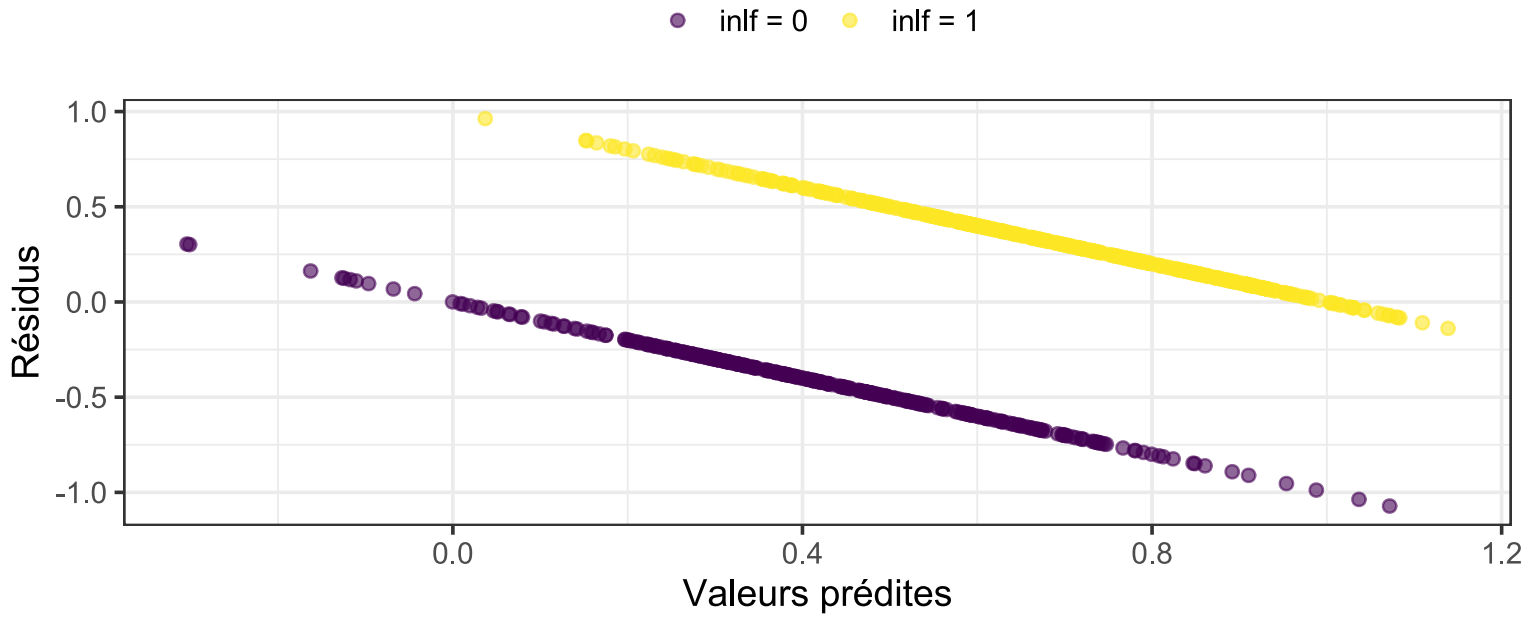
Comme $Y \in \{0, 1\}$, le terme d'erreur $\varepsilon_i = Y_i - \mathbb{P}(Y_i = 1|X_i)$ ne peut prendre que ***deux valeurs***. Notons $p_i = \mathbb{P}(Y_i = 1|X_i)$:

$$\varepsilon_i = \begin{cases} 1 - p_i \text{ avec une probabilité } p_i \\ -p_i \text{ avec une probabilité } 1 - p_i \end{cases}$$

- Les erreurs ne suivent donc ***pas une loi normale*** (une loi normale est continue !).

Problème n°3 : la forme des erreurs

- Les résidus du MPL forment deux « lignes » en fonction des valeurs prédites :



Problème n°4 : hétéroscédasticité

- Rappel : $\mathbb{V}(Y|X) = p(X)\big(1 - p(X)\big)$ pour une variable binaire.



Problème n°4 : hétéroscédasticité

- Rappel : $\mathbb{V}(Y|X) = p(X)\big(1 - p(X)\big)$ pour une variable binaire.
- Comme $p(X)$ dépend de X, la ***variance des erreurs dépend de*** X :

$$\mathbb{V}(\varepsilon_i|X_i) = p_i(1 - p_i) = (\beta_0 + \beta_1 X_i)(1 - \beta_0 - \beta_1 X_i)$$

Problème n°4 : hétéroscédasticité

- Rappel : $\mathbb{V}(Y|X) = p(X)\big(1 - p(X)\big)$ pour une variable binaire.
- Comme $p(X)$ dépend de X, la ***variance des erreurs dépend de*** X :

$$\mathbb{V}(\varepsilon_i|X_i) = p_i(1 - p_i) = (\beta_0 + \beta_1 X_i)(1 - \beta_0 - \beta_1 X_i)$$

- Le MPL est donc ***toujours hétéroscédastique*** (sauf cas trivial où $\beta_1 = 0$) : l'hypothèse d'homoscédasticité est violée par construction !

Problème n°4 : hétéroscédasticité

- Rappel : $\mathbb{V}(Y|X) = p(X)\big(1 - p(X)\big)$ pour une variable binaire.
- Comme $p(X)$ dépend de X, la ***variance des erreurs dépend de*** X :

$$\mathbb{V}(\varepsilon_i|X_i) = p_i(1 - p_i) = (\beta_0 + \beta_1 X_i)(1 - \beta_0 - \beta_1 X_i)$$

- Le MPL est donc ***toujours hétéroscédastique*** (sauf cas trivial où $\beta_1 = 0$) : l'hypothèse d'homoscédasticité est violée par construction !
- Conséquence : les ***écarts types*** usuels des MCO sont ***faux*** $\rightarrow$ les tests t, les valeurs-p et les intervalles de confiance ne sont pas fiables.



Problème n°4 : hétéroscédasticité

- Rappel : $\mathbb{V}(Y|X) = p(X)\big(1 - p(X)\big)$ pour une variable binaire.
- Comme $p(X)$ dépend de X, la ***variance des erreurs dépend de*** X :

$$\mathbb{V}(\varepsilon_i|X_i) = p_i(1 - p_i) = (\beta_0 + \beta_1 X_i)(1 - \beta_0 - \beta_1 X_i)$$

- Le MPL est donc ***toujours hétéroscédastique*** (sauf cas trivial où $\beta_1 = 0$) : l'hypothèse d'homoscédasticité est violée par construction !
- Conséquence : les ***écarts types*** usuels des MCO sont ***faux*** $\rightarrow$ les tests t, les valeurs-p et les intervalles de confiance ne sont pas fiables.

👉 Bonne nouvelle : ce problème se corrige facilement avec des ***écarts types robustes*** à l'hétéroscédasticité.

Quels « biais » exactement ?

Que cause l'utilisation des MCO avec une variable dépendante binaire ?

Problème	**Conséquence**
Probabilités prédites hors de $[0, 1]$	Prédictions sans signification
Effet marginal constant (forme linéaire)	Approximation de la vraie relation, qui est biaisée si elle est non linéaire
Hétéroscédasticité	*Écarts types faux* : tests et intervalles de confiance invalides
Erreurs non normales	Inférence valable seulement *asymptotiquement* (grands échantillons)

Quels « biais » exactement ?

Que cause l'utilisation des MCO avec une variable dépendante binaire ?

Problème	**Conséquence**
Probabilités prédites hors de $[0, 1]$	Prédictions sans signification
Effet marginal constant (forme linéaire)	Approximation de la vraie relation, qui est biaisée si elle est non linéaire
Hétéroscédasticité	***Écarts types faux*** : tests et intervalles de confiance invalides
Erreurs non normales	Inférence valable seulement ***asymptotiquement*** (grands échantillons)

⚠ Si $\mathbb{E}(Y|X)$ est réellement linéaire, les coefficients MCO restent ***sans biais*** et convergents : le problème porte surtout sur les ***écarts types*** et sur la ***plausibilité*** du modèle linéaire sur tout le domaine de X.

Correction : écarts types robustes

Avec `lm()`, les écarts types usuels supposent l'homoscédasticité. On utilise les écarts types robustes (*Eicker-Huber-White*) :

```
library(sandwich)
library(lmtest)

coeftest(lpm, vcov = vcovHC(lpm, type = "HC1"))
```



Correction : écarts types robustes

Avec `lm()`, les écarts types usuels supposent l'homoscédasticité. On utilise les écarts types robustes (*Eicker-Huber-White*) :

```
library(sandwich)
library(lmtest)

coeftest(lpm, vcov = vcovHC(lpm, type = "HC1"))
```

Variable	Coefficient	Écart type usuel	Écart type robuste
(Intercept)	0.7072	0.1504	0.1459
educ	0.0398	0.0074	0.0072
exper	0.0226	0.0022	0.0021
age	-0.0177	0.0024	0.0023
kidslt6	-0.2718	0.0336	0.0314
kidsge6	0.0125	0.0133	0.0136
nwifeinc	-0.0033	0.0015	0.0015



Ce que le MPL fait bien

- *Simplicité* : estimation par MCO, aucune hypothèse de distribution.
- *Interprétation directe* : les coefficients sont des variations de probabilité (en points de pourcentage).

Ce que le MPL fait bien

- *Simplicité* : estimation par MCO, aucune hypothèse de distribution.
- *Interprétation directe* : les coefficients sont des variations de probabilité (en points de pourcentage).
- *Effets moyens proches de ceux de modèles plus complexes* : lorsque les probabilités ne sont pas trop proches de 0 ou de 1, le MPL donne souvent de bonnes estimations de l'effet marginal moyen.



Ce que le MPL fait bien

- ***Simplicité*** : estimation par MCO, aucune hypothèse de distribution.
- ***Interprétation directe*** : les coefficients sont des variations de probabilité (en points de pourcentage).
- ***Effets moyens proches de ceux de modèles plus complexes*** : lorsque les probabilités ne sont pas trop proches de 0 ou de 1, le MPL donne souvent de bonnes estimations de l'effet marginal moyen.
- Très utilisé en ***évaluation de politiques publiques*** (RCT, DiD, RDD…) : on cherche un effet moyen sur une probabilité, pas la prédiction de la probabilité de chaque individu.



Ce que le MPL fait bien

- ***Simplicité*** : estimation par MCO, aucune hypothèse de distribution.
- ***Interprétation directe*** : les coefficients sont des variations de probabilité (en points de pourcentage).
- ***Effets moyens proches de ceux de modèles plus complexes*** : lorsque les probabilités ne sont pas trop proches de 0 ou de 1, le MPL donne souvent de bonnes estimations de l'effet marginal moyen.
- Très utilisé en ***évaluation de politiques publiques*** (RCT, DiD, RDD…) : on cherche un effet moyen sur une probabilité, pas la prédiction de la probabilité de chaque individu.
- Mais pour ***prédire des probabilités*** (surtout proches de 0 ou 1) ou lorsque la non-linéarité compte, il vaut mieux utiliser un modèle qui respecte $0 \leq p \leq 1 \rightarrow$ ***logit*** et ***probit***.

Logit et Probit

L'idée : une courbe en « S »

- Dans le MPL, la probabilité est égale directement à un ***score*** linéaire :

$$p = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

L'idée : une courbe en « S »

- Dans le MPL, la probabilité est égale directement à un ***score*** linéaire :

$$p = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

- Problème : ce score peut prendre ***n'importe quelle valeur*** (négative, supérieure à 1…), alors qu'une probabilité est toujours comprise entre 0 et 1.

L'idée : une courbe en « S »

- Dans le MPL, la probabilité est égale directement à un ***score*** linéaire :

$$p = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

- Problème : ce score peut prendre ***n'importe quelle valeur*** (négative, supérieure à 1…), alors qu'une probabilité est toujours comprise entre 0 et 1.

- Solution en ***deux étapes*** :

  1. Calculer un ***score*** $z = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$, exactement comme dans une régression linéaire ;

  2. ***Transformer*** ce score en probabilité grâce à une fonction G :

$$p = G(z)$$

L'idée : une courbe en « S »

- Dans le MPL, la probabilité est égale directement à un ***score*** linéaire :

$$p = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

- Problème : ce score peut prendre ***n'importe quelle valeur*** (négative, supérieure à 1…), alors qu'une probabilité est toujours comprise entre 0 et 1.

- Solution en ***deux étapes*** :

  1. Calculer un ***score*** $z = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$, exactement comme dans une régression linéaire ;

  2. ***Transformer*** ce score en probabilité grâce à une fonction G :

$$p = G(z)$$

- G est une courbe en « S » : elle « écrase » n'importe quel score z en une valeur comprise entre 0 et 1.



Deux choix classiques pour G

- ***Probit*** : $G = \Phi$, la fonction de répartition de la loi ***normale*** centrée réduite.



Deux choix classiques pour G

- ***Probit*** : $G = \Phi$, la fonction de répartition de la loi ***normale*** centrée réduite.
- ***Logit*** : $G = \Lambda$, la fonction de répartition de la loi ***logistique*** :

$$\Lambda(z) = \frac{e^z}{1 + e^z}$$

Deux choix classiques pour G

- ***Probit*** : $G = \Phi$, la fonction de répartition de la loi ***normale*** centrée réduite.
- ***Logit*** : $G = \Lambda$, la fonction de répartition de la loi ***logistique*** :

$$\Lambda(z) = \frac{e^z}{1 + e^z}$$

- Dans les deux cas, G est une ***fonction de répartition*** : elle est croissante, proche de 0 pour des scores très négatifs et proche de 1 pour des scores très élevés.



Deux choix classiques pour G

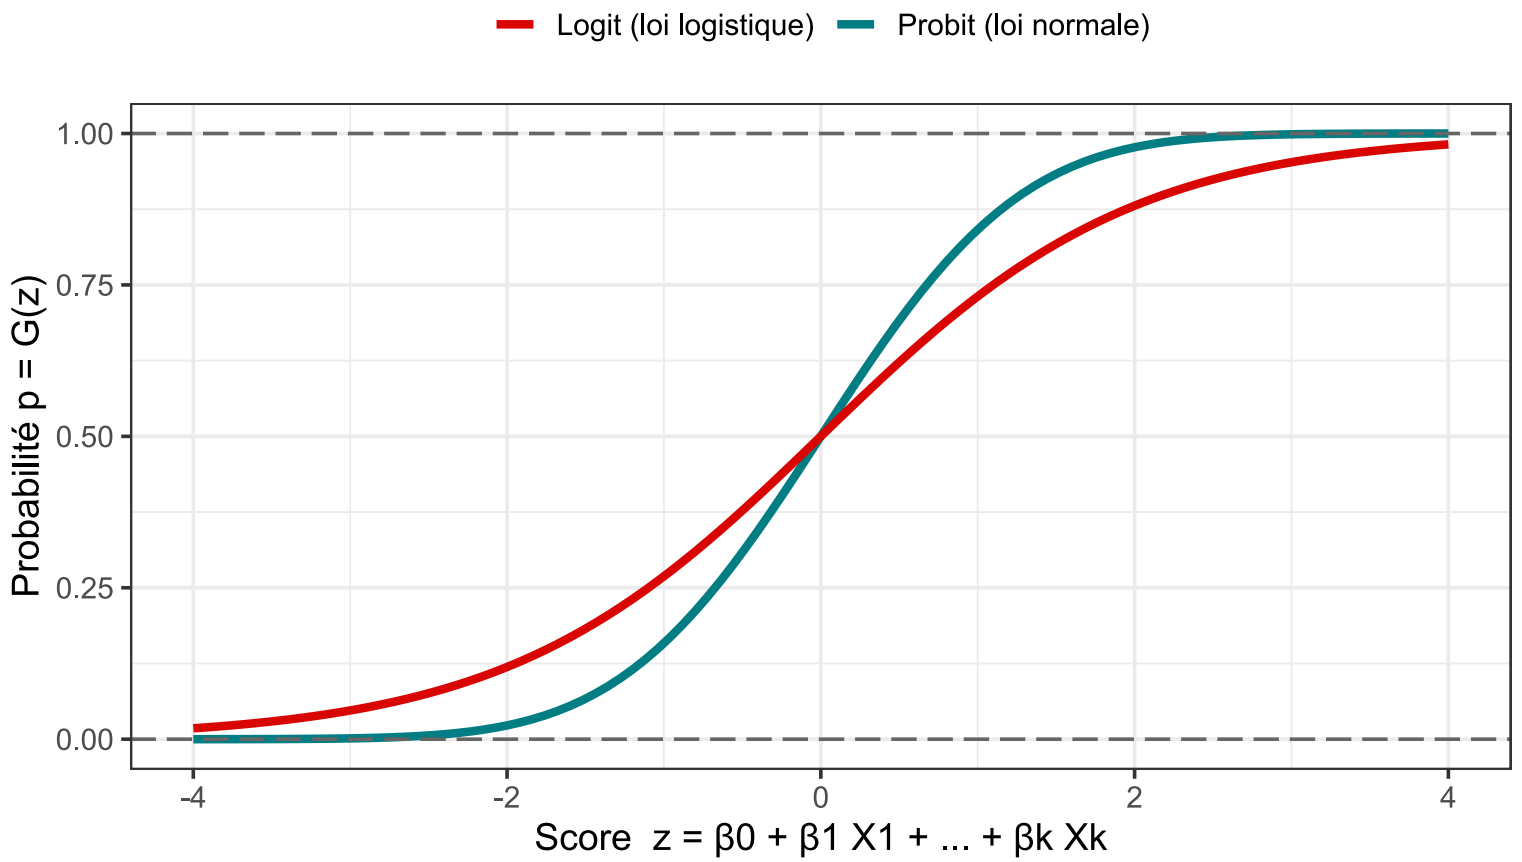
- ***Probit*** : $G = \Phi$, la fonction de répartition de la loi ***normale*** centrée réduite.
- ***Logit*** : $G = \Lambda$, la fonction de répartition de la loi ***logistique*** :

$$\Lambda(z) = \frac{e^z}{1 + e^z}$$

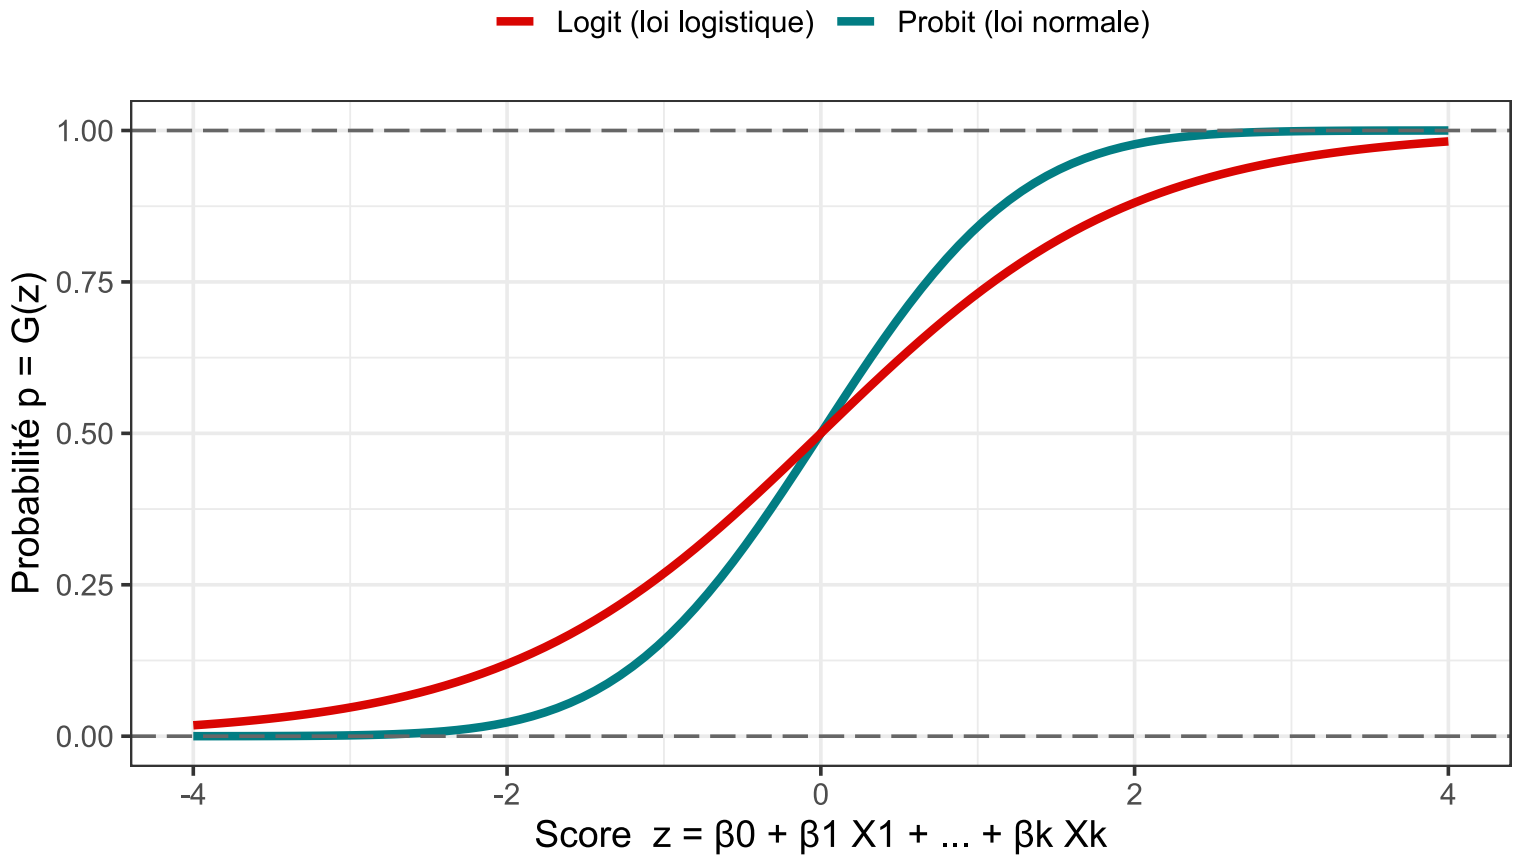
- Dans les deux cas, G est une ***fonction de répartition*** : elle est croissante, proche de 0 pour des scores très négatifs et proche de 1 pour des scores très élevés.
- En pratique, le logit et le probit donnent des résultats ***quasi identiques***. La différence est surtout une question d'habitude selon les disciplines.



Probit et logit : les deux courbes G



Probit et logit : les deux courbes G



Les deux courbes sont très proches : toujours entre 0 et 1, croissantes, et ***jamais linéaires***.

Que fait la courbe en « S » ?

Score z	Probit : Φ(z)	Logit : Λ(z)
-3	0.001	0.047
-2	0.023	0.119
-1	0.159	0.269
0	0.500	0.500
1	0.841	0.731
2	0.977	0.881
3	0.999	0.953



Que fait la courbe en « S » ?

Score z	Probit : $\Phi(z)$	Logit : $\Lambda(z)$
-3	0.001	0.047
-2	0.023	0.119
-1	0.159	0.269
0	0.500	0.500
1	0.841	0.731
2	0.977	0.881
3	0.999	0.953

- Un score très ***négatif*** donne une probabilité proche de 0.
- Un score égal à ***zéro*** donne une probabilité de 0.5.
- Un score très ***positif*** donne une probabilité proche de 1.



Que fait la courbe en « S » ?

Score z	Probit : $\Phi(z)$	Logit : $\Lambda(z)$
-3	0.001	0.047
-2	0.023	0.119
-1	0.159	0.269
0	0.500	0.500
1	0.841	0.731
2	0.977	0.881
3	0.999	0.953

- Un score très ***négatif*** donne une probabilité proche de 0.
- Un score égal à ***zéro*** donne une probabilité de 0.5.
- Un score très ***positif*** donne une probabilité proche de 1.

$\rightarrow$ Un score $z > 0$ signifie que l'événement est ***plus probable que non*** ($p > 0.5$).

Estimation : le maximum de vraisemblance

- Contrairement au MPL, le logit et le probit ne peuvent pas être estimés par MCO : le modèle est ***non linéaire***.

Estimation : le maximum de vraisemblance

- Contrairement au MPL, le logit et le probit ne peuvent pas être estimés par MCO : le modèle est ***non linéaire***.
- On utilise le ***maximum de vraisemblance*** (MV). ***Intuition*** : on cherche les valeurs des β pour lesquelles le modèle attribue une ***probabilité élevée à ce qui s'est réellement passé*** dans l'échantillon.
  - si la femme ***travaille*** ($Y = 1$), le modèle devrait prédire une probabilité p ***élevée*** ;
  - si elle ***ne travaille pas*** ($Y = 0$), le modèle devrait prédire une probabilité p ***faible*** (donc $1 - p$ élevée).

Estimation : le maximum de vraisemblance

- Contrairement au MPL, le logit et le probit ne peuvent pas être estimés par MCO : le modèle est ***non linéaire***.
- On utilise le ***maximum de vraisemblance*** (MV). ***Intuition*** : on cherche les valeurs des β pour lesquelles le modèle attribue une ***probabilité élevée à ce qui s'est réellement passé*** dans l'échantillon.
  - si la femme ***travaille*** ($Y = 1$), le modèle devrait prédire une probabilité p ***élevée*** ;
  - si elle ***ne travaille pas*** ($Y = 0$), le modèle devrait prédire une probabilité p ***faible*** (donc $1 - p$ élevée).
- La ***vraisemblance*** multiplie ces probabilités sur tous les individus de l'échantillon. On choisit les β qui la rendent la plus ***grande*** possible.



Estimation : le maximum de vraisemblance

- Contrairement au MPL, le logit et le probit ne peuvent pas être estimés par MCO : le modèle est ***non linéaire***.
- On utilise le ***maximum de vraisemblance*** (MV). ***Intuition*** : on cherche les valeurs des β pour lesquelles le modèle attribue une ***probabilité élevée à ce qui s'est réellement passé*** dans l'échantillon.
  - si la femme ***travaille*** ($Y = 1$), le modèle devrait prédire une probabilité p ***élevée*** ;
  - si elle ***ne travaille pas*** ($Y = 0$), le modèle devrait prédire une probabilité p ***faible*** (donc $1 - p$ élevée).
- La ***vraisemblance*** multiplie ces probabilités sur tous les individus de l'échantillon. On choisit les β qui la rendent la plus ***grande*** possible.
- MCO : on *minimise* la somme des carrés des erreurs. MV : on *maximise* la probabilité d'avoir observé notre échantillon.



Estimation : le maximum de vraisemblance

- MCO : on *minimise* la somme des carrés des erreurs. MV : on *maximise* la probabilité d'avoir observé notre échantillon.
- Pas de formule explicite : le calcul est fait ***numériquement*** par l'ordinateur. Sous `R` :
  - `glm(..., family = binomial(link = "logit"))`
  - `glm(..., family = binomial(link = "probit"))`



Estimation sous R : logit et probit

```
logit  <- glm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
              data = mroz, family = binomial(link = "logit"))

probit <- glm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
              data = mroz, family = binomial(link = "probit"))
```



Estimation sous R : logit et probit

```
logit  <- glm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
              data = mroz, family = binomial(link = "logit"))

probit <- glm(inlf ~ educ + exper + age + kidslt6 + kidsge6 + nwifeinc,
              data = mroz, family = binomial(link = "probit"))
```

Logit

```
tidy(logit) %>%
  mutate(across(where(is.numeric), ~ round(.x, 3)))
```

```
## # A tibble: 7 × 5
##   term        estimate std.error statistic p.value
##   <chr>          <dbl>     <dbl>     <dbl>   <dbl>
## 1 (Intercept)    0.838     0.841     0.996   0.319
## 2 educ           0.227     0.043     5.24    0
## 3 exper          0.12      0.014     8.79    0
## 4 age           -0.091     0.014    -6.36    0
## 5 kidslt6       -1.44      0.201    -7.14    0
## 6 kidsge6        0.058     0.073     0.793   0.428
## 7 nwifeinc      -0.02      0.008    -2.45    0.014
```

Probit

```
tidy(probit) %>%
  mutate(across(where(is.numeric), ~ round(.x, 3)))
```

```
## # A tibble: 7 × 5
##   term        estimate std.error statistic p.value
##   <chr>          <dbl>     <dbl>     <dbl>   <dbl>
## 1 (Intercept)    0.58      0.496     1.17    0.242
## 2 educ           0.134     0.025     5.29    0
## 3 exper          0.07      0.008     9.13    0
## 4 age           -0.056     0.008    -6.69    0
## 5 kidslt6       -0.874     0.117    -7.45    0
## 6 kidsge6        0.035     0.043     0.796   0.426
## 7 nwifeinc      -0.012     0.005    -2.38    0.017
```



Comparaison des coefficients : MPL, logit et probit

Variable	MPL	Logit	Probit
(Intercept)	0.707	0.838	0.580
educ	0.040	0.227	0.134
exper	0.023	0.120	0.070
age	-0.018	-0.091	-0.056
kidslt6	-0.272	-1.439	-0.874
kidsge6	0.013	0.058	0.035
nwifeinc	-0.003	-0.020	-0.012



Comparaison des coefficients : MPL, logit et probit

Variable	MPL	Logit	Probit
(Intercept)	0.707	0.838	0.580
educ	0.040	0.227	0.134
exper	0.023	0.120	0.070
age	-0.018	-0.091	-0.056
kidslt6	-0.272	-1.439	-0.874
kidsge6	0.013	0.058	0.035
nwifeinc	-0.003	-0.020	-0.012

- Les ***signes*** et la ***significativité*** sont similaires dans les trois modèles.
- Mais les ***ordres de grandeur*** diffèrent : les coefficients du logit et du probit ne sont ***pas directement comparables*** à ceux du MPL !



Comparaison des coefficients : MPL, logit et probit

Variable	MPL	Logit	Probit
(Intercept)	0.707	0.838	0.580
educ	0.040	0.227	0.134
exper	0.023	0.120	0.070
age	-0.018	-0.091	-0.056
kidslt6	-0.272	-1.439	-0.874
kidsge6	0.013	0.058	0.035
nwifeinc	-0.003	-0.020	-0.012

- Les ***signes*** et la ***significativité*** sont similaires dans les trois modèles.
- Mais les ***ordres de grandeur*** diffèrent : les coefficients du logit et du probit ne sont ***pas directement comparables*** à ceux du MPL !
- ***Pourquoi ?*** Dans le MPL, β_j est une variation de ***probabilité***. Dans le logit et le probit, β_j est une variation du ***score*** z.

Comment le modèle calcule-t-il une probabilité ?

Prenons une femme de 12 ans d'éducation, 10 ans d'expérience, âgée de 40 ans, sans enfant de moins de 6 ans, avec un enfant de 6 à 18 ans, et un revenu du ménage hors le sien de 20 000 dollars.



Comment le modèle calcule-t-il une probabilité ?

Prenons une femme de 12 ans d'éducation, 10 ans d'expérience, âgée de 40 ans, sans enfant de moins de 6 ans, avec un enfant de 6 à 18 ans, et un revenu du ménage hors le sien de 20 000 dollars.

Étape 1 : on calcule son ***score*** z avec les coefficients du probit.

```
b <- coef(probit)

z <- unname(b["(Intercept)"] + b["educ"] * 12 + b["exper"] * 10 +
            b["age"] * 40 + b["kidslt6"] * 0 + b["kidsge6"] * 1 +
            b["nwifeinc"] * 20)
z
```

```
## [1] 0.4670858
```



Comment le modèle calcule-t-il une probabilité ?

Prenons une femme de 12 ans d'éducation, 10 ans d'expérience, âgée de 40 ans, sans enfant de moins de 6 ans, avec un enfant de 6 à 18 ans, et un revenu du ménage hors le sien de 20 000 dollars.

Étape 1 : on calcule son ***score*** z avec les coefficients du probit.

```
b <- coef(probit)

z <- unname(b["(Intercept)"] + b["educ"] * 12 + b["exper"] * 10 +
            b["age"] * 40 + b["kidslt6"] * 0 + b["kidsge6"] * 1 +
            b["nwifeinc"] * 20)
z
```

```
## [1] 0.4670858
```

Étape 2 : on transforme le score en ***probabilité*** avec $G = \Phi$ (`pnorm()` sous `R`).

```
pnorm(z)
```

```
## [1] 0.6797807
```



Comment le modèle calcule-t-il une probabilité ?

On obtient exactement le même résultat avec `predict()` : c'est ce que fait `R` en coulisses.

```
predict(probit, type = "response",
        newdata = data.frame(educ = 12, exper = 10, age = 40,
                             kidslt6 = 0, kidsge6 = 1, nwifeinc = 20))
```

```
##         1
## 0.6797807
```



Comment le modèle calcule-t-il une probabilité ?

On obtient exactement le même résultat avec `predict()` : c'est ce que fait `R` en coulisses.

```
predict(probit, type = "response",
        newdata = data.frame(educ = 12, exper = 10, age = 40,
                             kidslt6 = 0, kidsge6 = 1, nwifeinc = 20))
```

```
##         1
## 0.6797807
```

- Cette femme a une probabilité de travailler de 68 % selon le modèle probit.



Comment le modèle calcule-t-il une probabilité ?

On obtient exactement le même résultat avec `predict()` : c'est ce que fait `R` en coulisses.

```
predict(probit, type = "response",
        newdata = data.frame(educ = 12, exper = 10, age = 40,
                             kidslt6 = 0, kidsge6 = 1, nwifeinc = 20))
```

```
##         1
## 0.6797807
```

- Cette femme a une probabilité de travailler de 68 % selon le modèle probit.
- Si l'on change une variable (par exemple `educ` passe de 12 à 13), le score z change de β_{educ}... mais de ***combien*** change la probabilité ? Cela dépend de l'endroit où l'on se trouve sur la courbe en « S ».



Comment interpréter les coefficients ?

- ***Signe*** de β_j :
  - $\beta_j > 0$: quand X_j augmente, le score z ***augmente*** et, comme G est croissante, la probabilité que $Y = 1$ ***augmente*** ;
  - $\beta_j < 0$: X_j ***diminue*** la probabilité que $Y = 1$.

Comment interpréter les coefficients ?

- ***Signe*** de β_j :
  - $\beta_j > 0$: quand X_j augmente, le score z ***augmente*** et, comme G est croissante, la probabilité que $Y = 1$ ***augmente*** ;
  - $\beta_j < 0$: X_j ***diminue*** la probabilité que $Y = 1$.
- ***Significativité*** : comme pour les MCO, on regarde la statistique z et la valeur-p (test que $\beta_j = 0$).

Comment interpréter les coefficients ?

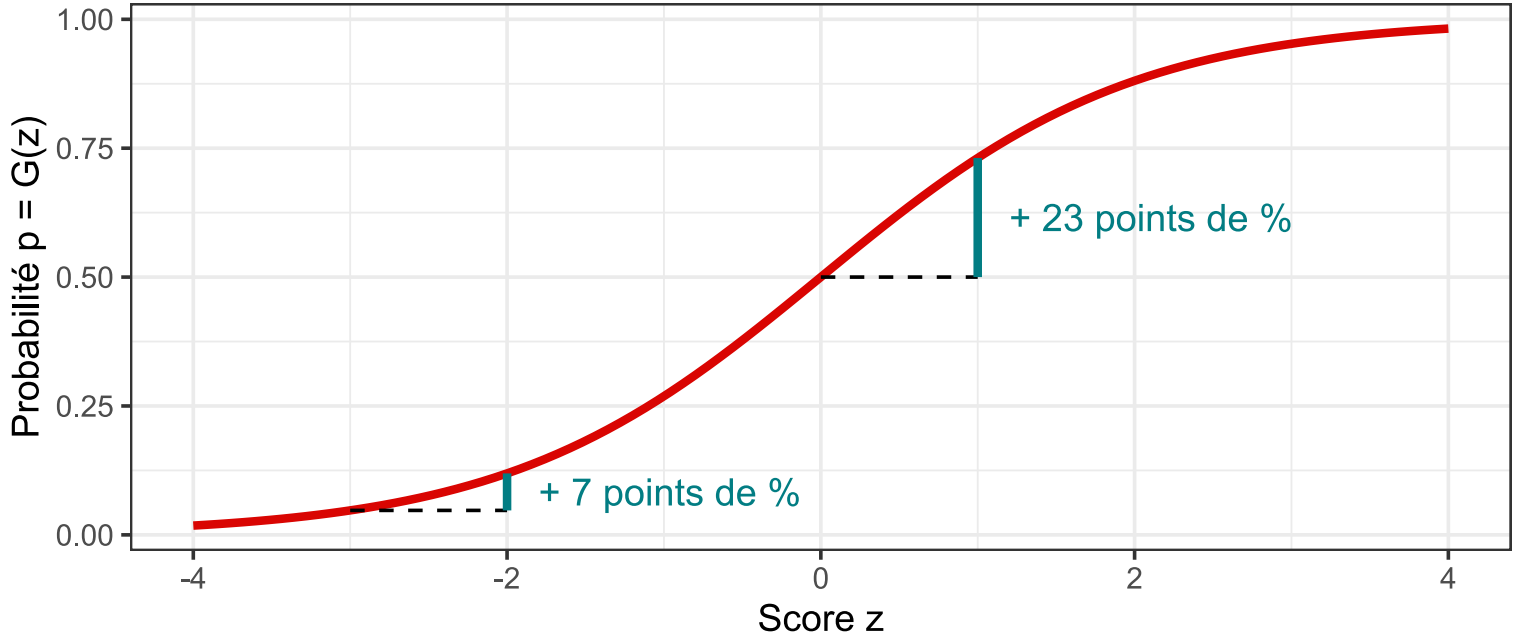
- ***Signe*** de β_j :
  - $\beta_j > 0$: quand X_j augmente, le score z ***augmente*** et, comme G est croissante, la probabilité que $Y = 1$ ***augmente*** ;
  - $\beta_j < 0$: X_j ***diminue*** la probabilité que $Y = 1$.
- ***Significativité*** : comme pour les MCO, on regarde la statistique z et la valeur-p (test que $\beta_j = 0$).
- ***Ampleur*** : β_j est la variation du ***score*** z, ***pas*** la variation de la probabilité.

Comment interpréter les coefficients ?

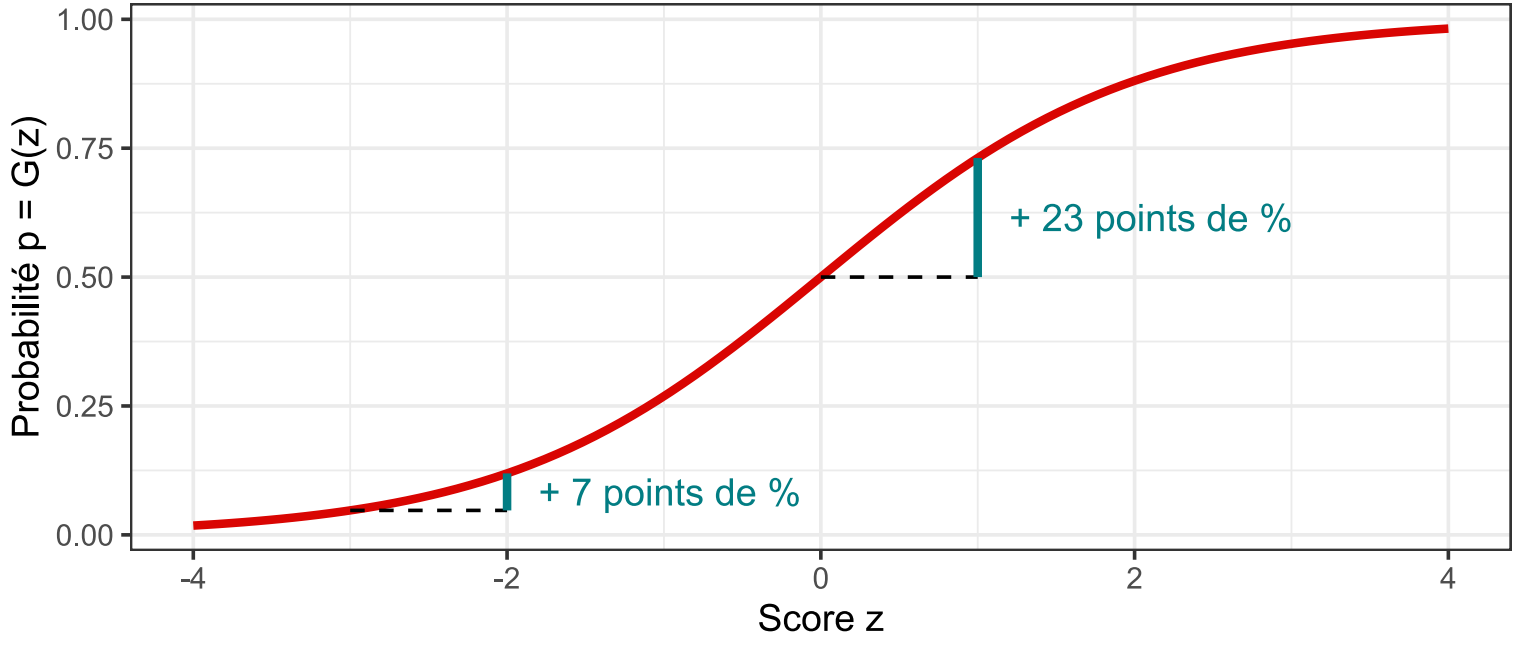
- ***Signe*** de β_j :
  - $\beta_j > 0$: quand X_j augmente, le score z ***augmente*** et, comme G est croissante, la probabilité que $Y = 1$ ***augmente*** ;
  - $\beta_j < 0$: X_j ***diminue*** la probabilité que $Y = 1$.
- ***Significativité*** : comme pour les MCO, on regarde la statistique z et la valeur-p (test que $\beta_j = 0$).
- ***Ampleur*** : β_j est la variation du ***score*** z, ***pas*** la variation de la probabilité.

⚠️ Le coefficient seul ne dit pas de combien la probabilité change. Pour cela, il faut tenir compte de la ***forme de la courbe en « S »***.

Un même effet sur le score, des effets différents sur la probabilité



Un même effet sur le score, des effets différents sur la probabilité



Le score augmente de 1 dans les deux cas. Mais la probabilité augmente ***beaucoup plus au milieu de la courbe*** (là où elle est raide) qu'en bas (là où elle est plate).

Effet marginal = pente de la courbe × β_j

- L'***effet marginal*** de X_j est la variation de la ***probabilité*** quand X_j augmente d'une unité (toutes choses égales par ailleurs) :

$$\text{effet marginal de } X_j \approx g(z) \times \beta_j$$

où $g(z)$ est la ***pente de la courbe en « S »*** au score z de l'individu.

Effet marginal = pente de la courbe × β_j

- L'***effet marginal*** de X_j est la variation de la ***probabilité*** quand X_j augmente d'une unité (toutes choses égales par ailleurs) :

$$\text{effet marginal de } X_j \approx g(z) \times \beta_j$$

où $g(z)$ est la ***pente de la courbe en « S »*** au score z de l'individu.

- probit : $g(z) = \phi(z)$ (densité de la loi normale)
- logit : $g(z) = \Lambda(z)\big(1 - \Lambda(z)\big)$

Effet marginal = pente de la courbe × β_j

- L'***effet marginal*** de X_j est la variation de la ***probabilité*** quand X_j augmente d'une unité (toutes choses égales par ailleurs) :

$$\text{effet marginal de } X_j \approx g(z) \times \beta_j$$

où $g(z)$ est la ***pente de la courbe en « S »*** au score z de l'individu.

- probit : $g(z) = \phi(z)$ (densité de la loi normale)
- logit : $g(z) = \Lambda(z)\big(1 - \Lambda(z)\big)$
- ***Au milieu de la courbe*** (p proche de 0.5) : la pente est forte $\rightarrow$ ***grand*** effet marginal.
- ***Aux extrémités*** (p proche de 0 ou de 1) : la pente est faible $\rightarrow$ ***petit*** effet marginal.

Effet marginal = pente de la courbe × β_j

- L'*effet marginal* de X_j est la variation de la *probabilité* quand X_j augmente d'une unité (toutes choses égales par ailleurs) :

$$\text{effet marginal de } X_j \approx g(z) \times \beta_j$$

où $g(z)$ est la *pente de la courbe en « S »* au score z de l'individu.

- probit : $g(z) = \phi(z)$ (densité de la loi normale)
- logit : $g(z) = \Lambda(z)\big(1 - \Lambda(z)\big)$
- *Au milieu de la courbe* (p proche de 0.5) : la pente est forte $\rightarrow$ *grand* effet marginal.
- *Aux extrémités* (p proche de 0 ou de 1) : la pente est faible $\rightarrow$ *petit* effet marginal.

$\rightarrow$ L'effet marginal *dépend de l'individu* (via son score z) : c'est la grande différence avec le MPL, où il est constant.



Effets marginaux : quelle valeur choisir ?

L'effet marginal varie d'un individu à l'autre. On résume généralement par une seule valeur :

Effets marginaux : quelle valeur choisir ?

L'effet marginal varie d'un individu à l'autre. On résume généralement par une seule valeur :

- ***Effet marginal moyen*** (*Average Marginal Effect*, AME) : on calcule l'effet marginal de ***chaque individu*** de l'échantillon, puis on fait la ***moyenne*** :

$$AME_j = \frac{1}{n} \sum_{i=1}^{n} g(z_i) \times \hat{\beta}_j$$

Effets marginaux : quelle valeur choisir ?

L'effet marginal varie d'un individu à l'autre. On résume généralement par une seule valeur :

- ***Effet marginal moyen*** (*Average Marginal Effect*, AME) : on calcule l'effet marginal de ***chaque individu*** de l'échantillon, puis on fait la ***moyenne*** :

$$AME_j = \frac{1}{n} \sum_{i=1}^{n} g(z_i) \times \hat{\beta}_j$$

- ***Effet marginal à la moyenne*** (*Marginal Effect at the Mean*, MEM) : effet marginal calculé pour un individu « moyen » (toutes ses caractéristiques égales à la moyenne).

Effets marginaux : quelle valeur choisir ?

L'effet marginal varie d'un individu à l'autre. On résume généralement par une seule valeur :

- ***Effet marginal moyen*** (*Average Marginal Effect*, AME) : on calcule l'effet marginal de ***chaque individu*** de l'échantillon, puis on fait la ***moyenne*** :

$$AME_j = \frac{1}{n} \sum_{i=1}^{n} g(z_i) \times \hat{\beta}_j$$

- ***Effet marginal à la moyenne*** (*Marginal Effect at the Mean*, MEM) : effet marginal calculé pour un individu « moyen » (toutes ses caractéristiques égales à la moyenne).

- Pour une ***variable binaire*** D, on ne dérive pas : on calcule la ***différence de probabilités prédites*** quand D passe de 0 à 1 (autres variables inchangées).

Effets marginaux : quelle valeur choisir ?

L'effet marginal varie d'un individu à l'autre. On résume généralement par une seule valeur :

- ***Effet marginal moyen*** (*Average Marginal Effect*, AME) : on calcule l'effet marginal de ***chaque individu*** de l'échantillon, puis on fait la ***moyenne*** :

$$AME_j = \frac{1}{n} \sum_{i=1}^{n} g(z_i) \times \hat{\beta}_j$$

- ***Effet marginal à la moyenne*** (*Marginal Effect at the Mean*, MEM) : effet marginal calculé pour un individu « moyen » (toutes ses caractéristiques égales à la moyenne).

- Pour une ***variable binaire*** D, on ne dérive pas : on calcule la ***différence de probabilités prédites*** quand D passe de 0 à 1 (autres variables inchangées).

Nous utiliserons l'***AME***, le plus courant en pratique.



L'effet marginal moyen pas à pas : l'éducation (probit)

```r
# Étape 1 : le score z de chaque femme
z <- predict(probit, type = "link")

# Étape 2 : la pente de la courbe en S pour chaque femme
pente <- dnorm(z)
head(pente)
```

```
##         1         2         3         4         5         6
## 0.3699185 0.3096466 0.3707577 0.3030984 0.3923245 0.1524577
```



L'effet marginal moyen pas à pas : l'éducation (probit)

```r
# Étape 1 : le score z de chaque femme
z <- predict(probit, type = "link")

# Étape 2 : la pente de la courbe en S pour chaque femme
pente <- dnorm(z)
head(pente)
```

```
##         1         2         3         4         5         6
## 0.3699185 0.3096466 0.3707577 0.3030984 0.3923245 0.1524577
```

```r
# Étape 3 : AME = pente moyenne × coefficient de l'éducation
mean(pente) * coef(probit)["educ"]
```

```
##       educ
## 0.04083005
```

L'effet marginal moyen pas à pas : l'éducation (probit)

```r
# Étape 1 : le score z de chaque femme
z <- predict(probit, type = "link")

# Étape 2 : la pente de la courbe en S pour chaque femme
pente <- dnorm(z)
head(pente)
```

```
##         1         2         3         4         5         6
## 0.3699185 0.3096466 0.3707577 0.3030984 0.3923245 0.1524577
```

```r
# Étape 3 : AME = pente moyenne × coefficient de l'éducation
mean(pente) * coef(probit)["educ"]
```

```
##       educ
## 0.04083005
```

- En moyenne, une année d'éducation supplémentaire augmente la probabilité de travailler d'environ 4.1 points de pourcentage.



Calcul de l'effet marginal moyen pour toutes les variables

```r
# AME de toutes les variables : pente moyenne g(z) × coefficient
ame_glm <- function(modele, densite) {
  z <- predict(modele, type = "link")   # score z de chaque individu
  mean(densite(z)) * coef(modele)
}

ame_logit  <- ame_glm(logit,  dlogis)   # pente de la courbe logistique
ame_probit <- ame_glm(probit, dnorm)    # pente de la courbe normale
```



Calcul de l'effet marginal moyen pour toutes les variables

```r
# AME de toutes les variables : pente moyenne g(z) × coefficient
ame_glm <- function(modele, densite) {
  z <- predict(modele, type = "link")   # score z de chaque individu
  mean(densite(z)) * coef(modele)
}

ame_logit  <- ame_glm(logit,  dlogis)   # pente de la courbe logistique
ame_probit <- ame_glm(probit, dnorm)    # pente de la courbe normale
```

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
exper	0.0226	0.0217	0.0214
age	-0.0177	-0.0165	-0.0170
kidslt6	-0.2718	-0.2608	-0.2670
kidsge6	0.0125	0.0105	0.0106
nwifeinc	-0.0033	-0.0037	-0.0035



Calcul de l'effet marginal moyen pour toutes les variables

```r
# AME de toutes les variables : pente moyenne g(z) × coefficient
ame_glm <- function(modele, densite) {
  z <- predict(modele, type = "link")   # score z de chaque individu
  mean(densite(z)) * coef(modele)
}

ame_logit  <- ame_glm(logit,  dlogis)   # pente de la courbe logistique
ame_probit <- ame_glm(probit, dnorm)    # pente de la courbe normale
```

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
exper	0.0226	0.0217	0.0214
age	-0.0177	-0.0165	-0.0170
kidslt6	-0.2718	-0.2608	-0.2670
kidsge6	0.0125	0.0105	0.0106
nwifeinc	-0.0033	-0.0037	-0.0035



Les effets marginaux moyens du logit et du probit sont ***très proches des coefficients du MPL*** !

Interprétation des effets marginaux moyens

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
kidslt6	-0.2718	-0.2608	-0.2670

Interprétation des effets marginaux moyens

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
kidslt6	-0.2718	-0.2608	-0.2670

- *Éducation* : une année d'éducation supplémentaire augmente en moyenne la probabilité de travailler d'environ 4.1 points de pourcentage (probit).



Interprétation des effets marginaux moyens

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
kidslt6	-0.2718	-0.2608	-0.2670

- *Éducation* : une année d'éducation supplémentaire augmente en moyenne la probabilité de travailler d'environ 4.1 points de pourcentage (probit).
- *Jeunes enfants* : un enfant de moins de 6 ans supplémentaire réduit en moyenne cette probabilité d'environ 26.7 points de pourcentage (probit).



Interprétation des effets marginaux moyens

Variable	MPL	AME logit	AME probit
educ	0.0398	0.0411	0.0408
kidslt6	-0.2718	-0.2608	-0.2670

- *Éducation* : une année d'éducation supplémentaire augmente en moyenne la probabilité de travailler d'environ 4.1 points de pourcentage (probit).
- *Jeunes enfants* : un enfant de moins de 6 ans supplémentaire réduit en moyenne cette probabilité d'environ 26.7 points de pourcentage (probit).
- Ces valeurs sont très proches de celles du MPL : ici, le MPL est une *bonne approximation de l'effet moyen*.



En pratique : interpréter un logit ou un probit en 3 étapes

1. Direction : regarder le ***signe*** et la ***significativité*** du coefficient $\beta_j \rightarrow$ l'effet est-il positif ou négatif ? Est-il statistiquement différent de zéro ?

En pratique : interpréter un logit ou un probit en 3 étapes

1. Direction : regarder le *signe* et la *significativité* du coefficient $\beta_j \rightarrow$ l'effet est-il positif ou négatif ? Est-il statistiquement différent de zéro ?

2. Ampleur : calculer l'*effet marginal moyen* (AME) pour mesurer de combien la *probabilité* change.

En pratique : interpréter un logit ou un probit en 3 étapes

1. Direction : regarder le *signe* et la *significativité* du coefficient $\beta_j \rightarrow$ l'effet est-il positif ou négatif ? Est-il statistiquement différent de zéro ?

2. Ampleur : calculer l'*effet marginal moyen* (AME) pour mesurer de combien la *probabilité* change.

3. Rédaction : exprimer l'effet en *points de pourcentage* sur la *probabilité*.

En pratique : interpréter un logit ou un probit en 3 étapes

1. Direction : regarder le ***signe*** et la ***significativité*** du coefficient $\beta_j \rightarrow$ l'effet est-il positif ou négatif ? Est-il statistiquement différent de zéro ?

2. Ampleur : calculer l'***effet marginal moyen*** (AME) pour mesurer de combien la ***probabilité*** change.

3. Rédaction : exprimer l'effet en ***points de pourcentage*** sur la ***probabilité***.

> *« Une année d'éducation supplémentaire augmente en moyenne de … points de pourcentage la probabilité de travailler, toutes choses égales par ailleurs. »*

En pratique : interpréter un logit ou un probit en 3 étapes

1. Direction : regarder le ***signe*** et la ***significativité*** du coefficient $\beta_j \rightarrow$ l'effet est-il positif ou négatif ? Est-il statistiquement différent de zéro ?

2. Ampleur : calculer l'***effet marginal moyen*** (AME) pour mesurer de combien la ***probabilité*** change.

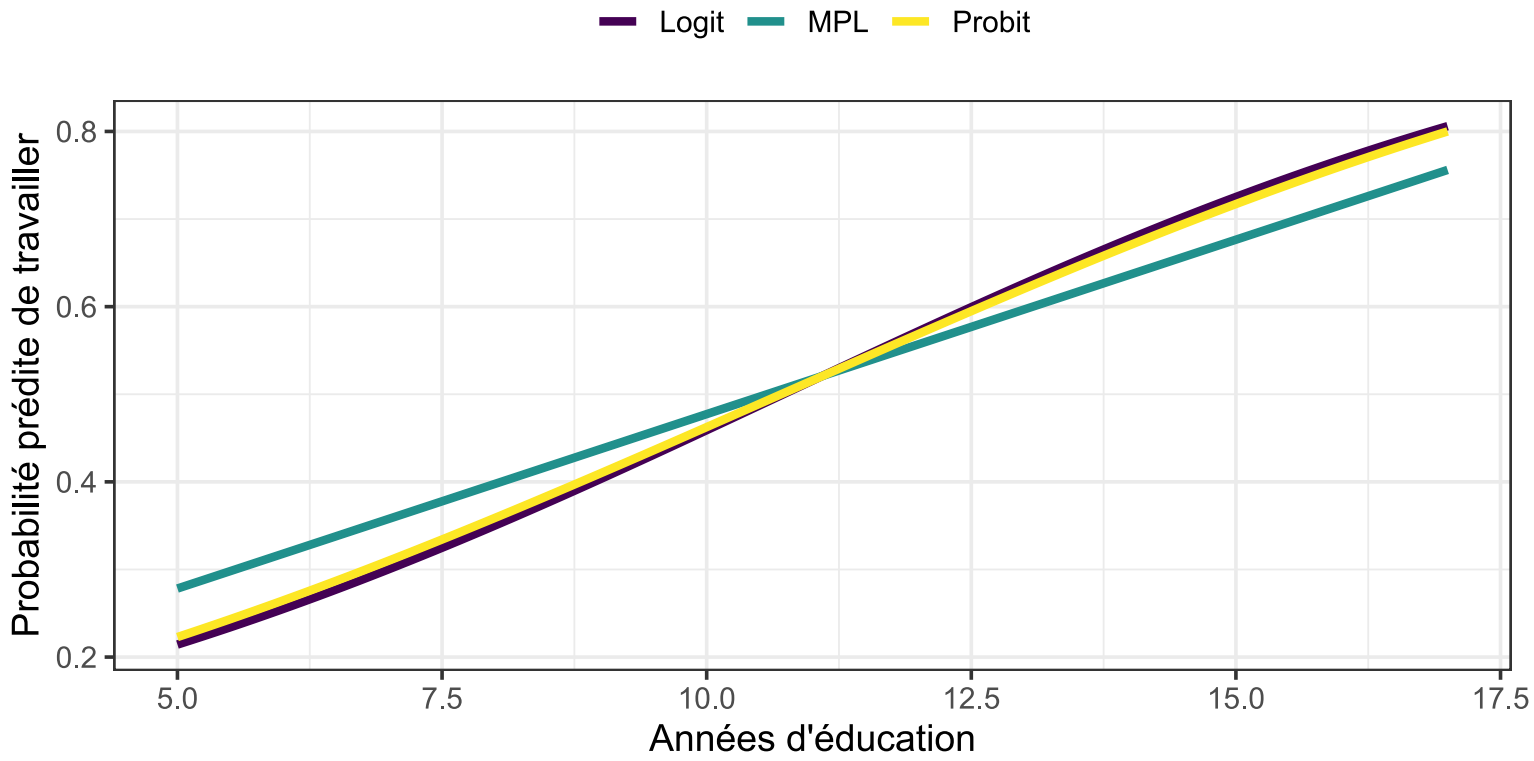
3. Rédaction : exprimer l'effet en ***points de pourcentage*** sur la ***probabilité***.

> *« Une année d'éducation supplémentaire augmente en moyenne de … points de pourcentage la probabilité de travailler, toutes choses égales par ailleurs. »*

⚠️ On ne dit ***jamais*** « une année d'éducation augmente la probabilité de β » avec le coefficient du logit ou du probit : β est une variation du ***score***, pas de la probabilité.

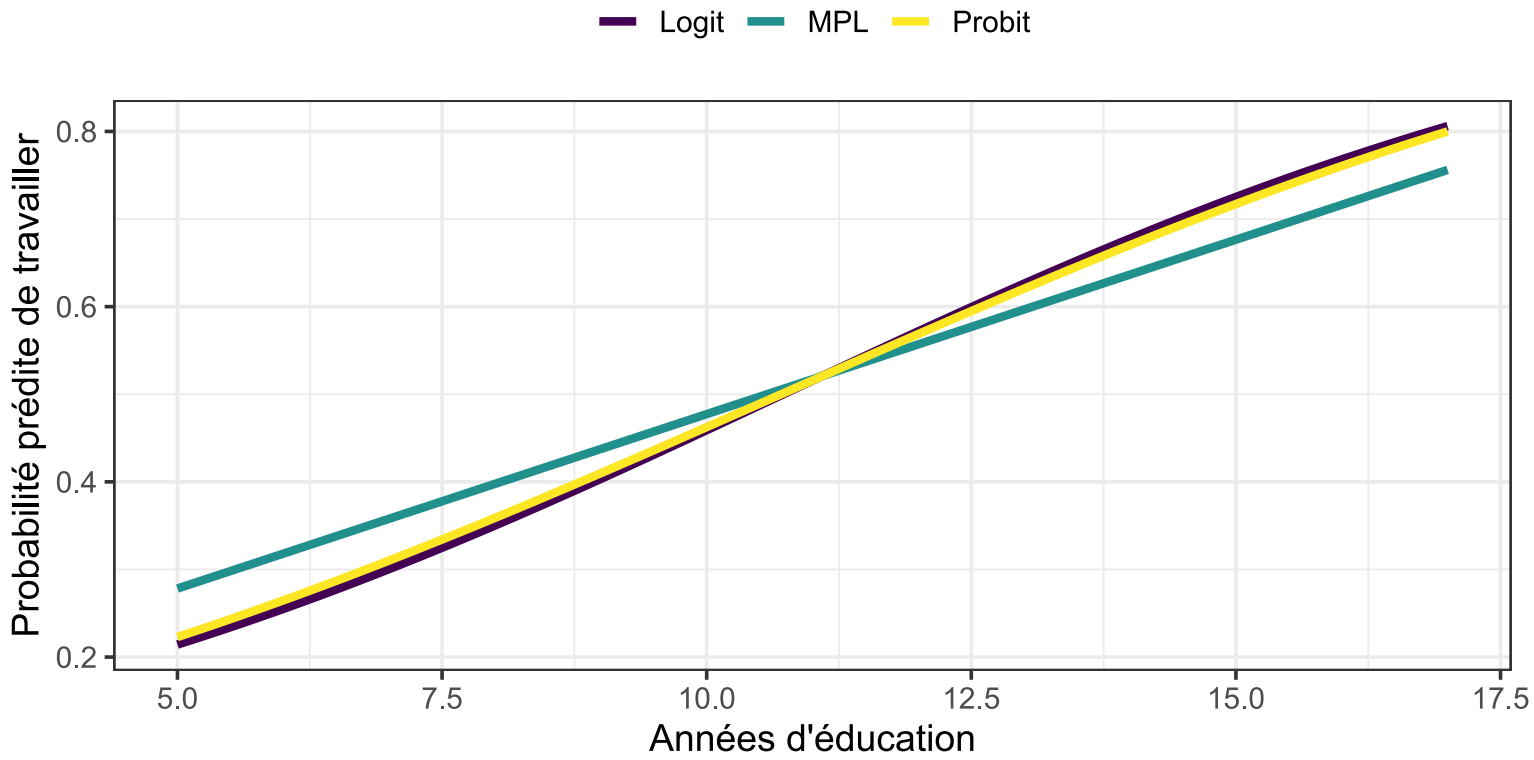
Probabilités prédites : MPL, logit et probit

On fait varier l'éducation en fixant les autres variables à leur moyenne :



Probabilités prédites : MPL, logit et probit

On fait varier l'éducation en fixant les autres variables à leur moyenne :



Les trois modèles donnent des prédictions très proches pour un individu « moyen ». Les différences apparaissent surtout aux ***extrémités***.

Prédire avec un logit ou un probit

- La fonction `predict()` renvoie par défaut le ***score*** z (`type = "link"`). Pour obtenir les ***probabilités***, on précise `type = "response"` :

```
p_logit <- predict(logit, type = "response")

range(p_logit)
```

```
## [1] 0.01184613 0.96892877
```



Prédire avec un logit ou un probit

- La fonction `predict()` renvoie par défaut le ***score*** z (`type = "link"`). Pour obtenir les ***probabilités***, on précise `type = "response"` :

```
p_logit <- predict(logit, type = "response")

range(p_logit)
```

```
## [1] 0.01184613 0.96892877
```

- Les probabilités prédites sont ***toujours comprises entre 0 et 1*** : contrairement au MPL, on n'obtient plus de valeurs absurdes.



Prédire avec un logit ou un probit

- La fonction `predict()` renvoie par défaut le ***score*** z (`type = "link"`). Pour obtenir les ***probabilités***, on précise `type = "response"` :

```
p_logit <- predict(logit, type = "response")

range(p_logit)
```

```
## [1] 0.01184613 0.96892877
```

- Les probabilités prédites sont ***toujours comprises entre 0 et 1*** : contrairement au MPL, on n'obtient plus de valeurs absurdes.

- Rappel pour le MPL : 34 prédictions en dehors de $[0, 1]$.



Qualité d'ajustement

Le R^2 n'a plus de sens simple pour les modèles de variable binaire. On utilise :

Qualité d'ajustement

Le R^2 n'a plus de sens simple pour les modèles de variable binaire. On utilise :

- Le ***pseudo-R2 de McFadden*** : compare la vraisemblance du modèle à celle d'un modèle sans variables explicatives.

```
pseudo_r2 <- 1 - logit$deviance / logit$null.deviance
pseudo_r2
```

```
## [1] 0.2111782
```



Qualité d'ajustement

Le R^2 n'a plus de sens simple pour les modèles de variable binaire. On utilise :

- Le ***pseudo-R2 de McFadden*** : compare la vraisemblance du modèle à celle d'un modèle sans variables explicatives.

```
pseudo_r2 <- 1 - logit$deviance / logit$null.deviance
pseudo_r2
```

```
## [1] 0.2111782
```

- Le ***taux de bonne classification*** : part des individus correctement classés quand on prédit $\hat{Y} = 1$ si $\hat{p} > 0.5$.

```
y_pred <- as.numeric(fitted(logit) > 0.5)
table(prédit = y_pred, observé = mroz$inlf)
```

```
##       observé
## prédit   0   1
##      0 212  81
##      1 113 347
```

```
mean(y_pred == mroz$inlf)
```

```
## [1] 0.7423639
```

Exercice 2 : logit et probit sur `mroz`

15:00

1. Estimez un ***logit*** et un ***probit*** pour `inlf` avec les mêmes variables explicatives que dans l'exercice 1 (utilisez `glm()` avec `family = binomial(link = ...)`).

2. Comparez les signes et les significativités des coefficients avec ceux du MPL. Les ordres de grandeur sont-ils comparables ?

3. Calculez les ***effets marginaux moyens*** de chaque variable (utilisez le code de la slide précédente). Comparez-les avec les coefficients du MPL.

4. Calculez les probabilités prédites du logit. Y en a-t-il en dehors de $[0, 1]$?

5. *Optionnel :* calculez à la main (score z, puis `plogis()`) la probabilité de travailler d'une femme de 12 ans d'éducation, 10 ans d'expérience, 40 ans, sans enfant de moins de 6 ans, avec un enfant de 6 à 18 ans et un revenu du ménage hors le sien de 20. Vérifiez avec `predict()`.



MPL, logit ou probit ?

MPL

- Simple, interprétation directe
- Effets moyens souvent proches
- Très utilisé en évaluation de politiques (RCT, DiD, RDD)
- Mais : prédictions hors de $[0, 1]$, écarts types robustes nécessaires

Logit / Probit

- Probabilités toujours dans $[0, 1]$
- Effets marginaux ***non constants***
- Meilleurs pour ***prédire*** des probabilités, surtout proches de 0 ou de 1
- Mais : interprétation moins directe (effets marginaux à calculer)



MPL, logit ou probit ?

MPL

- Simple, interprétation directe
- Effets moyens souvent proches
- Très utilisé en évaluation de politiques (RCT, DiD, RDD)
- Mais : prédictions hors de $[0, 1]$, écarts types robustes nécessaires

Logit / Probit

- Probabilités toujours dans $[0, 1]$
- Effets marginaux ***non constants***
- Meilleurs pour ***prédire*** des probabilités, surtout proches de 0 ou de 1
- Mais : interprétation moins directe (effets marginaux à calculer)

- ***Logit ou probit ?*** Le choix a très peu d'importance en pratique : les résultats sont quasi identiques.

Récapitulatif : MPL, logit et probit

	MPL	**Logit**	**Probit**
Modèle	$p = z$	$p = \Lambda(z)$	$p = \Phi(z)$
Estimation	MCO	Max. de vraisemblance	Max. de vraisemblance
p ***dans*** $[0, 1]$	Non	Oui	Oui
Effet marginal	Constant : β_j	Dépend de l'individu	Dépend de l'individu
Interprétation de β_j	Directe (en points de %)	Signe seulement (variation du score)	Signe seulement (variation du score)
Écarts types	Robustes nécessaires	Usuels (MV)	Usuels (MV)

avec $z = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$ le score linéaire.

Deuxième exemple : le refus de prêts hypothécaires

Y a-t-il discrimination dans l'octroi de prêts ?

- Données HMDA (*Home Mortgage Disclosure Act*) sur les demandes de prêts hypothécaires à ***Boston*** en 1990 (Munnell et al., 1996).
- Disponibles dans le package `R AER`, jeu de données `HMDA` : 2 380 demandes.



Y a-t-il discrimination dans l'octroi de prêts ?

- Données HMDA (*Home Mortgage Disclosure Act*) sur les demandes de prêts hypothécaires à ***Boston*** en 1990 (Munnell et al., 1996).
- Disponibles dans le package `R` `AER`, jeu de données `HMDA` : 2 380 demandes.

```
install.packages("AER")

data("HMDA", package = "AER")
```



Y a-t-il discrimination dans l'octroi de prêts ?

- Données HMDA (*Home Mortgage Disclosure Act*) sur les demandes de prêts hypothécaires à ***Boston*** en 1990 (Munnell et al., 1996).
- Disponibles dans le package `R AER`, jeu de données `HMDA` : 2 380 demandes.

```
install.packages("AER")

data("HMDA", package = "AER")
```

```
hmda <- HMDA %>%
  mutate(deny01 = as.numeric(deny == "yes"),
         afam01 = as.numeric(afam == "yes"))

hmda %>% select(deny, afam, pirat) %>% head()
```

```
##   deny afam pirat
## 1   no   no 0.221
## 2   no   no 0.265
## 3   no   no 0.372
## 4   no   no 0.320
## 5   no   no 0.360
## 6   no   no 0.240
```



Y a-t-il discrimination dans l'octroi de prêts ?

- Données HMDA (*Home Mortgage Disclosure Act*) sur les demandes de prêts hypothécaires à ***Boston*** en 1990 (Munnell et al., 1996).
- Disponibles dans le package `R AER`, jeu de données `HMDA` : 2 380 demandes.

```
install.packages("AER")

data("HMDA", package = "AER")
```

```
hmda <- HMDA %>%
  mutate(deny01 = as.numeric(deny == "yes"),
         afam01 = as.numeric(afam == "yes"))

hmda %>% select(deny, afam, pirat) %>% head()
```

```
##   deny afam pirat
## 1   no   no 0.221
## 2   no   no 0.265
## 3   no   no 0.372
## 4   no   no 0.320
## 5   no   no 0.360
## 6   no   no 0.240
```

- `deny01` : 1 si le prêt est ***refusé***. `afam01` : 1 si le demandeur est afro-américain. `pirat` : ratio paiements / revenu.



Taux de refus bruts

```
hmda %>%
  group_by(afam) %>%
  summarise(n = n(), taux_refus = mean(deny01))
```

```
## # A tibble: 2 × 3
##   afam      n taux_refus
##   <fct> <int>      <dbl>
## 1 no     2041     0.0926
## 2 yes     339     0.283
```



Taux de refus bruts

```
hmda %>%
  group_by(afam) %>%
  summarise(n = n(), taux_refus = mean(deny01))
```

```
## # A tibble: 2 × 3
##   afam      n taux_refus
##   <fct> <int>      <dbl>
## 1 no     2041     0.0926
## 2 yes     339     0.283
```

- Le taux de refus est de 28.3 % pour les demandeurs afro-américains contre 9.3 % pour les autres.



Taux de refus bruts

```
hmda %>%
  group_by(afam) %>%
  summarise(n = n(), taux_refus = mean(deny01))
```

```
## # A tibble: 2 × 3
##   afam      n taux_refus
##   <fct> <int>      <dbl>
## 1 no     2041     0.0926
## 2 yes     339     0.283
```

- Le taux de refus est de 28.3 % pour les demandeurs afro-américains contre 9.3 % pour les autres.
- *Question :* cette différence reflète-t-elle une discrimination ? Ou d'autres différences (revenus, endettement, historique de crédit) ?



Taux de refus bruts

```
hmda %>%
  group_by(afam) %>%
  summarise(n = n(), taux_refus = mean(deny01))
```

```
## # A tibble: 2 × 3
##   afam      n taux_refus
##   <fct> <int>      <dbl>
## 1 no     2041     0.0926
## 2 yes     339     0.283
```

- Le taux de refus est de 28.3 % pour les demandeurs afro-américains contre 9.3 % pour les autres.
- ***Question :*** cette différence reflète-t-elle une discrimination ? Ou d'autres différences (revenus, endettement, historique de crédit) ?
- Rappel du cours précédent : la sélection sur ***observables*** peut être contrôlée par la régression multiple. On contrôle ici par le ratio paiements / revenu (`pirat`).



MPL, logit et probit sur les données HMDA

```
lpm_h    <- lm(deny01 ~ afam01 + pirat, data = hmda)
logit_h  <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "logit"))
probit_h <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "probit"))
```



MPL, logit et probit sur les données HMDA

```
lpm_h    <- lm(deny01 ~ afam01 + pirat, data = hmda)
logit_h  <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "logit"))
probit_h <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "probit"))
```

Variable	MPL	Logit	Probit
(Intercept)	-0.091	-4.126	-2.259
afam01	0.177	1.273	0.708
pirat	0.559	5.370	2.742



MPL, logit et probit sur les données HMDA

```
lpm_h    <- lm(deny01 ~ afam01 + pirat, data = hmda)
logit_h  <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "logit"))
probit_h <- glm(deny01 ~ afam01 + pirat, data = hmda,
                family = binomial(link = "probit"))
```

Variable	MPL	Logit	Probit
(Intercept)	-0.091	-4.126	-2.259
afam01	0.177	1.273	0.708
pirat	0.559	5.370	2.742

- Les coefficients du logit et du probit sont ***positifs et significatifs*** : être afro-américain et avoir un ratio paiements/revenu élevé ***augmentent*** la probabilité de refus. Mais l'ampleur n'est pas directement lisible.



Effet marginal pour une variable binaire

Pour `afam01` (dummy), on calcule la ***différence de probabilités prédites*** entre $afam01 = 1$ et $afam01 = 0$, en moyenne sur l'échantillon :

```
ame_dummy <- function(modele, donnees, variable) {
  d1 <- donnees; d1[[variable]] <- 1
  d0 <- donnees; d0[[variable]] <- 0
  mean(predict(modele, d1, type = "response") -
       predict(modele, d0, type = "response"))
}
```



Effet marginal pour une variable binaire

Pour `afam01` (dummy), on calcule la ***différence de probabilités prédites*** entre $afam01 = 1$ et $afam01 = 0$, en moyenne sur l'échantillon :

```
ame_dummy <- function(modele, donnees, variable) {
  d1 <- donnees; d1[[variable]] <- 1
  d0 <- donnees; d0[[variable]] <- 0
  mean(predict(modele, d1, type = "response") -
       predict(modele, d0, type = "response"))
}
```

```
c(MPL    = ame_dummy(lpm_h,    hmda, "afam01"),
  Logit  = ame_dummy(logit_h,  hmda, "afam01"),
  Probit = ame_dummy(probit_h, hmda, "afam01"))
```

```
##       MPL     Logit    Probit
## 0.1774282 0.1664023 0.1695923
```



Effet marginal pour une variable binaire

Pour `afam01` (dummy), on calcule la ***différence de probabilités prédites*** entre $afam01 = 1$ et $afam01 = 0$, en moyenne sur l'échantillon :

```
ame_dummy <- function(modele, donnees, variable) {
  d1 <- donnees; d1[[variable]] <- 1
  d0 <- donnees; d0[[variable]] <- 0
  mean(predict(modele, d1, type = "response") -
       predict(modele, d0, type = "response"))
}
```

```
c(MPL    = ame_dummy(lpm_h,    hmda, "afam01"),
  Logit  = ame_dummy(logit_h,  hmda, "afam01"),
  Probit = ame_dummy(probit_h, hmda, "afam01"))
```

```
##       MPL     Logit    Probit
## 0.1774282 0.1664023 0.1695923
```

- À ratio paiements/revenu donné, un demandeur afro-américain a une probabilité de refus plus élevée d'environ 17 points de pourcentage (probit). Les trois modèles donnent des résultats proches.



Que conclure ? Association ou causalité ?

- Les trois modèles concluent à une ***association positive*** entre l'origine afro-américaine et le refus de prêt, même en contrôlant le ratio paiements/revenu.

Que conclure ? Association ou causalité ?

- Les trois modèles concluent à une ***association positive*** entre l'origine afro-américaine et le refus de prêt, même en contrôlant le ratio paiements/revenu.
- Cela prouve-t-il une ***discrimination*** (effet causal) ?

Que conclure ? Association ou causalité ?

- Les trois modèles concluent à une ***association positive*** entre l'origine afro-américaine et le refus de prêt, même en contrôlant le ratio paiements/revenu.
- Cela prouve-t-il une ***discrimination*** (effet causal) ?
  - Non, pas forcément : il peut exister des ***variables omises*** corrélées à l'origine et au refus (historique de crédit, ratio prêt/valeur du bien, emploi…).
  - Les prêteurs observent des caractéristiques que nous ne contrôlons pas ici.

Que conclure ? Association ou causalité ?

- Les trois modèles concluent à une ***association positive*** entre l'origine afro-américaine et le refus de prêt, même en contrôlant le ratio paiements/revenu.
- Cela prouve-t-il une ***discrimination*** (effet causal) ?
  - Non, pas forcément : il peut exister des ***variables omises*** corrélées à l'origine et au refus (historique de crédit, ratio prêt/valeur du bien, emploi…).
  - Les prêteurs observent des caractéristiques que nous ne contrôlons pas ici.
- Les modèles de variable binaire (MPL, logit, probit) ***n'ont pas, en eux-mêmes, de pouvoir causal*** : la question de l'identification (cours précédents) reste entière.

Que conclure ? Association ou causalité ?

- Les trois modèles concluent à une ***association positive*** entre l'origine afro-américaine et le refus de prêt, même en contrôlant le ratio paiements/revenu.
- Cela prouve-t-il une ***discrimination*** (effet causal) ?
  - Non, pas forcément : il peut exister des ***variables omises*** corrélées à l'origine et au refus (historique de crédit, ratio prêt/valeur du bien, emploi…).
  - Les prêteurs observent des caractéristiques que nous ne contrôlons pas ici.
- Les modèles de variable binaire (MPL, logit, probit) ***n'ont pas, en eux-mêmes, de pouvoir causal*** : la question de l'identification (cours précédents) reste entière.

👉 Il s'agit d'un *choix de forme fonctionnelle* pour une variable dépendante binaire, pas d'une stratégie d'identification.

Exercice 3 : les données HMDA

15:00

1. Chargez les données avec `data("HMDA", package = "AER")` et créez les variables binaires `deny01` et `afam01`.

2. Estimez le MPL de `deny01` sur `afam01`, `pirat` et `hirat` (ratio dépenses de logement / revenu). Calculez les écarts types robustes.

3. Estimez le logit et le probit correspondants. Calculez l'effet marginal moyen de `afam01` pour chaque modèle.

4. Les résultats sont-ils sensibles au choix du modèle ?

5. Ajoutez d'autres variables de contrôle (par exemple `lvrat`, `chist`, `mhist`, `selfemp`). L'effet de `afam01` change-t-il ? Que cela suggère-t-il sur les variables omises ?



Ce qu'il faut retenir

- Une ***variable binaire*** ne prend que deux valeurs, 0 et 1 : sa moyenne est une ***proportion*** et $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$.

Ce qu'il faut retenir

- Une ***variable binaire*** ne prend que deux valeurs, 0 et 1 : sa moyenne est une ***proportion*** et $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$.
- Le ***MPL*** (MCO sur Y binaire) est simple et ses coefficients se lisent directement en points de pourcentage, mais :
  - il peut prédire des probabilités ***en dehors de*** $[0, 1]$,
  - ses erreurs sont ***hétéroscédastiques*** $\rightarrow$ écarts types ***robustes*** nécessaires,
  - l'effet marginal est ***constant***.

Ce qu'il faut retenir

- Une ***variable binaire*** ne prend que deux valeurs, 0 et 1 : sa moyenne est une ***proportion*** et $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$.
- Le ***MPL*** (MCO sur Y binaire) est simple et ses coefficients se lisent directement en points de pourcentage, mais :
  - il peut prédire des probabilités ***en dehors de*** $[0, 1]$,
  - ses erreurs sont ***hétéroscédastiques*** $\rightarrow$ écarts types ***robustes*** nécessaires,
  - l'effet marginal est ***constant***.
- Le ***logit*** et le ***probit*** transforment un ***score*** linéaire z par une courbe en « S » G pour garantir $0 \leq p \leq 1$:
  - estimation par ***maximum de vraisemblance*** (`glm()`),
  - le coefficient est une variation du ***score***, pas de la probabilité $\rightarrow$ calculer les ***effets marginaux*** (AME), qui dépendent de la pente de la courbe.



Ce qu'il faut retenir

- Une ***variable binaire*** ne prend que deux valeurs, 0 et 1 : sa moyenne est une ***proportion*** et $\mathbb{E}(Y|X) = \mathbb{P}(Y = 1|X)$.
- Le ***MPL*** (MCO sur Y binaire) est simple et ses coefficients se lisent directement en points de pourcentage, mais :
  - il peut prédire des probabilités ***en dehors de*** $[0, 1]$,
  - ses erreurs sont ***hétéroscédastiques*** $\rightarrow$ écarts types ***robustes*** nécessaires,
  - l'effet marginal est ***constant***.
- Le ***logit*** et le ***probit*** transforment un ***score*** linéaire z par une courbe en « S » G pour garantir $0 \leq p \leq 1$:
  - estimation par ***maximum de vraisemblance*** (`glm()`),
  - le coefficient est une variation du ***score***, pas de la probabilité $\rightarrow$ calculer les ***effets marginaux*** (AME), qui dépendent de la pente de la courbe.
- En pratique, les ***effets marginaux moyens*** des trois modèles sont souvent très proches.



UNIVERSITÉ DE NAMUR

BONNE JOURNÉE !

	jeremy.donascimento@unamur.be
	Discord
	Slides