UNIVERSITÉ DE NAMUR

# Econométrie

## Propriétés du modèle de régression linéaire

Jérémy Do Nascimento Miguel
Université de Namur
2026-10-02

# Aujourd'hui - Propriétés du modèle de régression linéaire

Jusqu'à présent, nous avons vu comment utiliser les modèles linéaires et les interpréter.



# Aujourd'hui - Propriétés du modèle de régression linéaire

Jusqu'à présent, nous avons vu comment utiliser les modèles linéaires et les interpréter.

Dans cette session, nous allons nous concentrer sur les propriétés des estimateurs OLS :

1. **Absence de biais** : hypothèses H1 à H4
2. **Variance** des estimateurs : hypothèse H5
3. **Gauss-Markov** : pourquoi utiliser les OLS ?
4. **En pratique** : comment vérifier les hypothèses ? Le test de Breusch-Pagan



# Valeurs espérées des estimateurs OLS

# H1 : Linéarité en paramètres

La première hypothèse repose sur la linéarité en paramètres du modèle :



# H1 : Linéarité en paramètres

La première hypothèse repose sur la linéarité en paramètres du modèle :

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k + u$$

- La linéarité en paramètres signifie que le modèle est **linéaire dans les $\beta_j$**.
- Les variables explicatives, elles, peuvent être des fonctions non linéaires des variables d'origine (ex : $x^2$, $\ln(x)$).



# H2 : Échantillon aléatoire

La deuxième hypothèse porte sur l'origine des données. Les données utilisées pour estimer notre modèle sont **tirées** aléatoirement d'une population :

# H2 : Échantillon aléatoire

La deuxième hypothèse porte sur l'origine des données. Les données utilisées pour estimer notre modèle sont **tirées** aléatoirement d'une population :

$$\text{n obs} : \{(x_{i,1}, \ldots, x_{i,k}; y_i)\} : i = \{1, \ldots, n\}$$

- Si c'est le cas, nous pouvons alors estimer le modèle associé à H1 et le réécrire pour un individu donné :

$$y_i = \beta_0 + \beta_1 x_{i,1} + \ldots + \beta_k x_{i,k} + u_i$$

# H3 : Absence de colinéarité parfaite

- Dans un échantillon donné, aucune variable explicative ( $x$ ) ne doit être constante et aucune ne doit être une **combinaison linéaire** exacte des autres variables explicatives.

# H3 : Absence de colinéarité parfaite

- Dans un échantillon donné, aucune variable explicative ( $x$ ) ne doit être constante et aucune ne doit être une **combinaison linéaire** exacte des autres variables explicatives.
- La solution ? **Supprimer** une des variables qui donne une **information redondante**. Par exemple, nous n'avons pas besoin d'ajouter les variables `homme` et `femme` dans un même modèle.



# H3 : Absence de colinéarité parfaite

- Dans un échantillon donné, aucune variable explicative ( $x$ ) ne doit être constante et aucune ne doit être une **combinaison linéaire** exacte des autres variables explicatives.
- La solution ? **Supprimer** une des variables qui donne une **information redondante**. Par exemple, nous n'avons pas besoin d'ajouter les variables `homme` et `femme` dans un même modèle.
- Cette hypothèse peut également ne pas tenir lorsque le **nombre d'observations est trop petit** par rapport au nombre de paramètres à estimer ( $\widehat{\beta_k}$ ). On a besoin d'au moins $k+1$ observations pour pouvoir estimer un modèle avec $k+1$ paramètres.



# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple, il existe une relation non linéaire entre la variable dépendante et une de nos variables explicatives, que le modèle ne capture pas.



# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple, il existe une relation non linéaire entre la variable dépendante et une de nos variables explicatives, que le modèle ne capture pas.
- Omission d'une variable importante, corrélée avec une variable explicative : $COV(u, x) \neq 0$.

# H4 : Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple, il existe une relation non linéaire entre la variable dépendante et une de nos variables explicatives, que le modèle ne capture pas.
- Omission d'une variable importante, corrélée avec une variable explicative : $COV(u, x) \neq 0$.

Si H4 est vérifiée, on dit que l'ensemble de nos variables sont **exogènes** ; sinon, il y a un problème d'**endogénéité**. Nous verrons comment résoudre ce problème plus tard dans le semestre.



# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Échantillonnage aléatoire

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Échantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Échantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite
- **H4** : Moyenne conditionnelle nulle ( $E(u|x_1, \ldots, x_k) = 0$ )

# Théorème : Absence de biais des estimateurs OLS

**Théorème — Absence de biais**

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Échantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite
- **H4** : Moyenne conditionnelle nulle ( $E(u|x_1, \ldots, x_k) = 0$ )

Si une seule de ces hypothèses n'est pas vérifiée, l'estimateur OLS peut devenir biaisé.

# Variance des estimateurs OLS

# H5 : Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.



# H5 : Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables explicatives, doit être **constante** :

# H5 : Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables explicatives, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

# H5 : Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables explicatives, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

- Autrement dit, la dispersion des erreurs ne doit **pas dépendre** des valeurs prises par les $x$.

# H5 : Homoscédasticité

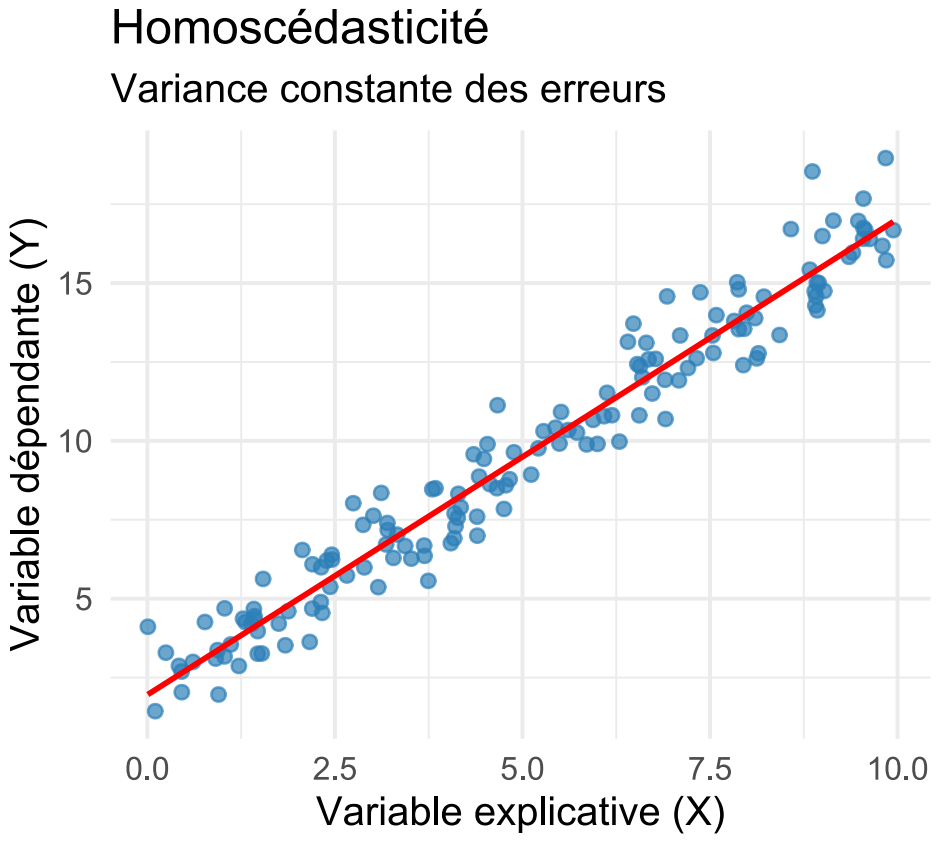
Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

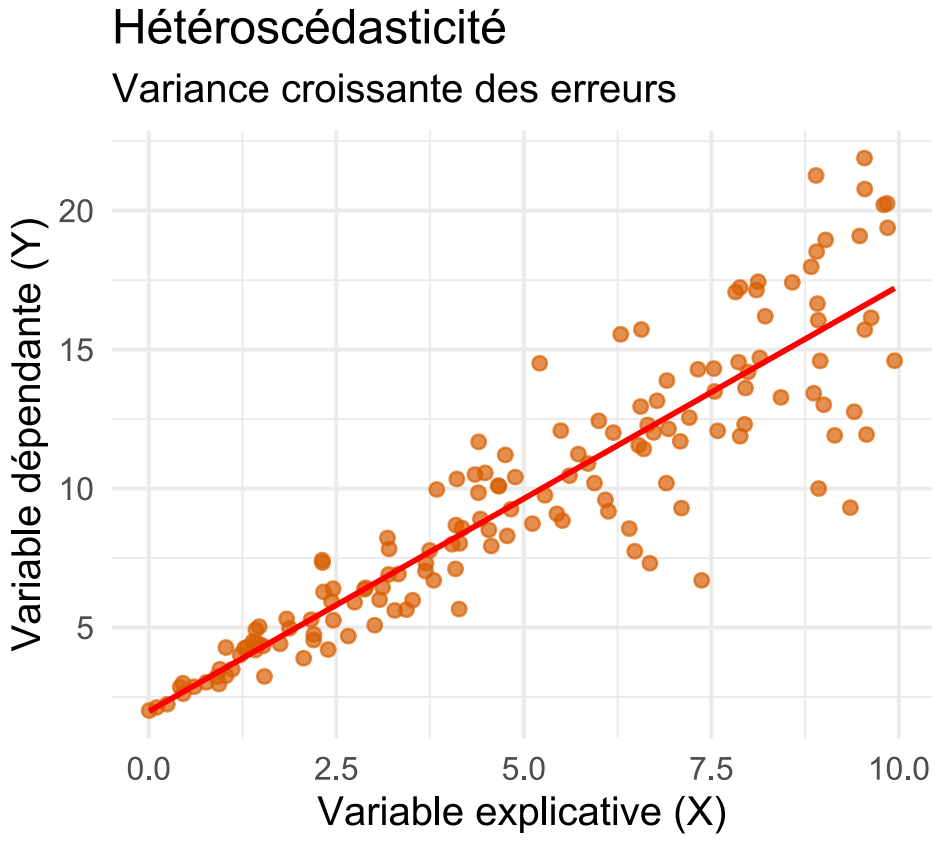
La variance de l'erreur, conditionnellement aux variables explicatives, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

- Autrement dit, la dispersion des erreurs ne doit **pas dépendre** des valeurs prises par les $x$.
- Si cette hypothèse n'est **pas vérifiée**, on parle d'**hétéroscédasticité** : la variance de l'erreur varie selon les observations.

# Homoscédasticité visuellement



# La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS (conditionnellement aux $x$ ) peut s'écrire :

# La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS (conditionnellement aux $x$ ) peut s'écrire :

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

# La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS (conditionnellement aux $x$ ) peut s'écrire :

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Décomposons chaque terme de cette formule :

# Terme 1 : $\sigma^2$ — La variance de l'erreur

$$\sigma^2 = Var(u)$$

# Terme 1 : $\sigma^2$ — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.

# Terme 1 : $\sigma^2$ — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.
- **Plus il y a de "bruit"** dans les données (facteurs non observés, mesures imprécises...), **plus $\sigma^2$ est grand**.

# Terme 1 : $\sigma^2$ — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.
- **Plus il y a de "bruit"** dans les données (facteurs non observés, mesures imprécises...), **plus $\sigma^2$ est grand**.
- Un $\sigma^2$ élevé $\Rightarrow$ une variance de $\widehat{\beta_j}$ plus grande $\Rightarrow$ une estimation **moins précise**.

# Terme 2 : $SST_j$ — La variation totale de $x_j$

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

# Terme 2 : $SST_j$ — La variation totale de $x_j$

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable $x_j$ dans notre échantillon.

# Terme 2 : $SST_j$ — La variation totale de $x_j$

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable $x_j$ dans notre échantillon.
- Concrètement : est-ce que $x_j$ prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?

# Terme 2 : $SST_j$ — La variation totale de $x_j$

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable $x_j$ dans notre échantillon.
- Concrètement : est-ce que $x_j$ prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?
- Un $SST_j$ élevé $\Rightarrow$ plus d'information disponible sur $x_j$ $\Rightarrow$ une estimation **plus précise** (la variance diminue).

# Terme 2 : $SST_j$ — La variation totale de $x_j$

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable $x_j$ dans notre échantillon.
- Concrètement : est-ce que $x_j$ prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?
- Un $SST_j$ élevé $\Rightarrow$ plus d'information disponible sur $x_j$ $\Rightarrow$ une estimation **plus précise** (la variance diminue).
- **Intuition** : il est plus facile d'estimer l'effet d'une variable qui varie beaucoup que celui d'une variable presque constante.

# Terme 3 : $R_j^2$ — La colinéarité avec les autres $x$

$R_j^2 = R^2$ de la régression de $x_j$ sur toutes les autres variables explicatives

# Terme 3 : $R_j^2$ — La colinéarité avec les autres $x$

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables explicatives}$$

- Il mesure à quel point $x_j$ peut être **expliquée** (prédite) par les autres variables explicatives du modèle.

# Terme 3 : $R_j^2$ — La colinéarité avec les autres $x$

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables explicatives}$$

- Il mesure à quel point $x_j$ peut être **expliquée** (prédite) par les autres variables explicatives du modèle.
- $R_j^2$ proche de **0** $\Rightarrow x_j$ apporte une information **indépendante** des autres variables.

# Terme 3 : $R_j^2$ — La colinéarité avec les autres $x$

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables explicatives}$$

- Il mesure à quel point $x_j$ peut être **expliquée** (prédite) par les autres variables explicatives du modèle.
- $R_j^2$ proche de **0** $\Rightarrow$ $x_j$ apporte une information **indépendante** des autres variables.
- $R_j^2$ proche de **1** $\Rightarrow$ $x_j$ est presque une **combinaison linéaire** des autres $x$ (colinéarité forte, cf. H3).

# Terme 3 : $R_j^2$ — La colinéarité avec les autres $x$

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables explicatives}$$

- Il mesure à quel point $x_j$ peut être **expliquée** (prédite) par les autres variables explicatives du modèle.
- $R_j^2$ proche de **0** $\Rightarrow$ $x_j$ apporte une information **indépendante** des autres variables.
- $R_j^2$ proche de **1** $\Rightarrow$ $x_j$ est presque une **combinaison linéaire** des autres $x$ (colinéarité forte, cf. H3).
- Un $R_j^2$ élevé $\Rightarrow$ $(1 - R_j^2)$ devient petit $\Rightarrow$ la variance de $\widehat{\beta_j}$ **augmente fortement**.

# En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

**Variance de $\widehat{\beta_j}$**

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

# En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

**Variance de `$\widehat{\beta_j}$`**

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

# En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

**Variance de `$\widehat{\beta_j}$`**

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- $\sigma^2$ est **petit** : peu de bruit dans le modèle

# En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

**Variance de $\widehat{\beta_j}$**

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- $\sigma^2$ est **petit** : peu de bruit dans le modèle
- $SST_j$ est **grand** : $x_j$ varie beaucoup dans l'échantillon

# En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

**Variance de $\widehat{\beta_j}$**

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- $\sigma^2$ est **petit** : peu de bruit dans le modèle
- $SST_j$ est **grand** : $x_j$ varie beaucoup dans l'échantillon
- $R_j^2$ est **petit** : $x_j$ n'est pas colinéaire avec les autres variables

# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.



# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.



# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- $SCR$ (ou $SSR$) est la **somme des carrés des résidus**.

# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- $SCR$ (ou $SSR$) est la **somme des carrés des résidus**.
- $n-k-1$ est le nombre de **degrés de liberté** : $n$ observations moins $(k+1)$ paramètres estimés ( $\beta_0, \beta_1, \ldots, \beta_k$ ). Avec ce dénominateur, $\hat{\sigma}^2$ est un estimateur **sans biais** de $\sigma^2$ sous H1 à H5.

# Un problème : $\sigma^2$ est inconnu

Dans la pratique, la variance de l'erreur $\sigma^2$ n'est **jamais observée** : elle dépend des erreurs $u_i$, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- $SCR$ (ou $SSR$) est la **somme des carrés des résidus**.
- $n-k-1$ est le nombre de **degrés de liberté** : $n$ observations moins $(k+1)$ paramètres estimés ( $\beta_0, \beta_1, \ldots, \beta_k$ ). Avec ce dénominateur, $\hat{\sigma}^2$ est un estimateur **sans biais** de $\sigma^2$ sous H1 à H5.
- $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ est appelé l'**erreur standard de la régression** (*Standard Error of the Regression*, SER).



# Écart-type vs erreur standard de $\widehat{\beta_j}$

# Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

# Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$ : l'**écart-type théorique** de l'estimateur, qui dépend de $\sigma$, **inconnu** en pratique.

# Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$ : l'**écart-type théorique** de l'estimateur, qui dépend de $\sigma$, **inconnu** en pratique.
- $se(\widehat{\beta_j})$ : l'**erreur standard estimée**, où l'on remplace $\sigma$ par son estimation $\hat{\sigma}$, calculable à partir des données.

# Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$ : l'**écart-type théorique** de l'estimateur, qui dépend de $\sigma$, **inconnu** en pratique.
- $se(\widehat{\beta_j})$ : l'**erreur standard estimée**, où l'on remplace $\sigma$ par son estimation $\hat{\sigma}$, calculable à partir des données.

Pourquoi c'est important ?

- Le $se(\widehat{\beta_j})$ mesure la **précision** de notre estimation : plus il est petit, plus $\widehat{\beta_j}$ est fiable.
- Il est indispensable pour construire des **tests d'hypothèses** et des **intervalles de confiance** sur $\beta_j$.



# Précision de $\widehat{\beta_1}$ : à vous de jouer

Bruit : σ = **2**
↑ $\sigma^2$ : moins précis

Taille d'échantillon : n = **50**
↑ n : plus de SST

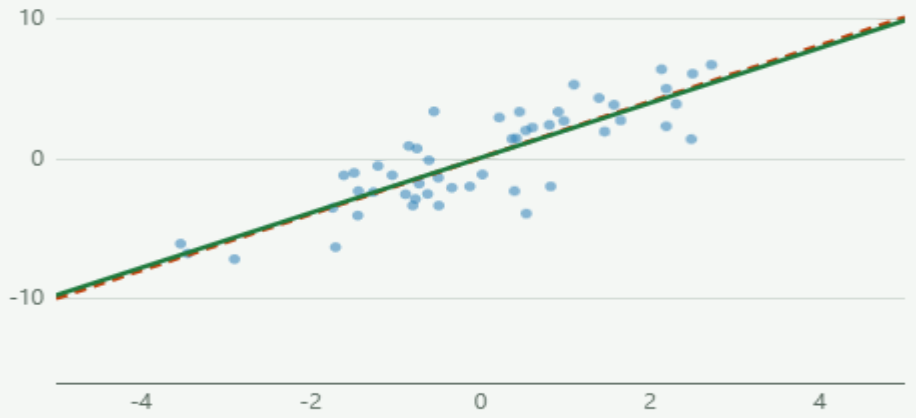
Dispersion de $x_1$ : $sd(x_1)$ = **1,5**
↑ $sd(x_1)$ : plus de SST

Corrélation $x_1$ / $x_2$ : ρ = **0**
↑ ρ : $R^2$ élevé, moins précis

Nouvel échantillon | + 200 échantillons | Réinitialiser | ☐ Zoomer sur la distribution de $\hat{\beta}_1$

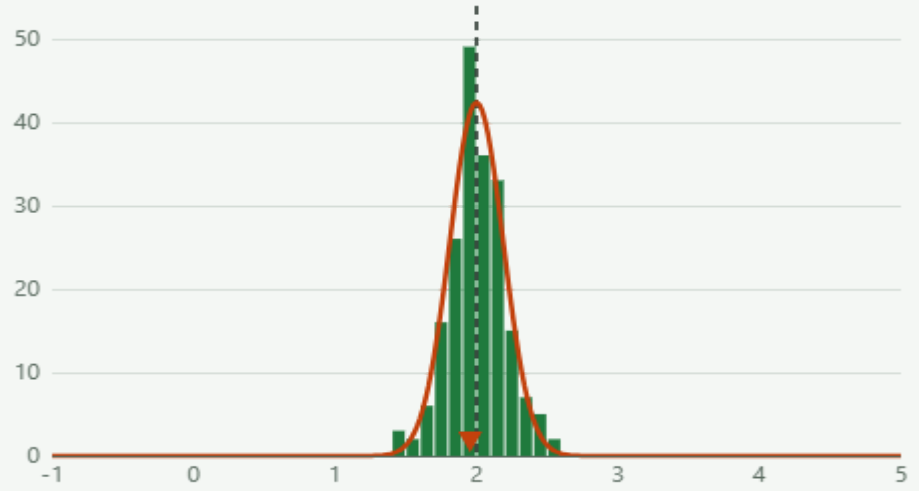
**Un échantillon : relation entre y et $x_1$ ($x_2$ contrôlée)**

Observations — Droite estimée (pente $\hat{\beta}_1$) — Vraie droite ($\beta_1$ = 2)




**Distribution des $\hat{\beta}_1$** — 200 échantillons

Estimations $\hat{\beta}_1$ — N($\beta_1$, sd théorique)




$sd(\hat{\beta}_1) = \sigma / \sqrt{(SST_1 \times (1 - R_1^2))} = 2 / \sqrt{(112{,}5 \times 1)} =$ **0,189**

Vraie valeur $\beta_1$ = **2** Moyenne des $\hat{\beta}_1$ = **2,006** Écart-type observé des $\hat{\beta}_1$ = **0,198** Dernier échantillon : $\hat{\beta}_1$ = **1,955**, se estimée = **0,185**

# Le théorème de Gauss-Markov

# Pourquoi utiliser les OLS ? Le théorème de Gauss-Markov

Sous les hypothèses **H1 à H5**, le théorème de **Gauss-Markov** nous garantit que les estimateurs OLS sont les meilleurs estimateurs linéaires sans biais : on dit qu'ils sont **BLUE**.



# Pourquoi utiliser les OLS ? Le théorème de Gauss-Markov

Sous les hypothèses **H1 à H5**, le théorème de **Gauss-Markov** nous garantit que les estimateurs OLS sont les meilleurs estimateurs linéaires sans biais : on dit qu'ils sont **BLUE**.

**BLUE — Best Linear Unbiased Estimator**

$$Var(\widehat{\beta_j}^{OLS}) \leq Var(\widetilde{\beta_j}) \quad \text{pour tout estimateur } \widetilde{\beta_j} \text{ linéaire et sans biais}$$

# Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.



# Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations $y_i$.



# Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations $y_i$.
- **U**nbiased (Sans biais) : en moyenne, sur un grand nombre d'échantillons, l'estimateur donne la **vraie valeur** du paramètre : $E(\widehat{\beta_j}) = \beta_j$ (H1 à H4).

# Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations $y_i$.
- **U**nbiased (Sans biais) : en moyenne, sur un grand nombre d'échantillons, l'estimateur donne la **vraie valeur** du paramètre : $E(\widehat{\beta_j}) = \beta_j$ (H1 à H4).
- **E**stimator (Estimateur) : c'est une **règle de calcul** (une formule) permettant d'obtenir une valeur estimée $\widehat{\beta_j}$ à partir d'un échantillon de données.

# Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour $\beta_j$. Alors pourquoi utiliser spécifiquement les OLS ?



# Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour $\beta_j$. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.



# Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour $\beta_j$. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.



# Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour $\beta_j$. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.
- OLS **n'est pas nécessairement le meilleur estimateur dans l'absolu** : si on autorise le biais, ou des estimateurs non linéaires, il peut exister de meilleures alternatives.



# Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour $\beta_j$. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.
- OLS **n'est pas nécessairement le meilleur estimateur dans l'absolu** : si on autorise le biais, ou des estimateurs non linéaires, il peut exister de meilleures alternatives.



OLS est donc **optimal dans sa classe**, celle des estimateurs linéaires et sans biais, pas dans l'absolu.

# Vérifier les hypothèses en pratique

# Peut-on tester les hypothèses ?

| Hypothèse | Testable ? | Diagnostic empirique | Outil R |
|---|---|---|---|
| **H1** Linéarité | Partiellement | Résidus vs valeurs ajustées, test RESET | `resettest()` |
| **H2** Échantillon aléatoire | Non (dépend de la collecte) | Documentation, représentativité | - |
| **H3** Pas de colinéarité parfaite | Oui | Coefficients `NA`, VIF | `alias()`, `vif()` |
| **H4** Moyenne conditionnelle nulle | **Non** directement | RESET, stabilité des coefficients, tests d'exogénéité | `resettest()` |
| **H5** Homoscédasticité | Oui | Graphique des résidus, Breusch-Pagan, White | `bptest()` |



# Peut-on tester les hypothèses ?

| Hypothèse | Testable ? | Diagnostic empirique | Outil R |
|---|---|---|---|
| **H1** Linéarité | Partiellement | Résidus vs valeurs ajustées, test RESET | `resettest()` |
| **H2** Échantillon aléatoire | Non (dépend de la collecte) | Documentation, représentativité | - |
| **H3** Pas de colinéarité parfaite | Oui | Coefficients `NA`, VIF | `alias()`, `vif()` |
| **H4** Moyenne conditionnelle nulle | **Non** directement | RESET, stabilité des coefficients, tests d'exogénéité | `resettest()` |
| **H5** Homoscédasticité | Oui | Graphique des résidus, Breusch-Pagan, White | `bptest()` |



Certaines hypothèses se vérifient avec les **données**, d'autres seulement avec des **arguments** sur la manière dont elles ont été collectées.

# H1 : Linéarité en paramètres

- La linéarité **en paramètres** est un choix de modélisation, pas un test. Le vrai risque est une **forme fonctionnelle mal spécifiée**.

# H1 : Linéarité en paramètres

- La linéarité **en paramètres** est un choix de modélisation, pas un test. Le vrai risque est une **forme fonctionnelle mal spécifiée**.
- **Diagnostic graphique** : les résidus vs valeurs ajustées ne doivent montrer aucune structure (pas de courbe en U).

# H1 : Linéarité en paramètres

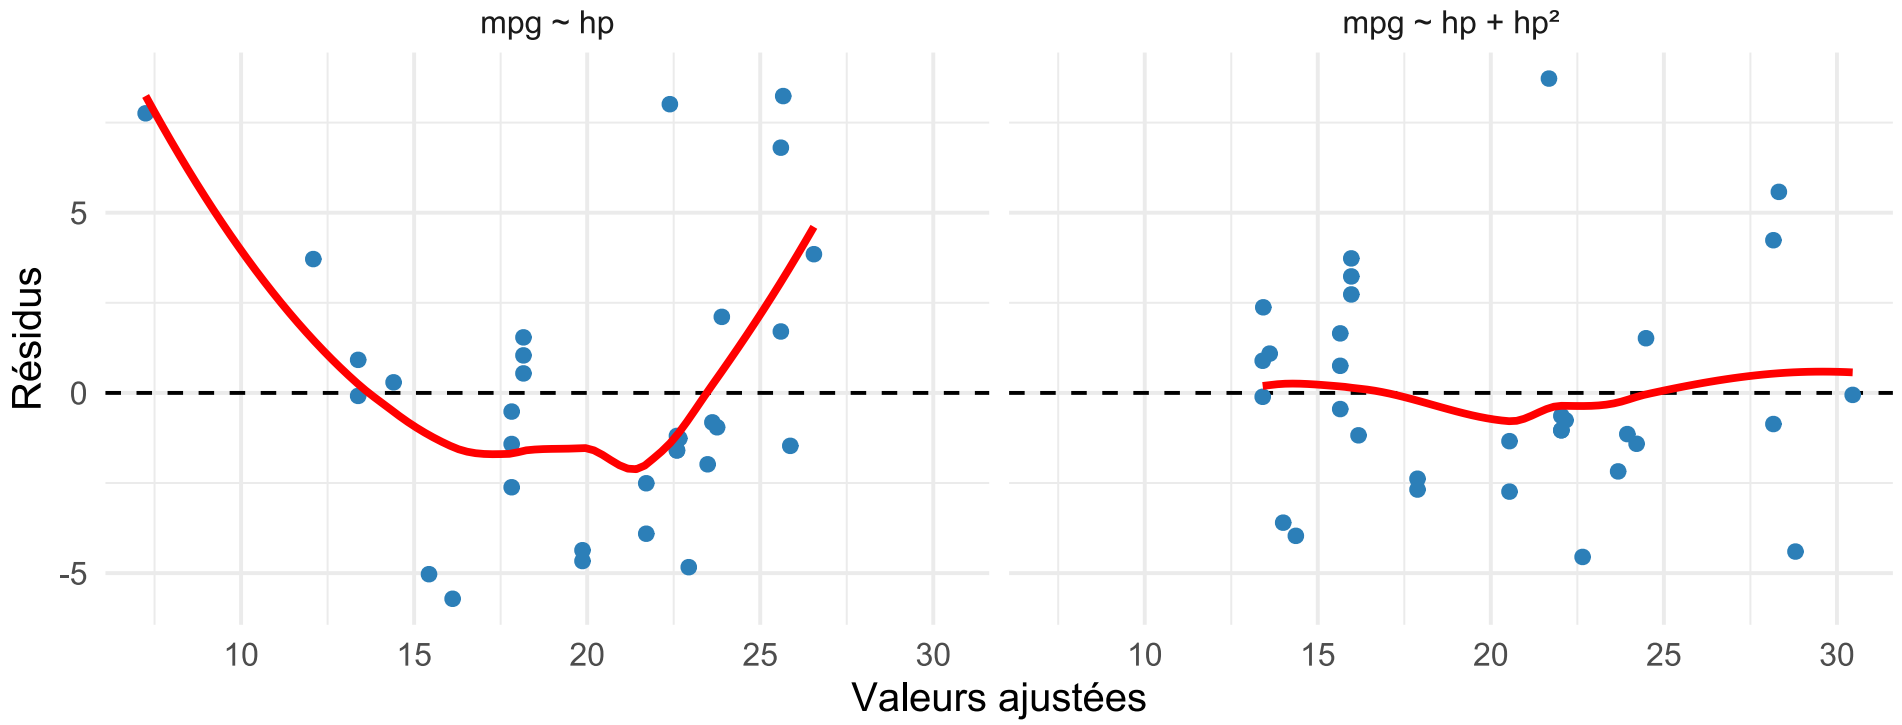
- La linéarité **en paramètres** est un choix de modélisation, pas un test. Le vrai risque est une **forme fonctionnelle mal spécifiée**.
- **Diagnostic graphique** : les résidus vs valeurs ajustées ne doivent montrer aucune structure (pas de courbe en U).
- **Test RESET de Ramsey** : on ajoute $\hat{y}^2, \hat{y}^3$ au modèle et on teste leur significativité.
  - $H_0$ : la forme fonctionnelle est correcte.
  - $p < 0{,}05$ : on rejette $H_0$, le modèle est mal spécifié.

```
resettest(lm(mpg ~ hp, data = mtcars), power = 2:3, type = "fitted")
```

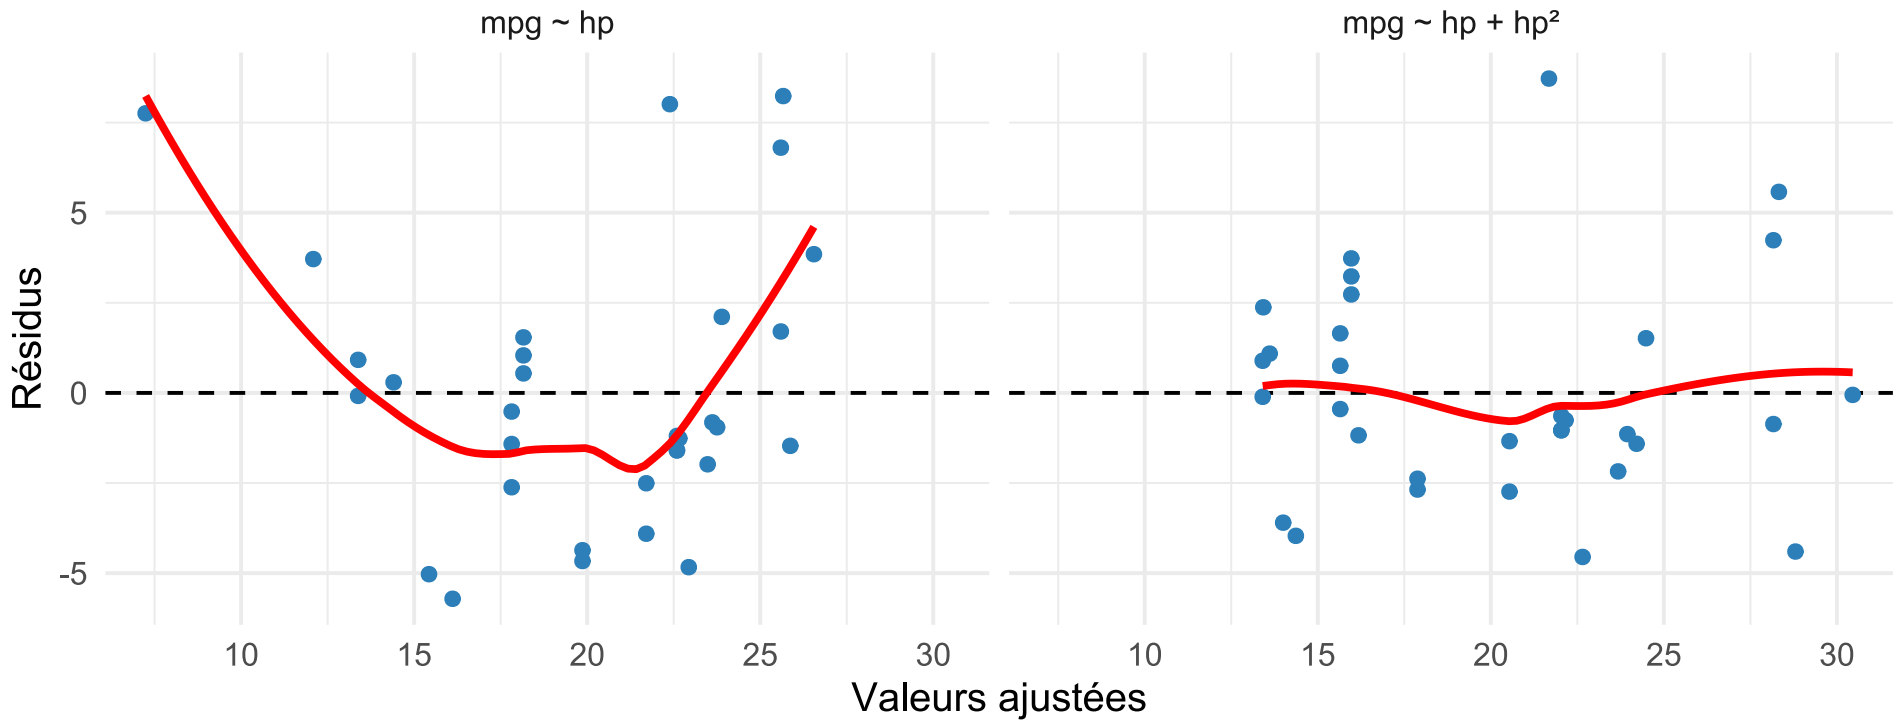
```
##
##     RESET test
##
## data:  lm(mpg ~ hp, data = mtcars)
## RESET = 9.2467, df1 = 2, df2 = 28, p-value = 0.0008255
```



# H1 : exemple visuel



# H1 : exemple visuel




Une structure en U dans les résidus (à gauche) signale une **non-linéarité omise** : ajouter $hp^2$ règle le problème.

# H2 : Échantillon aléatoire

- Aucun test ne peut le confirmer à partir des données seules : tout dépend de **comment les données ont été collectées**.

# H2 : Échantillon aléatoire

- Aucun test ne peut le confirmer à partir des données seules : tout dépend de **comment les données ont été collectées**.
- Questions à se poser :
  - Chaque individu avait-il la **même chance** d'être sélectionné ?
  - Y a-t-il de la **non-réponse** ou une **sélection** (ex : seulement les personnes employées) ?
  - Les observations sont-elles **indépendantes** (pas de séries temporelles ni de grappes, ex : élèves d'une même classe) ?



# H2 : Échantillon aléatoire

- Aucun test ne peut le confirmer à partir des données seules : tout dépend de **comment les données ont été collectées**.
- Questions à se poser :
  - Chaque individu avait-il la **même chance** d'être sélectionné ?
  - Y a-t-il de la **non-réponse** ou une **sélection** (ex : seulement les personnes employées) ?
  - Les observations sont-elles **indépendantes** (pas de séries temporelles ni de grappes, ex : élèves d'une même classe) ?
- **Diagnostics partiels** :
  - comparer les moyennes de l'échantillon à des statistiques de la **population** connue (recensement) ;
  - en séries temporelles, tester l'autocorrélation des erreurs : `bgtest()` (Breusch-Godfrey).



# H3 : Absence de colinéarité parfaite

R détecte la colinéarité parfaite **automatiquement** : un coefficient apparaît comme `NA`.

```
set.seed(1)
d <- data.frame(y = rnorm(20), homme = rep(c(1, 0), 10))
d$femme <- 1 - d$homme        # femme = 1 - homme : piège des variables muettes
coef(lm(y ~ homme + femme, data = d))
```

```
## (Intercept)       homme       femme
##   0.1059339   0.1691799          NA
```



# H3 : Absence de colinéarité parfaite

R détecte la colinéarité parfaite **automatiquement** : un coefficient apparaît comme `NA`.

```
set.seed(1)
d <- data.frame(y = rnorm(20), homme = rep(c(1, 0), 10))
d$femme <- 1 - d$homme        # femme = 1 - homme : piège des variables muettes
coef(lm(y ~ homme + femme, data = d))
```

```
## (Intercept)       homme       femme
##   0.1059339   0.1691799          NA
```

Pour la colinéarité **forte mais imparfaite**, on utilise le **facteur d'inflation de la variance** :

$$VIF_j = \frac{1}{1 - R_j^2}$$

# H3 : Absence de colinéarité parfaite

R détecte la colinéarité parfaite **automatiquement** : un coefficient apparaît comme `NA`.

```
set.seed(1)
d <- data.frame(y = rnorm(20), homme = rep(c(1, 0), 10))
d$femme <- 1 - d$homme        # femme = 1 - homme : piège des variables muettes
coef(lm(y ~ homme + femme, data = d))
```

```
## (Intercept)       homme       femme
##   0.1059339   0.1691799          NA
```

Pour la colinéarité **forte mais imparfaite**, on utilise le **facteur d'inflation de la variance** :

$$VIF_j = \frac{1}{1 - R_j^2}$$

```
vif(lm(mpg ~ wt + hp + disp, data = mtcars))
```

```
##       wt       hp     disp
## 4.844618 2.736633 7.324517
```



- Règle pratique : $VIF > 10$ (ou $> 5$) pose problème. C'est exactement le terme $\frac{1}{1-R_j^2}$ de la variance de $\widehat{\beta_j}$.

# H4 : Moyenne conditionnelle nulle

**Attention** : on ne peut pas tester $E(u|x) = 0$ avec les résidus. Par construction, les résidus OLS sont **toujours non corrélés** aux $x$.

# H4 : Moyenne conditionnelle nulle

**Attention** : on ne peut pas tester $E(u|x) = 0$ avec les résidus. Par construction, les résidus OLS sont **toujours non corrélés** aux $x$.

Simulons un modèle avec une variable omise ( $x_2$ corrélée à $x_1$ ), où $y = 1 + 2x_1 + 3x_2 + u$ :

```
set.seed(42)
n  <- 500
x1 <- rnorm(n)
x2 <- 0.7 * x1 + rnorm(n)
y  <- 1 + 2 * x1 + 3 * x2 + rnorm(n)

court <- lm(y ~ x1)         # x2 omise
long  <- lm(y ~ x1 + x2)
```



# H4 : Moyenne conditionnelle nulle

**Attention** : on ne peut pas tester $E(u|x) = 0$ avec les résidus. Par construction, les résidus OLS sont **toujours non corrélés** aux $x$.

Simulons un modèle avec une variable omise ( $x_2$ corrélée à $x_1$ ), où $y = 1 + 2x_1 + 3x_2 + u$ :

```
set.seed(42)
n  <- 500
x1 <- rnorm(n)
x2 <- 0.7 * x1 + rnorm(n)
y  <- 1 + 2 * x1 + 3 * x2 + rnorm(n)

court <- lm(y ~ x1)         # x2 omise
long  <- lm(y ~ x1 + x2)
```

- $\widehat{\beta_1}$ (modèle court) : **4.11**
- $\widehat{\beta_1}$ (modèle complet) : **2.04**
- Vraie valeur : **2**

- $|cor(\hat{u}, x_1)|$ dans le modèle court : **0**

Le biais existe, mais les résidus ne le montrent pas.

# H4 : que faire alors ?

- **Argumenter** économiquement : quelles variables importantes ai-je oubliées ? Dans quel sens biaisent-elles ?

# H4 : que faire alors ?

- **Argumenter** économiquement : quelles variables importantes ai-je oubliées ? Dans quel sens biaisent-elles ?
- **Test de stabilité** : les coefficients changent-ils fortement quand on ajoute des contrôles ? (cf. exemple précédent : 4.11 vs 2.04).

# H4 : que faire alors ?

- **Argumenter** économiquement : quelles variables importantes ai-je oubliées ? Dans quel sens biaisent-elles ?
- **Test de stabilité** : les coefficients changent-ils fortement quand on ajoute des contrôles ? (cf. exemple précédent : 4.11 vs 2.04).
- **Test RESET** : détecte certaines formes de mauvaise spécification.

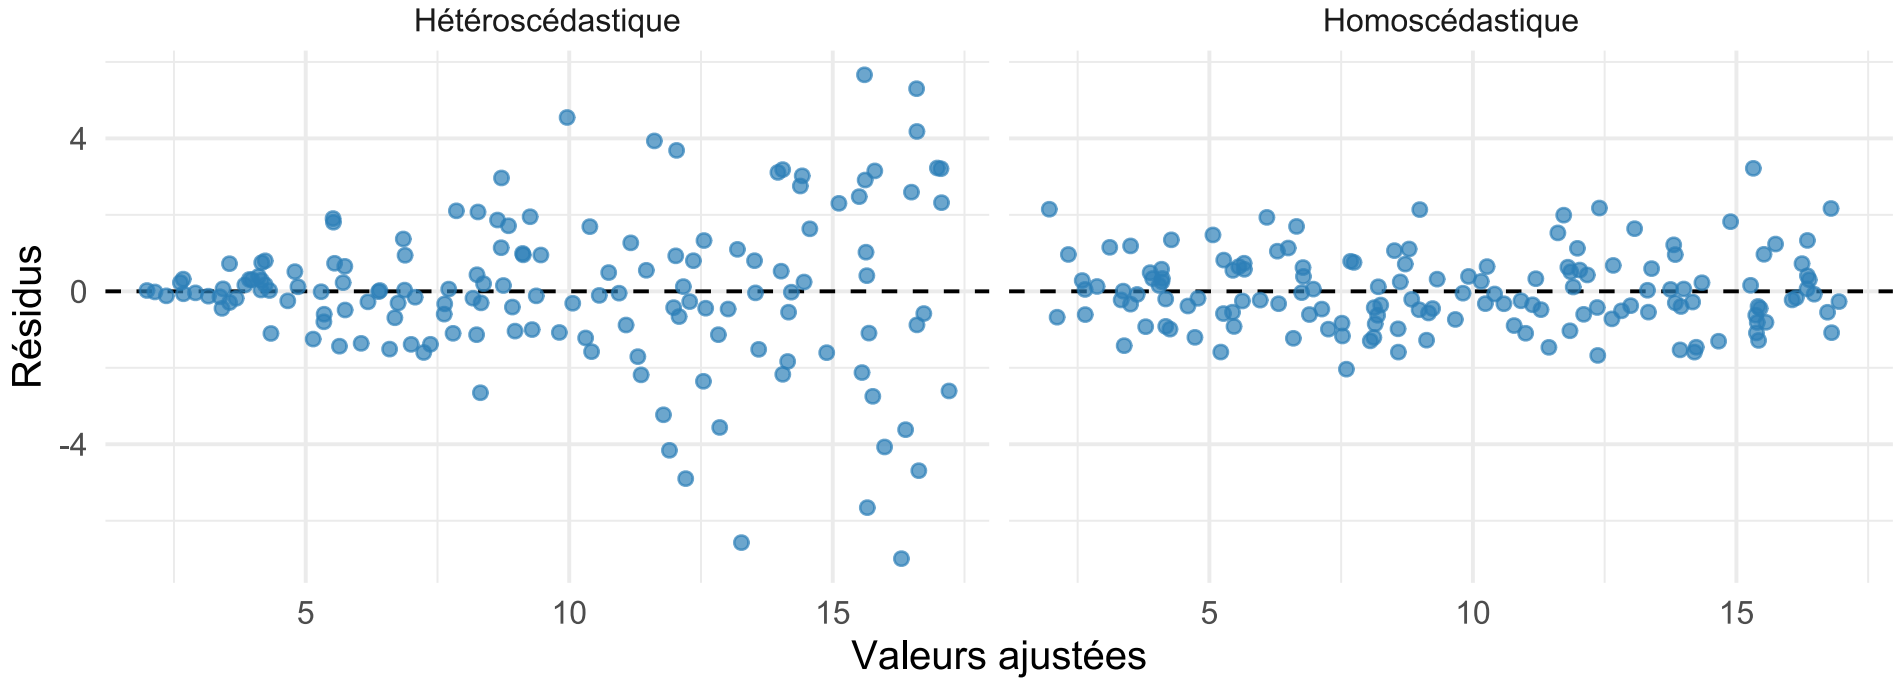


# H4 : que faire alors ?

- **Argumenter** économiquement : quelles variables importantes ai-je oubliées ? Dans quel sens biaisent-elles ?
- **Test de stabilité** : les coefficients changent-ils fortement quand on ajoute des contrôles ? (cf. exemple précédent : 4.11 vs 2.04).
- **Test RESET** : détecte certaines formes de mauvaise spécification.
- **Méthodes d'exogénéité** (variables instrumentales, test de Hausman) : nous les verrons plus tard dans le semestre.

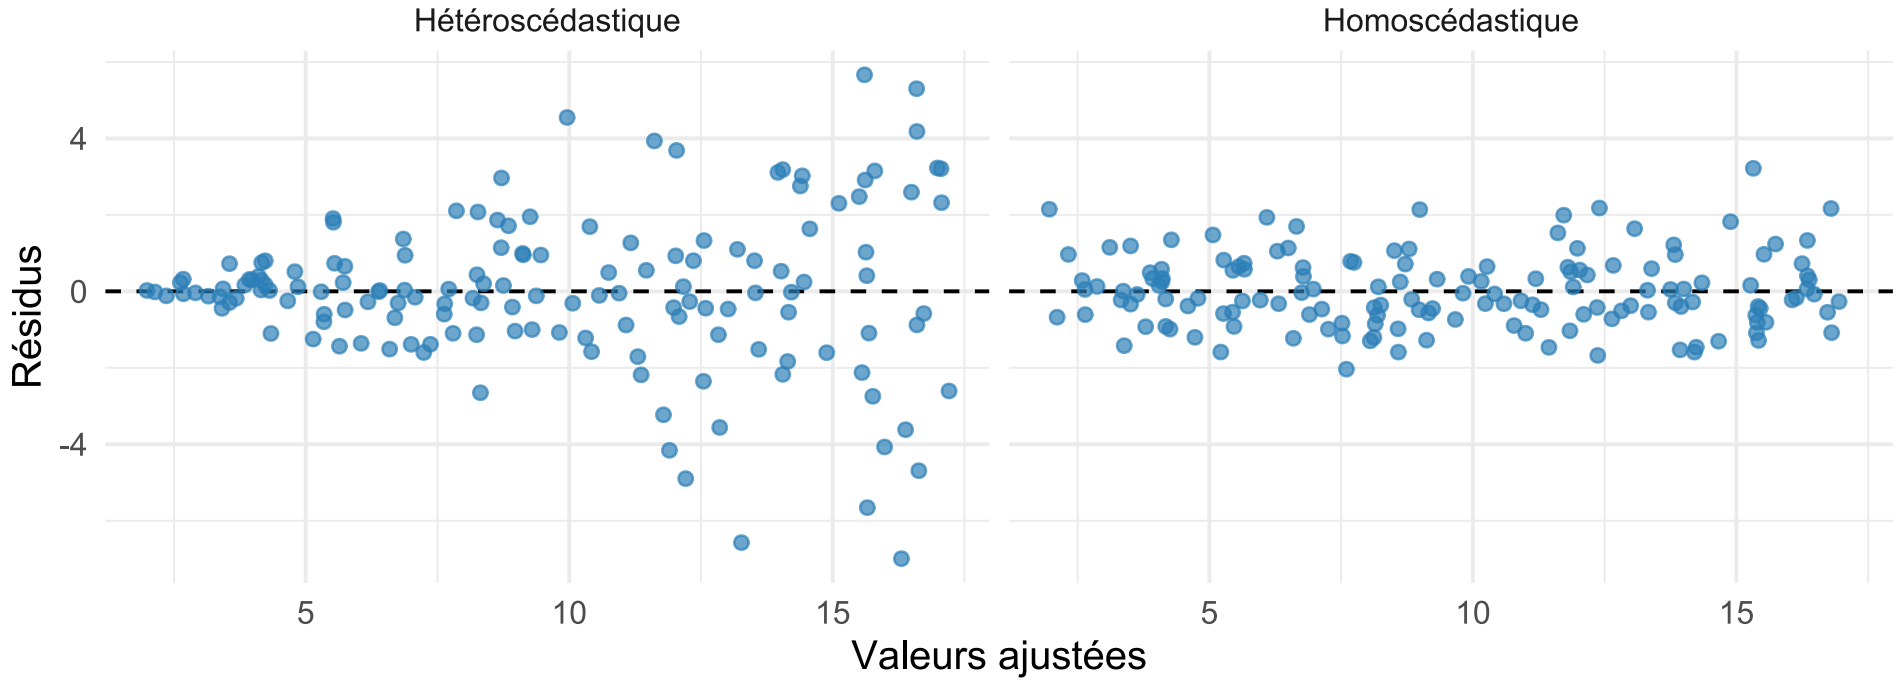
# H5 : Homoscédasticité

- **Diagnostic graphique** : un « entonnoir » dans le nuage des résidus vs valeurs ajustées signale de l'hétéroscédasticité.



# H5 : Homoscédasticité

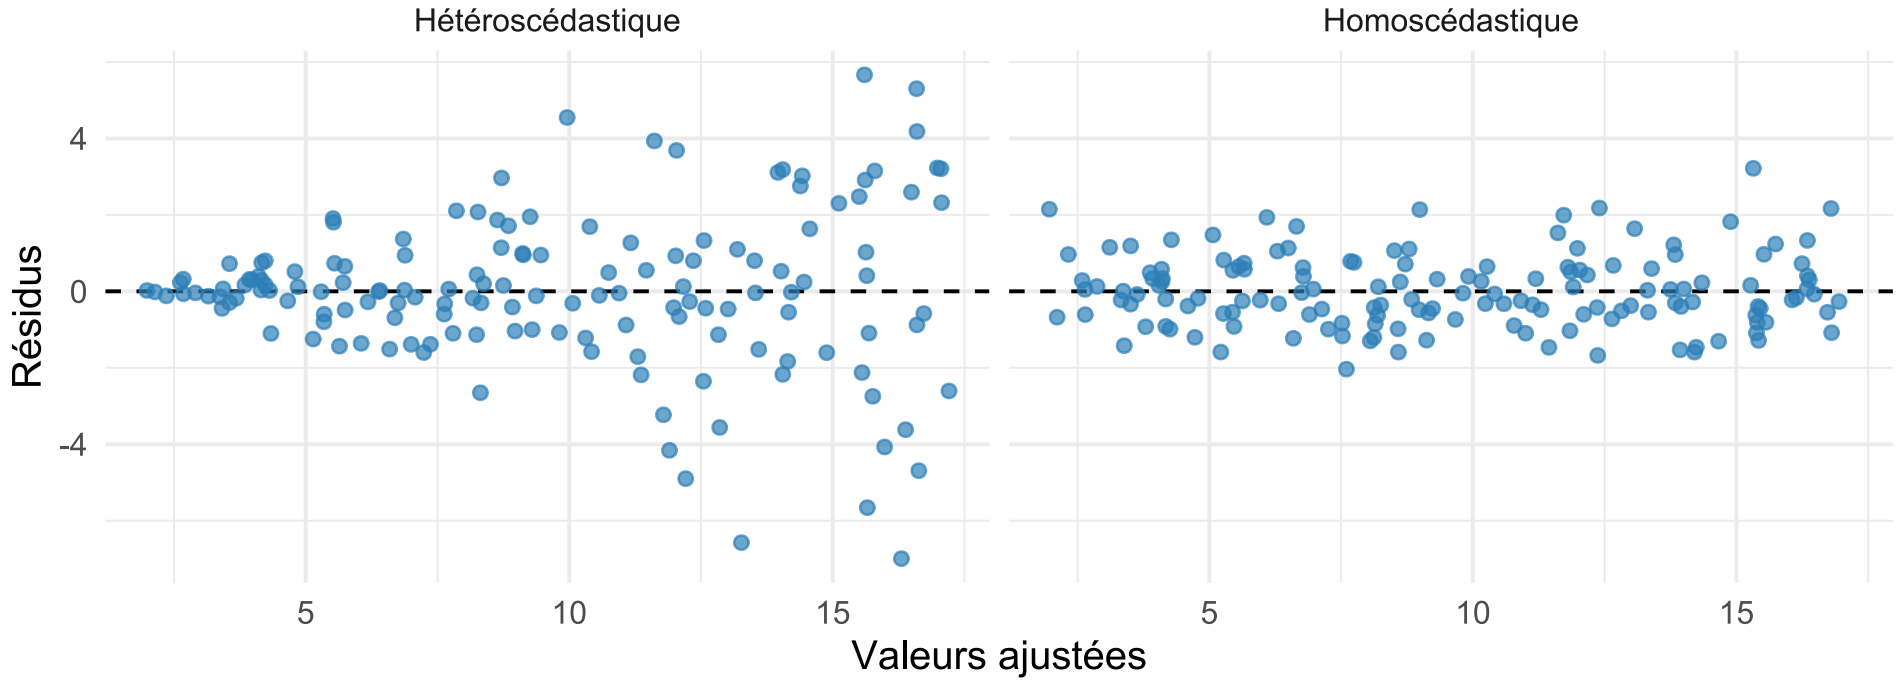
- **Diagnostic graphique** : un « entonnoir » dans le nuage des résidus vs valeurs ajustées signale de l'hétéroscédasticité.




- **Tests formels** : **Breusch-Pagan** (diapositives suivantes) et **White** (version plus générale, avec carrés et interactions).

# H5 : Homoscédasticité

- **Diagnostic graphique** : un « entonnoir » dans le nuage des résidus vs valeurs ajustées signale de l'hétéroscédasticité.




- **Tests formels** : **Breusch-Pagan** (diapositives suivantes) et **White** (version plus générale, avec carrés et interactions).

# Le test de Breusch-Pagan : l'idée

- Si H5 est vraie, la variance des erreurs **ne dépend pas** des $x$. Le carré des résidus $\hat{u}_i^2$ ne devrait donc **pas être expliqué** par les $x$.

# Le test de Breusch-Pagan : l'idée

- Si H5 est vraie, la variance des erreurs **ne dépend pas** des $x$. Le carré des résidus $\hat{u}_i^2$ ne devrait donc **pas être expliqué** par les $x$.
- **Principe** : on régresse $\hat{u}^2$ sur les variables explicatives et on regarde si elles ont un pouvoir explicatif.



# Le test de Breusch-Pagan : l'idée

- Si H5 est vraie, la variance des erreurs **ne dépend pas** des $x$. Le carré des résidus $\hat{u}_i^2$ ne devrait donc **pas être expliqué** par les $x$.
- **Principe** : on régresse $\hat{u}^2$ sur les variables explicatives et on regarde si elles ont un pouvoir explicatif.

**Test de Breusch-Pagan**

$`H_0 : Var(u|x_1, \ldots, x_k) = \sigma^2 \big(\text{homoscédasticité}\big) H_1 : Var(u|x_1, \ldots, x_k)$ $dépenddesx`$ (\text{hétéroscédasticité})

# Breusch-Pagan : la procédure

1. Estimer le modèle par OLS et récupérer les résidus $\hat{u}_i$.



# Breusch-Pagan : la procédure

1. Estimer le modèle par OLS et récupérer les résidus $\hat{u}_i$.
2. Régression auxiliaire :

$$\hat{u}_i^2 = \delta_0 + \delta_1 x_{i,1} + \ldots + \delta_k x_{i,k} + v_i$$

# Breusch-Pagan : la procédure

1. Estimer le modèle par OLS et récupérer les résidus $\hat{u}_i$.
2. Régression auxiliaire :

$$\hat{u}_i^2 = \delta_0 + \delta_1 x_{i,1} + \ldots + \delta_k x_{i,k} + v_i$$

3. Tester $H_0 : \delta_1 = \ldots = \delta_k = 0$ avec la statistique du **multiplicateur de Lagrange** :

$$LM = n \times R^2_{\hat{u}^2} \sim \chi^2_k \quad \text{sous } H_0$$

# Breusch-Pagan : la procédure

1. Estimer le modèle par OLS et récupérer les résidus $\hat{u}_i$.
2. Régression auxiliaire :

$$\hat{u}_i^2 = \delta_0 + \delta_1 x_{i,1} + \ldots + \delta_k x_{i,k} + v_i$$

3. Tester $H_0 : \delta_1 = \ldots = \delta_k = 0$ avec la statistique du **multiplicateur de Lagrange** :

$$LM = n \times R^2_{\hat{u}^2} \sim \chi^2_k \quad \text{sous } H_0$$

4. **Décision** : si la $p$-value $< 0{,}05$, on **rejette** $H_0$ et on conclut à l'hétéroscédasticité.

# Breusch-Pagan : la procédure

1. Estimer le modèle par OLS et récupérer les résidus $\hat{u}_i$.
2. Régression auxiliaire :

$$\hat{u}_i^2 = \delta_0 + \delta_1 x_{i,1} + \ldots + \delta_k x_{i,k} + v_i$$

3. Tester $H_0 : \delta_1 = \ldots = \delta_k = 0$ avec la statistique du **multiplicateur de Lagrange** :

$$LM = n \times R^2_{\hat{u}^2} \sim \chi^2_k \quad \text{sous } H_0$$

4. **Décision** : si la $p$-value $< 0{,}05$, on **rejette** $H_0$ et on conclut à l'hétéroscédasticité.

- Intuition : un $R^2$ élevé dans la régression auxiliaire signifie que les $x$ prédisent la taille des erreurs.

# Breusch-Pagan dans R

On reprend les modèles estimés sur les données simulées de la diapositive sur l'homoscédasticité :

```
mod_homo   <- lm(y ~ x, data = homo)     # erreurs de variance constante
mod_hetero <- lm(y ~ x, data = hetero)   # erreurs de variance croissante avec x
```



# Breusch-Pagan dans R

On reprend les modèles estimés sur les données simulées de la diapositive sur l'homoscédasticité :

```
mod_homo   <- lm(y ~ x, data = homo)     # erreurs de variance constante
mod_hetero <- lm(y ~ x, data = hetero)   # erreurs de variance croissante avec x
```

```
bptest(mod_homo)
```

```
##
##     studentized Breusch-Pagan test
##
## data:  mod_homo
## BP = 1.4233, df = 1, p-value = 0.2329
```

```
bptest(mod_hetero)
```

```
##
##     studentized Breusch-Pagan test
##
## data:  mod_hetero
## BP = 33.249, df = 1, p-value = 8.107e-09
```



# Breusch-Pagan : interprétation

| **Modèle** | **LM** | **$p$-value** | **Décision** |
|---|---|---|---|
| Homoscédastique | 1.42 | 0.23 | On ne rejette pas $H_0$ |
| Hétéroscédastique | 33.25 | 8.1e-09 | **On rejette $H_0$** |

# Breusch-Pagan : interprétation

| Modèle | LM | $p$-value | Décision |
|---|---|---|---|
| Homoscédastique | 1.42 | 0.23 | On ne rejette pas $H_0$ |
| Hétéroscédastique | 33.25 | 8.1e-09 | **On rejette $H_0$** |

Vérification « à la main » : $LM = n \times R^2$ de la régression auxiliaire

```
aux <- lm(resid(mod_hetero)^2 ~ x, data = hetero)
LM  <- nrow(hetero) * summary(aux)$r.squared
c(LM = LM, p_value = pchisq(LM, df = 1, lower.tail = FALSE))
```

```
##           LM      p_value
## 3.324918e+01 8.107396e-09
```



`bptest()` calcule par défaut la version « studentisée » (Koenker), identique à `(n \times R^2)` et plus robuste à la non-normalité.

# Que faire si on rejette H0 ?

- Les $\widehat{\beta_j}$ restent **sans biais** (H1 à H4 suffisent), mais les $se(\widehat{\beta_j})$ habituels sont **faux** : les tests $t$ et les intervalles de confiance sont donc invalides.

# Que faire si on rejette H0 ?

- Les $\widehat{\beta_j}$ restent **sans biais** (H1 à H4 suffisent), mais les $se(\widehat{\beta_j})$ habituels sont **faux** : les tests $t$ et les intervalles de confiance sont donc invalides.
- Solution : des **erreurs standards robustes à l'hétéroscédasticité** (White / HC).

```
coeftest(mod_hetero)                                          # erreurs standards classiques
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept) 1.977958   0.336512  5.8778  2.65e-08 ***
## x           1.531618   0.058046 26.3864 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(mod_hetero, vcov = vcovHC(mod_hetero, type = "HC1"))   # erreurs standards robustes
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept) 1.977958   0.227191  8.7062 5.699e-15 ***
## x           1.531618   0.066364 23.0792 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



# Que faire si on rejette H0 ?

- Les $\widehat{\beta_j}$ restent **sans biais** (H1 à H4 suffisent), mais les $se(\widehat{\beta_j})$ habituels sont **faux** : les tests $t$ et les intervalles de confiance sont donc invalides.
- Solution : des **erreurs standards robustes à l'hétéroscédasticité** (White / HC).

```
coeftest(mod_hetero)                                          # erreurs standards classiques
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept) 1.977958   0.336512  5.8778  2.65e-08 ***
## x           1.531618   0.058046 26.3864 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(mod_hetero, vcov = vcovHC(mod_hetero, type = "HC1"))   # erreurs standards robustes
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept) 1.977958   0.227191  8.7062 5.699e-15 ***
## x           1.531618   0.066364 23.0792 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



# Limites du test de Breusch-Pagan

- Il détecte uniquement une hétéroscédasticité **linéaire** dans les $x$ : un test non significatif ne prouve pas l'homoscédasticité.

# Limites du test de Breusch-Pagan

- Il détecte uniquement une hétéroscédasticité **linéaire** dans les $x$ : un test non significatif ne prouve pas l'homoscédasticité.
- Avec un **grand échantillon**, même une hétéroscédasticité négligeable peut être « significative ».



# Limites du test de Breusch-Pagan

- Il détecte uniquement une hétéroscédasticité **linéaire** dans les $x$ : un test non significatif ne prouve pas l'homoscédasticité.
- Avec un **grand échantillon**, même une hétéroscédasticité négligeable peut être « significative ».
- Il faut toujours **combiner** le test et le **graphique** des résidus.



# Limites du test de Breusch-Pagan

- Il détecte uniquement une hétéroscédasticité **linéaire** dans les $x$ : un test non significatif ne prouve pas l'homoscédasticité.
- Avec un **grand échantillon**, même une hétéroscédasticité négligeable peut être « significative ».
- Il faut toujours **combiner** le test et le **graphique** des résidus.
- En pratique, beaucoup d'économistes utilisent directement des erreurs standards robustes, sans passer par le test.



UNIVERSITÉ DE NAMUR

# BONNE JOURNÉE !

| | |
|---|---|
| | jeremy.donascimento@unamur.be |
| | Discord |
| | Slides |