UNIVERSITÉ DE NAMUR

Econométrie

Propriétés du modèle de régression linéaire

Jérémy Do Nascimento Miguel
Université de Namur
2026-09-16

Aujourd'hui - Propriétés du modèle de régression linéaire

Jusqu à présent nous avons vu comment utiliser les modèles linéaires et leurs interpération



Aujourd'hui - Propriétés du modèle de régression linéaire

Jusqu à présent nous avons vu comment utiliser les modèles linéaires et leurs interpération

Dans cette session, nous allons nous concentrer sur les propriétés de ces estimateurs :

1. Pourquoi les utilisons-nous : hypothèses de **Gauss-Markov**
2. Etude de la **variance** de ces estimateurs



Aujourd'hui - Propriétés du modèle de régression linéaire

Jusqu à présent nous avons vu comment utiliser les modèles linéaires et leurs interpération

Dans cette session, nous allons nous concentrer sur les propriétés de ces estimateurs :

1. Pourquoi les utilisons-nous : hypothèses de **Gauss-Markov**
2. Etude de la **variance** de ces estimateurs

Nous allons voir en détails pourquoi ces estimateurs sont ceux que l on préfère utiliser : **sans biais**



Valeurs Espérées des Estimateurs OLS

H1: Linéarité en paramètres

La première hypothèse repose sur la linéarité en paramètres du modèle :



H1: Linéarité en paramètres

La première hypothèse repose sur la linéarité en paramètres du modèle :

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k + u$$

- La linéarité en paramètres signifie juste que la relation estimée par les paramètres du modèle (β_k) est **linéaire**.
- Les variables indépendantes (x) peuvent être linéaires ou non



H2: Echantillon aléatoire

La seconde hypothèse statut sur l'origine des données. Les données utilisées pour estimer notre modèle sont **tirées** aléatoirement d'une population :

H2: Echantillon aléatoire

La seconde hypothèse statut sur l'origine des données. Les données utilisées pour estimer notre modèle sont **tirées** aléatoirement d'une population :

$$\text{n obs} : \{(x_{i,1}, \dots, x_{i,k}; y_i)\} : i = \{1, \dots, n\}$$

- Si c'est le cas, nous pouvons alors estimer le modèle associé à H1 et le réécrire pour un individu donné.

$$y_i = \beta_0 + \beta_1 x_{i,1} + \dots + \beta_k x_{i,k} + u_i$$

H3: L'absence de collinéarité parfaite

- Dans un échantillon donné, aucune variable dépendante (x) ne doit être constante et aucune ne doit être la **combinaison linéaire** exacte de variables dépendantes.



H3: L'absence de collinéarité parfaite

- Dans un échantillon donné, aucune variable dépendante (x) ne doit être constante et aucune ne doit être la **combinaison linéaire** exacte de variables dépendantes.
- La solution ? **Supprimer** une des variables qui donne une **information redondante**. Par exemple, nous n'avons pas besoin d'ajouter les variables `homme` et `femme` dans un modèle.



H3: L'absence de collinéarité parfaite

- Dans un échantillon donné, aucune variable dépendante (x) ne doit être constante et aucune ne doit être la **combinaison linéaire** exacte de variables dépendantes.
- La solution ? **Supprimer** une des variables qui donne une **information redondante**. Par exemple, nous n'avons pas besoin d'ajouter les variables `homme` et `femme` dans un modèle.
- Cette hypothèse peut également ne pas tenir lorsque le **nombre d'observations est trop petit** par rapport au nombre de paramètres à estimer ($\widehat{\beta_k}$). On a besoin d'au moins $k+1$ observations pour pouvoir estimer un modèle avec $k+1$ paramètres.

H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple il y a une relation non linéaire entre une de nos variables dépendantes et notre variable indépendante.

H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple il y a une relation non linéaire entre une de nos variables dépendantes et notre variable indépendante.
- Omission d'une variable importante, $COV(u, x) \neq 0$



H4: Moyenne conditionnelle nulle

- La moyenne conditionnelle des erreurs doit être nulle :

$$E(u|x_1, x_2, \ldots, x_k) = 0$$

Cas où cette hypothèse n'est pas vérifiée :

- La forme fonctionnelle du modèle est mal spécifiée : par exemple il y a une relation non linéaire entre une de nos variables dépendantes et notre variable indépendante.
- Omission d'une variable importante, $COV(u, x) \neq 0$

Si H4 est vérifiée, on dit alors que l'ensemble de nos variables sont exogènes, sinon qu'il y a un problème d'endogénéité. Nous verrons comment résoudre ce problème plus tard dans le semestre.



Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Echantillonnage aléatoire

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Echantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Echantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite
- **H4** : Moyenne conditionnelle nulle ($E(u|x_1, \ldots, x_k) = 0$)

Théorème : Absence de biais des estimateurs OLS

Théorème — Absence de biais

Sous les hypothèses H1 à H4 :

$$E(\widehat{\beta_j}) = \beta_j \quad \text{pour } j = 0, 1, \ldots, k$$

Ce résultat repose entièrement sur la validité conjointe des quatre premières hypothèses de Gauss-Markov :

- **H1** : Linéarité en paramètres
- **H2** : Echantillonnage aléatoire
- **H3** : Absence de colinéarité parfaite
- **H4** : Moyenne conditionnelle nulle ($E(u|x_1, \ldots, x_k) = 0$)

Si une seule de ces hypothèses n'est pas vérifiée, l'estimateur OLS peut devenir biaisé.

H5: Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.



H5: Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables indépendantes, doit être **constante** :

H5: Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables indépendantes, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

H5: Homoscédasticité

Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

La variance de l'erreur, conditionnellement aux variables indépendantes, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

- Autrement dit, la dispersion des erreurs ne doit **pas dépendre** des valeurs prises par les x.



H5: Homoscédasticité

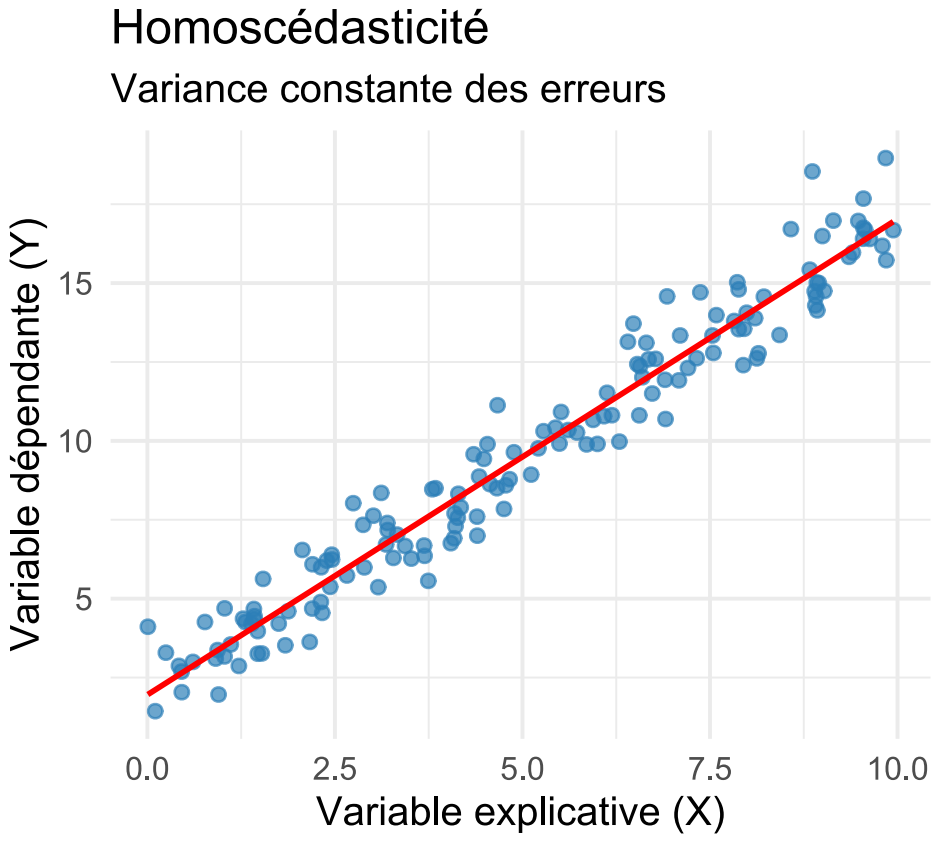
Pour étudier la **variance** de nos estimateurs, nous avons besoin d'une cinquième hypothèse.

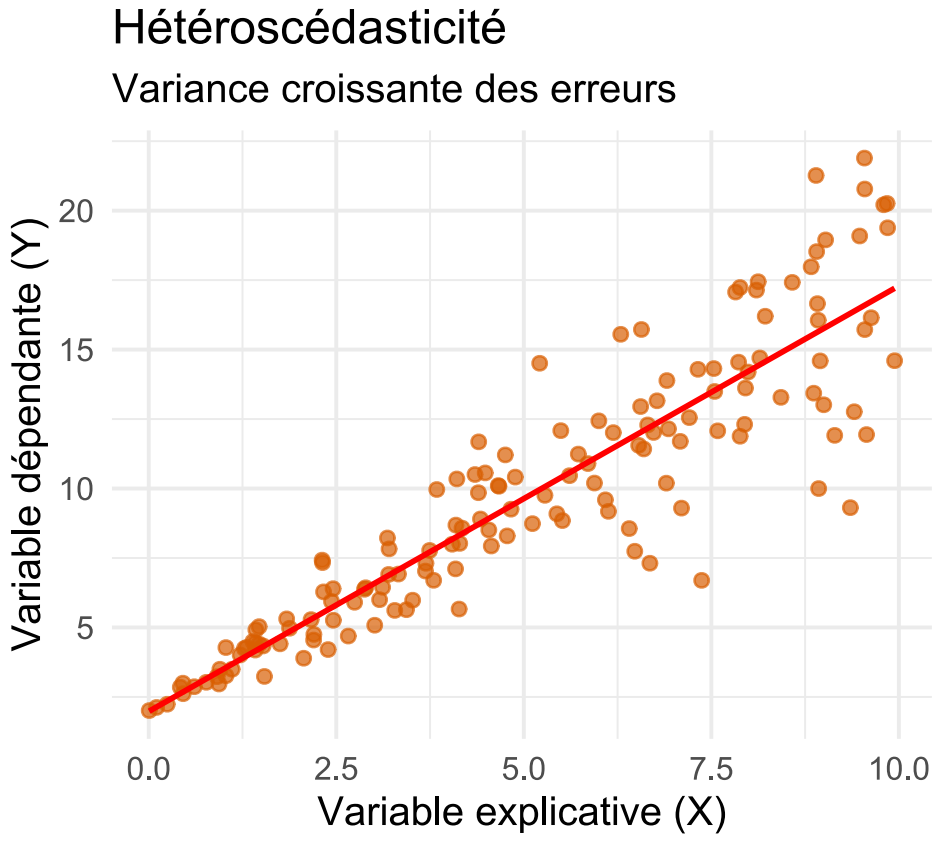
La variance de l'erreur, conditionnellement aux variables indépendantes, doit être **constante** :

$$Var(u|x_1, x_2, \ldots, x_k) = \sigma^2$$

- Autrement dit, la dispersion des erreurs ne doit **pas dépendre** des valeurs prises par les x.
- Si cette hypothèse n'est **pas vérifiée**, on parle d'**hétéroscédasticité** : la variance de l'erreur varie selon les observations.

Homoscédasticité visuellement





La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS peut s'écrire :

La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS peut s'écrire :

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

La variance de $\widehat{\beta_j}$

Sous les hypothèses H1 à H5, la variance de notre estimateur OLS peut s'écrire :

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Décomposons chaque terme de cette formule :

Terme 1 : σ^2 — La variance de l'erreur

$$\sigma^2 = Var(u)$$

Terme 1 : σ^2 — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.

Terme 1 : σ^2 — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.
- **Plus il y a de "bruit"** dans les données (facteurs non observés, mesures imprécises...), **plus σ^2 est grand**.

Terme 1 : σ^2 — La variance de l'erreur

$$\sigma^2 = Var(u)$$

- C'est la **variance du terme d'erreur** : elle mesure à quel point nos données s'écartent en moyenne du modèle.
- **Plus il y a de "bruit"** dans les données (facteurs non observés, mesures imprécises...), **plus σ^2 est grand**.
- Un σ^2 élevé $\Rightarrow$ une variance de $\widehat{\beta_j}$ plus grande $\Rightarrow$ une estimation **moins précise**.

Terme 2 : SST_j — La variation totale de x_j

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

Terme 2 : SST_j — La variation totale de x_j

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable x_j dans notre échantillon.

Terme 2 : SST_j — La variation totale de x_j

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable x_j dans notre échantillon.
- Concrètement : est-ce que x_j prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?

Terme 2 : SST_j — La variation totale de x_j

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable x_j dans notre échantillon.
- Concrètement : est-ce que x_j prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?
- Un SST_j élevé $\Rightarrow$ plus d'information disponible sur x_j $\Rightarrow$ une estimation **plus précise** (la variance diminue).

Terme 2 : SST_j — La variation totale de x_j

$$SST_j = \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2$$

- C'est la **dispersion totale** des valeurs de la variable x_j dans notre échantillon.
- Concrètement : est-ce que x_j prend des valeurs très **variées** dans nos données, ou est-ce que toutes les observations se ressemblent ?
- Un SST_j élevé $\Rightarrow$ plus d'information disponible sur x_j $\Rightarrow$ une estimation **plus précise** (la variance diminue).
- **Intuition** : il est plus facile d'estimer l'effet d'une variable qui varie beaucoup que celui d'une variable presque constante.

Terme 3 : R_j^2 — La colinéarité avec les autres x

$R_j^2 = R^2$ de la régression de x_j sur toutes les autres variables x_k

Terme 3 : R_j^2 — La colinéarité avec les autres x

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables } x_k$$

- Il mesure à quel point x_j peut être **expliquée** (prédite) par les autres variables indépendantes du modèle.

Terme 3 : R_j^2 — La colinéarité avec les autres x

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables } x_k$$

- Il mesure à quel point x_j peut être **expliquée** (prédite) par les autres variables indépendantes du modèle.
- R_j^2 proche de **0** $\Rightarrow$ x_j apporte une information **indépendante** des autres variables.

Terme 3 : R_j^2 — La colinéarité avec les autres x

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables } x_k$$

- Il mesure à quel point x_j peut être **expliquée** (prédite) par les autres variables indépendantes du modèle.
- R_j^2 proche de **0** $\Rightarrow$ x_j apporte une information **indépendante** des autres variables.
- R_j^2 proche de **1** $\Rightarrow$ x_j est presque une **combinaison linéaire** des autres x (colinéarité forte, cf. H3).



Terme 3 : R_j^2 — La colinéarité avec les autres x

$$R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur toutes les autres variables } x_k$$

- Il mesure à quel point x_j peut être **expliquée** (prédite) par les autres variables indépendantes du modèle.
- R_j^2 proche de **0** $\Rightarrow$ x_j apporte une information **indépendante** des autres variables.
- R_j^2 proche de **1** $\Rightarrow$ x_j est presque une **combinaison linéaire** des autres x (colinéarité forte, cf. H3).
- Un R_j^2 élevé $\Rightarrow$ $(1 - R_j^2)$ devient petit $\Rightarrow$ la variance de $\widehat{\beta_j}$ **augmente fortement**.

En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

Variance de $\widehat{\beta_j}$

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

Variance de $\widehat{\beta_j}$

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

Variance de $\widehat{\beta_j}$

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- σ^2 est **petit** : peu de bruit dans le modèle

En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

Variance de $\widehat{\beta_j}$

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- σ^2 est **petit** : peu de bruit dans le modèle
- SST_j est **grand** : x_j varie beaucoup dans l'échantillon

En résumé : ce qui rend $\widehat{\beta_j}$ plus précis

Variance de $\widehat{\beta_j}$

$$Var(\widehat{\beta_j}) = \frac{\sigma^2}{SST_j \times (1 - R_j^2)}$$

Notre estimation est **plus précise** (variance plus faible) lorsque :

- σ^2 est **petit** : peu de bruit dans le modèle
- SST_j est **grand** : x_j varie beaucoup dans l'échantillon
- R_j^2 est **petit** : x_j n'est pas colinéaire avec les autres variables

Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.



Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- SCR (ou SSR) est la **somme des carrés des résidus**.

Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- SCR (ou SSR) est la **somme des carrés des résidus**.
- $n-k-1$ est le nombre de **degrés de liberté** : n observations moins $(k+1)$ paramètres estimés ($\beta_0, \beta_1, \ldots, \beta_k$).

Un problème : σ^2 est inconnu

Dans la pratique, la variance de l'erreur σ^2 n'est **jamais observée** : elle dépend des erreurs u_i, qui ne sont pas observables.

- Nous devons donc **l'estimer** à partir des résidus $\hat{u}_i = y_i - \hat{y}_i$ de notre régression.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k-1} = \frac{SCR}{n-k-1}$$

- SCR (ou SSR) est la **somme des carrés des résidus**.
- $n-k-1$ est le nombre de **degrés de liberté** : n observations moins $(k+1)$ paramètres estimés ($\beta_0, \beta_1, \ldots, \beta_k$).
- $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ est appelé l'**erreur standard de la régression** (*Standard Error of the Regression*, SER).



Écart-type vs erreur standard de $\widehat{\beta_j}$

Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$: l'**écart-type théorique** de l'estimateur qui dépend de σ, qui est **inconnu** en pratique.

Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$: l'**écart-type théorique** de l'estimateur qui dépend de σ, qui est **inconnu** en pratique.
- $se(\widehat{\beta_j})$: l'**erreur standard estimée** où on remplace σ par son estimation $\hat{\sigma}$, calculable à partir des données.

Écart-type vs erreur standard de $\widehat{\beta_j}$

$$sd(\widehat{\beta_j}) = \frac{\sigma}{\sqrt{SST_j(1-R_j^2)}} \quad \Longrightarrow \quad se(\widehat{\beta_j}) = \frac{\hat{\sigma}}{\sqrt{SST_j(1-R_j^2)}}$$

- $sd(\widehat{\beta_j})$: l'**écart-type théorique** de l'estimateur qui dépend de σ, qui est **inconnu** en pratique.
- $se(\widehat{\beta_j})$: l'**erreur standard estimée** où on remplace σ par son estimation $\hat{\sigma}$, calculable à partir des données.

Pourquoi c'est important ?

- Le $se(\widehat{\beta_j})$ mesure la **précision** de notre estimation : plus il est petit, plus $\widehat{\beta_j}$ est fiable.
- Il est indispensable pour construire des **tests d'hypothèses** et des **intervalles de confiance** sur β_j.

Pourquoi utiliser les OLS ? Le théorème de Gauss-Markov

Sous les hypothèses **H1 à H5**, le théorème de **Gauss-Markov** nous garantit que les estimateurs OLS sont les meilleurs estimateurs linéaires sans biais : on dit qu'ils sont **BLUE**.



Pourquoi utiliser les OLS ? Le théorème de Gauss-Markov

Sous les hypothèses **H1 à H5**, le théorème de **Gauss-Markov** nous garantit que les estimateurs OLS sont les meilleurs estimateurs linéaires sans biais : on dit qu'ils sont **BLUE**.

BLUE — Best Linear Unbiased Estimator

$$\widehat{\beta_j}^{OLS} \text{ est BLUE} \iff Var(\widehat{\beta_j}^{OLS}) \leq Var(\widetilde{\beta_j}) \quad \forall\, \widetilde{\beta_j} \text{ linéaire et sans biais}$$

Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.



Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations y_i.



Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations y_i.
- **U**nbiased (Sans biais) : en moyenne, sur un grand nombre d'échantillons, l'estimateur donne la **vraie valeur** du paramètre : $E(\widehat{\beta_j}) = \beta_j$ (H1 à H4).

Décomposons l'acronyme BLUE

- **B**est (Meilleur) : parmi tous les estimateurs linéaires sans biais, l'estimateur OLS est celui qui a la **plus petite variance**.
- **L**inear (Linéaire) : l'estimateur $\widehat{\beta_j}$ peut s'écrire comme une **combinaison linéaire** des observations y_i.
- **U**nbiased (Sans biais) : en moyenne, sur un grand nombre d'échantillons, l'estimateur donne la **vraie valeur** du paramètre : $E(\widehat{\beta_j}) = \beta_j$ (H1 à H4).
- **E**stimator (Estimateur) : c'est une **règle de calcul** (une formule) permettant d'obtenir une valeur estimée $\widehat{\beta_j}$ à partir d'un échantillon de données.

Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour β_j. Alors pourquoi utiliser spécifiquement les OLS ?



Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour β_j. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.



Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour β_j. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.



Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour β_j. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.
- OLS **n'est pas nécessairement le meilleur estimateur dans l'absolu** : si on autorise le biais, ou des estimateurs non linéaires, il peut exister de meilleures alternatives.



Pourquoi choisir OLS plutôt qu'un autre estimateur ?

Il existe une infinité d'estimateurs linéaires et sans biais possibles pour β_j. Alors pourquoi utiliser spécifiquement les OLS ?

- Parce que le théorème de Gauss-Markov montre qu'**aucun autre estimateur linéaire sans biais** ne peut faire **mieux en termes de variance**.
- Une variance plus petite signifie des estimations **plus précises et plus stables** d'un échantillon à l'autre.
- OLS **n'est pas nécessairement le meilleur estimateur dans l'absolu** : si on autorise le biais, ou des estimateurs non linéaires, il peut exister de meilleures alternatives.



OLS est donc **optimal dans sa classe**, celle des estimateurs linéaires et sans biais, pas dans l'absolu.

UNIVERSITÉ DE NAMUR

BONNE JOURNÉE !

	jeremy.donascimento@unamur.be
	Discord
	Slides