UNIVERSITÉ DE NAMUR

Econométrie

Regression Linéaire Multivarié

Jérémy Do Nascimento Miguel
Université de Namur
2026-09-28

Ce cours - Modèle linéaire multivarié

- Situation où nous avons de nombreuses variables indépendantes
- Comment interpréter les variables continues et binaires
- La trappe des variables binaires
- Le biais de variable omise
- R_2 ajusté
- Application empirique:
  - *Santé des élèves* et *Abstentéisme*

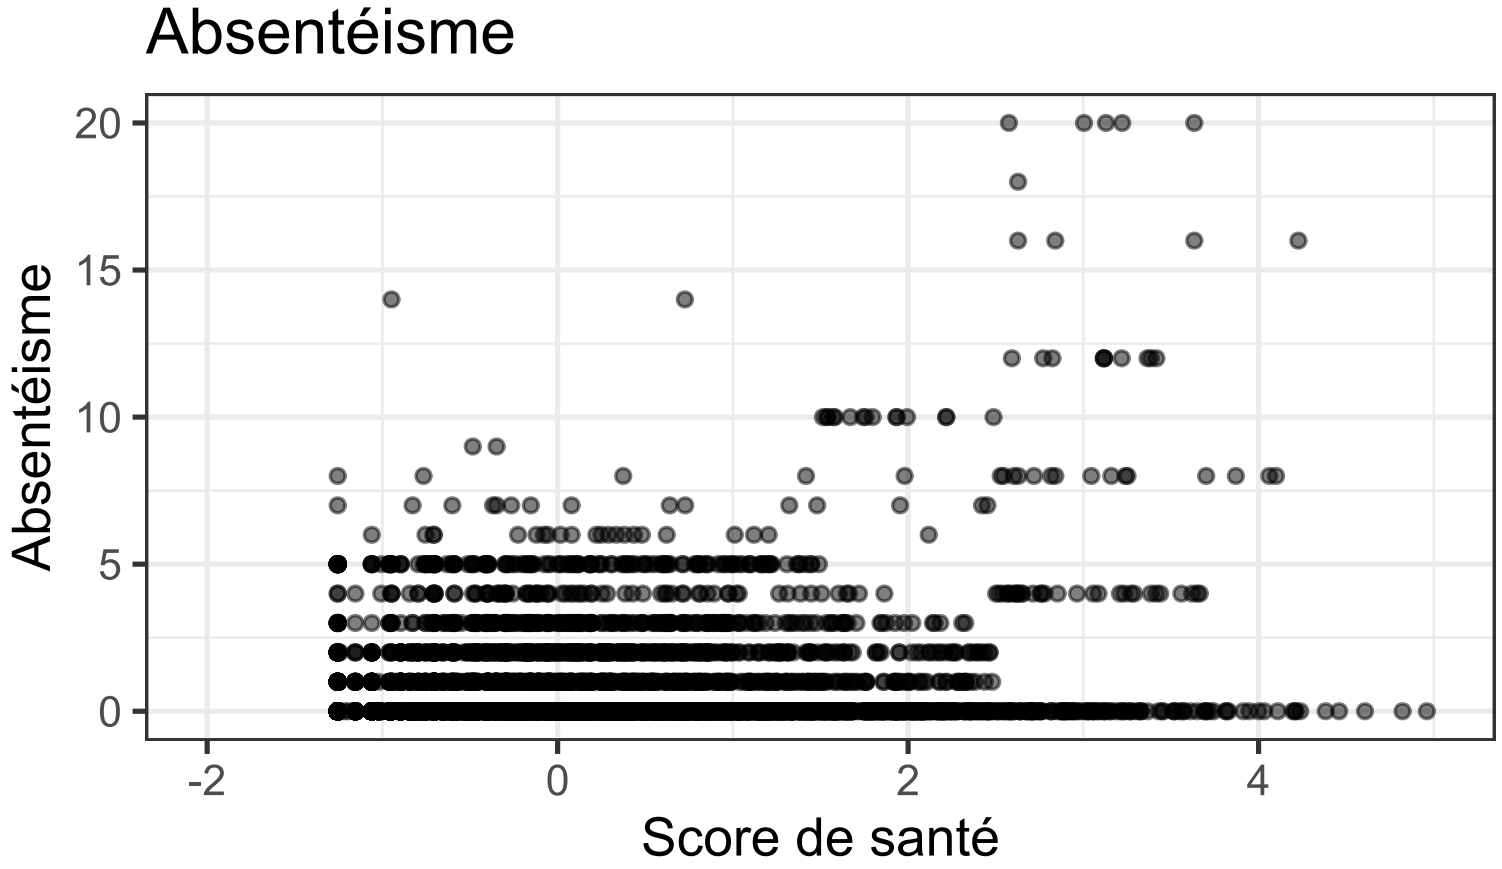
Santé des élèves et Abstentéisme

- Revenons à l'analyse de Kremer et Miguel (2003) de l'effet de la santé des étudiant.e.s sur l'absentéisme à l'école au Kenya.

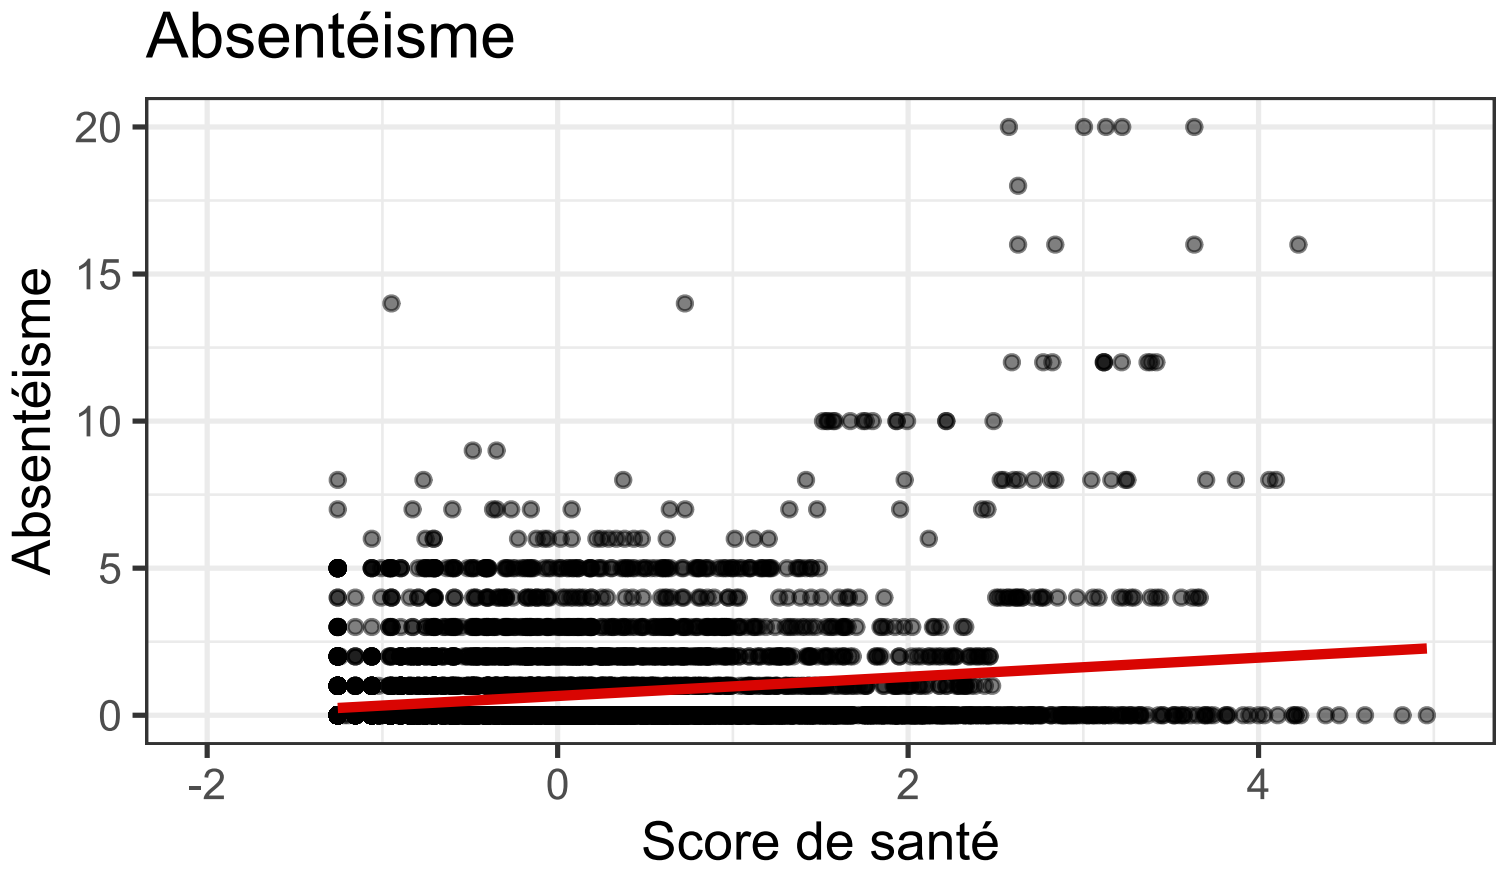
Santé des élèves et Abstentéisme

- Revenons à l'analyse de Kremer et Miguel (2003) de l'effet de la santé des étudiant.e.s sur l'absentéisme à l'école au Kenya.
- Avec un modèle de **régression linéaire univarié**, nous trouvions que la santé des élèves étaient négativement ***corrélé*** avec l'absentéisme des étudiants.

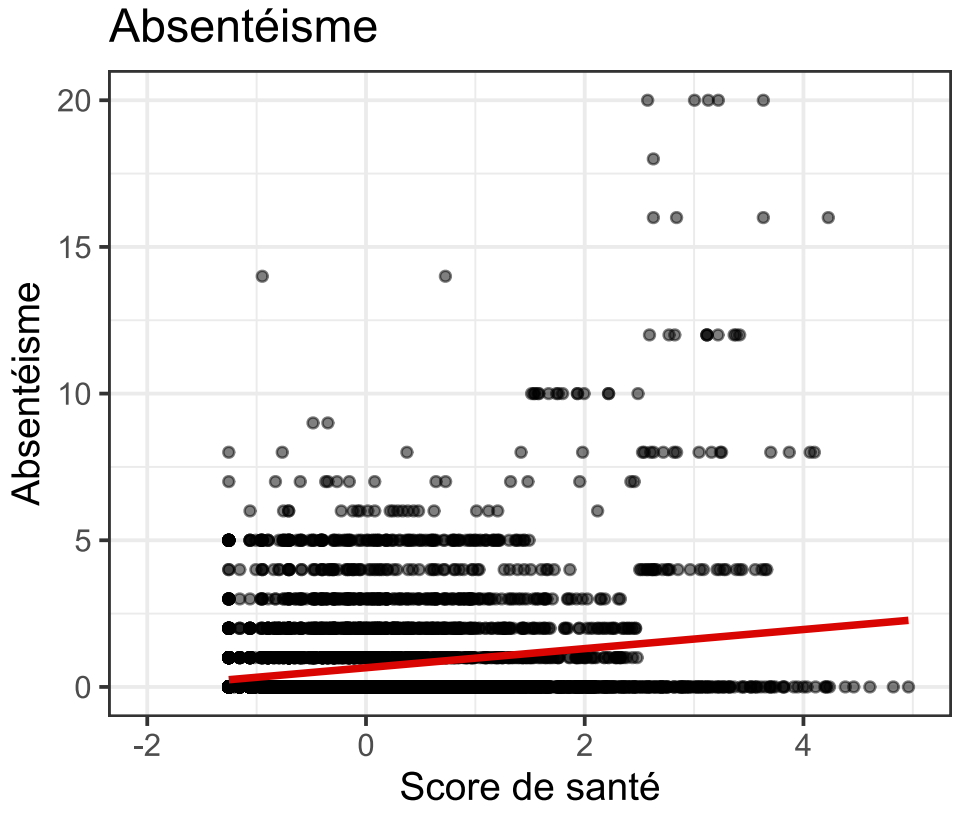
Santé et abstentéisme des étudiant.e.s : Relation brute



Santé et abstentéisme des étudiant.e.s : Relation brute



Santé et abstentéisme des étudiant.e.s : Relation brute




```
lm(absdays_98 ~ score, data)
```

```
##
## Call:
## lm(formula = absdays_98 ~ score, data = data)
##
## Coefficients:
## (Intercept)        score
##      0.6558       0.3306
```

Santé et abstentéisme des étudiant.e.s

- Revenons à l'analyse de Kremer et Miguel (2003) de l'effet de la santé des étudiant.e.s sur l'absentéisme à l'école au Kenya.
- Avec un modèle de **régression linéaire univarié**, nous trouvions que la santé des élèves étaient négativement ***corrélé*** avec l'absentéisme des étudiants.

Santé et abstentéisme des étudiant.e.s

- Revenons à l'analyse de Kremer et Miguel (2003) de l'effet de la santé des étudiant.e.s sur l'absentéisme à l'école au Kenya.
- Avec un modèle de **régression linéaire univarié**, nous trouvions que la santé des élèves étaient négativement ***corrélé*** avec l'absentéisme des étudiants.
- Est-ce qu'il peut y avoir d'autres variables **corrélées** avec la santé des étudiant.e.s ***mais aussi*** avec l'absentéisme ?
- En particulier, l'absence de toilettes à l'école peut être un facteur favorisant l'absentéisme.



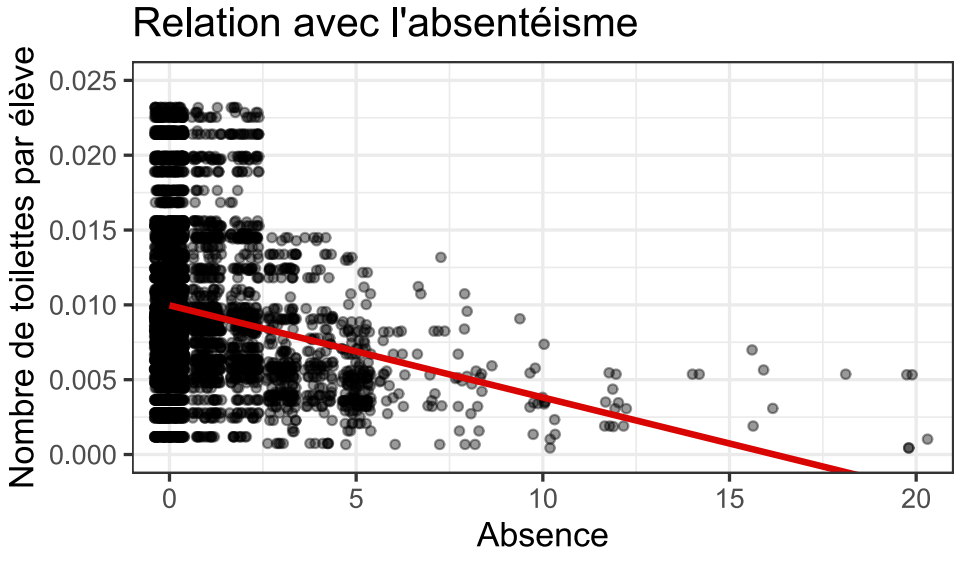
Santé et abstentéisme des étudiant.e.s

- Revenons à l'analyse de Kremer et Miguel (2003) de l'effet de la santé des étudiant.e.s sur l'absentéisme à l'école au Kenya.
- Avec un modèle de **régression linéaire univarié**, nous trouvions que la santé des élèves étaient négativement ***corrélé*** avec l'absentéisme des étudiants.
- Est-ce qu'il peut y avoir d'autres variables **corrélées** avec la santé des étudiant.e.s ***mais aussi*** avec l'absentéisme ?
- En particulier, l'absence de toilettes à l'école peut être un facteur favorisant l'absentéisme.
- Regardons cela



Santé et abstentéisme des étudiant.e.s : cofounders

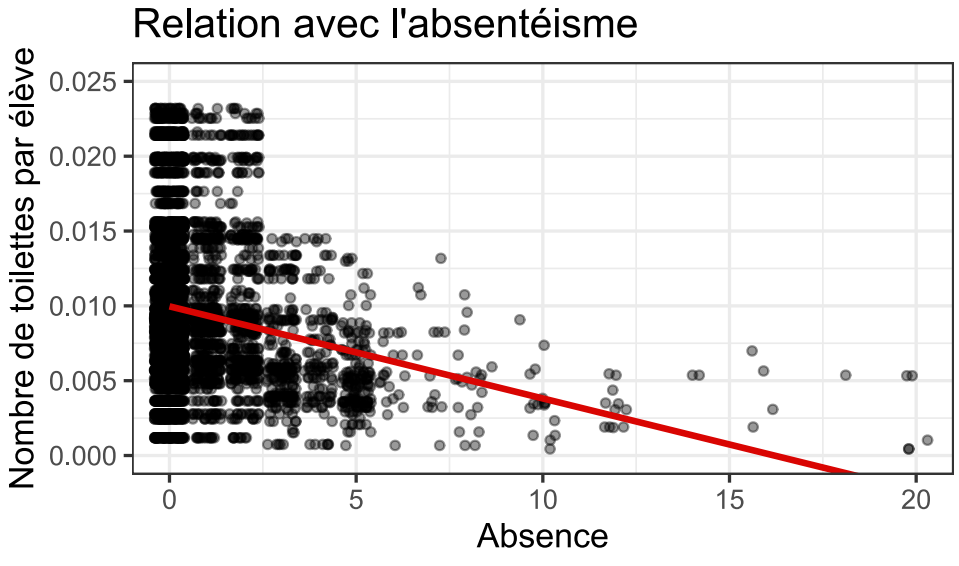
Lien entre **l'absentéisme** et **le nombre de toilettes par élève** dans l'école.



👉 En moyenne, il y a plus d'absentéisme dans les écoles avec moins de toilettes.

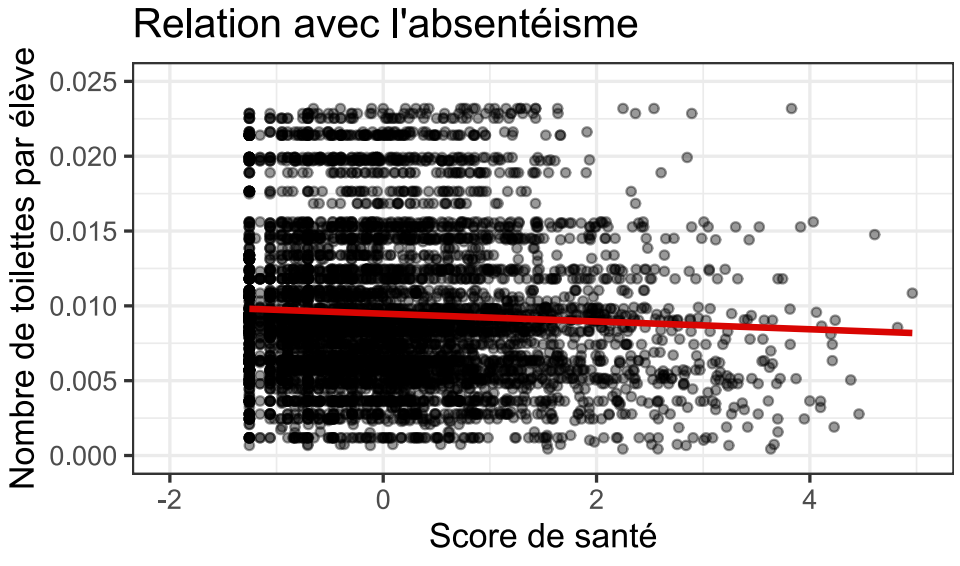
Santé et abstentéisme des étudiant.e.s : cofounders

Lien entre **l'absentéisme** et **le nombre de toilettes par élève** dans l'école.



👉 En moyenne, il y a plus d'absentéisme dans les écoles avec moins de toilettes.

Relation entre la **santé des élèves** et **le nombre de toilettes** à l'école.



👉 En moyenne, plus il y a de toilettes par élève, meilleure est la santé des élèves.

Santé et abstentéisme des étudiant.e.s : régression multivarié

- Supposons que l'on veuille connaître l'effet de la santé sur l'absentéisme, **en contrôlant pour** le fait qu'il existe une relation entre le nombre de toilettes disponibles et à la fois l'absentéisme et l'état de santé des élèves.

Santé et abstentéisme des étudiant.e.s : régression multivarié

- Supposons que l'on veuille connaître l'effet de la santé sur l'absentéisme, **en contrôlant pour** le fait qu'il existe une relation entre le nombre de toilettes disponibles et à la fois l'absentéisme et l'état de santé des élèves.

- Pour ce faire, il faut inclure à la fois les variables `score` et `latr_pup` comme *régresseurs* dans la régression.



Santé et abstentéisme des étudiant.e.s : régression multivarié

- Supposons que l'on veuille connaître l'effet de la santé sur l'absentéisme, **en contrôlant pour** le fait qu'il existe une relation entre le nombre de toilettes disponibles et à la fois l'absentéisme et l'état de santé des élèves.
- Pour ce faire, il faut inclure à la fois les variables `score` et `latr_pup` comme *régresseurs* dans la régression.
- Ainsi, on peut obtenir une estimation de l'effet de la santé des élèves sur l'absentéisme, **purgée de l'effet de la variable liée à l'accès aux toilettes**.



Santé et abstentéisme des étudiant.e.s : régression multivarié

- Supposons que l'on veuille connaître l'effet de la santé sur l'absentéisme, **en contrôlant pour** le fait qu'il existe une relation entre le nombre de toilettes disponibles et à la fois l'absentéisme et l'état de santé des élèves.
- Pour ce faire, il faut inclure à la fois les variables `score` et `latr_pup` comme *régresseurs* dans la régression.
- Ainsi, on peut obtenir une estimation de l'effet de la santé des élèves sur l'absentéisme, **purgée de l'effet de la variable liée à l'accès aux toilettes**.
- Le modèle que l'on souhaite estimer devient:

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{Nbr de toilettes}_i + u_i$$

Santé et abstentéisme des étudiant.e.s : régression multivarié

- Supposons que l'on veuille connaître l'effet de la santé sur l'absentéisme, **en contrôlant pour** le fait qu'il existe une relation entre le nombre de toilettes disponibles et à la fois l'absentéisme et l'état de santé des élèves.
- Pour ce faire, il faut inclure à la fois les variables `score` et `latr_pup` comme *régresseurs* dans la régression.
- Ainsi, on peut obtenir une estimation de l'effet de la santé des élèves sur l'absentéisme, **purgée de l'effet de la variable liée à l'accès aux toilettes**.
- Le modèle que l'on souhaite estimer devient:

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{Nbr de toilettes}_i + u_i$$

- Ceci est une ***régression multivariée*** ! Nous allons l'estimer plus tard après avoir formaliser ce que l'on vient de voir.



Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

avec y_i est la ***variable dépendante*** et x_i la ***variable indépendante***.

Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

avec y_i est la ***variable dépendante*** et x_i la ***variable indépendante***.

- Rappel : on dit que `X` *affecte* `Y` lorsque un changement de la valeur de `X` ***sans changer rien d'autre*** change la valeur de `Y`.



Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

avec y_i est la ***variable dépendante*** et x_i la ***variable indépendante***.

- Rappel : on dit que `X` *affecte* `Y` lorsque un changement de la valeur de `X` ***sans changer rien d'autre*** change la valeur de `Y`.

⚠️ Sauf si tous les autres facteur impactant y_i ne sont pas corrélés avec x_i, β_1 **ne peut pas être interprété comme un effet causal**.

Objectif de la régression multivariée

- Rappel comment écrivons nous un **modèle linéaire simple** ?

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

avec y_i est la ***variable dépendante*** et x_i la ***variable indépendante***.

- Rappel : on dit que `X` *affecte* `Y` lorsque un changement de la valeur de `X` ***sans changer rien d'autre*** change la valeur de `Y`.

⚠ Sauf si tous les autres facteur impactant y_i ne sont pas corrélés avec x_i, β_1 **ne peut pas être interprété comme un effet causal**.

On a donc besoin **d'enrichir le modèle** et de prendre en compte les éléments qui sont corrélés simultanément avec y_i **and** x_i.



Modèle de régression multivarié

Le modèle étendu peut s'écrire comme suit :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{3,i} + \cdots + \beta_k x_{k,i} + u_i,$$

où x_1, x_2, ..., x_k sont k régresseurs, et β_1, β_2, ..., β_k sont les k coefficients associés.

Modèle de régression multivarié

Le modèle étendu peut s'écrire comme suit :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{3,i} + \cdots + \beta_k x_{k,i} + u_i,$$

où x_1, x_2, ..., x_k sont k régresseurs, et β_1, β_2, ..., β_k sont les k coefficients associés.

Estimation : On obtient les valeurs de $(\beta_0, \beta_1, \beta_2, \ldots, \beta_k)$ de la même manière qu'auparavant, en utilisant les **OLS**.

- $(\beta_0^{OLS}, \beta_1^{OLS}, \beta_2^{OLS}, \ldots, \beta_k^{OLS})$ sont les valeurs qui minimisent la **Somme des Carrés des Résidus**.
- C'est-à-dire qu'elles minimisent

$$\begin{aligned}\sum_i u_i^2 &= \sum_i (y_i - \hat{y}_i)^2 \\ &= \sum_i \left[y_i - (\beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{3,i} + \cdots + \beta_k x_{k,i})\right]^2\end{aligned}$$



Modèle de régression multivarié

Pour l'instant, supposons que la variable dépendante (y_i) et les variables indépendantes (x_k) sont toutes numériques.

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**



Modèle de régression multivarié

Pour l'instant, supposons que la variable dépendante (y_i) et les variables indépendantes (x_k) sont toutes numériques.

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Pente (β_k) : **Le changement prédit, en moyenne, de la valeur de y *associé* à une augmentation d'une unité de x_k...**
>
> **... en maintenant tous les autres régresseurs constants !**

Modèle de régression multivarié

Pour l'instant, supposons que la variable dépendante (y_i) et les variables indépendantes (x_k) sont toutes numériques.

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Pente (β_k) : **Le changement prédit, en moyenne, de la valeur de y *associé* à une augmentation d'une unité de x_k... ... en maintenant tous les autres régresseurs constants !**

- Remarquez que le fait de *maintenir tous les autres régresseurs constants* est la seule partie qui change par rapport au MLS (Modèle Linéaire Simple).
- Autrement dit, on considère l'effet individuel de la variable x_k sur y **de manière isolée**, indépendamment de l'effet que les autres régresseurs pourraient avoir sur y.



Modèle de régression multivarié

Pour l'instant, supposons que la variable dépendante (y_i) et les variables indépendantes (x_k) sont toutes numériques.

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Pente (β_k) : **Le changement prédit, en moyenne, de la valeur de y *associé* à une augmentation d'une unité de x_k... ... en maintenant tous les autres régresseurs constants !**

- Remarquez que le fait de *maintenir tous les autres régresseurs constants* est la seule partie qui change par rapport au MLS (Modèle Linéaire Simple).
- Autrement dit, on considère l'effet individuel de la variable x_k sur y **de manière isolée**, indépendamment de l'effet que les autres régresseurs pourraient avoir sur y.
- **Lien avec l'inférence causale** : Seuls les régresseurs inclus dans le modèle sont maintenus constants ; ceux qui ne sont pas dans le modèle peuvent encore varier et "biaiser" vos estimations.

Implémentation dans R

- Très proche d'une régression univarié :

```
lm(formula = variable dépendante ~  variable independante 1 + variable independante 2 + ...,
   data = data.frame avec les données)
```



Implémentation dans R

- Très proche d'une régression univarié :

```
lm(formula = variable dépendante ~  variable independante 1 + variable independante 2 + ...,
   data = data.frame avec les données)
```

Santé des élèves et absentéisme: Régression multivarié

Estimons le modèle suivant en utilisant OLS :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{Nbr de toilettes}_i + u_i$$

```
lm(absdays_98 ~ score + latr_pup, data)
```

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Questions

1. Comment intreprétez-vous chacun de ces coefficients ?
2. Comment expliquer vous la différence dans le coefficient de `score` en comparaison avec le modèle univarié ?



Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Réponses

1. Comment intreprétez-vous chacun de ces coefficients ?

- β_0 = 1.27: Quand `score` et `latr_pup` sont égales à 0, la *valeur prédite* du nombre de jours d'école manqués est 1.27



Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Réponses

1. Comment intreprétez-vous chacun de ces coefficients ?

- β_0 = 1.27: Quand `score` et `latr_pup` sont égales à 0, la *valeur prédite* du nombre de jours d'école manqués est 1.27

- β_1 = 0.3227: En gardant le *nombre de toilettes par élève* constant dans l'école, une hausse du score de mauvaise santé par 1 est ***associé, en moyenne,*** avec une hausse de 0.32 du nombre de jours d'absentéisme.



Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Réponses

1. Comment intreprétez-vous chacun de ces coefficients ?

- β_0 = 1.27: Quand `score` et `latr_pup` sont égales à 0, la *valeur prédite* du nombre de jours d'école manqués est 1.27
- β_1 = 0.3227: En gardant le *nombre de toilettes par élève* constant dans l'école, une hausse du score de mauvaise santé par 1 est ***associé, en moyenne,*** avec une hausse de 0.32 du nombre de jours d'absentéisme.
- β_2 = - 0.628: En gardant le *le score de santé* constant, une hausse du nombre de toilettes par 100 élèves est ***associé, en moyenne,*** avec une baisse de 0.628 du nombre de jours d'absentéisme.



Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Réponses

2. Comment expliquer vous la différence dans le coefficient de `score` en comparaison avec le modèle univarié ?



Santé des élèves et absentéisme: Régression multivarié

```
##
## Call:
## lm(formula = absdays_98 ~ score + latr_pup, data = data)
##
## Coefficients:
## (Intercept)        score     latr_pup
##      1.2662       0.3227     -62.8514
```

Réponses

2. Comment expliquer vous la différence dans le coefficient de `score` en comparaison avec le modèle univarié ?

- β_1 est relativement proche mais diminue lors de l'inclusion de cette nouvelle variable. La raison est sûrement qu'une partie de l'effet trouvé vient des écoles avec des faibles accès aux sanitaires.



Interprétation des coefficients

$$\hat{y} = \widehat{\beta_0} + \widehat{\beta_1} x_1 + \widehat{\beta_2} x_2 + u_i$$

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Effets partiels (β_1) et (β_2) : **La valeur prédite de y $(\hat{y})$ si les autres régresseurs $(x_1, x_2$ sont égaux à 0.**

Interprétation des coefficients

$$\hat{y} = \widehat{\beta_0} + \widehat{\beta_1} x_1 + \widehat{\beta_2} x_2 + u_i$$

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Effets partiels (β_1) et (β_2) : **La valeur prédite de y $(\hat{y})$ si les autres régresseurs $(x_1, x_2$ sont égaux à 0.**

Si l'on souhaite estimer l'effet d'une variation des régresseurs sur notre variable dépendante

$$\Delta\hat{y} = \Delta\widehat{\beta_1} x_1 + \Delta\widehat{\beta_2} x_2$$

Interprétation des coefficients

$$\hat{y} = \widehat{\beta_0} + \widehat{\beta_1} x_1 + \widehat{\beta_2} x_2 + u_i$$

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Effets partiels (β_1) et (β_2) : **La valeur prédite de y $(\hat{y})$ si les autres régresseurs $(x_1, x_2$ sont égaux à 0.**

Si l'on souhaite estimer l'effet d'une variation des régresseurs sur notre variable dépendante

$$\Delta\hat{y} = \Delta\widehat{\beta_1} x_1 + \Delta\widehat{\beta_2} x_2$$

Si l'on maintient x_2 fixe (i.e., $\Delta x_2 = 0$), alors $\Delta\hat{y} = \Delta\widehat{\beta_1} x_1$



Interprétation des coefficients

$$\hat{y} = \widehat{\beta_0} + \widehat{\beta_1} x_1 + \widehat{\beta_2} x_2 + u_i$$

> Constante (β_0) : **La valeur prédite de y $(\hat{y})$ si tous les régresseurs $(x_1, x_2, x_3, \dots)$ sont égaux à 0.**
>
> Effets partiels (β_1) et (β_2) : **La valeur prédite de y $(\hat{y})$ si les autres régresseurs $(x_1, x_2$ sont égaux à 0.**

Si l'on souhaite estimer l'effet d'une variation des régresseurs sur notre variable dépendante

$$\Delta\hat{y} = \Delta\widehat{\beta_1} x_1 + \Delta\widehat{\beta_2} x_2$$

Si l'on maintient x_2 fixe (i.e., $\Delta x_2 = 0$), alors $\Delta\hat{y} = \Delta\widehat{\beta_1} x_1$

Et si l'on maintient x_1 fixe (i.e., $\Delta x_1 = 0$), alors $\Delta\hat{y} = \Delta\widehat{\beta_2} x_2$



Pourcentage vs Point de Pourcentage : Une introduction

Exemple : Le % d'élèves défavorisés dans la classe passe de 10 à 25 % ?

Pourcentage vs Point de Pourcentage : Une introduction

Exemple : Le % d'élèves défavorisés dans la classe passe de 10 à 25 % ?

Questions :

1. Quel est le changement en *points de pourcentage* ?
2. Quel est le changement en *pourcentage* ?



Pourcentage vs. Point de pourcentage : Les bases

Exemple : Le % d'élèves défavorisés dans la classe passe de 10 à 25 % ?

Réponses :

1. C'est une augmentation de $25 - 10 = 15$ ***points de pourcentage***.

Pourcentage vs. Point de pourcentage : Les bases

Exemple : Le % d'élèves défavorisés dans la classe passe de 10 à 25 % ?

Réponses :

1. C'est une augmentation de $25 - 10 = 15$ ***points de pourcentage***.
2. C'est une augmentation de $\frac{25-10}{10}\% = 150$ ***pour cent***.

Pourcentage vs. Point de pourcentage : Les bases

Exemple : Le % d'élèves défavorisés dans la classe passe de 10 à 25 % ?

Réponses :

1. C'est une augmentation de $25 - 10 = 15$ ***points de pourcentage***.
2. C'est une augmentation de $\frac{25-10}{10}\% = 150$ ***pour cent***.

Il est ***essentiel*** de faire attention si l'on parle de changements en ***points de pourcentage*** ou en ***pourcentage*** ! Ces deux notions impliquent des magnitudes radicalement différentes !

Tâche 1

10:00

Analysons les résultats de régression en utilisant l'absentéisme comme variable dépendante.

1. Chargez les données depuis ici en utilisant la fonction `read_dta()` du package `haven`. Assignez-les à un objet `data`.

2. Régressez `absdays_98` d'abord sur `score`, puis ajoutez `pup_pop` et assignez le résultat à un nouvel objet `reg1` et `reg2`. Interprétez les coefficients. Comment se comparent-ils à la régression linéaire simple ?

3. (Optionnel) Quelles sont les autres variables disponibles que nous pourrions ajouter à la régression ?

    - Exécutez la régression avec toutes ces variables et assignez-la à `reg_full`.
    - Examinez les coefficients.
    - Discutez de tous les coefficients : signe et magnitude.



Variables numérique et binaire : interprétation

Vous savez déjà comment interpréter une variable numérique (i.e., continue)

Variables numérique et binaire : interprétation

Vous savez déjà comment interpréter une variable numérique (i.e., continue)

Comment faire si l'une des variables est une variable ***binaire***, c'est à dire qu'elle peut prendre la valeur de 1 si certaines conditions sont `TRUE` et 0 si ce n'est pas le cas ?



Variables numérique et binaire : interprétation

Vous savez déjà comment interpréter une variable numérique (i.e., continue)

Comment faire si l'une des variables est une variable ***binaire***, c'est à dire qu'elle peut prendre la valeur de 1 si certaines conditions sont `TRUE` et 0 si ce n'est pas le cas ?

Exemple: Comment interpréter les coefficients dans le modèle suivant

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

`worm_treat` est une binaire égale à 1 si l'enfant a reçu un vermifuge, 0 si non

Variables numérique et binaire : interprétation

Vous savez déjà comment interpréter une variable numérique (i.e., continue)

Comment faire si l'une des variables est une variable ***binaire***, c'est à dire qu'elle peut prendre la valeur de 1 si certaines conditions sont `TRUE` et 0 si ce n'est pas le cas ?

Exemple: Comment interpréter les coefficients dans le modèle suivant

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

`worm_treat` est une binaire égale à 1 si l'enfant a reçu un vermifuge, 0 si non

```
lm(formula = absdays_98 ~ score + worm_treat, data = data)
```

```
##
## Call:
## lm(formula = absdays_98 ~ score + worm_treat, data = data)
##
## Coefficients:
## (Intercept)        score   worm_treat
##     0.68192      0.33547     -0.05781
```



Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} = 0) &= \beta_0 + \beta_1 \times 0 + \beta_2 \times 0 \\ &= \beta_0\end{aligned}$$

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} = 0) &= \beta_0 + \beta_1 \times 0 + \beta_2 \times 0 \\ &= \beta_0\end{aligned}$$

$\rightarrow \beta_0$ correspond à la valeur espérée moyenne d'absentéisme lorsque le score de santé vaut 0 et l'élève n'a pas reçu de vermifuge.

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\mathbb{E}(\text{Absentéisme} | \text{worm_treat} \in \{0, 1\} \ \& \ \text{Score} = n_1) = \beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}$$

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\mathbb{E}(\text{Absentéisme} | \text{worm_treat} \in \{0,1\} \ \& \ \text{Score} = n_1) = \beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}$$

$$\mathbb{E}(\text{Absentéisme} | \text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1 + 1) = \beta_0 + \beta_1 \times (n_1 + 1) + \beta_2 \times \text{worm_treat}$$

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Score} = n_1) = \beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}$$

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1 + 1) = \beta_0 + \beta_1 \times (n_1 + 1) + \beta_2 \times \text{worm_treat}$$

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1 + 1) - \mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1)$$
$$= \beta_0 + \beta_1 \times (n_1 + 1) + \beta_2 \times \text{worm_treat} - (\beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}) = \beta_1$$



Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Score} = n_1) = \beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}$$

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1 + 1) = \beta_0 + \beta_1 \times (n_1 + 1) + \beta_2 \times \text{worm_treat}$$

$$\mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1 + 1) - \mathbb{E}(\text{Absentéisme}|\text{worm_treat} \in \{0,1\} \ \& \ \text{Santé} = n_1)$$
$$= \beta_0 + \beta_1 \times (n_1 + 1) + \beta_2 \times \text{worm_treat} - (\beta_0 + \beta_1 \times n_1 + \beta_2 \times \text{worm_treat}) = \beta_1$$

$\rightarrow \beta_1$ correspond au changement espéré de l'absentéisme en moyenne lié, en moyenne, avec une hausse de 1 du score de santé, en controllant pour le fait que l'élève se soit fait.e vermifuger

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 1 \\ &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2\end{aligned}$$

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}
\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 1 \\
&= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \\
\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 0 \\
&= \beta_0 + \beta_1 \times \text{Santé}
\end{aligned}$$

Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 1 \\ &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2\end{aligned}$$

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 0 \\ &= \beta_0 + \beta_1 \times \text{Santé}\end{aligned}$$

$$\begin{aligned}&\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé}) \\ &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 - (\beta_0 + \beta_1 \times \text{Santé}) = \beta_2\end{aligned}$$



Variables numérique et binaire : formellement

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 1 \\ &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2\end{aligned}$$

$$\begin{aligned}\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} \in \mathbb{N}) &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 \times 0 \\ &= \beta_0 + \beta_1 \times \text{Santé}\end{aligned}$$

$$\begin{aligned}&\mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé}) \\ &= \beta_0 + \beta_1 \times \text{Santé} + \beta_2 - (\beta_0 + \beta_1 \times \text{Santé}) = \beta_2\end{aligned}$$

$\rightarrow \beta_2$ correspond à la différence espérée moyenne d'absentéisme entre un élève vermifugé.e et non vermifugé.e, en gardant le score de santé constant.

Variables numérique et binaire : résumé

Notre modèle est :

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Santé}_i + \beta_2 \text{worm_treat}_i + u_i$$

Nous avons les égalités suivantes :

$$\beta_0 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} = 0)$$

$$\beta_1 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} \in \{0, 1\} \ \& \ \text{Santé} = n_1 + 1) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} \in \{0, 1\} \ \& \ \text{Santé} = n_1)$$

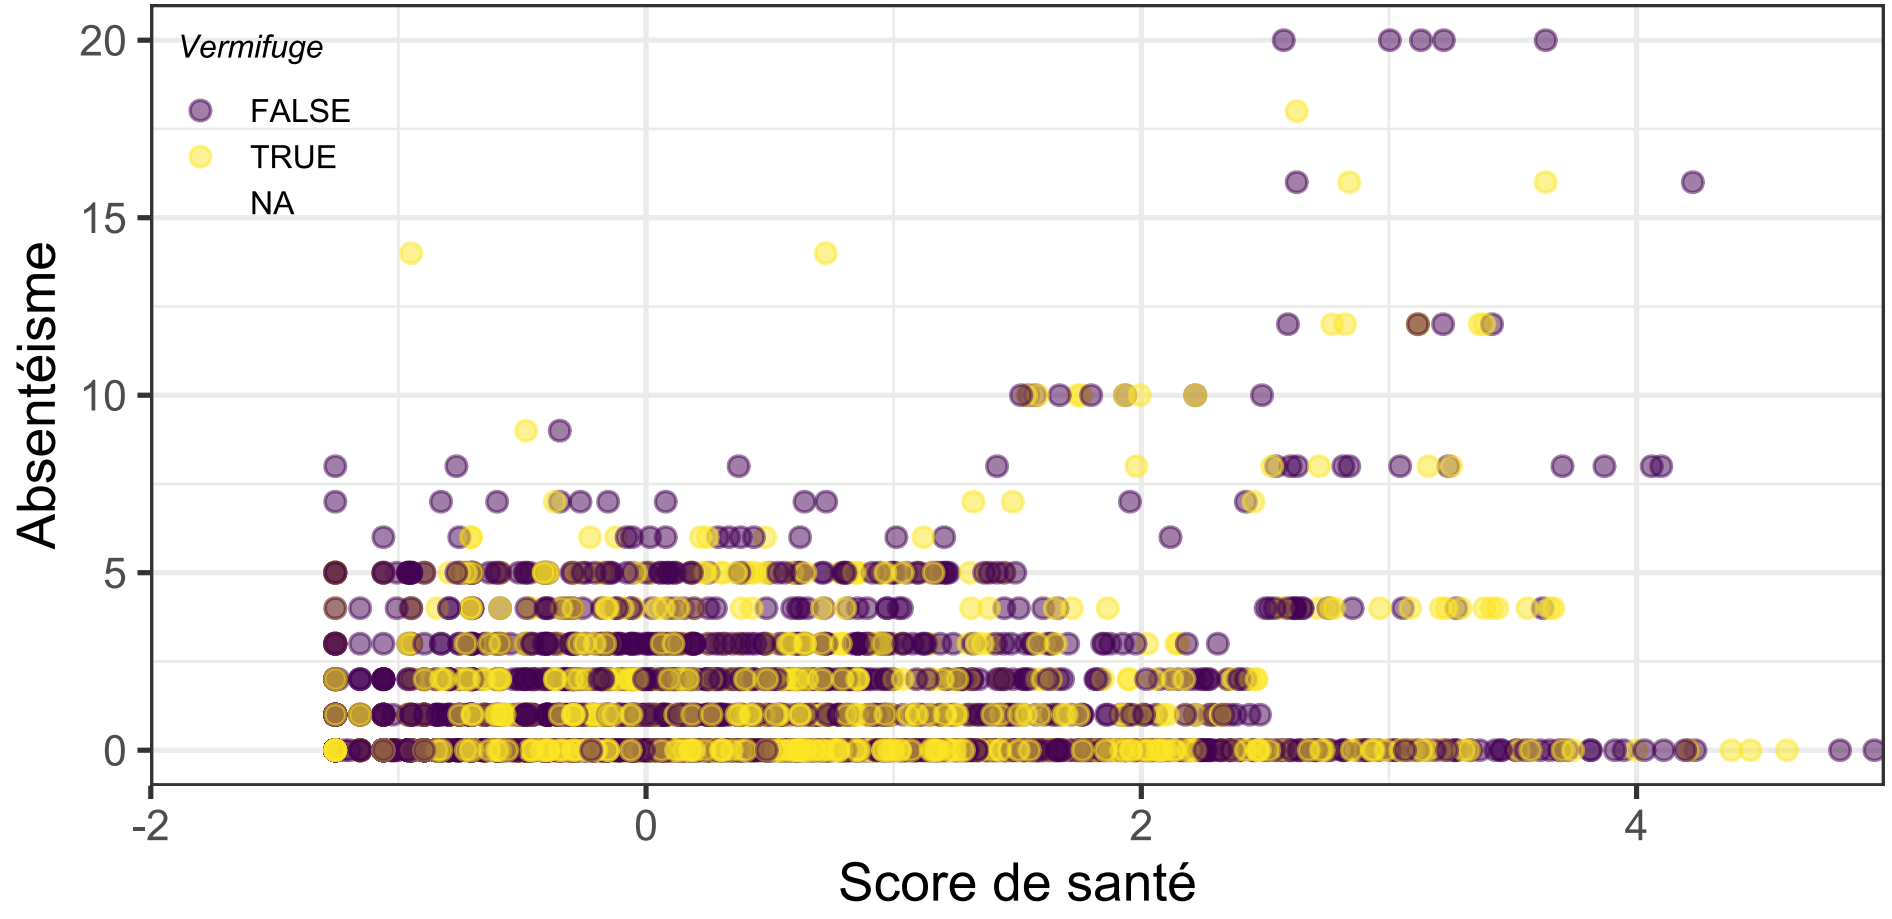
$$\beta_2 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Santé} \in \mathbb{N})$$

$$\beta_0 + \beta_2 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} = 0)$$



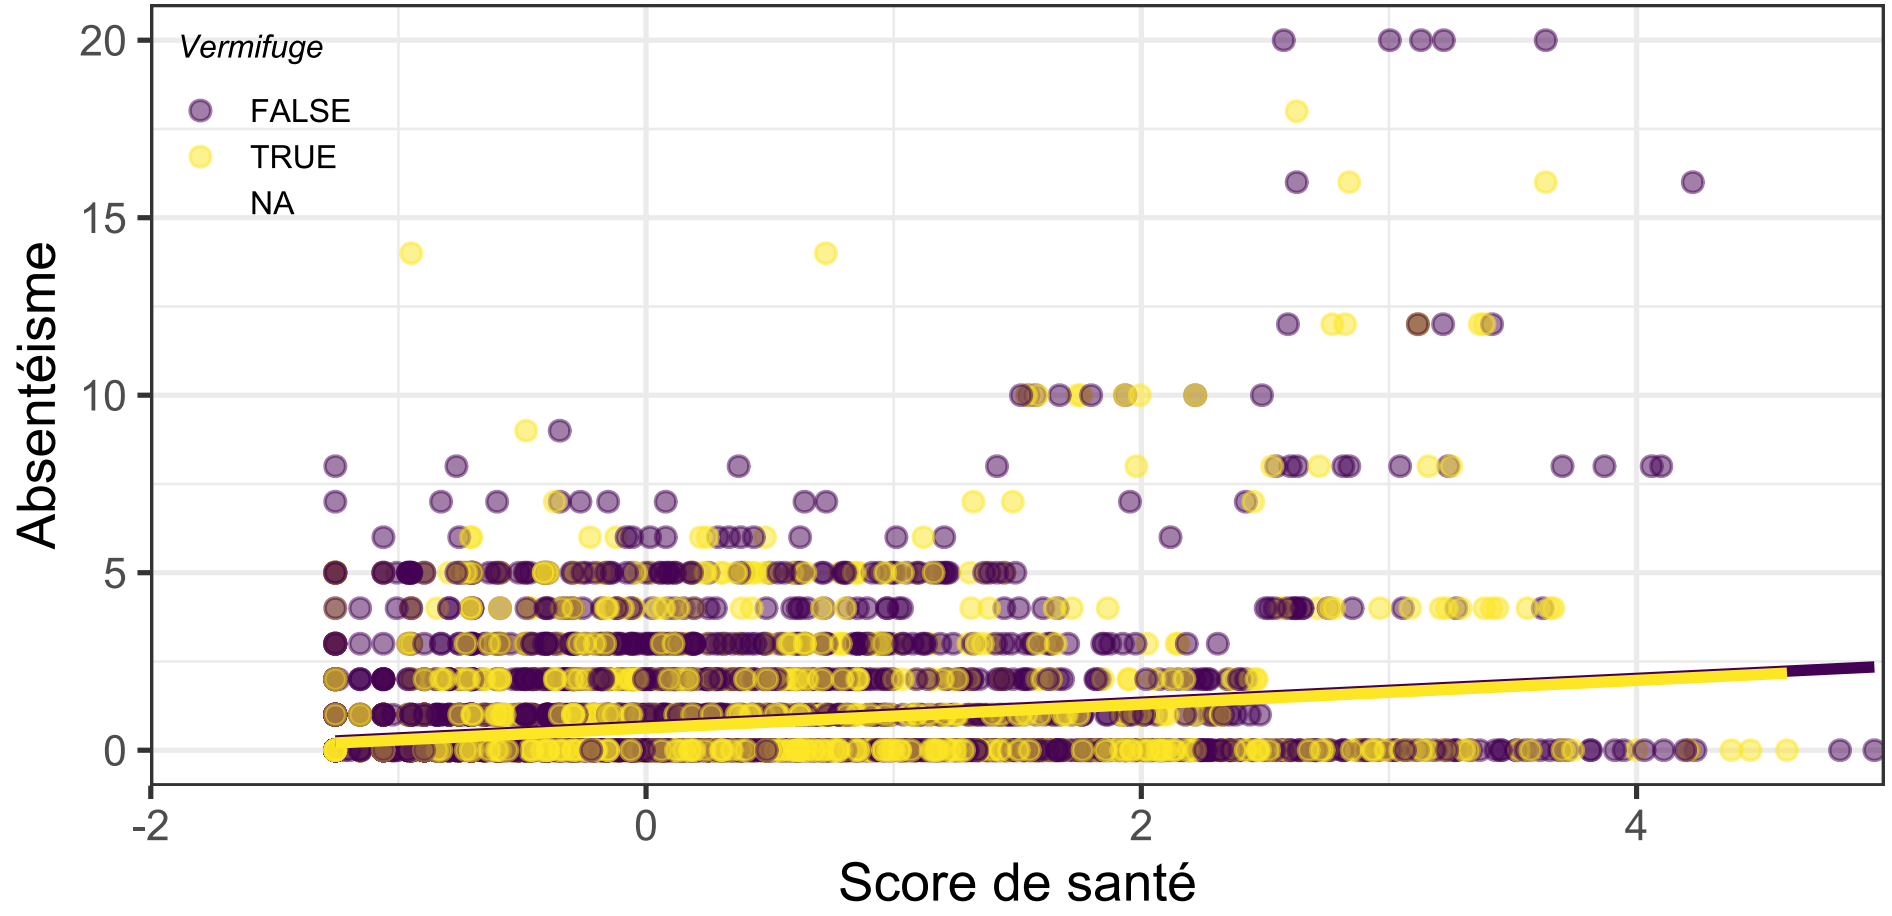
Variables numérique et binaire : graphiquement

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Score}_i + \beta_2 \text{worm_treat}_i + u_i$$



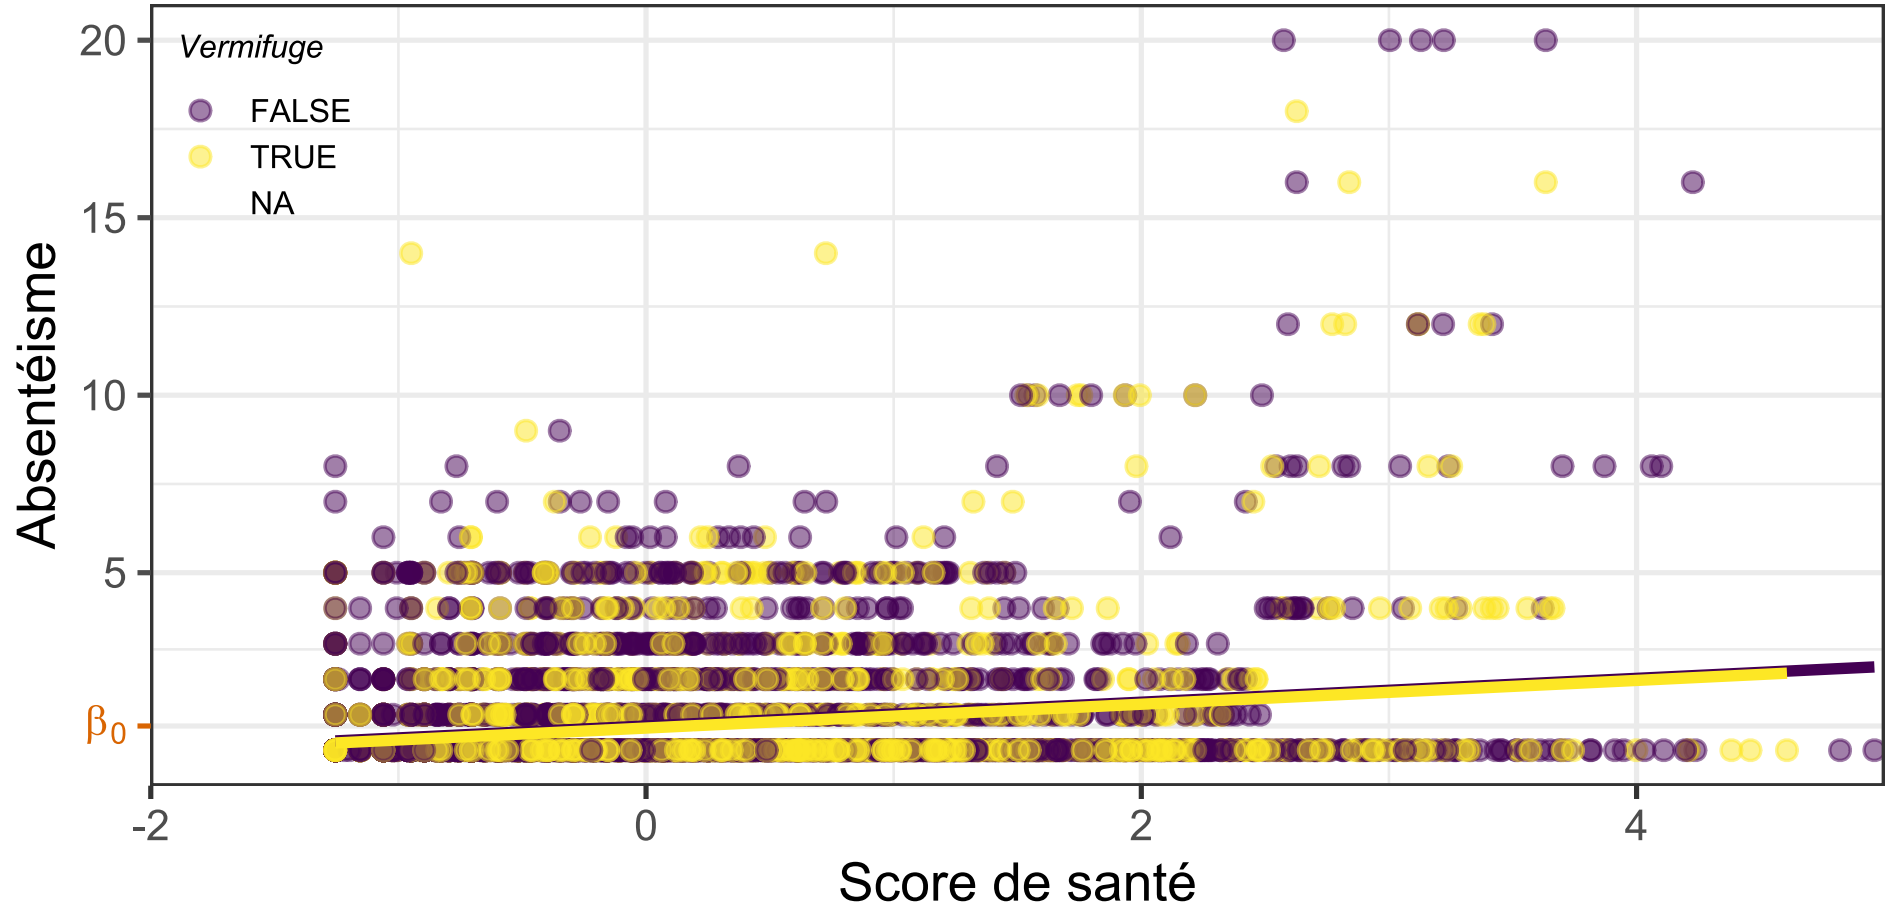
Variables numérique et binaire : graphiquement

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Score}_i + \beta_2 \text{worm_treat}_i + u_i$$



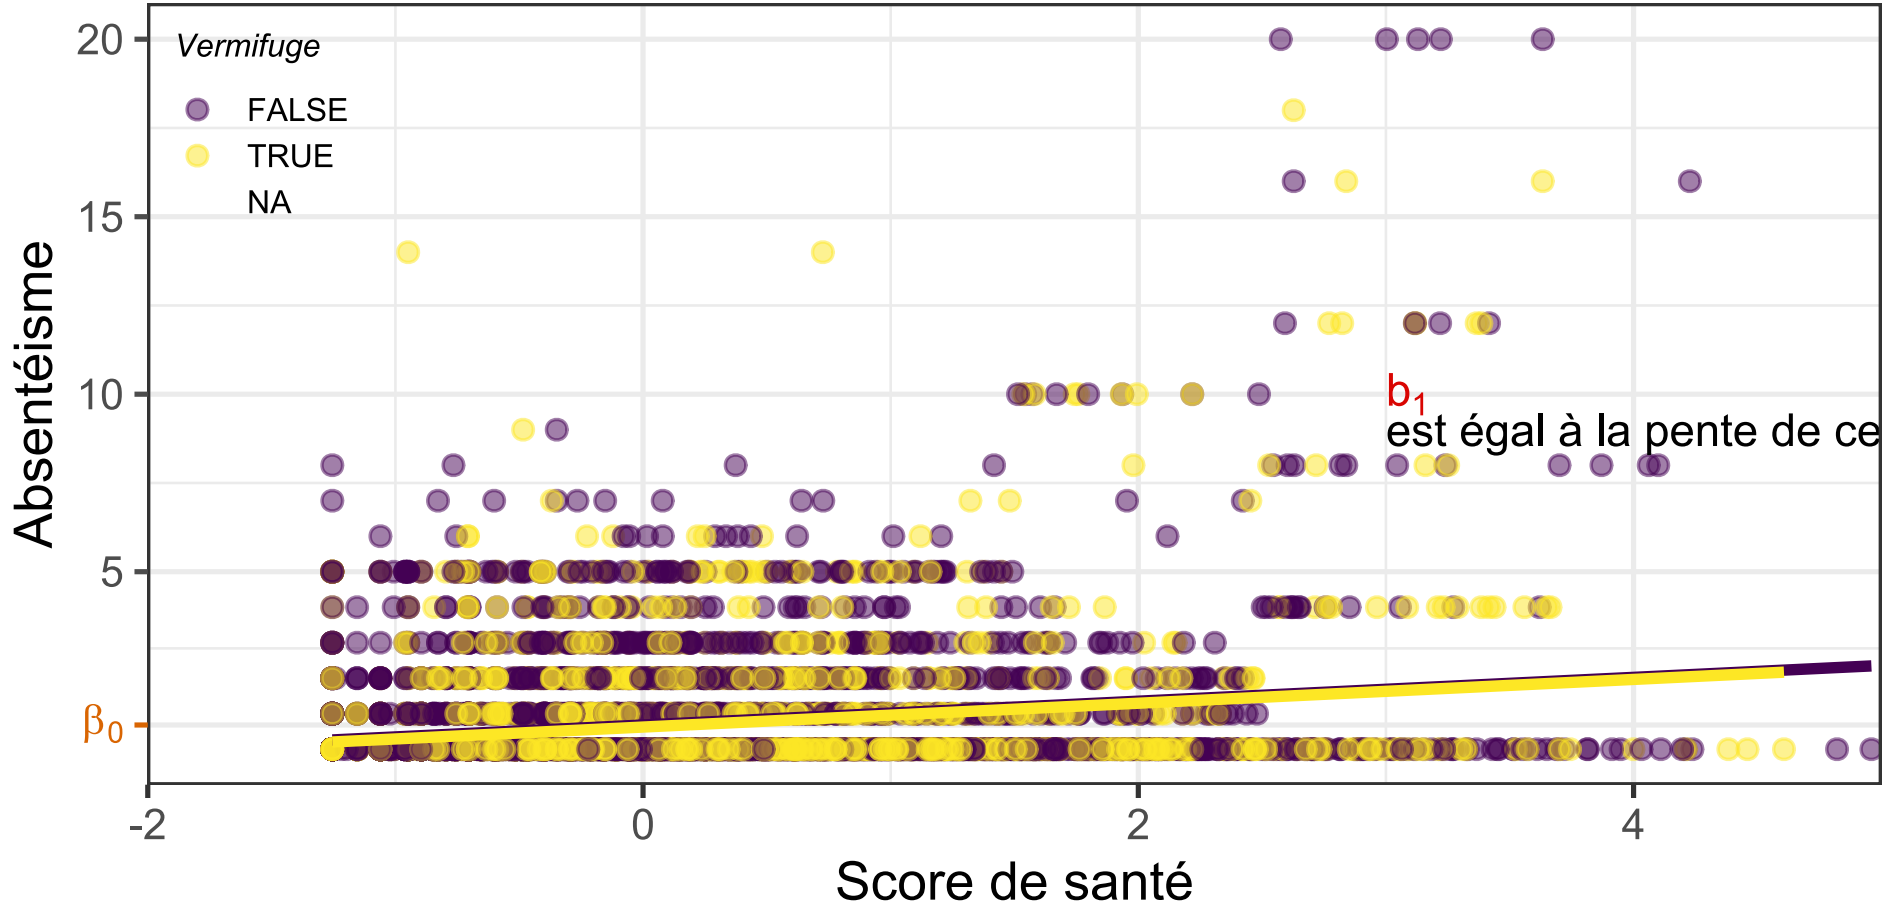
Variables numérique et binaire : graphiquement

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Score}_i + \beta_2 \text{worm_treat}_i + u_i$$



Variables numérique et binaire : graphiquement

$$\text{Absentéisme}_i = \beta_0 + \beta_1 \text{Score}_i + \beta_2 \text{worm_treat}_i + u_i$$



Absence de collinéarité parfaite

Il y a une condition à respecter pour ajouter des variables dans notre modèle :

> Chaque nouvelle variable doit ajouter **au moins *un peu* d'information nouvelle**.

Absence de collinéarité parfaite

Il y a une condition à respecter pour ajouter des variables dans notre modèle :

> Chaque nouvelle variable doit ajouter **au moins *un peu* d'information nouvelle**.

En d'autres termes, les régresseurs **ne peuvent pas être parfaitement collinéaire**, i.e., une combination linéaire d'autres variables:

$$x_2 \neq ax_1 + b$$



Absence de collinéarité parfaite

Il y a une condition à respecter pour ajouter des variables dans notre modèle :

> Chaque nouvelle variable doit ajouter **au moins *un peu* d'information nouvelle**.

En d'autres termes, les régresseurs **ne peuvent pas être parfaitement collinéaire**, i.e., une combination linéaire d'autres variables:

$$x_2 \neq ax_1 + b$$

Même si non parfaitement collinéaire, l'effets individuels de variables hautement corrélées sera difficile à identifier.

Absence de collinéarité parfaite

Il y a une condition à respecter pour ajouter des variables dans notre modèle :

> Chaque nouvelle variable doit ajouter **au moins *un peu* d'information nouvelle**.

En d'autres termes, les régresseurs **ne peuvent pas être parfaitement collinéaire**, i.e., une combination linéaire d'autres variables:

$$x_2 \neq ax_1 + b$$

Même si non parfaitement collinéaire, l'effets individuels de variables hautement corrélées sera difficile à identifier.

Une autre règle important est que le nombre d'observations doit toujours être supérieur aux nombres de variables indépendantes dans le modèle (on verra plus tard pourquoi).



Absence de collinéarité parfaite

Cette règle est particulièrement importante pour les ***variables catégorielles***, i.e., variables qui ne prennent qu'une valeur finie (e.g., saison, niveau d'éducation, genre, etc.)

Absence de collinéarité parfaite

Cette règle est particulièrement importante pour les ***variables catégorielles***, i.e., variables qui ne prennent qu'une valeur finie (e.g., saison, niveau d'éducation, genre, etc.)

Revenons à notre `worm_treat` régression:

```
##
## Call:
## lm(formula = absdays_98 ~ score + worm_treat, data = data)
##
## Coefficients:
## (Intercept)        score   worm_treat
##     0.68192      0.33547     -0.05781
```



Absence de collinéarité parfaite

Cette règle est particulièrement importante pour les ***variables catégorielles***, i.e., variables qui ne prennent qu'une valeur finie (e.g., saison, niveau d'éducation, genre, etc.)

Revenons à notre `worm_treat` régression:

```
##
## Call:
## lm(formula = absdays_98 ~ score + worm_treat, data = data)
##
## Coefficients:
## (Intercept)        score   worm_treat
##     0.68192      0.33547     -0.05781
```

Que se passe-t-il si l'on crée deux variables `worm_1` and a `worm_0` et que l'on régresse `abddays_98` sur ces deux (et `score`)?



Absence de collinéarité parfaite

Que se passe-t-il si l'on crée deux variables `worm_1` and a `worm_0` et que l'on régresse `abddays_98` sur ces deux (et `score`)?

```
data <- data %>%
  mutate(worm_1 = (worm_treat == 1),
         worm_0 = (worm_treat == 0))
lm(absdays_98 ~ score + worm_0 +
     worm_1, data)
```

```
##
## Call:
## lm(formula = absdays_98 ~ score + worm_0 + worm_1, data = data)
##
## Coefficients:
## (Intercept)        score   worm_0TRUE   worm_1TRUE
##     0.62411      0.33547      0.05781           NA
```

Uniquement l'une de ces deux variables a un coefficient ! Pourquoi ?



Absence de collinéarité parfaite

Que se passe-t-il si l'on crée deux variables `worm_1` and a `worm_0` et que l'on régresse `abddays_98` sur ces deux (et `score`)?

```
data <- data %>%
  mutate(worm_1 = (worm_treat == 1),
         worm_0 = (worm_treat == 0))
lm(absdays_98 ~ score + worm_0 +
     worm_1, data)
```

```
##
## Call:
## lm(formula = absdays_98 ~ score + worm_0 + worm_1, data = data)
##
## Coefficients:
## (Intercept)        score   worm_0TRUE   worm_1TRUE
##     0.62411      0.33547      0.05781           NA
```

Uniquement l'une de ces deux variables a un coefficient ! Pourquoi ?

```
data %>% count(worm_1 == 1 - worm_0)
```

```
## # A tibble: 2 × 2
##   `worm_0 == 1 - worm_1`     n
##   <lgl>                  <int>
## 1 TRUE                    6693
## 2 NA                        80
```



Absence de collinéarité parfaite

→ R détecte automatiquement la collinéarité parfaite entre les variables et en supprime l'une d'entre elle

Absence de collinéarité parfaite

$\rightarrow$ R détecte automatiquement la collinéarité parfaite entre les variables et en supprime l'une d'entre elle

⚠️ Pour l'interprétation, il faut faire attention à la ***catégorie omise (ou de référence)*** : la catégorie de "référence" à partir de laquelle on interpréte notre coefficient. Rappel :

$$\beta_2 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Score} \in \mathbb{N})$$

Absence de collinéarité parfaite

$\rightarrow$ `R` détecte automatiquement la collinéarité parfaite entre les variables et en supprime l'une d'entre elle

⚠️ Pour l'interprétation, il faut faire attention à la ***catégorie omise (ou de référence)*** : la catégorie de "référence" à partir de laquelle on interpréte notre coefficient. Rappel :

$$\beta_2 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Score} \in \mathbb{N})$$

Cela s'applique dans les cas avec plus de deux catégories. Vous n'avez pas à créer une variable binaire pour chaque possibilité, `R` va le faire automatiquement (tant qu'elles sont sauvées comme `character` ou `factor`).



Absence de collinéarité parfaite

$\rightarrow$ `R` détecte automatiquement la collinéarité parfaite entre les variables et en supprime l'une d'entre elle

⚠️ Pour l'interprétation, il faut faire attention à la ***catégorie omise (ou de référence)*** : la catégorie de "référence" à partir de laquelle on interpréte notre coefficient. Rappel :

$$\beta_2 = \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 1 \ \& \ \text{Santé} \in \mathbb{N}) - \mathbb{E}(\text{Absentéisme} | \text{worm_treat} = 0 \ \& \ \text{Score} \in \mathbb{N})$$

Cela s'applique dans les cas avec plus de deux catégories. Vous n'avez pas à créer une variable binaire pour chaque possibilité, `R` va le faire automatiquement (tant qu'elles sont sauvées comme `character` ou `factor`).

MAIS vous avez besoin de vérifier quelle catégorie a été choisir comme ***catégorie ommise***.



Tâche 2: Piège variables binaires

10:00

1. Chargez les données *STAR* depuis ici, en utilisant `read.csv`, et assignez-les à un objet appelé `star_df`. Ne conservez que les observations sans `NA` avec le code suivant : `star_df <- star_df[complete.cases(star_df),]`

2. Créez trois variables muettes (dummy) : (i) `small` égale à `TRUE` si les élèves sont dans une petite classe et `FALSE` sinon ; (ii) `regular` égale à `TRUE` si les élèves sont dans une classe régulière et `FALSE` sinon ; (iii) `regular_plus` égale à `TRUE` si les élèves sont dans une classe régulière+assistant et `FALSE` sinon. (*Indice : pour créer une variable muette, écrivez* `dummy = (variable=="value")`, *à l'intérieur du verbe dplyr approprié*) Créez une dernière variable, `sum`, égale à la somme de `small`, `regular` et `regular_plus`. À quoi `sum` est-elle égale ? Que signifie ce résultat ?

3. Régressez `math` sur `regular_plus`. Quel est le score moyen prédit de `math` pour les élèves dans une classe régulière+assistant ?

4. Régressez `math` sur `small`, `regular` et `regular_plus`. Que remarquez-vous ? Quelle est la catégorie omise (de référence) ? Cela correspond-il à la question précédente ?

5. Régressez `math` sur `star`. Que remarquez-vous ? Quelle est la catégorie omise ? Interprétez le coefficient.



Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.



Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.

Notons y notre variable dépendante, x notre régresseur et z notre variable omise. L'objectif est d'estimer $\widehat{\beta_1}$:

Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.

Notons y notre variable dépendante, x notre régresseur et z notre variable omise. L'objectif est d'estimer $\widehat{\beta_1}$:

1. ***Modèle linéaire multivarié*** : $y = \beta_0 + \beta_1 x + \beta_2 z + u$

Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.

Notons y notre variable dépendante, x notre régresseur et z notre variable omise. L'objectif est d'estimer $\widehat{\beta_1}$:

1. ***Modèle linéaire multivarié*** : $y = \beta_0 + \beta_1 x + \beta_2 z + u$

Mais pour des raisons diverses, comme une limite de données, il se peut que l'on doive omettre β_2

Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.

Notons y notre variable dépendante, x notre régresseur et z notre variable omise. L'objectif est d'estimer $\widehat{\beta_1}$:

1. ***Modèle linéaire multivarié*** : $y = \beta_0 + \beta_1 x + \beta_2 z + u$

Mais pour des raisons diverses, comme une limite de données, il se peut que l'on doive omettre β_2

2. ***Variable omise sur le régresseur*** : $\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x + u$



Bias de variable omise (OVB)

Biais de variable omise (OVB) : Le fait d'omettre des variables de contrôle importantes du modèle de régression

Ceci rend le coefficient de votre régresseur d'intérêt *biaisé*.

Notons y notre variable dépendante, x notre régresseur et z notre variable omise. L'objectif est d'estimer $\widehat{\beta_1}$:

1. ***Modèle linéaire multivarié*** : $y = \beta_0 + \beta_1 x + \beta_2 z + u$

Mais pour des raisons diverses, comme une limite de données, il se peut que l'on doive omettre β_2

2. ***Variable omise sur le régresseur*** : $\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x + u$

On sait que $\tilde{\beta}_1 = \widehat{\beta_1} + \widehat{\beta_2}\tilde{\delta}_1$ avec $\tilde{\delta}_1$ qui est la pente de la régression de x sur z



Bias de variable omise (OVB)

$$
\begin{aligned}
E(\tilde{\beta}_1) &= E(\widehat{\beta_1} + \widehat{\beta_2}\tilde{\delta}_1) \\
&= E(\widehat{\beta_1}) + E(\widehat{\beta_2})\tilde{\delta}_1 \\
&= \beta_1 + \beta_2\delta_1 \\
E(\tilde{\beta}_1) - \beta_1 &= \underbrace{\beta_2\delta_1}_{OVB}
\end{aligned}
$$

Bias de variable omise (OVB)

$$
\begin{aligned}
E(\tilde{\beta}_1) &= E(\widehat{\beta_1} + \widehat{\beta_2}\tilde{\delta}_1) \\
&= E(\widehat{\beta_1}) + E(\widehat{\beta_2})\tilde{\delta}_1 \\
&= \beta_1 + \beta_2\delta_1 \\
E(\tilde{\beta}_1) - \beta_1 &= \underbrace{\beta_2\delta_1}_{OVB}
\end{aligned}
$$

Autrement dit, $\beta_1 = \tilde{\beta}_1 + OVB$

Bias de variable omise (OVB)

En résumé :

$$\text{OVB} = \beta_2 \times \underbrace{\frac{Cov(x,z)}{Var(x)}}_{\tilde{\delta}}$$

De cette formule, on peut obtenir :

- **Magnitude** du OVB (uniquement si on observe z),
- ***Signe*** du OVB (positive/négatif) : en pratique on observa pas z (sinon il serait juste inclus dans la reg.)

Bias de variable omise (OVB)

En résumé :

$$\text{OVB} = \beta_2 \times \underbrace{\frac{Cov(x,z)}{Var(x)}}_{\tilde{\delta}}$$

De cette formule, on peut obtenir :

- **Magnitude** du OVB (uniquement si on observe z),
- ***Signe*** du OVB (positive/négatif) : en pratique on observa pas z (sinon il serait juste inclus dans la reg.)

Questions:

1. Dans quels cas $\tilde{\beta}_1$ n'est il pas biaisé ?
2. Imaginez que vous voulez découvrir la relation entre le revenu et le nombre d'années d'éducation. Pourquoi une régression simple du revenu sur le nombre d'années d'éducation pourrait-elle ne pas donner des estimations fiables ? Ex de variable omise ? Signe attendu du biais de variable omise ?



Bias de variable omise (OVB)

Dans quels cas $\tilde{\beta}_1$ n'est il pas biaisé ?

1. Lorsque $\beta_2 = 0$: cela signifie que z ne doit pas être inclus dans notre modèle
2. $\tilde{\delta}_1 = 0$: i.e., $COV(x, z) = 0$

Si $COV(x, z) \neq 0 \Rightarrow$ le signe de $\tilde{\delta}$ correspond au signe de $Corr(x, z)$

	$Corr(x, z) > 0$	$Corr(x, z) < 0$
$\beta_2 > 0$	+	-
$\beta_2 < 0$	-	+

Bias de variable omise (OVB) : En pratique

Revenons à notre exemple initial entre l'absentéisme et la santé des élèves. Nous avions :

Modèle linéaire simple : $\text{Absentéisme} = \tilde{\beta}_0 + \tilde{\beta}_1 \text{Score} + u$

```
## (Intercept)       score
##   0.6558044   0.3306233
```



Bias de variable omise (OVB) : En pratique

Revenons à notre exemple initial entre l'absentéisme et la santé des élèves. Nous avions :

Modèle linéaire simple : $\text{Absentéisme} = \tilde{\beta}_0 + \tilde{\beta}_1 \text{Score} + u$

```
## (Intercept)       score
##   0.6558044   0.3306233
```

Modèle linéaire multivarié : $\text{Absentéisme} = \beta_0 + \beta_1 \text{Score} + \beta_2 \text{worm_treat} + e$

```
## (Intercept)       score  worm_treat
##  0.68192443  0.33547348 -0.05781189
```



Bias de variable omise (OVB) : En pratique

Revenons à notre exemple initial entre l'absentéisme et la santé des élèves. Nous avions :

Modèle linéaire simple : $\text{Absentéisme} = \tilde{\beta}_0 + \tilde{\beta}_1 \text{Score} + u$

```
## (Intercept)       score
##   0.6558044   0.3306233
```

Modèle linéaire multivarié : $\text{Absentéisme} = \beta_0 + \beta_1 \text{Score} + \beta_2 \text{worm_treat} + e$

```
## (Intercept)       score  worm_treat
##  0.68192443  0.33547348 -0.05781189
```

Variable omise sur régresseur: $\text{worm_treat} = \delta_0 + \delta_1 \text{Score} + u$

```
## (Intercept)       score
##  0.36566875  0.01791031
```



Bias de variable omise (OVB) : En pratique

Revenons à notre exemple initial entre l'absentéisme et la santé des élèves. Nous avions :

Modèle linéaire simple : $\text{Absentéisme} = \tilde{\beta}_0 + \tilde{\beta}_1 \text{Score} + u$

```
## (Intercept)       score
##   0.6558044   0.3306233
```

Modèle linéaire multivarié : $\text{Absentéisme} = \beta_0 + \beta_1 \text{Score} + \beta_2 \text{worm_treat} + e$

```
## (Intercept)       score  worm_treat
##  0.68192443  0.33547348 -0.05781189
```

Variable omise sur régresseur: $\text{worm_treat} = \delta_0 + \delta_1 \text{Score} + u$

```
## (Intercept)       score
##  0.36566875  0.01791031
```

On obtient :

$$\tilde{\beta}_1 = 0.331 = \underbrace{0.335}_{\beta_1} + \underbrace{(-0.058)}_{\beta_2} \times \underbrace{(0.018)}_{\delta_1} = \beta_1 + OVB$$

Inclusion de variable inutile

- Nous avons vu quels sont les risques d'omettre une variable importante dans notre modèle. Existe-il un risque similaire lorsque l'on **sur-spécifie** notre modèle ?

Inclusion de variable inutile

- Nous avons vu quels sont les risques d'omettre une variable importante dans notre modèle. Existe-il un risque similaire lorsque l'on **sur-spécifie** notre modèle ?
- **Sur-spécifier** un modèle singifie que l'on au moins une des variables de notre modèle dont le coefficient est égal à 0. Cette variable n'a donc aucune **relation** statistique avec notre variable dépendante.



Inclusion de variable inutile

- Nous avons vu quels sont les risques d'omettre une variable importante dans notre modèle. Existe-il un risque similaire lorsque l'on **sur-spécifie** notre modèle ?
- **Sur-spécifier** un modèle singifie que l'on au moins une des variables de notre modèle dont le coefficient est égal à 0. Cette variable n'a donc aucune **relation** statistique avec notre variable dépendante.
- Inclure ces variables n'a aucun effet sur la valeur des coefficients des autres variables, cela a uniquement un effet négatif sur la variance de nos estimateurs (i.e., leur précision).



R^2 Ajusté

- Pas d'une importance capitale, mais comme il est très largement rapporté, il faut simplement le connaître.



R^2 Ajusté

- Pas d'une importance capitale, mais comme il est très largement rapporté, il faut simplement le connaître.
- Par construction, le R^2 augmente toujours lorsqu'un nouveau régresseur est ajouté à la régression.



R^2 Ajusté

- Pas d'une importance capitale, mais comme il est très largement rapporté, il faut simplement le connaître.
- Par construction, le R^2 augmente toujours lorsqu'un nouveau régresseur est ajouté à la régression.
- Le R^2 *ajusté* impose une pénalité pour l'ajout de régresseurs au modèle. Les détails ne sont pas essentiels, car dans la grande majorité des cas, le R^2 et le R^2 ajusté sont assez similaires.



R^2 vs R^2 ajusté : ajouter des variables aide-t-il vraiment ?

R^2 : part de la variance de y expliquée par le modèle

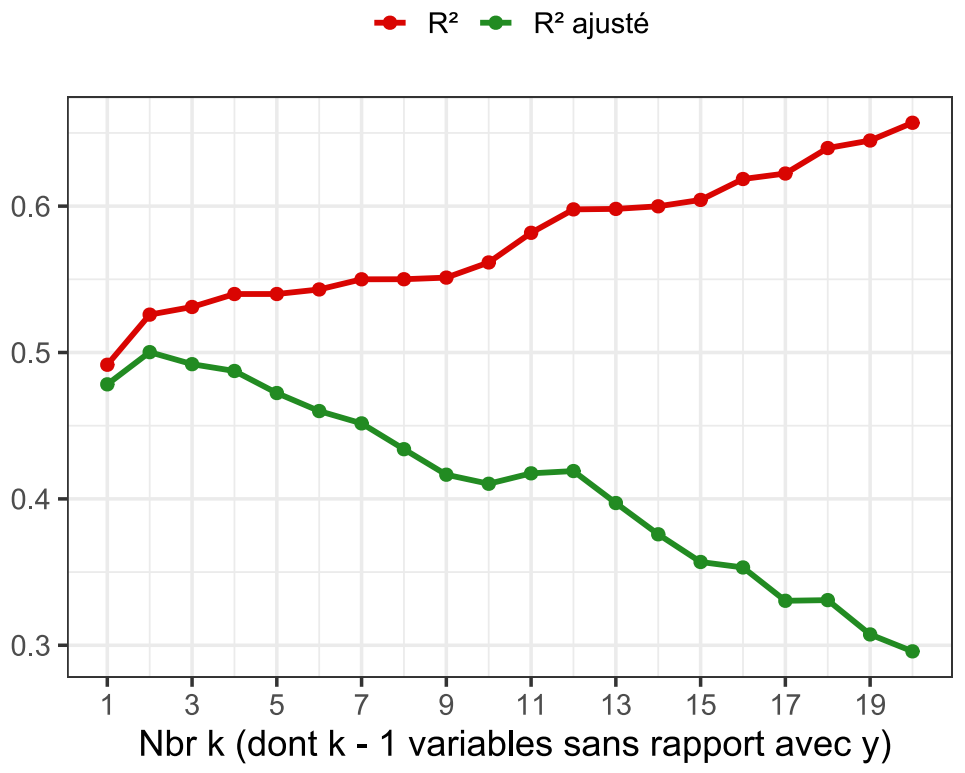
$$R^2 = 1 - \frac{SCR}{SCT}$$

$\Rightarrow$ ne peut **jamais diminuer** quand on ajoute un régresseur, même inutile

R^2 ajusté : pénalise le nombre de régresseurs k

$$\bar{R}^2 = 1 - \frac{SCR/(n-k-1)}{SCT/(n-1)}$$

$\Rightarrow$ **baisse** si k+1 n'apporte presque rien



R^2 vs R^2 ajusté : ajouter des variables aide-t-il vraiment ?

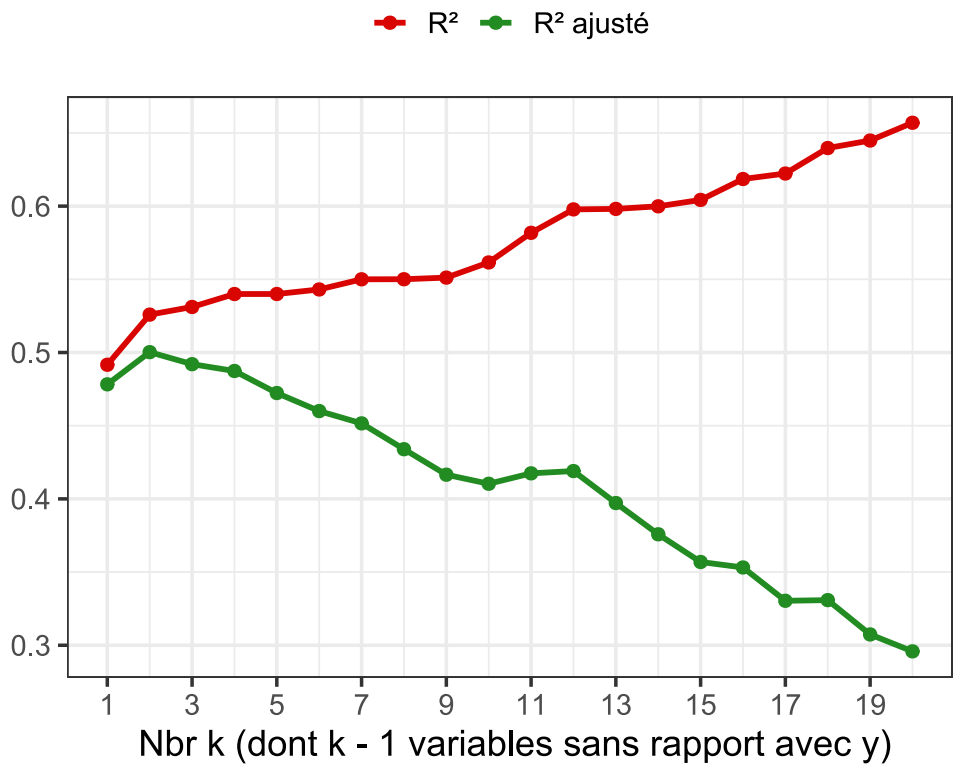
R^2 : part de la variance de y expliquée par le modèle

$$R^2 = 1 - \frac{SCR}{SCT}$$

$\Rightarrow$ ne peut **jamais diminuer** quand on ajoute un régresseur, même inutile

R^2 ajusté : pénalise le nombre de régresseurs k

$$\bar{R}^2 = 1 - \frac{SCR/(n-k-1)}{SCT/(n-1)}$$



$\Rightarrow$ **baisse** si k+1 n'apporte presque rien

Conclusion : pour comparer des modèles avec un nombre de régresseurs différent, on

Tâche 3 : Récapitulatif

10:00

Utilisons les données *STAR* (utilisées dans la tâche précédente) pour revoir les principaux concepts abordés.

1. En utilisant les données filtrées de la tâche précédente, régressez `math` sur `school` (tabulez la variable pour savoir ce qu'elle contient). Interprétez les coefficients. Quelle est la catégorie omise ? Les trouvez-vous surprenants ? Pourquoi ? Quelle pourrait être une variable omise ?

2. Calculez la part des élèves éligibles au déjeuner gratuit (c'est-à-dire `lunch` égal à "free") par catégorie de localisation de l'école. Que constatez-vous ? Ajoutez `free` à la régression de la question précédente. Comment les coefficients changent-ils ?

3. Régressez `math` sur `star`. Après avoir interprété les coefficients, régressez `math` sur `star`, `gender`, `ethnicity`, `lunch`, `degree`, `experience` et `school`. En vous rappelant qu'il s'agit d'une expérience randomisée, la randomisation semble-t-elle avoir été bien faite ?

4. Quel est le R^2 ajusté de la régression multiple précédente ? Comment l'interprétez-vous ? Que pourriez-vous en déduire quant à l'importance des caractéristiques observables individuelles, des enseignants et des écoles dans l'explication des résultats scolaires ?



UNIVERSITÉ DE NAMUR

Bonne journée !

	jeremy.donascimento@unamur.be
	Discord
	Slides