UNIVERSITÉ DE NAMUR

# Econométrie

## Extensions du modèle de régression linéaire

Jérémy Do Nascimento Miguel
Université de Namur
2026-10-15

# Aujourd'hui - Extensions du modèle de régression linéaire

Selon les données et les relations entre les variables d'intérêt, il peut être nécessaire de s'éloigner du modèle de base.



# Aujourd'hui - Extensions du modèle de régression linéaire

Selon les données et les relations entre les variables d'intérêt, il peut être nécessaire de s'éloigner du modèle de base.

Nous allons nous concentrer sur 3 variations importantes :

1. ***Relations non-linéaires*** : modèles logarithmiques et polynomiaux
2. ***Interactions*** entre variables
3. Régression ***standardisée***



# Aujourd'hui - Extensions du modèle de régression linéaire

Selon les données et les relations entre les variables d'intérêt, il peut être nécessaire de s'éloigner du modèle de base.

Nous allons nous concentrer sur 3 variations importantes :

1. ***Relations non-linéaires*** : modèles logarithmiques et polynomiaux
2. ***Interactions*** entre variables
3. Régression ***standardisée***

Dans chaque cas, la façon dont on estime ces coefficients ne change pas (i.e. OLS).



# Aujourd'hui - Extensions du modèle de régression linéaire

Selon les données et les relations entre les variables d'intérêt, il peut être nécessaire de s'éloigner du modèle de base.

Nous allons nous concentrer sur 3 variations importantes :

1. ***Relations non-linéaires*** : modèles logarithmiques et polynomiaux
2. ***Interactions*** entre variables
3. Régression ***standardisée***

Dans chaque cas, la façon dont on estime ces coefficients ne change pas (i.e. OLS).

Applications empiriques :

(i) *frais de scolarité* et *potentiel de revenu*, (ii) *salaire*, *éducation* et *genre*, (iii) *taille de classe* et *performance des élèves*



# Relations Non-Linéaires

# Prendre en compte les relations non-linéaires

Il existe deux "méthodes" principales :



# Prendre en compte les relations non-linéaires

Il existe deux "méthodes" principales :

1. Modèles *log*



# Prendre en compte les relations non-linéaires

Il existe deux "méthodes" principales :

1. Modèles *log*
2. Modèles *polynomiaux*



# Modèles logarithmiques

- Les modèles vus jusqu'à présent peuvent être appelés spécifications ***niveau-niveau***. La variable dépendante et la variable indépendante sont toutes deux mesurées en niveau.

# Modèles logarithmiques

- Les modèles vus jusqu'à présent peuvent être appelés spécifications ***niveau-niveau***. La variable dépendante et la variable indépendante sont toutes deux mesurées en niveau.
    - Ce *niveau* peut être : des euros, des années, un nombre d'élèves, un %

# Modèles logarithmiques

- Les modèles vus jusqu'à présent peuvent être appelés spécifications ***niveau-niveau***. La variable dépendante et la variable indépendante sont toutes deux mesurées en niveau.
  - Ce *niveau* peut être : des euros, des années, un nombre d'élèves, un %
- Prendre le logarithme *naturel* de la variable dépendante et/ou de la (des) variable(s) indépendante(s) nous amène à définir 3 autres types de régressions (abus de notation : $ln(x) = \log_e(x) = \log(x)$) :
  - ***Log - niveau*** :

$$\log(y_i) = \beta_0 + \beta_1 x_{1,i} + \ldots + e_i$$

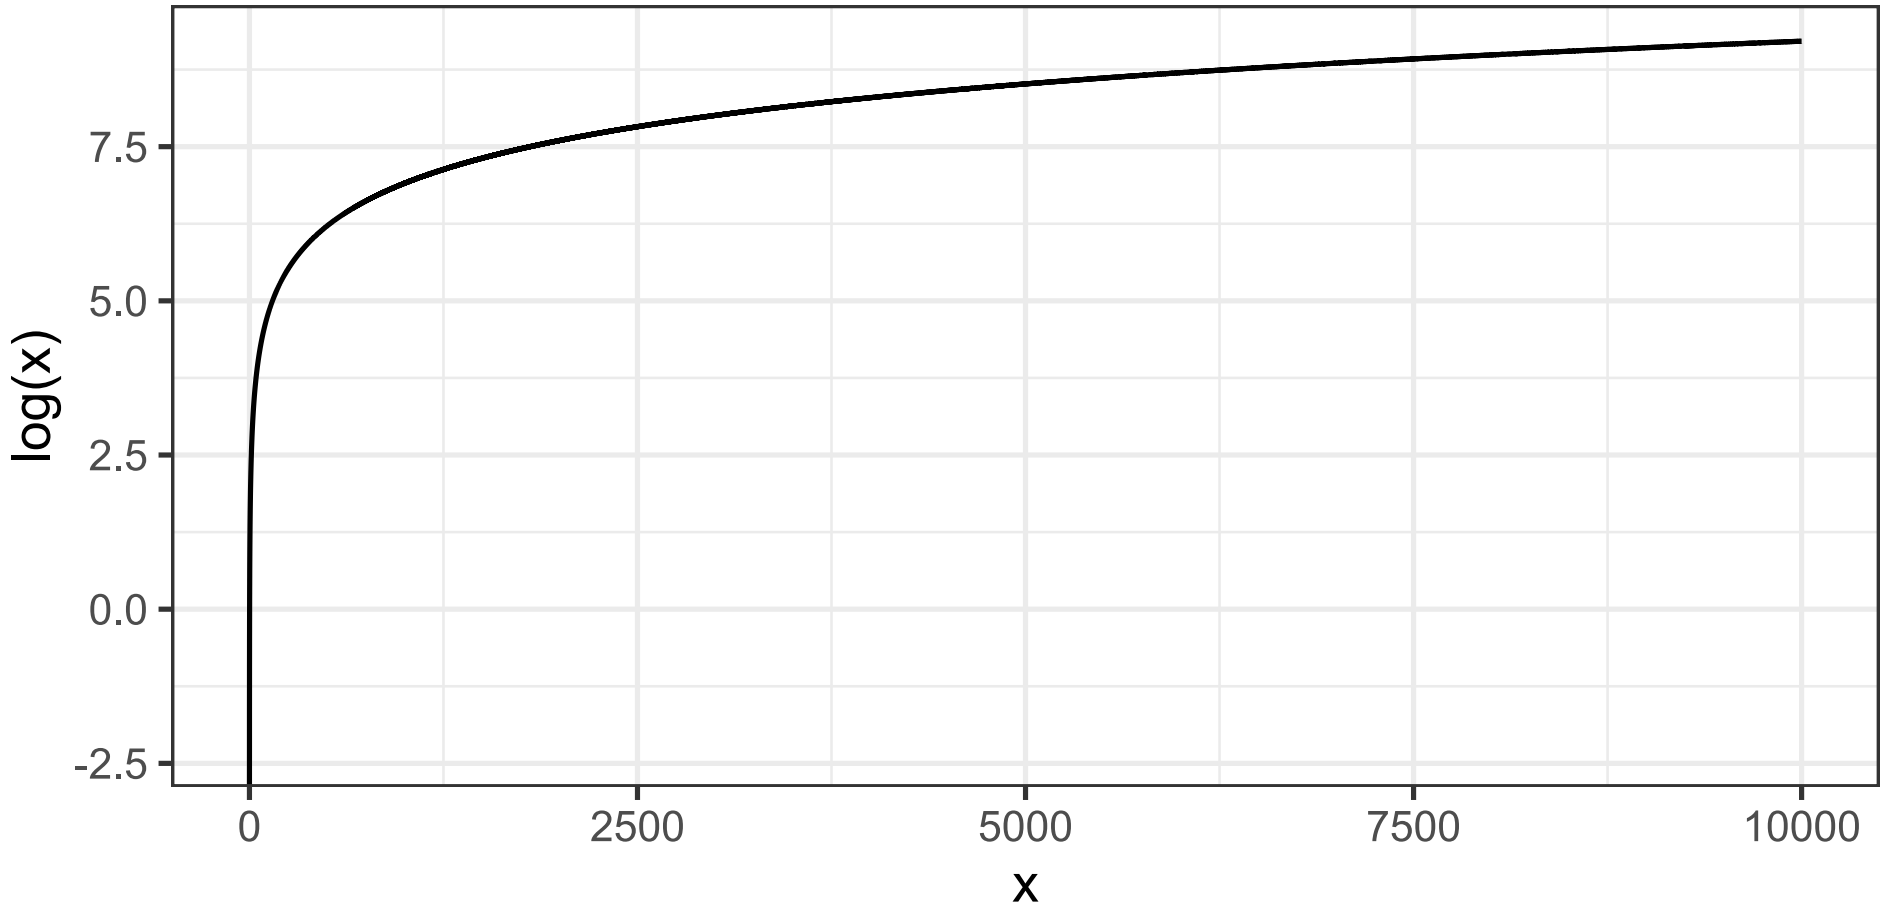
  - ***Niveau - log*** :

$$\mathrm{y}_i = \beta_0 + \beta_1 \log(x_{1,i}) + \ldots + e_i$$

  - ***Log - log*** :

$$\log(y_i) = \beta_0 + \beta_1 \log(x_{1,i}) + \ldots + e_i$$

# La fonction logarithme (naturel) : une introduction 😉



# La fonction logarithme (naturel) : une introduction 😉

La fonction logarithme naturel est la fonction inverse de la fonction exponentielle, i.e. $log(\exp(x)) = x$

# La fonction logarithme (naturel) : une introduction 😉

La fonction logarithme naturel est la fonction inverse de la fonction exponentielle, i.e. $log(\exp(x)) = x$

$\rightarrow$ puisque pour tout $x$, $\exp(x) > 0 \implies$ la fonction logarithme naturel n'est définie que pour des ***valeurs strictement positives*** ! (Elle n'est pas définie en 0 !)

# La fonction logarithme (naturel) : une introduction 😉

La fonction logarithme naturel est la fonction inverse de la fonction exponentielle, i.e. $log(\exp(x)) = x$

$\rightarrow$ puisque pour tout $x$, $\exp(x) > 0 \implies$ la fonction logarithme naturel n'est définie que pour des ***valeurs strictement positives*** ! (Elle n'est pas définie en 0 !)

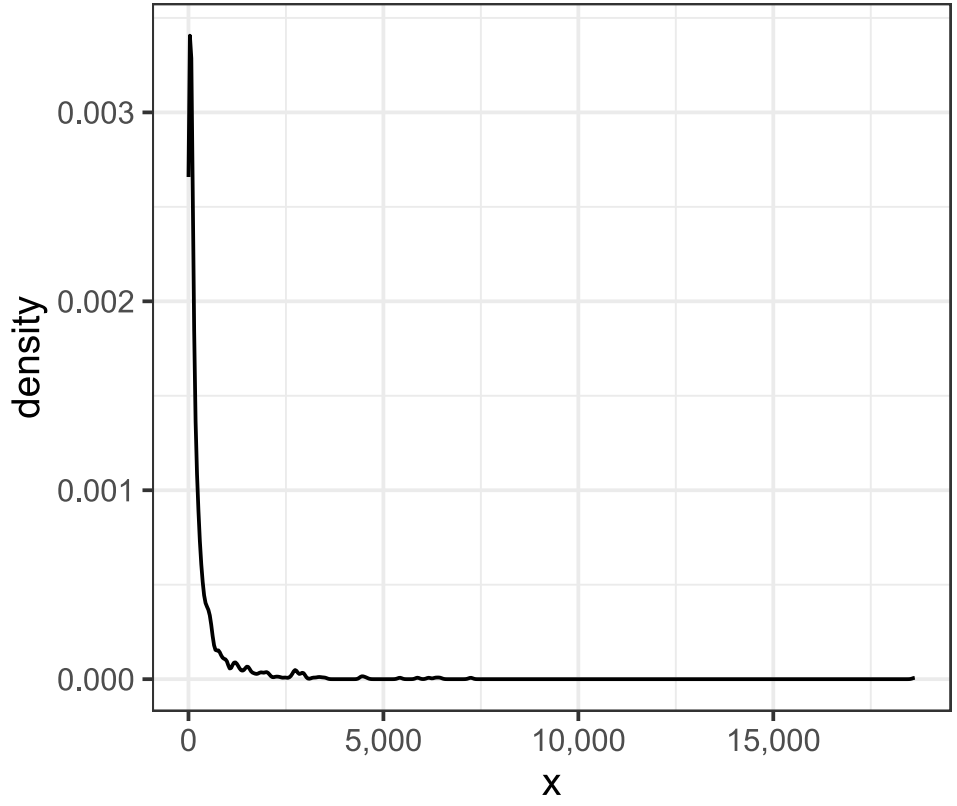
⚠️ Vous ne pouvez logger vos variables que si elles ne prennent pas de valeurs nulles ou négatives ! Pensez-y toujours avant de prendre le log de votre variable dépendante ou indépendante(s)

# La fonction logarithme (naturel) : une introduction 😉

Si vous avez des distributions très *asymétriques*, prendre le log la rendra plus proche d'une *distribution normale*

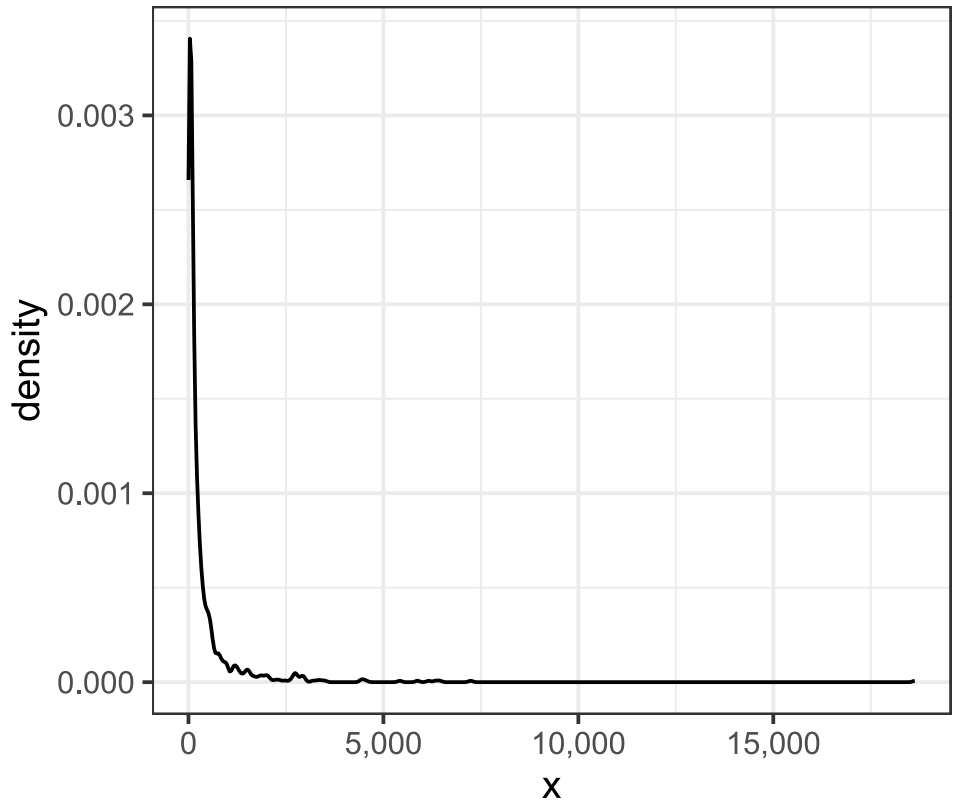
# La fonction logarithme (naturel) : une introduction 😉

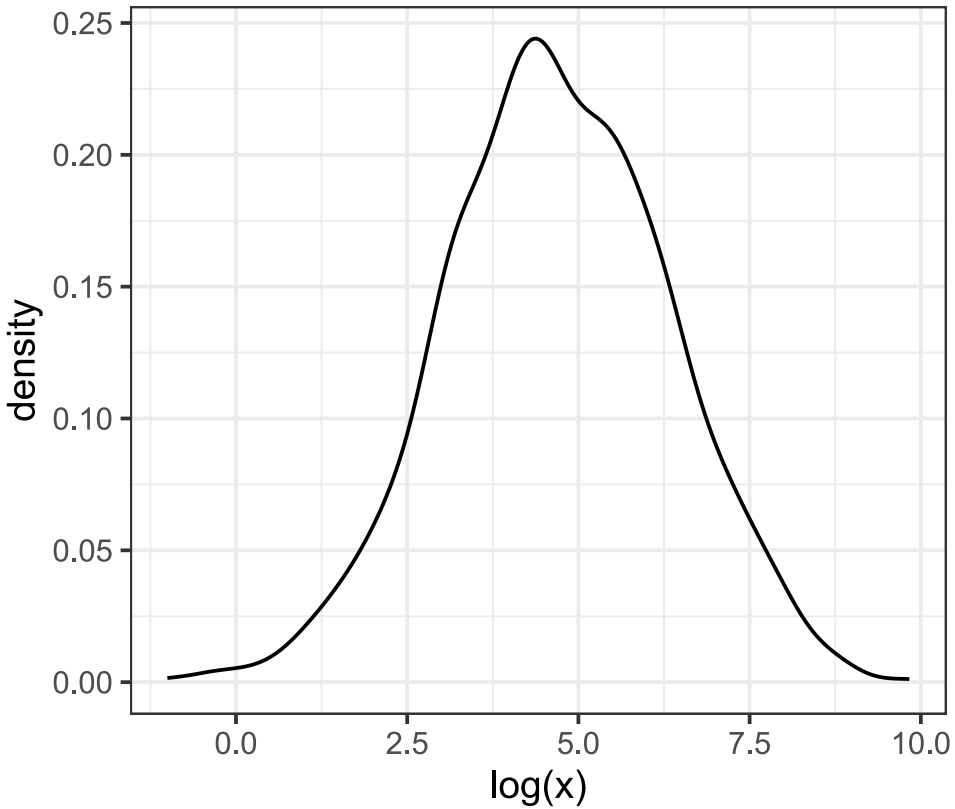
Si vous avez des distributions très ***asymétriques***, prendre le log la rendra plus proche d'une ***distribution normale***



# La fonction logarithme (naturel) : une introduction 😉

Si vous avez des distributions très ***asymétriques***, prendre le log la rendra plus proche d'une ***distribution normale***



# Modèles logarithmiques : interprétations simplifiées

| Spécification | Modèle | Interprétation de $\beta_1$ |
|---|---|---|
| Niveau - Niveau | $y = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1$ **changement d'une unité** de y |
| Log - Niveau | $\log(y) = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y |
| Niveau - Log | $y = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1/100$ **changement d'une unité** de y |
| Log - Log | $\log(y) = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1$ **changement en pourcentage** de y |



# Modèles logarithmiques : interprétations simplifiées

| Spécification | Modèle | Interprétation de $\beta_1$ |
|---|---|---|
| Niveau - Niveau | $y = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1$ **changement d'une unité** de y |
| Log - Niveau | $\log(y) = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y |
| Niveau - Log | $y = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1/100$ **changement d'une unité** de y |
| Log - Log | $\log(y) = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1$ **changement en pourcentage** de y |



- Cela peut ressembler à des recettes de cuisine mais bien sûr, cela peut être dérivé avec des mathématiques relativement simples.

# Modèles logarithmiques : interprétations simplifiées

| Spécification | Modèle | Interprétation de $\beta_1$ |
|---|---|---|
| Niveau - Niveau | $y = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1$ **changement d'une unité** de y |
| Log - Niveau | $\log(y) = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y |
| Niveau - Log | $y = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1/100$ **changement d'une unité** de y |
| Log - Log | $\log(y) = \beta_0 + \beta_1 \log(x) + e$ | Une augmentation d'**un pourcent** de $x$ est associée, en moyenne, à un $\beta_1$ **changement en pourcentage** de y |



- Cela peut ressembler à des recettes de cuisine mais bien sûr, cela peut être dérivé avec des mathématiques relativement simples.

# Modèles logarithmiques : interprétations générales

Pour *toute augmentation de $x$, $\Delta x$, et tout $\beta_1$* ($\Delta x = 5\% = 0.05 \implies 1 + \Delta x = 1.05$) :

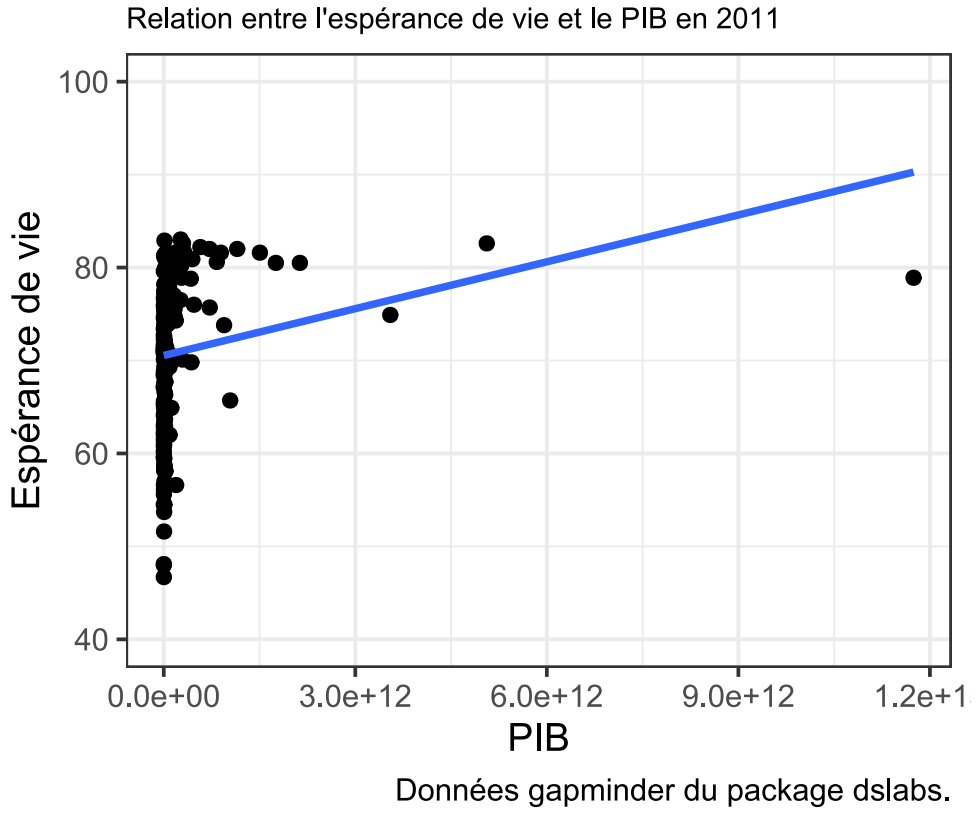
| **Spécification** | **Modèle** | **Interprétation de $\beta_1$** |
|---|---|---|
| Niveau - Niveau | $y = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1$ **changement d'une unité** de y |
| Log - Niveau | $\log(y) = \beta_0 + \beta_1 x + e$ | Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $(e^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y |
| Niveau - Log | $y = \beta_0 + \beta_1 \log(x) + e$ | Une $\Delta x$ augmentation en **pourcentage** de $x$ est associée, en moyenne, à un $\beta_1 \times \log(1 + \Delta x)$ **changement d'une unité** de y |
| Log - Log | $\log(y) = \beta_0 + \beta_1 \log(x) + e$ | Une $\Delta x$ augmentation en **pourcentage** de $x$ est associée, en moyenne, à un $((1 + \Delta x)^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y |

# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.

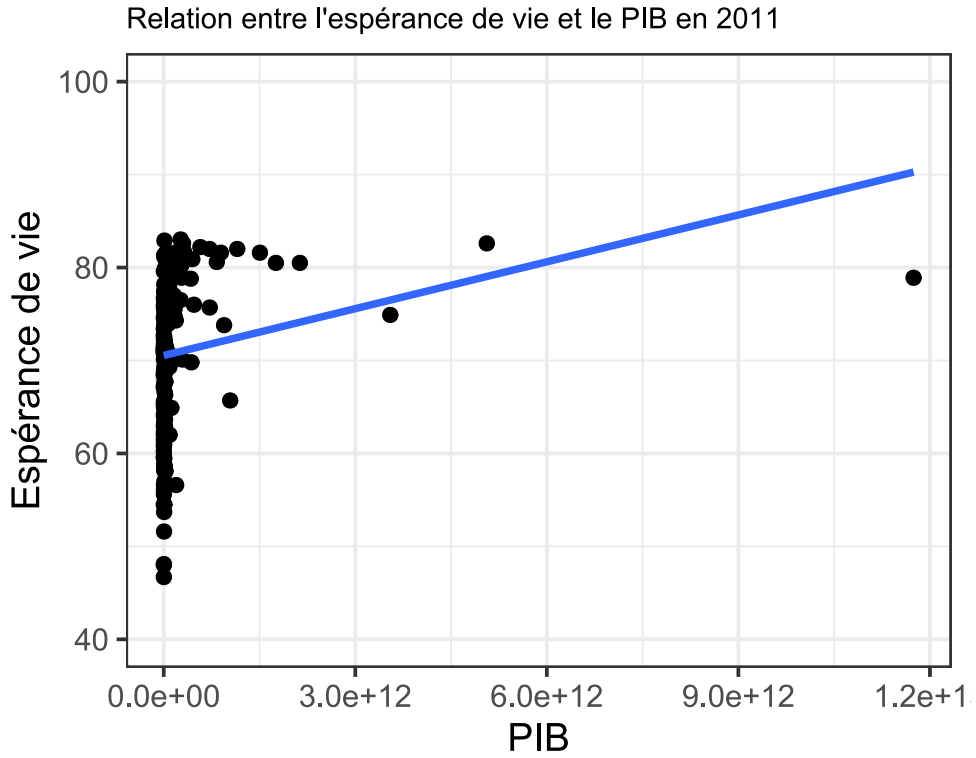
# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.

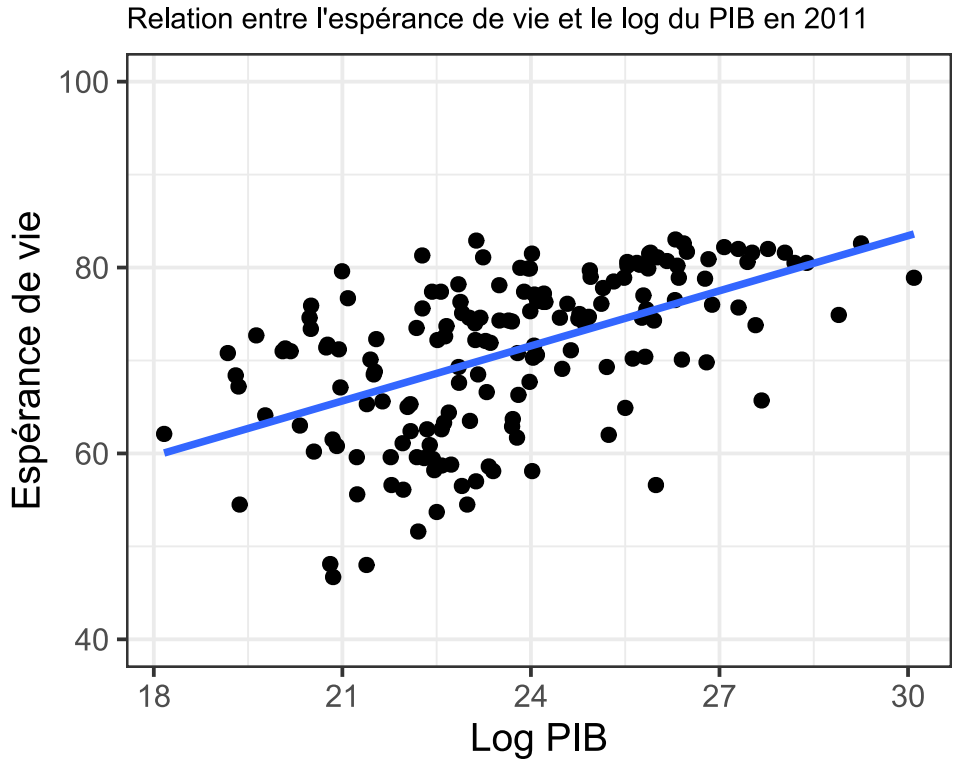


# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.



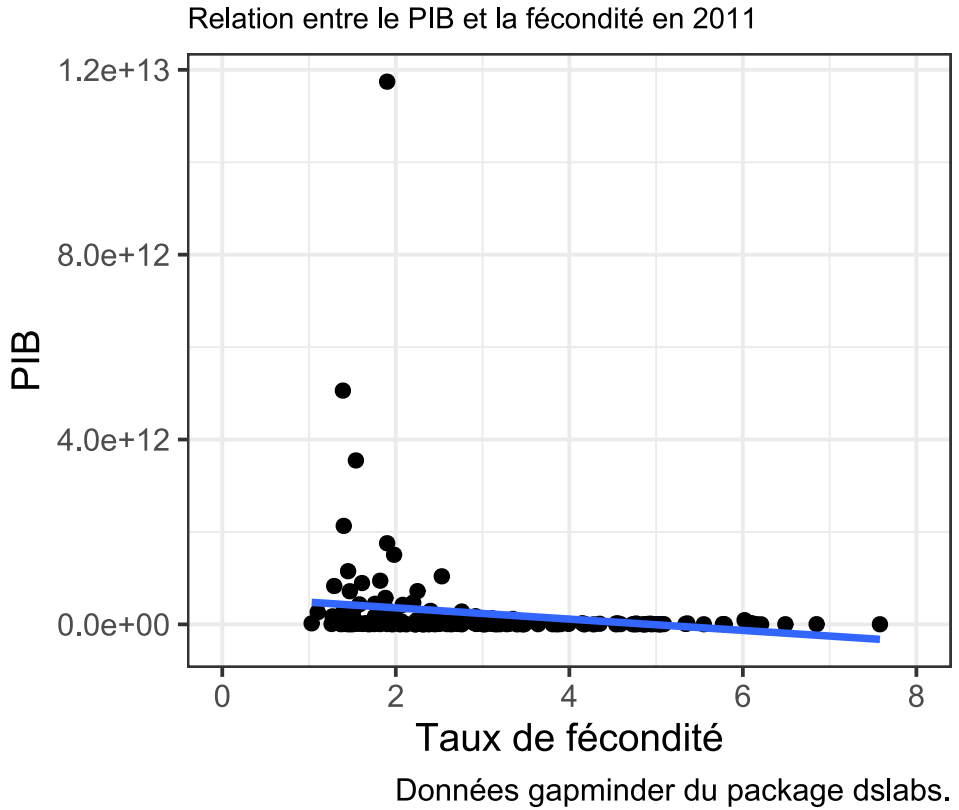

Données gapminder du package dslabs.




Données gapminder du package dslabs.

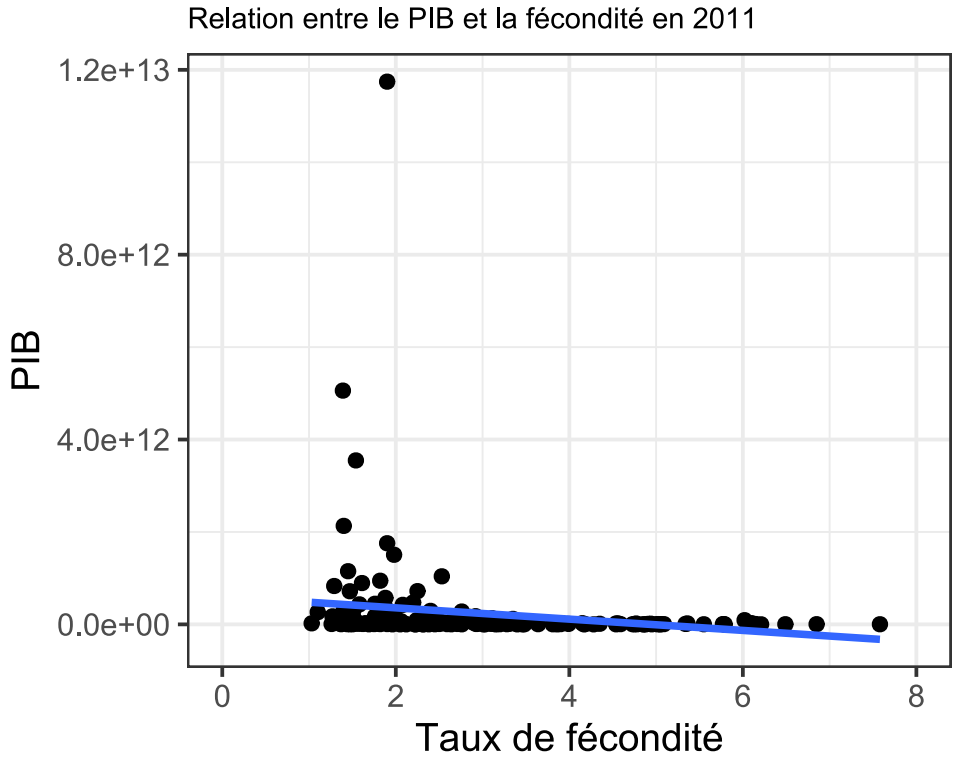
# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.

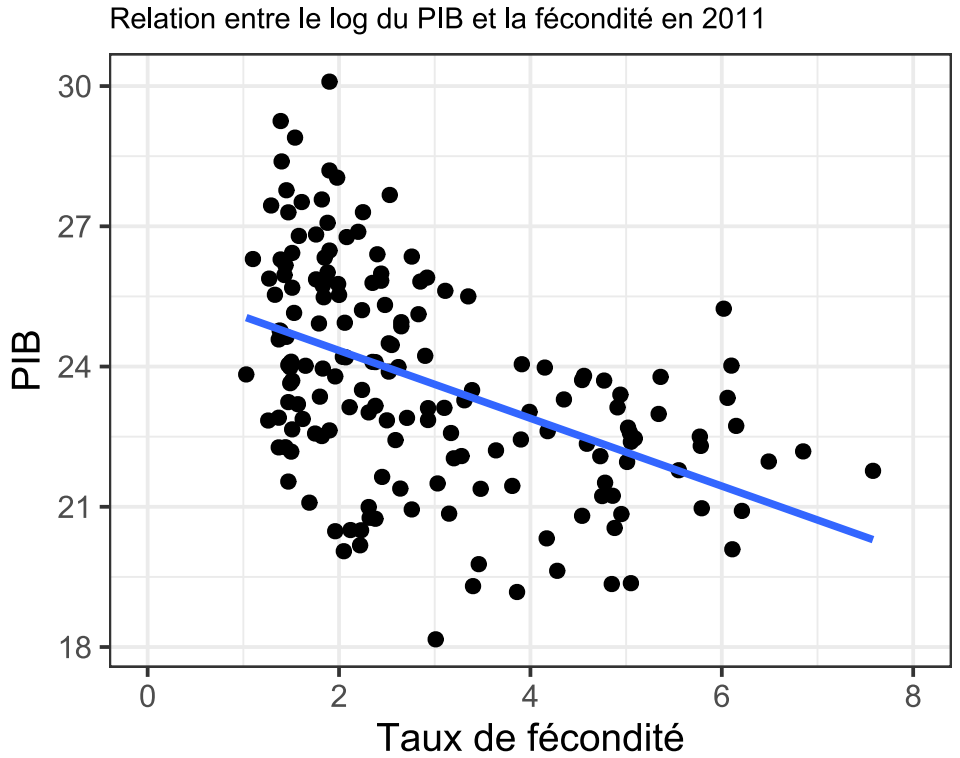


# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.




Données gapminder du package dslabs.




Données gapminder du package dslabs.

# Quand utiliser des modèles logarithmiques ?

1. Si la relation entre $x$ et $y$ ressemble à une fonction logarithmique ou exponentielle.
2. Pour interpréter facilement les coefficients comme des ***élasticités***, qui jouent un rôle central en théorie économique.

***Élasticité de $y$ par rapport à $x$ :*** changement en pourcentage de $y$ suite à une augmentation de 1% de $x$.

# Prendre en compte d'autres types de relations non-linéaires

Que se passe-t-il si la relation entre $x$ et $y$ n'est pas exponentielle/logarithmique ?



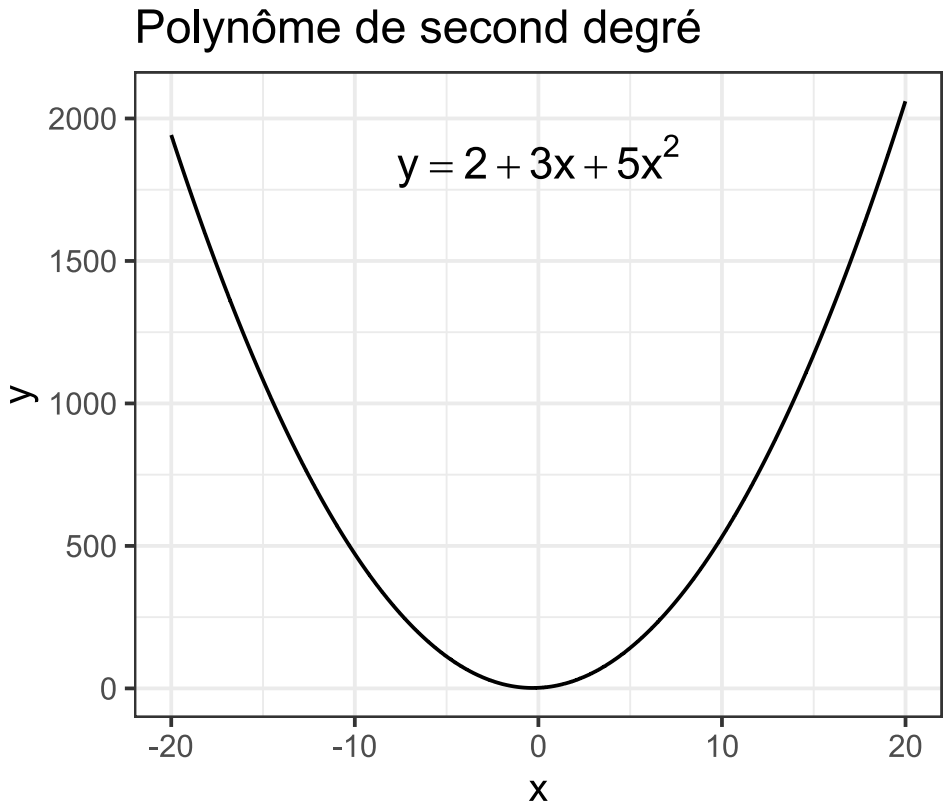
# Prendre en compte d'autres types de relations non-linéaires

Que se passe-t-il si la relation entre $x$ et $y$ n'est pas exponentielle/logarithmique ?

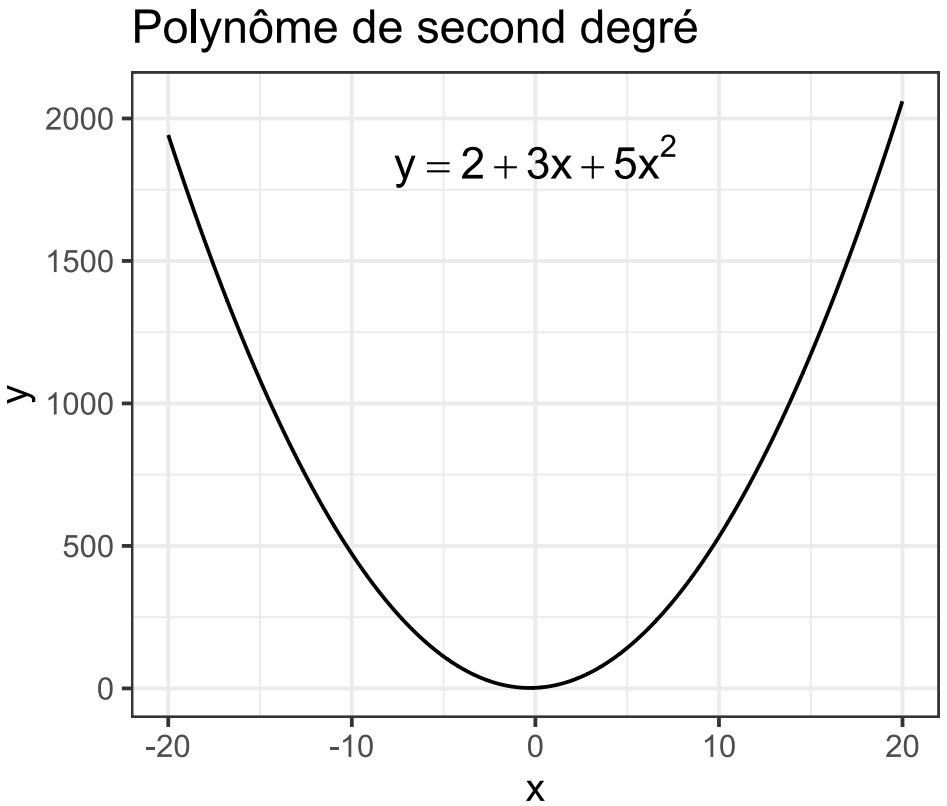
$\rightarrow$ régressions ***polynomiales*** : il suffit de prendre une fonction polynomiale du régresseur !

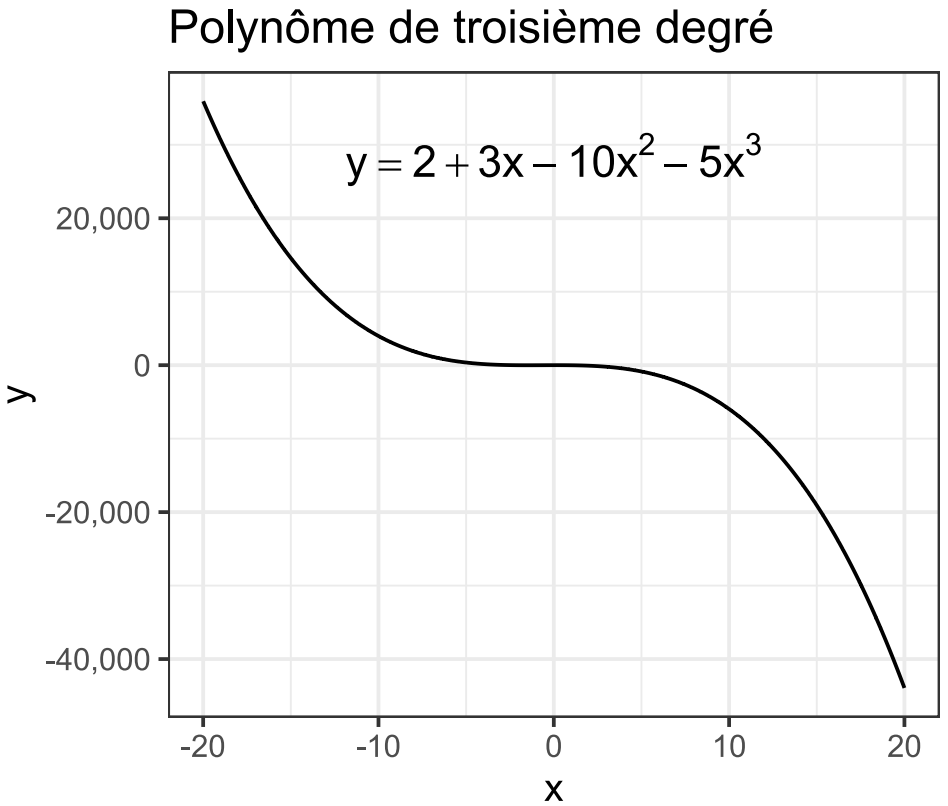


# Polynomial Wut ? 😳



# Polynomial Wut ? 😳



# Régressions polynomiales

Qu'est-ce que cela signifie en pratique ?



# Régressions polynomiales

Qu'est-ce que cela signifie en pratique ?

$\rightarrow$ ajouter un ordre plus élevé du régresseur à la régression, selon la relation visuelle (ou attendue)



# Régressions polynomiales

Qu'est-ce que cela signifie en pratique ?

$\rightarrow$ ajouter un ordre plus élevé du régresseur à la régression, selon la relation visuelle (ou attendue)

Plusieurs façons de le faire en `R` :

```
lm(y ~ x + I(x^2) + I(x^3), data)
```



# Régressions polynomiales

Qu'est-ce que cela signifie en pratique ?

$\rightarrow$ ajouter un ordre plus élevé du régresseur à la régression, selon la relation visuelle (ou attendue)

Plusieurs façons de le faire en `R` :

```
lm(y ~ x + I(x^2) + I(x^3), data)
```

```
lm(y ~ poly(x, 3, raw = TRUE), data)
```



# Régressions polynomiales

Qu'est-ce que cela signifie en pratique ?

→ ajouter un ordre plus élevé du régresseur à la régression, selon la relation visuelle (ou attendue)

Plusieurs façons de le faire en `R` :

```
lm(y ~ x + I(x^2) + I(x^3), data)
```

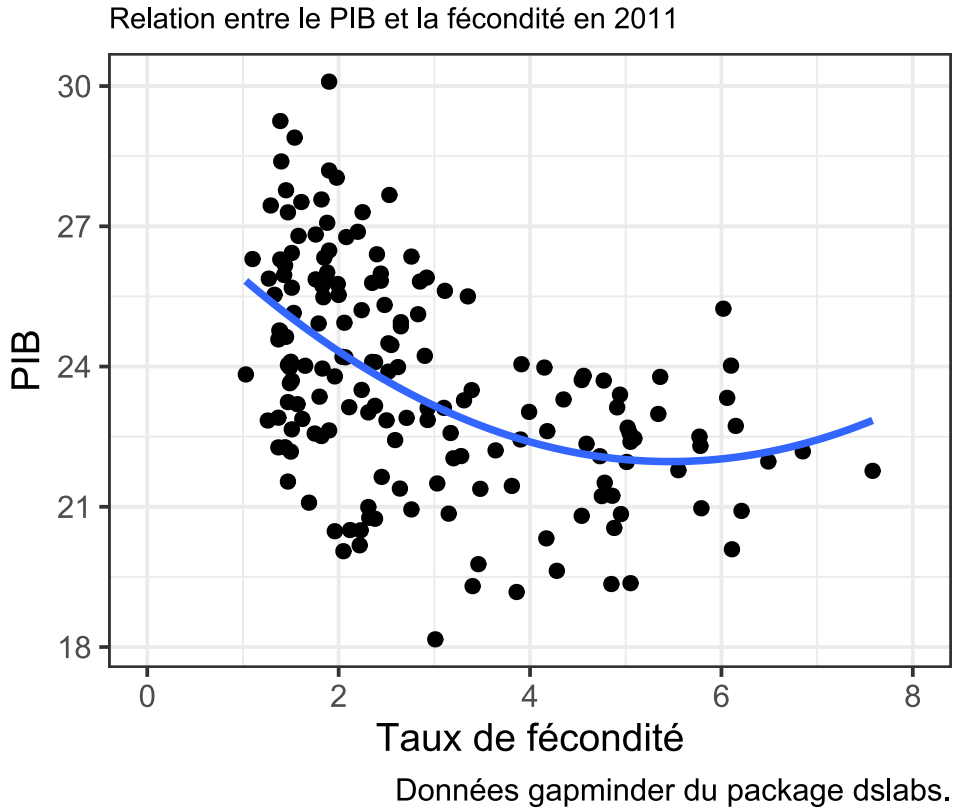
```
lm(y ~ poly(x, 3, raw = TRUE), data)
```

⚠️ Pour que la forme fonctionnelle soit véritablement polynomiale, les coefficients associés à tous les termes doivent être statistiquement différents de zéro. Nous verrons plus loin comment vérifier cette condition.



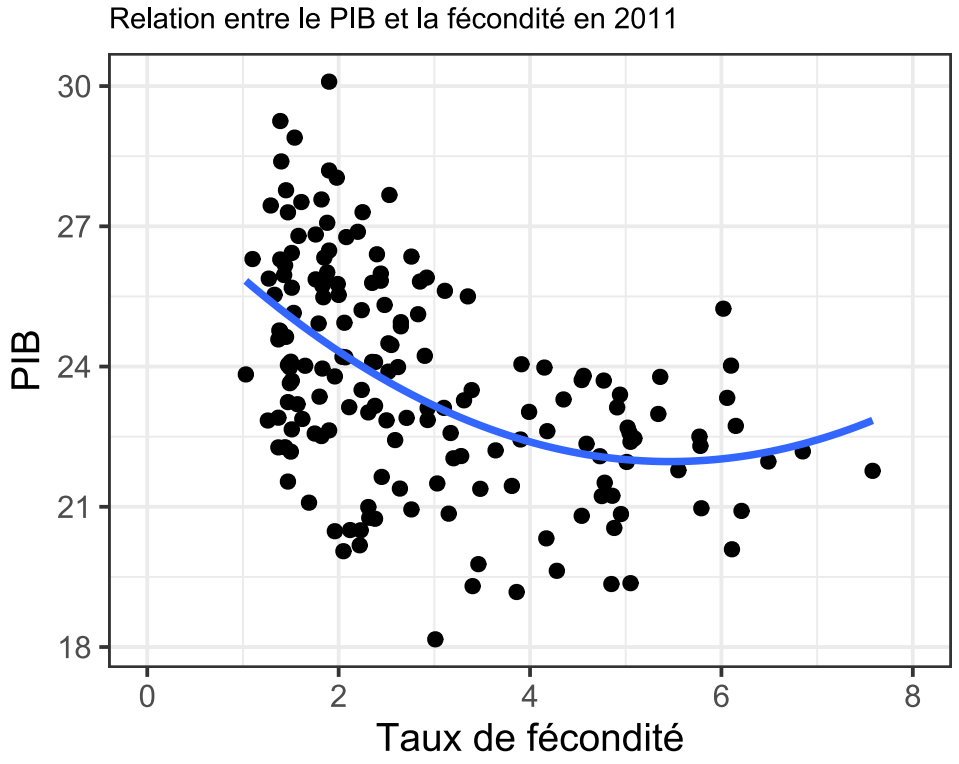
# Régressions polynomiales

*2ème ordre :*



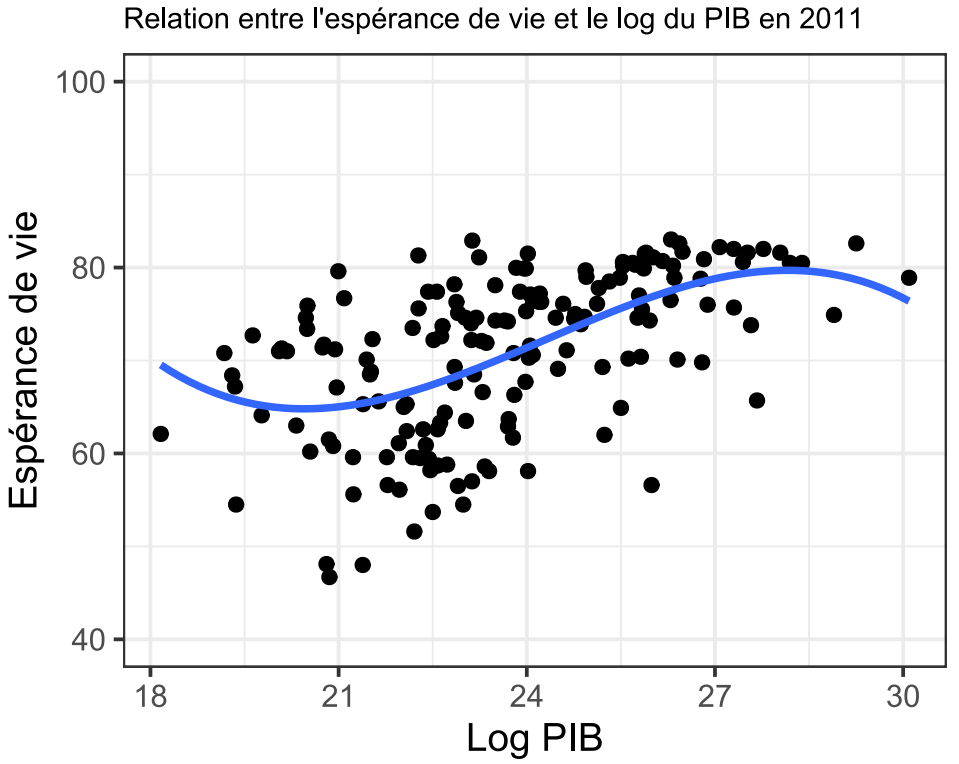
# Régressions polynomiales

*2ème ordre :*




Données gapminder du package dslabs.

*3ème ordre :*




Données gapminder du package dslabs.

# Rappel : trouver l'extremum d'une reg. quadratique

Considérons le modèle estimé :

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + e$$

L'effet marginal de (X) sur (Y) est obtenu en dérivant le modèle :

$$\frac{\partial y}{\partial x} = \beta_1 + 2\beta_2 x$$



# Rappel : trouver l'extremum d'une reg. quadratique

Considérons le modèle estimé :

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + e$$

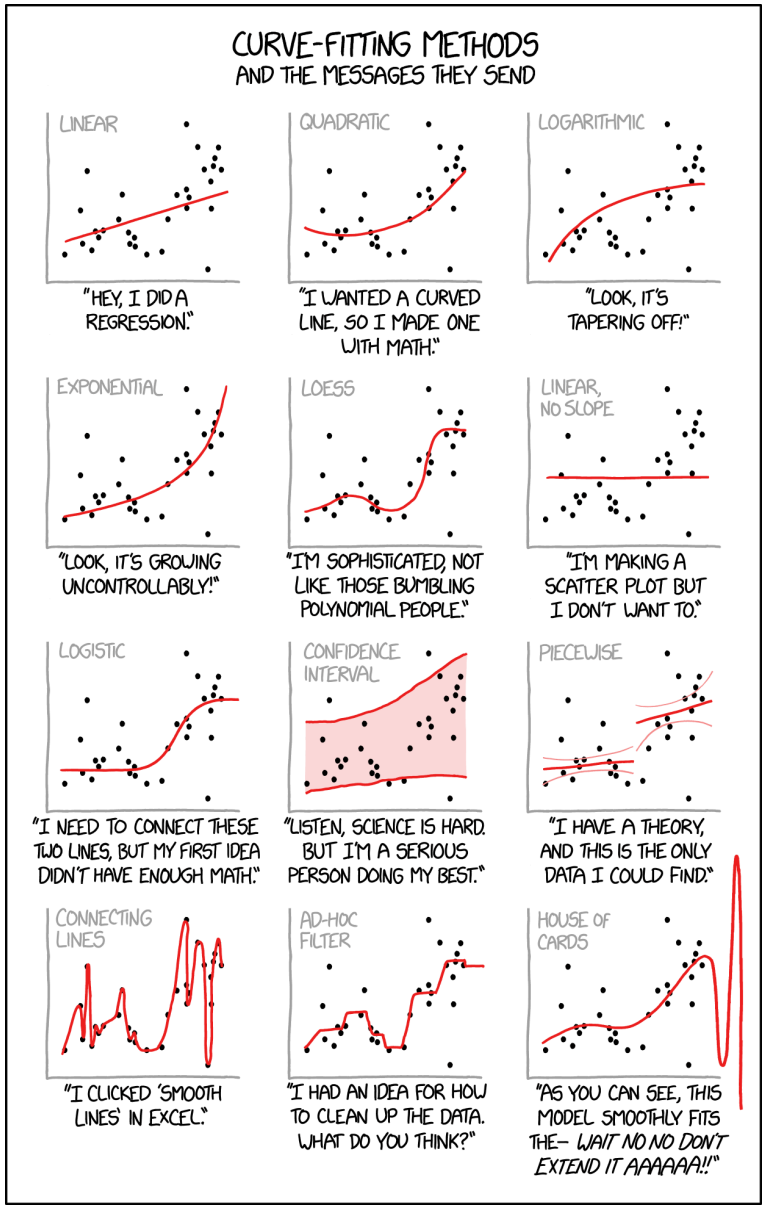
L'effet marginal de (X) sur (Y) est obtenu en dérivant le modèle :

$$\frac{\partial y}{\partial x} = \beta_1 + 2\beta_2 x$$

Le **point de retournement** correspond au point où la pente est nulle : $$ \begin{aligned} \beta_1 + 2\beta_2x^ &= *0* | *x^* & = -\frac{\beta_1}{2\beta_2} \end{aligned} $$

Interprétation

- Si (\beta_2 > 0) : la courbe est en **U** donc (x^*) est un *minimum*.*
- Si (\beta_2 < 0) : la courbe est en **U inversé** donc (x^*) est un *maximum*.*


CURVE-FITTING METHODS
AND THE MESSAGES THEY SEND
LINEAR
"HEY, I DID A REGRESSION."
QUADRATIC
"I WANTED A CURVED LINE, SO I MADE ONE WITH MATH."
LOGARITHMIC
"LOOK, IT'S TAPERING OFF!"
EXPONENTIAL
"LOOK, IT'S GROWING UNCONTROLLABLY!"
LOESS
"I'M SOPHISTICATED, NOT LIKE THOSE BUMBLING POLYNOMIAL PEOPLE."
LINEAR, NO SLOPE
"I'M MAKING A SCATTER PLOT BUT I DON'T WANT TO."
LOGISTIC
"I NEED TO CONNECT THESE TWO LINES, BUT MY FIRST IDEA DIDN'T HAVE ENOUGH MATH."
CONFIDENCE INTERVAL
"LISTEN, SCIENCE IS HARD. BUT I'M A SERIOUS PERSON DOING MY BEST."
PIECEWISE
"I HAVE A THEORY, AND THIS IS THE ONLY DATA I COULD FIND."
CONNECTING LINES
"I CLICKED 'SMOOTH LINES' IN EXCEL."
AD-HOC FILTER
"I HAD AN IDEA FOR HOW TO CLEAN UP THE DATA. WHAT DO YOU THINK?"
HOUSE OF CARDS
"AS YOU CAN SEE, THIS MODEL SMOOTHLY FITS THE– WAIT NO NO DON'T EXTEND IT AAAAAA!!"

# Tâche 1 : Relations non-linéaires

10:00

1. Chargez les données ici. Ce jeu de données contient des informations sur les frais de scolarité et les revenus estimés des diplômés d'universités américaines. Plus de détails ici.

2. Créez un nuage de points du revenu médian en milieu de carrière estimé (`mid_career_pay`) $(axe - y)$ en fonction des frais de scolarité hors état (`out_of_state_tuition`) $(axe - x)$. Diriez-vous que la relation est globalement linéaire ou plutôt non-linéaire ? Utilisez `geom_smooth(method = "lm", se = F) + geom_smooth(method = "lm", se = F, formula = y ~ poly(x, 2, raw= T))` pour ajuster à la fois une droite de régression linéaire et une régression de second ordre. Laquelle semble la plus appropriée cette fois-ci ?

3. Créez une variable égale aux frais de scolarité hors état divisés par 1000. Régressez le revenu médian en milieu de carrière sur les frais de scolarité hors état divisés par 1000. Interprétez le coefficient.

4. Régressez le revenu médian en milieu de carrière sur les frais de scolarité hors état divisés par 1000 et son carré. *Indice :* vous pouvez utiliser soit `poly(x, 2, raw = T)` soit `x + I(x^2)`, où x est votre régresseur. Que signifie le signe positif du terme au carré ?



# Termes d'Interaction

# Interagir des régresseurs

- On interagit deux régresseurs lorsque l'on pense que ***l'effet de l'un dépend de la valeur de l'autre***.
    - *Exemple :* Le rendement de l'éducation sur le salaire varie selon le genre.

# Interagir des régresseurs

- On interagit deux régresseurs lorsque l'on pense que ***l'effet de l'un dépend de la valeur de l'autre***.
    - *Exemple :* Le rendement de l'éducation sur le salaire varie selon le genre.
- En pratique, si l'on interagit $x_1$ et $x_2$, on écrirait notre modèle ainsi :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{1,i} \times x_{2,i} + \ldots + e_i$$

# Interagir des régresseurs

- On interagit deux régresseurs lorsque l'on pense que ***l'effet de l'un dépend de la valeur de l'autre***.
    - *Exemple :* Le rendement de l'éducation sur le salaire varie selon le genre.
- En pratique, si l'on interagit $x_1$ et $x_2$, on écrirait notre modèle ainsi :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{1,i} \times x_{2,i} + \ldots + e_i$$

- L'interprétation de $\beta_1$, $\beta_2$, et $\beta_3$ dépendra du type de $x_1$ et $x_2$.



# Interagir des régresseurs

- On interagit deux régresseurs lorsque l'on pense que ***l'effet de l'un dépend de la valeur de l'autre***.
  - *Exemple :* Le rendement de l'éducation sur le salaire varie selon le genre.
- En pratique, si l'on interagit $x_1$ et $x_2$, on écrirait notre modèle ainsi :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \beta_3 x_{1,i} \times x_{2,i} + \ldots + e_i$$

- L'interprétation de $\beta_1$, $\beta_2$, et $\beta_3$ dépendra du type de $x_1$ et $x_2$.
- Concentrons-nous sur les cas où un régresseur est une variable ***binaire/catégorielle*** et l'autre est ***continue***.
- Cela vous donnera l'intuition pour les autres cas :
  - Les deux régresseurs sont des variables binaires/catégorielles,
  - Les deux régresseurs sont des variables continues.



# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.



# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?



# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?

Notre modèle de régression devient :

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i \times \text{experience}_i + e_i$$

# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?

Notre modèle de régression devient :

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i \times \text{experience}_i + e_i$$

Effet d'être en petite classe avec un.e enseignant.e ayant 10 ans d'expérience ?



# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?

Notre modèle de régression devient :

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i \times \text{experience}_i + e_i$$

Effet d'être en petite classe avec un.e enseignant.e ayant 10 ans d'expérience ?

$$\mathbb{E}[\text{score}_i | \text{small}_i = 1 \ \& \ \text{experience}_i = 10] = \beta_0 + \beta_1 + \beta_2 * 10 + \beta_3 * 10$$

# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?

Notre modèle de régression devient :

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i \times \text{experience}_i + e_i$$

Effet d'être en petite classe avec un.e enseignant.e ayant 10 ans d'expérience ?

$$\mathbb{E}[\text{score}_i | \text{small}_i = 1 \ \& \ \text{experience}_i = 10] = \beta_0 + \beta_1 + \beta_2 * 10 + \beta_3 * 10$$

$$\mathbb{E}[\text{score}_i | \text{small}_i = 0 \ \& \ \text{experience}_i = 10] = \beta_0 + \beta_2 * 10$$



# Interagir des régresseurs : Exemple

Nous allons utiliser les données de l'expérience *STAR* qui étudie l'effet des petites classes sur l'apprentissage des élèves aux Etats-Unis.

Comment l'effet d'être dans une petite classe vs une classe régulière varie-t-il avec l'expérience de l'enseignant.e ?

Notre modèle de régression devient :

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i \times \text{experience}_i + e_i$$

Effet d'être en petite classe avec un.e enseignant.e ayant 10 ans d'expérience ?

$$\mathbb{E}[\text{score}_i | \text{small}_i = 1 \ \& \ \text{experience}_i = 10] = \beta_0 + \beta_1 + \beta_2 * 10 + \beta_3 * 10$$

$$\mathbb{E}[\text{score}_i | \text{small}_i = 0 \ \& \ \text{experience}_i = 10] = \beta_0 + \beta_2 * 10$$

$$\begin{aligned}\mathbb{E}[\text{score}_i | \text{small}_i = 1 \ \& \ \text{experience}_i = 10] - \mathbb{E}[\text{score}_i | \text{small}_i = 0 \ \& \ \text{experience}_i = 10] \\ = \beta_0 + \beta_1 + \beta_2 * 10 + \beta_3 * 10 - (\beta_0 + \beta_2 * 10) \\ = \beta_1 + \beta_3 * 10\end{aligned}$$

# Interagir des régresseurs

En exécutant la régression pour le score en `math` (pour tous les niveaux), on obtient :

```
lm(math ~ small+ experience + small*experience, star_df)
```

```
##
## Call:
## lm(formula = math ~ small + experience + small * experience,
##     data = star_df)
##
## Coefficients:
##          (Intercept)             smallTRUE            experience
##              534.1919                15.8906                 1.3305
## smallTRUE:experience
##               -0.3034
```

*Interprétation :*

# Interagir des régresseurs

En exécutant la régression pour le score en `math` (pour tous les niveaux), on obtient :

```
lm(math ~ small+ experience + small*experience, star_df)
```

```
##
## Call:
## lm(formula = math ~ small + experience + small * experience,
##     data = star_df)
##
## Coefficients:
##          (Intercept)             smallTRUE            experience
##              534.1919                15.8906                 1.3305
## smallTRUE:experience
##               -0.3034
```

*Interprétation :*

- Le terme d'interaction permet à l'impact d'être dans une petite classe de varier avec l'expérience de l'enseignant.e.



# Interagir des régresseurs

En exécutant la régression pour le score en `math` (pour tous les niveaux), on obtient :

```
lm(math ~ small+ experience + small*experience, star_df)
```

```
##
## Call:
## lm(formula = math ~ small + experience + small * experience,
##     data = star_df)
##
## Coefficients:
##          (Intercept)             smallTRUE            experience
##              534.1919                15.8906                 1.3305
## smallTRUE:experience
##               -0.3034
```

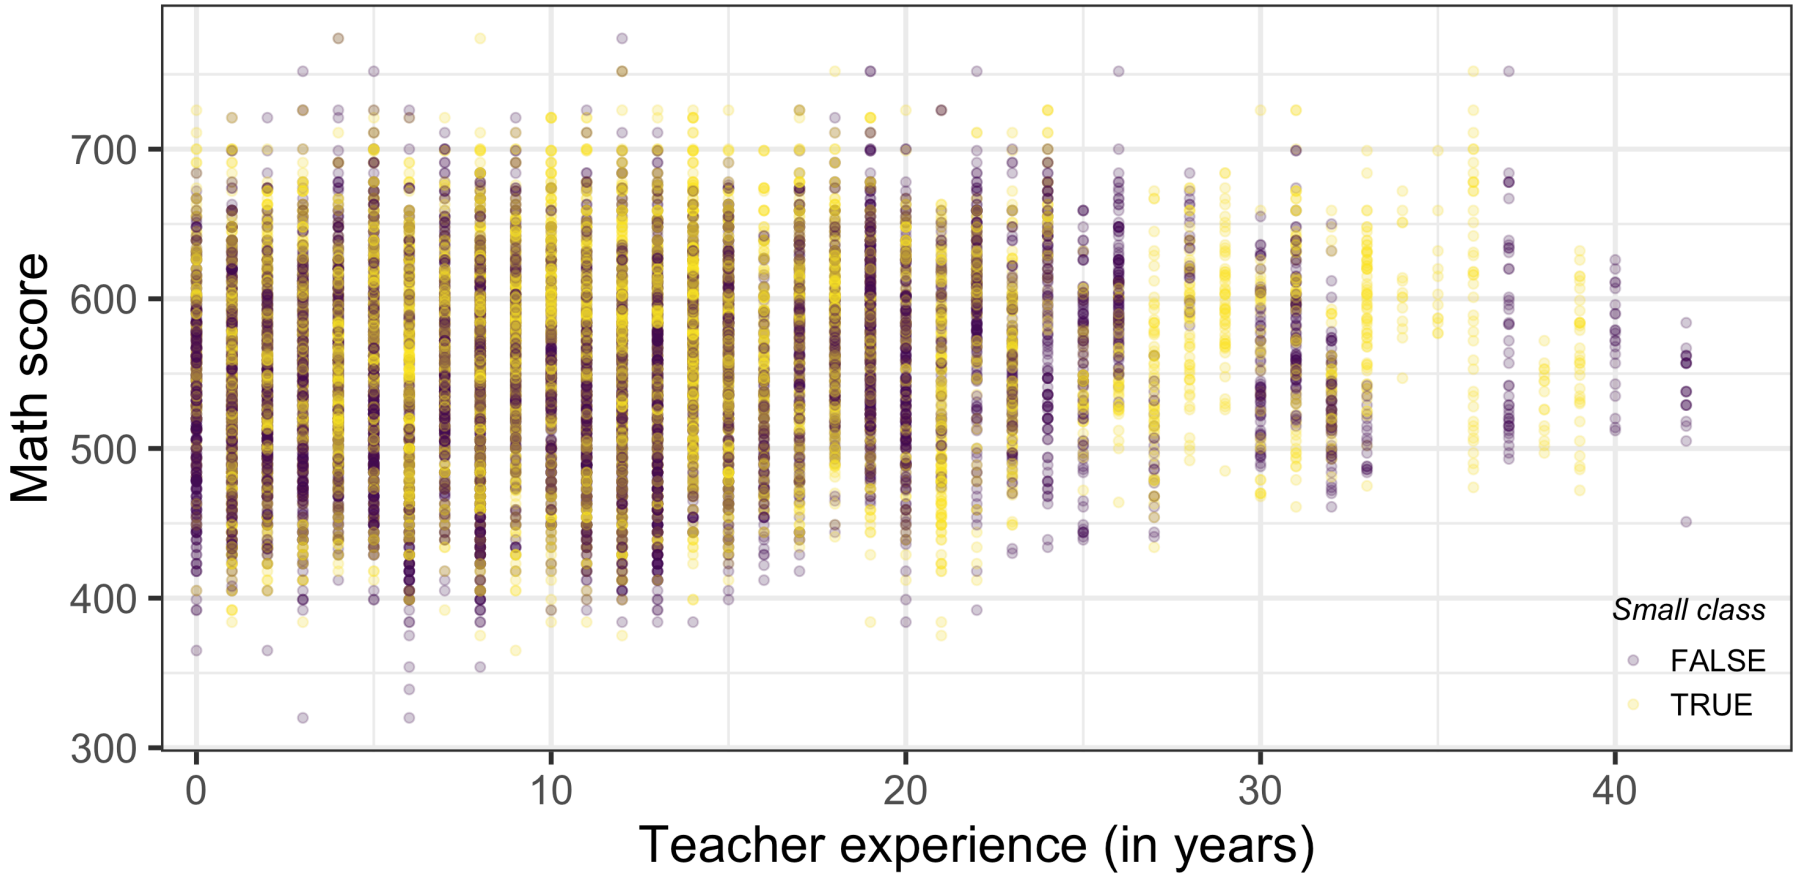
*Interprétation :*

- Le terme d'interaction permet à l'impact d'être dans une petite classe de varier avec l'expérience de l'enseignant.e.
- En particulier, on observe toujours un *impact positif d'être dans une petite classe* sur le score en math,
- mais cet *effet diminue avec l'expérience de l'enseignant.e*.



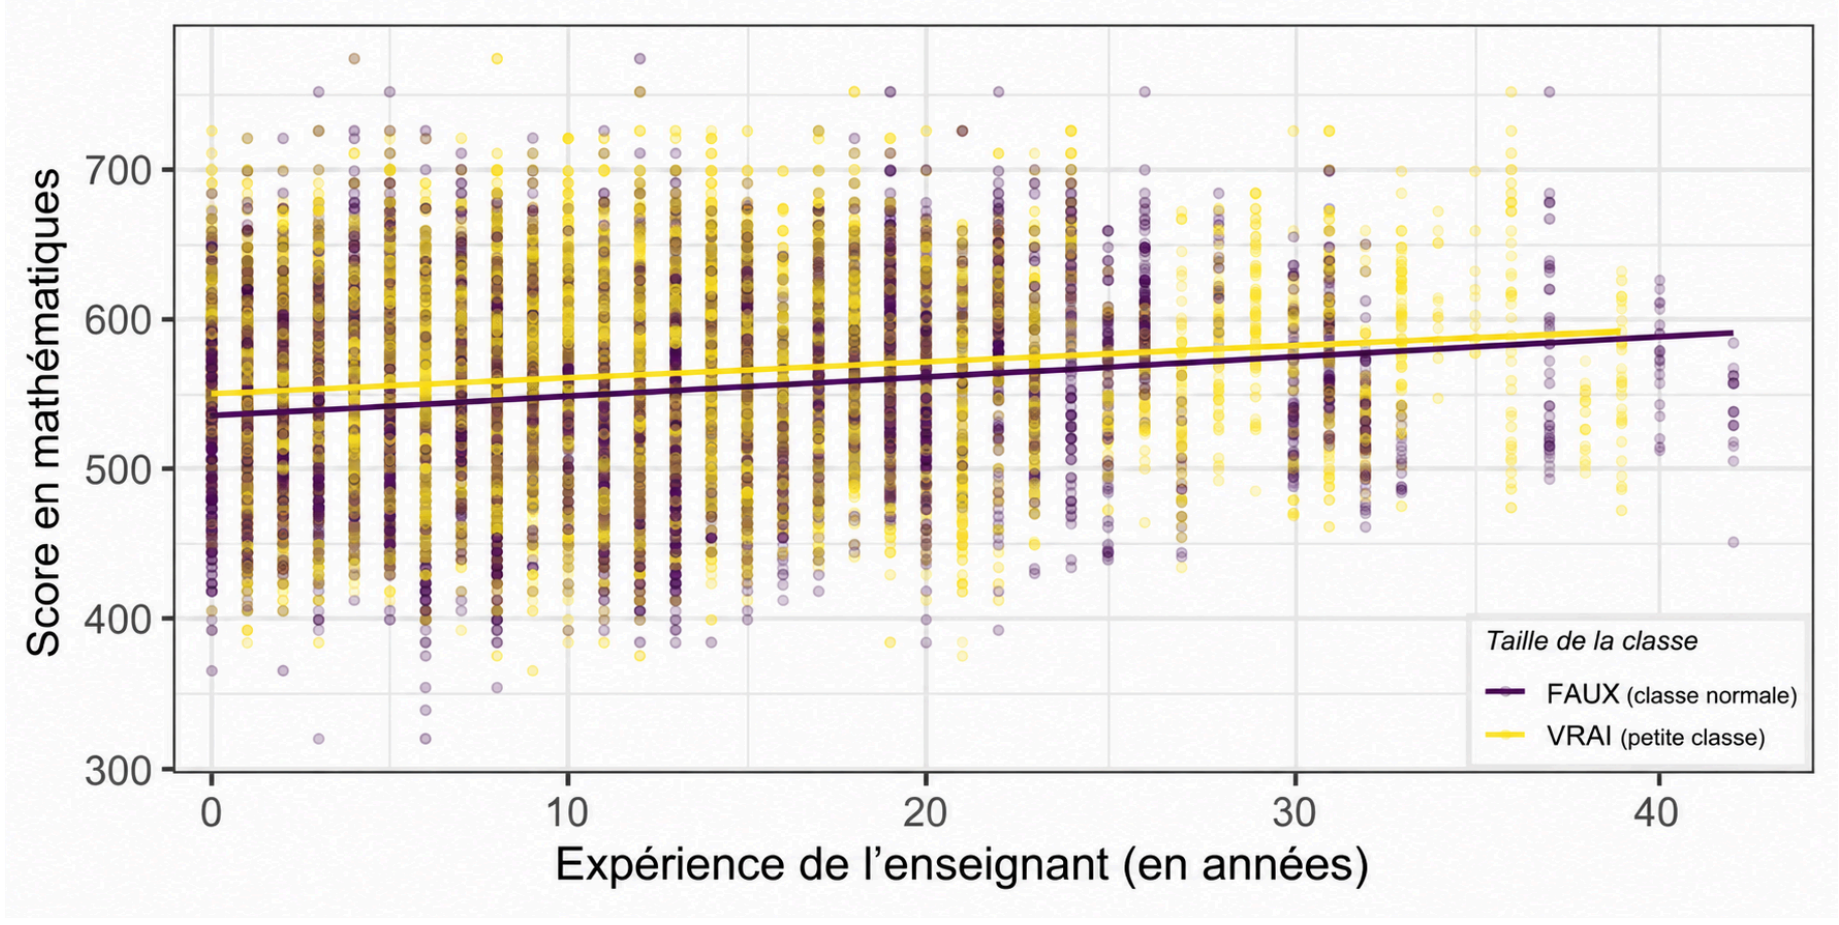
# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



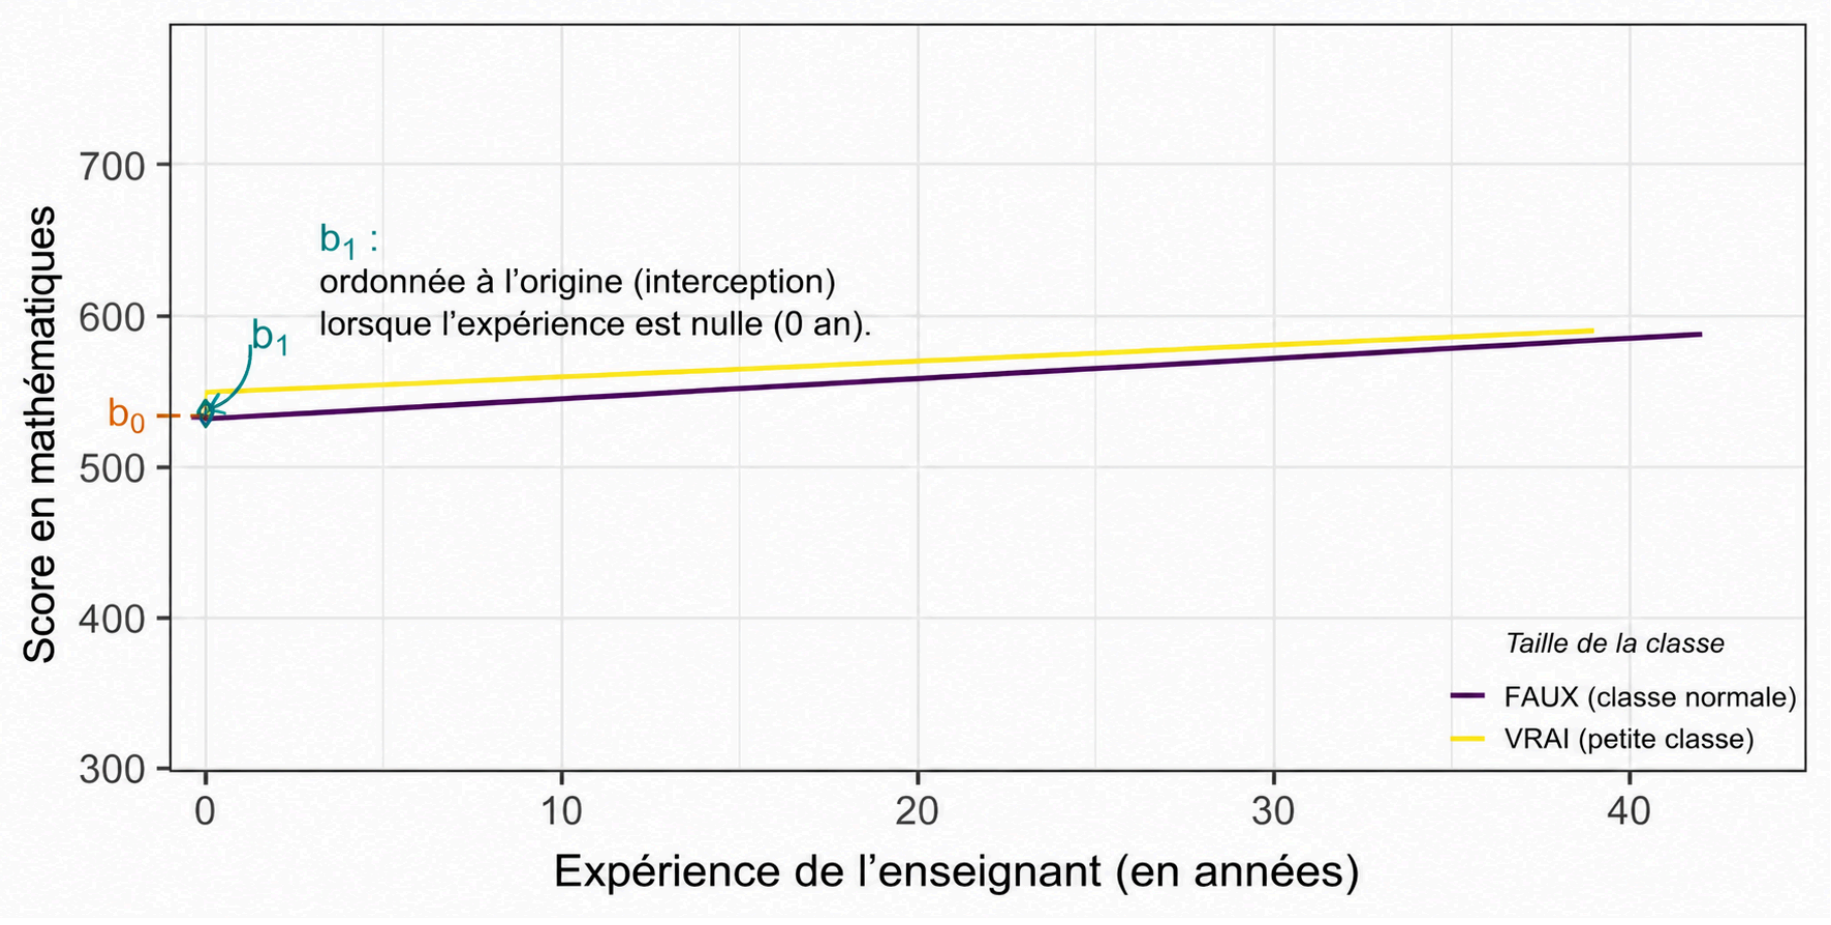
# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



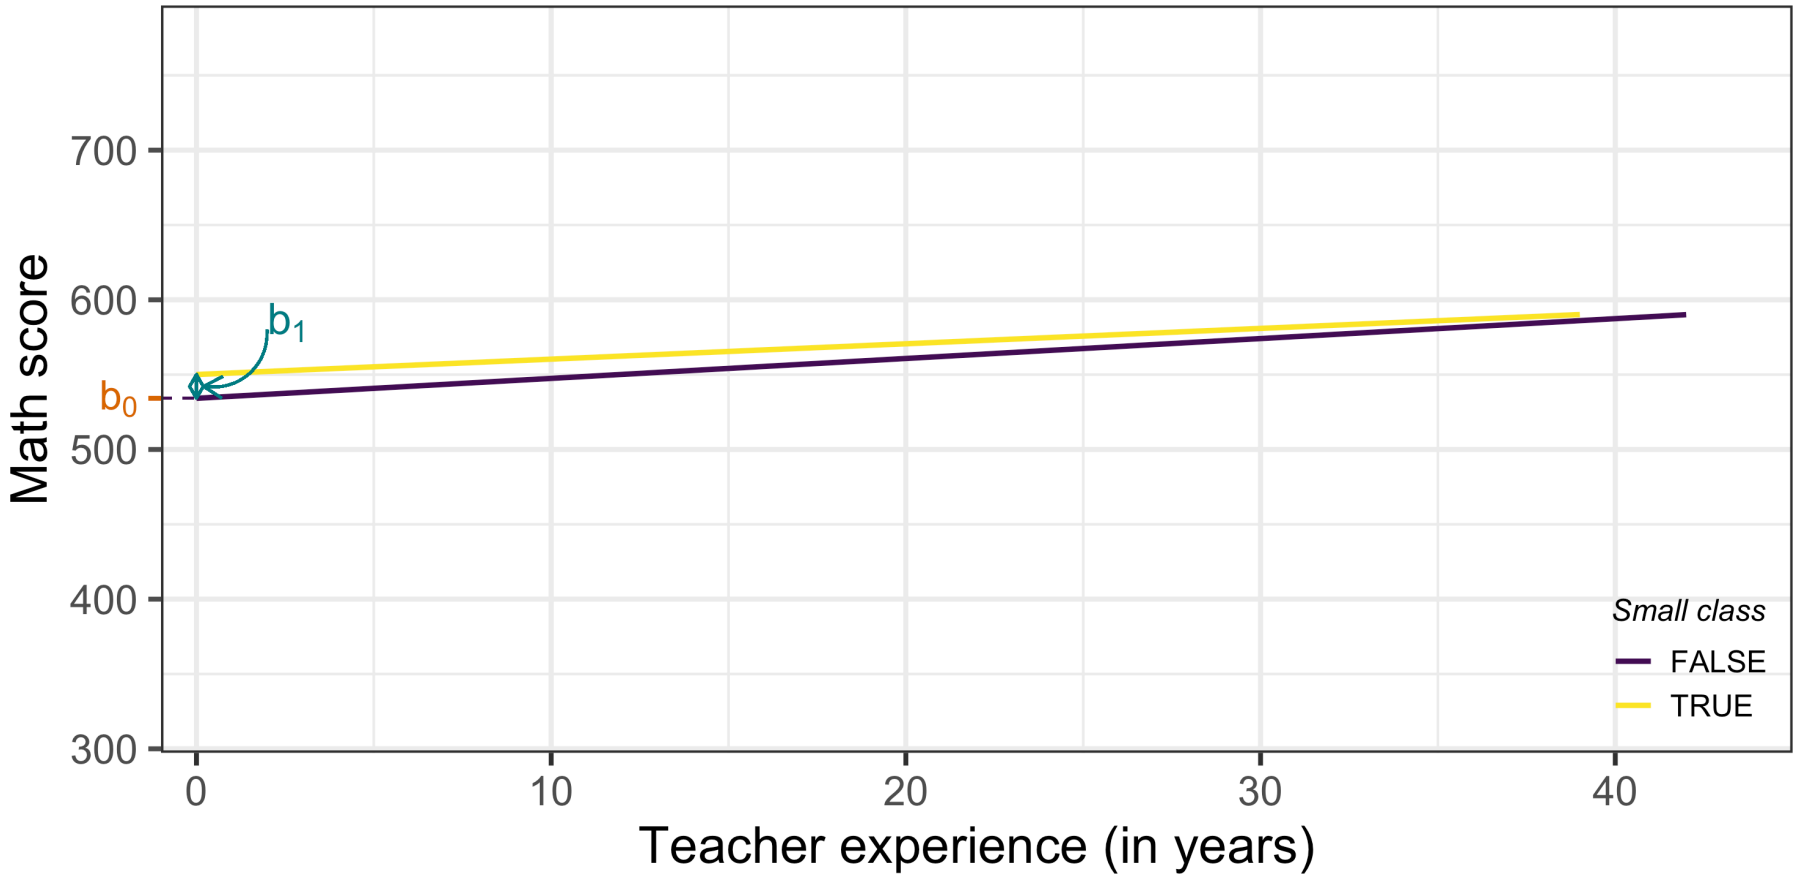
# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



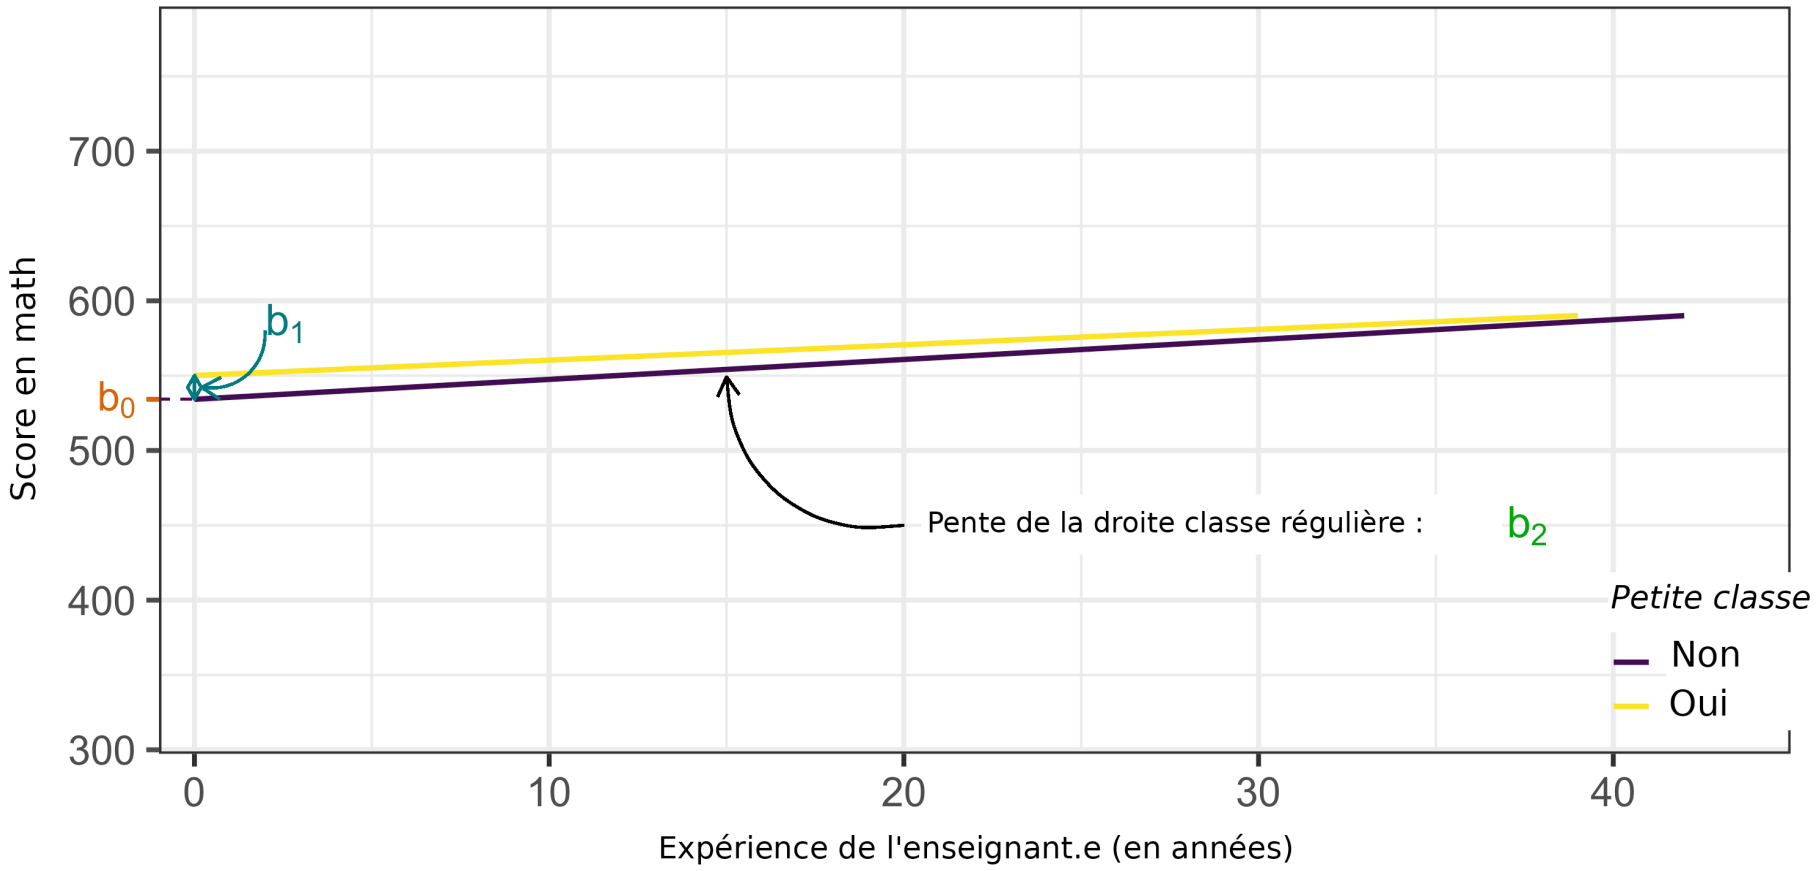
# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



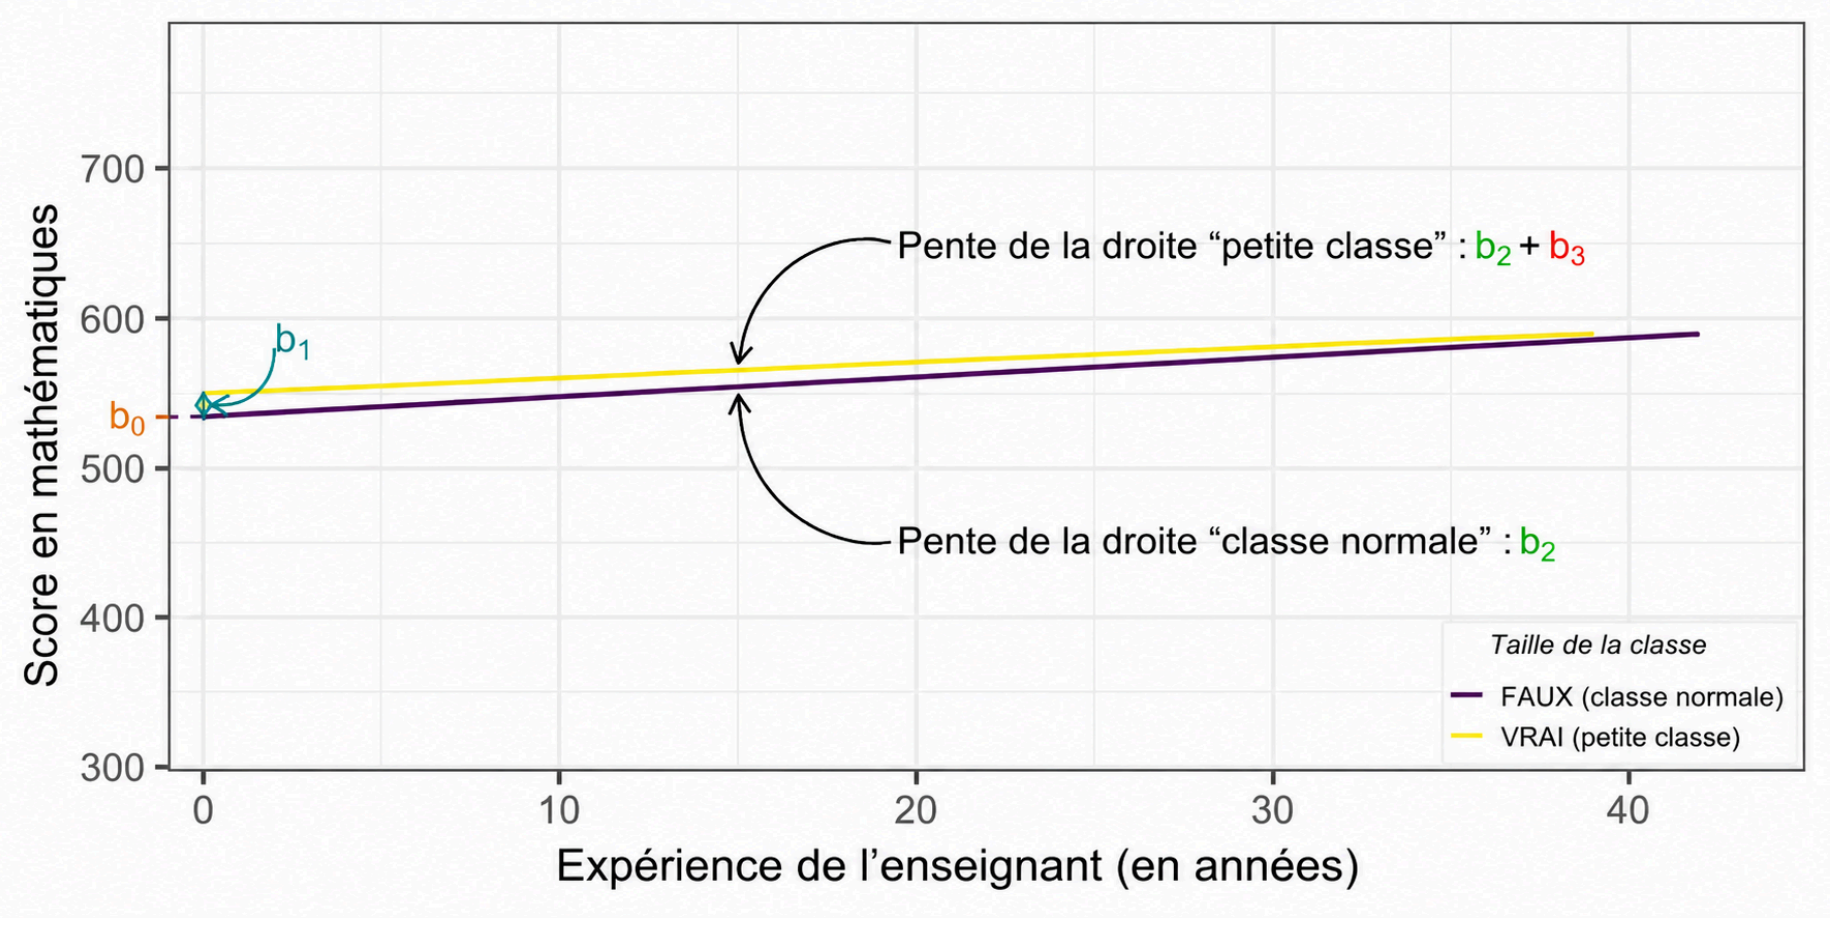
# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



# Interagir des régresseurs : graphiquement

$$\text{score}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{experience}_i + \beta_3 \text{small}_i * \text{experience}_i + e_i$$



# Tâche 2 : Salaires, éducation et genre en 1985

10:00

1. Chargez les données `CPS1985` du package `AER`.
2. Consultez l'`aide` pour obtenir la définition de chaque variable : `?CPS1985`
3. Nous ne savons pas si les personnes travaillent à temps partiel ou à temps plein, est-ce que cela a de l'importance ici ?
4. Créez la variable `log_wage` égale au log de `wage`.
5. Régressez `log_wage` sur `gender` et `education`, et sauvegardez le résultat sous `reg1`. Interprétez chaque coefficient.
6. Régressez `log_wage` sur `gender`, `education` et leur interaction `gender*education`, sauvegardez le résultat sous `reg2`. Interprétez chaque coefficient. L'écart salarial entre genres diminue-t-il avec l'éducation ?
7. Créez un graphique montrant cette interaction. (*Indice :* utilisez l'argument `color = gender` dans `aes` et `geom_smooth(method = "lm", se = F)` pour obtenir une droite de régression par genre.)



# Régression Standardisée

# Régression standardisée

Définissons ce que signifie *standardiser* une variable.



# Régression standardisée

Définissons ce que signifie *standardiser* une variable.

> ***Standardiser*** une variable $x$ signifie *centrer* la variable et diviser la valeur centrée par son propre écart-type (i.e., centrer-réduire) :

$$x_i^{stand} = \frac{x_i - \bar{x}}{\sigma(x)}$$

où $\bar{x}$ est la moyenne de $x$ et $\sigma(x)$ est l'écart-type de $x$, i.e. $\sigma(x) = \sqrt{\mathrm{Var}(x)}$.



# Régression standardisée

Définissons ce que signifie *standardiser* une variable.

> ***Standardiser*** une variable $x$ signifie *centrer* la variable et diviser la valeur centrée par son propre écart-type (i.e., centrer-réduire) :

$$x_i^{stand} = \frac{x_i - \bar{x}}{\sigma(x)}$$

où $\bar{x}$ est la moyenne de $x$ et $\sigma(x)$ est l'écart-type de $x$, i.e. $\sigma(x) = \sqrt{\mathrm{Var}(x)}$.

$x^{stand}$ a maintenant une moyenne de 0 et un écart-type de 1, i.e. $\overline{x^{stand}} = 0$ et $\sigma(x^{stand}) = 1$

# Régression standardisée

Définissons ce que signifie *standardiser* une variable.

> ***Standardiser*** une variable $x$ signifie *centrer* la variable et diviser la valeur centrée par son propre écart-type (i.e., centrer-réduire) :

$$x_i^{stand} = \frac{x_i - \bar{x}}{\sigma(x)}$$

où $\bar{x}$ est la moyenne de $x$ et $\sigma(x)$ est l'écart-type de $x$, i.e. $\sigma(x) = \sqrt{\text{Var}(x)}$.

$x^{stand}$ a maintenant une moyenne de 0 et un écart-type de 1, i.e. $\overline{x^{stand}} = 0$ et $\sigma(x^{stand}) = 1$

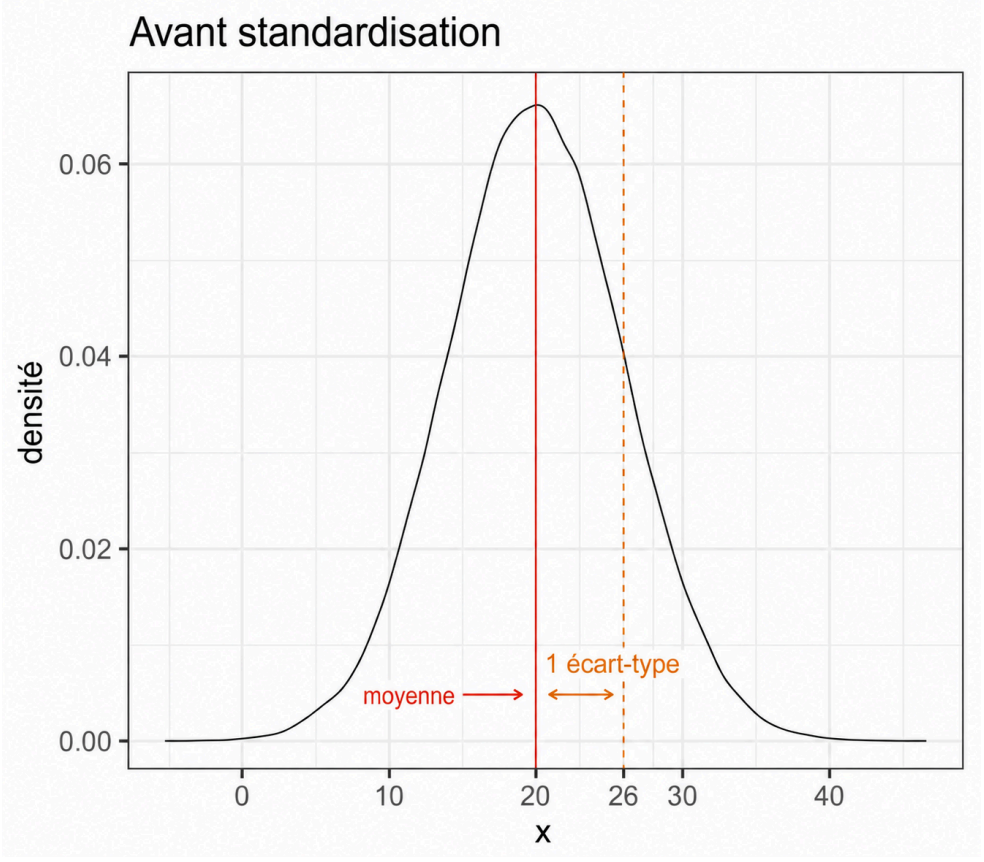
Intuitivement, standardiser ***met les variables à la même échelle*** afin de pouvoir les comparer.

Dans notre exemple sur la taille de classe et la performance des élèves, cela aidera à interpréter :

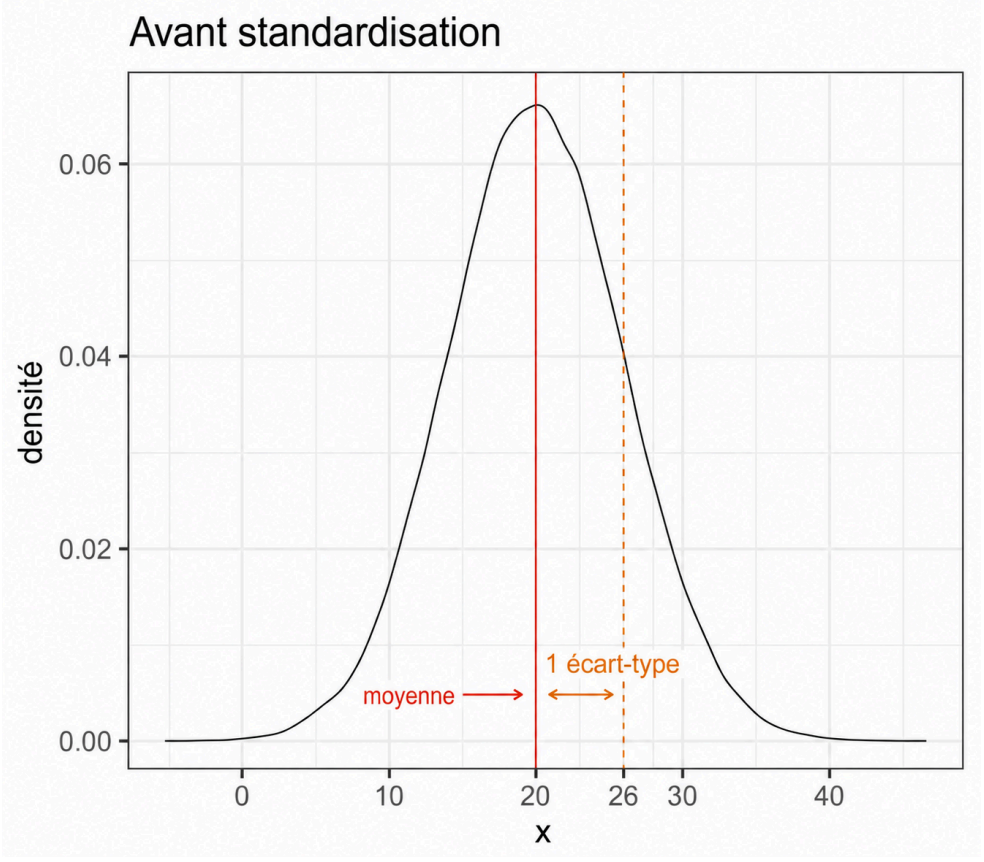


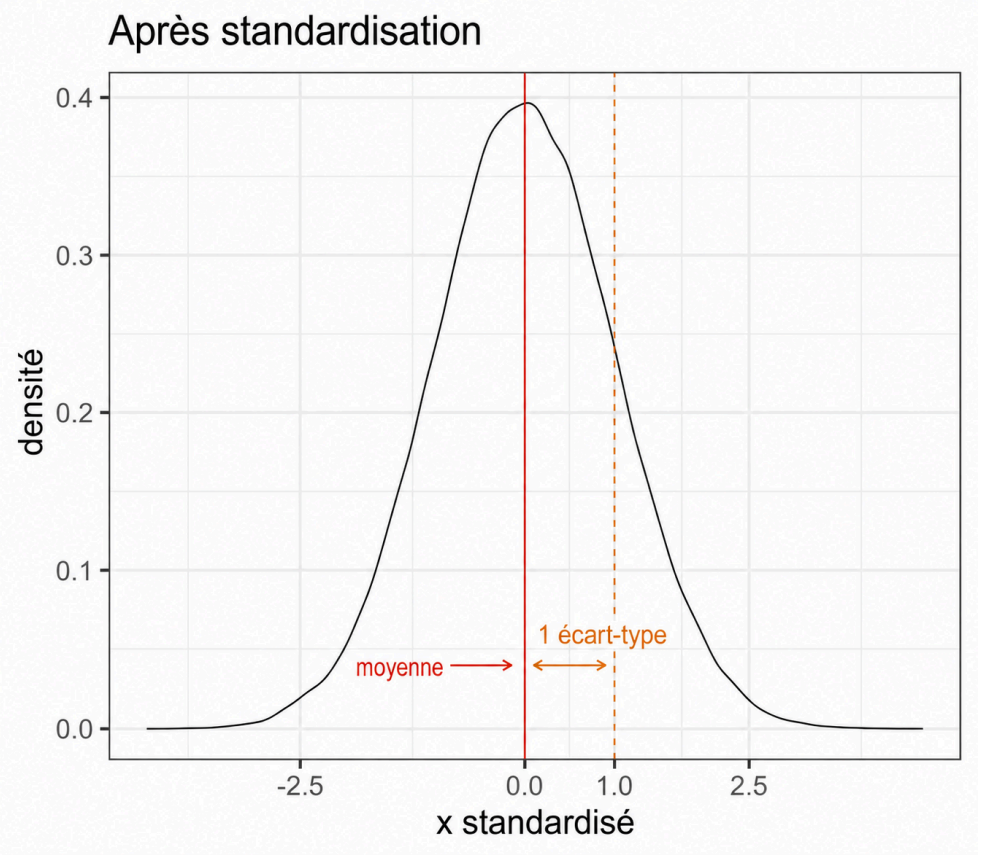
- La **magnitude** des effets,
- L'**importance relative de chaque variable**.

# Régression standardisée : graphiquement



# Régression standardisée : graphiquement



# Régression standardisée : interprétation

Si la variable ***dépendante*** $y$ est standardisée, le modèle est $y^{stand} = \beta_0 + \sum_{k=1}^{K} \beta_k x_k + e$ :

# Régression standardisée : interprétation

Si la variable ***dépendante*** $y$ est standardisée, le modèle est $y^{stand} = \beta_0 + \sum_{k=1}^{K} \beta_k x_k + e$ :

- Par définition, $\beta_k$ mesure le changement prédit de $y^{stand}$ associé à une augmentation d'une unité de $x_k$.
- Si $y^{stand}$ augmente de un, cela signifie que $y$ augmente d'un écart-type. Donc $\beta_k$ mesure le changement de $y$ **en tant que part de l'écart-type de $y$**.



# Régression standardisée : interprétation

Si la variable ***dépendante*** $y$ est standardisée, le modèle est $y^{stand} = \beta_0 + \sum_{k=1}^{K} \beta_k x_k + e$ :

- Par définition, $\beta_k$ mesure le changement prédit de $y^{stand}$ associé à une augmentation d'une unité de $x_k$.
- Si $y^{stand}$ augmente de un, cela signifie que $y$ augmente d'un écart-type. Donc $\beta_k$ mesure le changement de $y$ **en tant que part de l'écart-type de $y$**.

Si le ***régresseur*** $x_k$ est standardisé, i.e. le modèle est $y = \beta_0 + \sum_{k=1}^{K} \beta_k x_k^{stand} + e$ :

# Régression standardisée : interprétation

Si la variable ***dépendante*** $y$ est standardisée, le modèle est $y^{stand} = \beta_0 + \sum_{k=1}^{K} \beta_k x_k + e$ :

- Par définition, $\beta_k$ mesure le changement prédit de $y^{stand}$ associé à une augmentation d'une unité de $x_k$.
- Si $y^{stand}$ augmente de un, cela signifie que $y$ augmente d'un écart-type. Donc $\beta_k$ mesure le changement de $y$ **en tant que part de l'écart-type de $y$**.

Si le ***régresseur*** $x_k$ est standardisé, i.e. le modèle est $y = \beta_0 + \sum_{k=1}^{K} \beta_k x_k^{stand} + e$ :

- Par définition, $\beta_k$ mesure le changement prédit de $y$ associé à une augmentation d'une unité de $x_k^{stand}$ .
- Si $x_k^{stand}$ augmente d'une unité, cela signifie que $x_k$ augmente d'un écart-type. Donc $\beta_k$ mesure le changement prédit de $y$ **associé à une augmentation de $x_k$ d'un écart-type**.



# Tâche 3 : Régression standardisée

07:00

Revenons à notre jeu de données grades. Rappelez-vous que pour charger les données, vous devez utiliser la fonction `read_dta()` du package `haven`. Voici les estimations obtenues en régressant le score moyen en mathématiques sur l'ensemble complet des régresseurs.

```
##      (Intercept)          classize     disadvantaged school_enrollment
##     78.560725298       0.003320773      -0.389333008       0.000758258
##           female         religious
##      0.923710499       2.876146701
```

1. Créez une nouvelle variable `avgmath_stand` égale au score de math standardisé. Vous pouvez utiliser la fonction `scale()` (combinée avec `mutate`) ou le faire manuellement avec `R` de base.

2. Effectuez la régression complète en utilisant le score de math standardisé comme variable dépendante. Interprétez les coefficients et leur magnitude.

3. Créez les variables standardisées pour chaque régresseur *continu* sous le nom `<régresseur>_stand`.

    - Aurait-il un sens de standardiser la variable `religious` ?

4. Régressez `avgmath_stand` sur l'ensemble complet des régresseurs standardisés et

UNIVERSITÉ DE NAMUR

# BONNE JOURNÉE !

| | |
|---|---|
| | jeremy.donascimento@unamur.be |
| .Namurgreen | Discord |
| | Slides |

# Modèles logarithmiques : approximations

Pourquoi les approximations montrées précédemment sont-elles vraies ?

# Modèles logarithmiques : approximations

Pourquoi les approximations montrées précédemment sont-elles vraies ?

***Log-Niveau***

*Interprétation générale :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $(e^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y.

*Interprétation simplifiée :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y.

# Modèles logarithmiques : approximations

Pourquoi les approximations montrées précédemment sont-elles vraies ?

***Log-Niveau***

*Interprétation générale :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $(e^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y.

*Interprétation simplifiée :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y.

Ceci est dû au fait que, pour un petit $\beta_1$, $e^{\beta_1} \approx 1 + \beta_1 \iff \beta_1 \approx e^{\beta_1} - 1$

# Modèles logarithmiques : approximations

Pourquoi les approximations montrées précédemment sont-elles vraies ?

***Log-Niveau***

*Interprétation générale :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $(e^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y.

*Interprétation simplifiée :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y.

Ceci est dû au fait que, pour un petit $\beta_1$, $e^{\beta_1} \approx 1 + \beta_1 \iff \beta_1 \approx e^{\beta_1} - 1$

$\rightarrow$ pour $\beta_1 = 0.04$, $e^{\beta_1} - 1 = e^{0.04} - 1 = 0.0408$

# Modèles logarithmiques : approximations

Pourquoi les approximations montrées précédemment sont-elles vraies ?

***Log-Niveau***

*Interprétation générale :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $(e^{\beta_1} - 1) \times 100$ **changement en pourcentage** de y.

*Interprétation simplifiée :* Une augmentation d'**une unité** de $x$ est associée, en moyenne, à un $\beta_1 \times 100$ **changement en pourcentage** de y.

Ceci est dû au fait que, pour un petit $\beta_1$, $e^{\beta_1} \approx 1 + \beta_1 \iff \beta_1 \approx e^{\beta_1} - 1$

$\rightarrow$ pour $\beta_1 = 0.04$, $e^{\beta_1} - 1 = e^{0.04} - 1 = 0.0408$

$\rightarrow$ pour $\beta_1 =

# L'expérience STAR (Student/Teacher Achievement Ratio)

Expérience du Tennessee sur le **S**tudent/**T**eacher **A**chievement **R**atio (voir Krueger (1999))

- Financée par la législature du Tennessee pour un coût total d'environ **12 millions de dollars**.
- L'expérience a débuté durant l'année scolaire **1985-1986** et s'est déroulée sur **quatre ans**.



# L'expérience STAR (Student/Teacher Achievement Ratio)

Expérience du Tennessee sur le **S**tudent/**T**eacher **A**chievement **R**atio (voir Krueger (1999))

- Financée par la législature du Tennessee pour un coût total d'environ **12 millions de dollars**.
- L'expérience a débuté durant l'année scolaire **1985-1986** et s'est déroulée sur **quatre ans**.
- **11 600 élèves** et leurs enseignants ont été **assignés aléatoirement** à l'un des **trois groupes** suivants, de la maternelle (*kindergarten*) jusqu'à la troisième année du primaire (*third grade*) :
  1. ***Petite classe*** : 13 à 17 élèves par enseignant,
  2. ***Classe ordinaire*** : 22 à 25 élèves,
  3. ***Classe ordinaire avec assistant pédagogique*** : 22 à 25 élèves avec un enseignant et un **assistant pédagogique** à temps plein.



# L'expérience STAR (Student/Teacher Achievement Ratio)

Expérience du Tennessee sur le **S**tudent/**T**eacher **A**chievement **R**atio (voir Krueger (1999))

- Financée par la législature du Tennessee pour un coût total d'environ **12 millions de dollars**.
- L'expérience a débuté durant l'année scolaire **1985-1986** et s'est déroulée sur **quatre ans**.
- **11 600 élèves** et leurs enseignants ont été **assignés aléatoirement** à l'un des **trois groupes** suivants, de la maternelle (*kindergarten*) jusqu'à la troisième année du primaire (*third grade*) :
  1. ***Petite classe*** : 13 à 17 élèves par enseignant,
  2. ***Classe ordinaire*** : 22 à 25 élèves,
  3. ***Classe ordinaire avec assistant pédagogique*** : 22 à 25 élèves avec un enseignant et un **assistant pédagogique** à temps plein.
- La randomisation a été réalisée **au sein de chaque école**.
- Les compétences des élèves en **mathématiques** et en **lecture** ont été évaluées vers le

# L'expérience STAR (Student/Teacher Achievement Ratio)

Expérience du Tennessee sur le **S**tudent/**T**eacher **A**chievement **R**atio (voir Krueger (1999))

- Financée par la législature du Tennessee pour un coût total d'environ **12 millions de dollars**.
- L'expérience a débuté durant l'année scolaire **1985-1986** et s'est déroulée sur **quatre ans**.
- **11 600 élèves** et leurs enseignants ont été **assignés aléatoirement** à l'un des **trois groupes** suivants, de la maternelle (*kindergarten*) jusqu'à la troisième année du primaire (*third grade*) :
  1. ***Petite classe*** : 13 à 17 élèves par enseignant,
  2. ***Classe ordinaire*** : 22 à 25 élèves,
  3. ***Classe ordinaire avec assistant pédagogique*** : 22 à 25 élèves avec un enseignant et un **assistant pédagogique** à temps plein.
- La randomisation a été réalisée **au sein de chaque école**.
- Les compétences des élèves en **mathématiques** et en **lecture** ont été évaluées vers le