UNIVERSITÉ DE NAMUR

Econométrie

Inférence

Jérémy Do Nascimento Miguel
Université de Namur
2026-10-13

Aujourd'hui - Inférence statistique en économétrie

- Intepréter une ***table de régression***
- Comparer l'inférence ***basée sur la théorie*** et la ***simulation***
- Hypothèses du ***Modèle de régression classique***
- Application empiriques :
  - Taille de la classe et performance
  - Rendement à l'éducation par genre



L'expérience STAR : le dispositif

- ***STAR*** = *Student/Teacher Achievement Ratio*, Tennessee, 1985-1989.
- Environ **11 600 élèves** dans **79 écoles**, suivis de la maternelle à la 3e année primaire.

L'expérience STAR : le dispositif

- ***STAR*** = *Student/Teacher Achievement Ratio*, Tennessee, 1985-1989.
- Environ **11 600 élèves** dans **79 écoles**, suivis de la maternelle à la 3e année primaire.
- **Tirage au sort à l'intérieur de chaque école** : chaque élève est affecté à l'un de trois types de classes :
  - ***petite classe*** : 13 à 17 élèves (le *traitement*),
  - ***classe normale*** : 22 à 25 élèves (le *contrôle*),
  - ***classe normale avec assistant***.

L'expérience STAR : le dispositif

- ***STAR*** = *Student/Teacher Achievement Ratio*, Tennessee, 1985-1989.
- Environ **11 600 élèves** dans **79 écoles**, suivis de la maternelle à la 3e année primaire.
- **Tirage au sort à l'intérieur de chaque école** : chaque élève est affecté à l'un de trois types de classes :
  - ***petite classe*** : 13 à 17 élèves (le *traitement*),
  - ***classe normale*** : 22 à 25 élèves (le *contrôle*),
  - ***classe normale avec assistant***.
- Tests standardisés (lecture, maths) passés chaque année.

STAR : pourquoi est-ce une bonne expérience ?

- L'affectation est ***aléatoire*** : en moyenne, élèves en petites et grandes classes ont les mêmes caractéristiques (milieu social, aptitude…).

→ Plus de ***biais de sélection*** : une différence de moyennes donne un ***effet causal***.

- Hors expérience, les écoles ou familles aisées peuvent obtenir des petites classes : on mesurerait l'effet du milieu social, pas celui de la taille.

Résultat principal

- Les élèves en petites classes obtiennent de **meilleurs résultats**, surtout en début de scolarité et pour les élèves **défavorisés**.

Limites

- Certains élèves ont changé de type de classe ou quitté l'école.
- Les résultats portent sur le Tennessee des années 1980.

Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*

Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*
- On considère le modèle de régression suivant que l'on estime par OLS :

$$\text{math score}_i = \beta_0 + \beta_1 \text{small}_i + u_i$$

Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*
- On considère le modèle de régression suivant que l'on estime par OLS :

$$\text{math score}_i = \beta_0 + \beta_1 \text{small}_i + u_i$$

```
library(tidyverse)

star_df = read.csv("https://www.dropbox.com/s/bf1fog8y
star_df = star_df[complete.cases(star_df),]
star_df = star_df %>%
  filter(star %in% c("small","regular") &
           grade == "k") %>%
  mutate(small = (star == "small"))
```



Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*
- On considère le modèle de régression suivant que l'on estime par OLS :

$$\text{math score}_i = \beta_0 + \beta_1 \text{small}_i + u_i$$

```
library(tidyverse)

star_df = read.csv("https://www.dropbox.com/s/bf1fog8y
star_df = star_df[complete.cases(star_df),]
star_df = star_df %>%
  filter(star %in% c("small","regular") &
           grade == "k") %>%
  mutate(small = (star == "small"))
```

```
reg_star = lm(math ~ small, star_df)
reg_star
```

```
##
## Call:
## lm(formula = math ~ small, data = star_df)
##
## Coefficients:
## (Intercept)    smallTRUE
##     484.446        8.895
```



Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*
- On considère le modèle de régression suivant que l'on estime par OLS :

$$\text{math score}_i = \beta_0 + \beta_1 \text{small}_i + u_i$$

```
library(tidyverse)

star_df = read.csv("https://www.dropbox.com/s/bf1fog8y
star_df = star_df[complete.cases(star_df),]
star_df = star_df %>%
  filter(star %in% c("small","regular") &
           grade == "k") %>%
  mutate(small = (star == "small"))
```

```
reg_star = lm(math ~ small, star_df)
reg_star
```

```
##
## Call:
## lm(formula = math ~ small, data = star_df)
##
## Coefficients:
## (Intercept)    smallTRUE
##     484.446        8.895
```

- Que se passerait-il si l'on tirerait un autre échantillon aléatoire d'écoles, trouverait-on une valeur différente de pour β_1?



Retour à la taille de la classe et performances

- Revenons aux données du programme ***STAR***, et concentrons nous sur :
  - les *petites* classes et les *classiques* ,
  - *Maternelle*
- On considère le modèle de régression suivant que l'on estime par OLS :

$$\text{math score}_i = \beta_0 + \beta_1 \text{small}_i + u_i$$

```
library(tidyverse)

star_df = read.csv("https://www.dropbox.com/s/bf1fog8y
star_df = star_df[complete.cases(star_df),]
star_df = star_df %>%
  filter(star %in% c("small","regular") &
           grade == "k") %>%
  mutate(small = (star == "small"))
```

```
reg_star = lm(math ~ small, star_df)
reg_star
```

```
##
## Call:
## lm(formula = math ~ small, data = star_df)
##
## Coefficients:
## (Intercept)    smallTRUE
##     484.446        8.895
```

- Que se passerait-il si l'on tirerait un autre échantillon aléatoire d'écoles, trouverait-on une valeur différente de pour β_1?
- *Oui*, mais dans quelle mesure l'estimation sera différente ?



Inférence : $\hat{\beta}_k$ vs β_k

- $\hat{\beta}_0, \hat{\beta}_1$ sont des ***estimations ponctuelles*** calculées à partir de notre échantillon.
  - Tout comme la proportion d'échantillon $\hat{p}$ dans notre exemple des pâtes !

Inférence : $\hat{\beta}_k$ vs β_k

- $\hat{\beta}_0, \hat{\beta}_1$ sont des ***estimations ponctuelles*** calculées à partir de notre échantillon.
  - Tout comme la proportion d'échantillon $\hat{p}$ dans notre exemple des pâtes !

- En fait, la prédiction de notre modèle…

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$



Inférence : $\hat{\beta}_k$ vs β_k

- $\hat{\beta}_0, \hat{\beta}_1$ sont des ***estimations ponctuelles*** calculées à partir de notre échantillon.
  - Tout comme la proportion d'échantillon $\hat{p}$ dans notre exemple des pâtes !

- En fait, la prédiction de notre modèle…

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$

… est une ***estimation*** d'une **véritable droite de population** inconnue

$$y = \beta_0 + \beta_1 x_1$$

où β_0, β_1 sont les ***paramètres de population*** qui nous intéressent.

Inférence : $\hat{\beta}_k$ vs β_k

- $\hat{\beta}_0, \hat{\beta}_1$ sont des ***estimations ponctuelles*** calculées à partir de notre échantillon.
  - Tout comme la proportion d'échantillon $\hat{p}$ dans notre exemple des pâtes !

- En fait, la prédiction de notre modèle…

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$

… est une ***estimation*** d'une **véritable droite de population** inconnue

$$y = \beta_0 + \beta_1 x_1$$

où β_0, β_1 sont les ***paramètres de population*** qui nous intéressent.

- Vous rencontrerez souvent $\hat{\beta}_k$ pour désigner l'estimation d'échantillon de β_k.

Inférence : $\hat{\beta}_k$ vs β_k

- $\hat{\beta}_0, \hat{\beta}_1$ sont des ***estimations ponctuelles*** calculées à partir de notre échantillon.
  - Tout comme la proportion d'échantillon $\hat{p}$ dans notre exemple des pâtes !

- En fait, la prédiction de notre modèle…

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$

… est une ***estimation*** d'une **véritable droite de population** inconnue

$$y = \beta_0 + \beta_1 x_1$$

où β_0, β_1 sont les ***paramètres de population*** qui nous intéressent.

- Vous rencontrerez souvent $\hat{\beta}_k$ pour désigner l'estimation d'échantillon de β_k.
- Mobilisons ce que nous savons sur les ***intervalles de confiance***, les ***tests d'hypothèses*** et les ***erreurs types*** pour étudier ces $\hat{\beta}_k$!



Comprendre une table de régression

Voici notre régression en utilisant le package `fixest` :

```
library(fixest)
feols(math ~ small, star_df)
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 484.44638    1.15034 421.13285  < 2.2e-16 ***
## smallTRUE     8.89519    1.67833   5.30002 1.2327e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.5   Adj. R2: 0.008003
```

- Il y a 3 nouvelles colonnes : `Std error`, `t value`, `Pr(>|t|)`.



Comprendre une table de régression

Voici notre régression en utilisant le package `fixest` :

```
library(fixest)
feols(math ~ small, star_df)
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 484.44638    1.15034 421.13285  < 2.2e-16 ***
## smallTRUE     8.89519    1.67833   5.30002 1.2327e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.5   Adj. R2: 0.008003
```

- Il y a 3 nouvelles colonnes : `Std error`, `t value`, `Pr(>|t|)`.

Entrée	Signification
`Std. error`	Erreur type de β_k
`t value`	Test statistique observé associé à $H_0 : \beta_k = 0, H_A : \beta_k \neq 0$

Comprendre une table de régression

Voici notre régression en utilisant le package `fixest` :

```
library(fixest)
feols(math ~ small, star_df)
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 484.44638    1.15034 421.13285  < 2.2e-16 ***
## smallTRUE     8.89519    1.67833   5.30002 1.2327e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.5   Adj. R2: 0.008003
```

- Il y a 3 nouvelles colonnes : `Std error`, `t value`, `Pr(>|t|)`.

Entrée	Signification
`Std. error`	Erreur type de β_k
`t value`	Test statistique observé associé à $H_0 : \beta_k = 0, H_A : \beta_k \neq 0$

Erreur type de β_k

> ***Erreur type de*** $\hat{\beta}_k$ ***:*** écart-type de la distribution d'échantillonnage de $\hat{\beta}_k$.

Erreur type de β_k

> ***Erreur type de*** $\hat{\beta}_k$ ***:*** écart-type de la distribution d'échantillonnage de $\hat{\beta}_k$.

Imaginons que nous puissions refaire l'expérience 1000 fois sur 1000 échantillons différents :

- Nous ferions tourner 1000 régressions et obtiendrions 1000 estimations de β_k, $\hat{\beta}_k$.



Erreur type de β_k

> ***Erreur type de*** $\hat{\beta}_k$ ***:*** écart-type de la distribution d'échantillonnage de $\hat{\beta}_k$.

Imaginons que nous puissions refaire l'expérience 1000 fois sur 1000 échantillons différents :

- Nous ferions tourner 1000 régressions et obtiendrions 1000 estimations de β_k, $\hat{\beta}_k$.
- L'erreur type de $\hat{\beta}_k$ quantifie la variation attendue de $\hat{\beta}_k$ à travers (*une infinité d'*) échantillons.



Erreur type de $\hat{\beta}_{\text{small}}$

- À partir du tableau, on obtient $\hat{\text{SE}}(\hat{\beta}_{\text{small}}) = 1.68$
  - Remarquez que l'on écrit $\hat{\text{SE}}$ et non SE car 1.68 est une estimation de la véritable erreur type de $\hat{\beta}_{\text{small}}$ obtenue à partir de notre échantillon.
  - Nous aimerions connaître la véritable erreur type SE, mais nous n'avons qu'un seul échantillon !



Erreur type de $\hat{\beta}_{\text{small}}$

- À partir du tableau, on obtient $\hat{\text{SE}}(\hat{\beta}_{\text{small}}) = 1.68$
  - Remarquez que l'on écrit $\hat{\text{SE}}$ et non SE car 1.68 est une estimation de la véritable erreur type de $\hat{\beta}_{\text{small}}$ obtenue à partir de notre échantillon.
  - Nous aimerions connaître la véritable erreur type SE, mais nous n'avons qu'un seul échantillon !
- Simulons la distribution d'échantillonnage de $\hat{\beta}_{\text{small}}$ pour voir d'où elle provient.



Tâche 1

07:00

Comme nous l'avons fait pour la distribution d'échantillonnage de la proportion de *pâtes vertes*, nous voulons générer la distribution bootstrap de $\hat{\beta}_{\text{small}}$.

1. Copiez le code de chargement et de nettoyage de la diapositive 3 et exécutez-le.

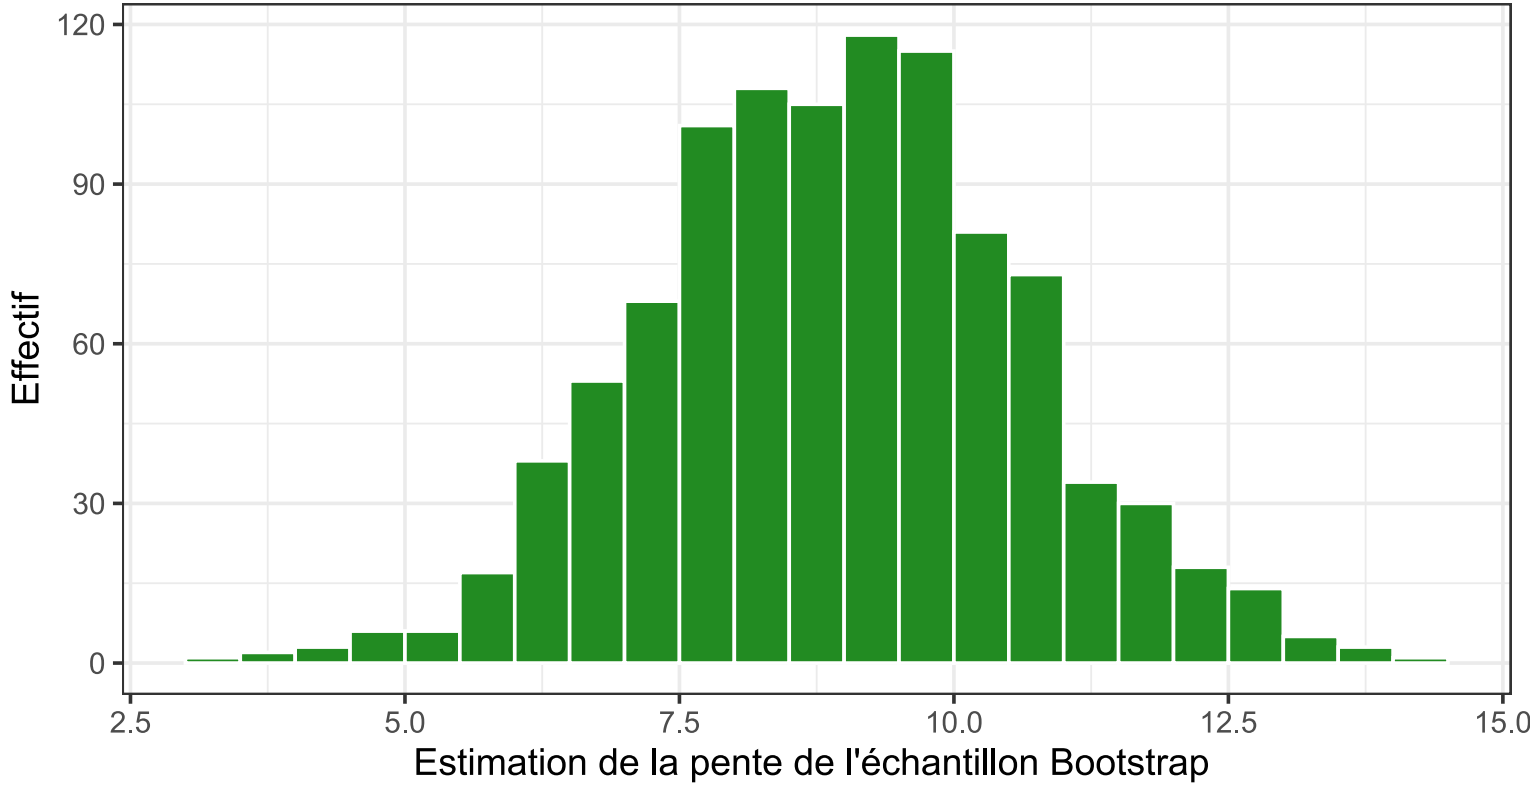
2. Générez la distribution bootstrap de $\hat{\beta}_{\text{small}}$ à partir de 1000 échantillons tirés de `star_df`. Vous pouvez le faire avec le code suivant

```
bootstrap_distrib <- star_df %>%
    mutate(small=as.numeric(small)) %>%
    specify(response = math, explanatory = small) %>%
    generate(reps = 1000, type = "bootstrap") %>%
    calculate(stat = "slope")
```

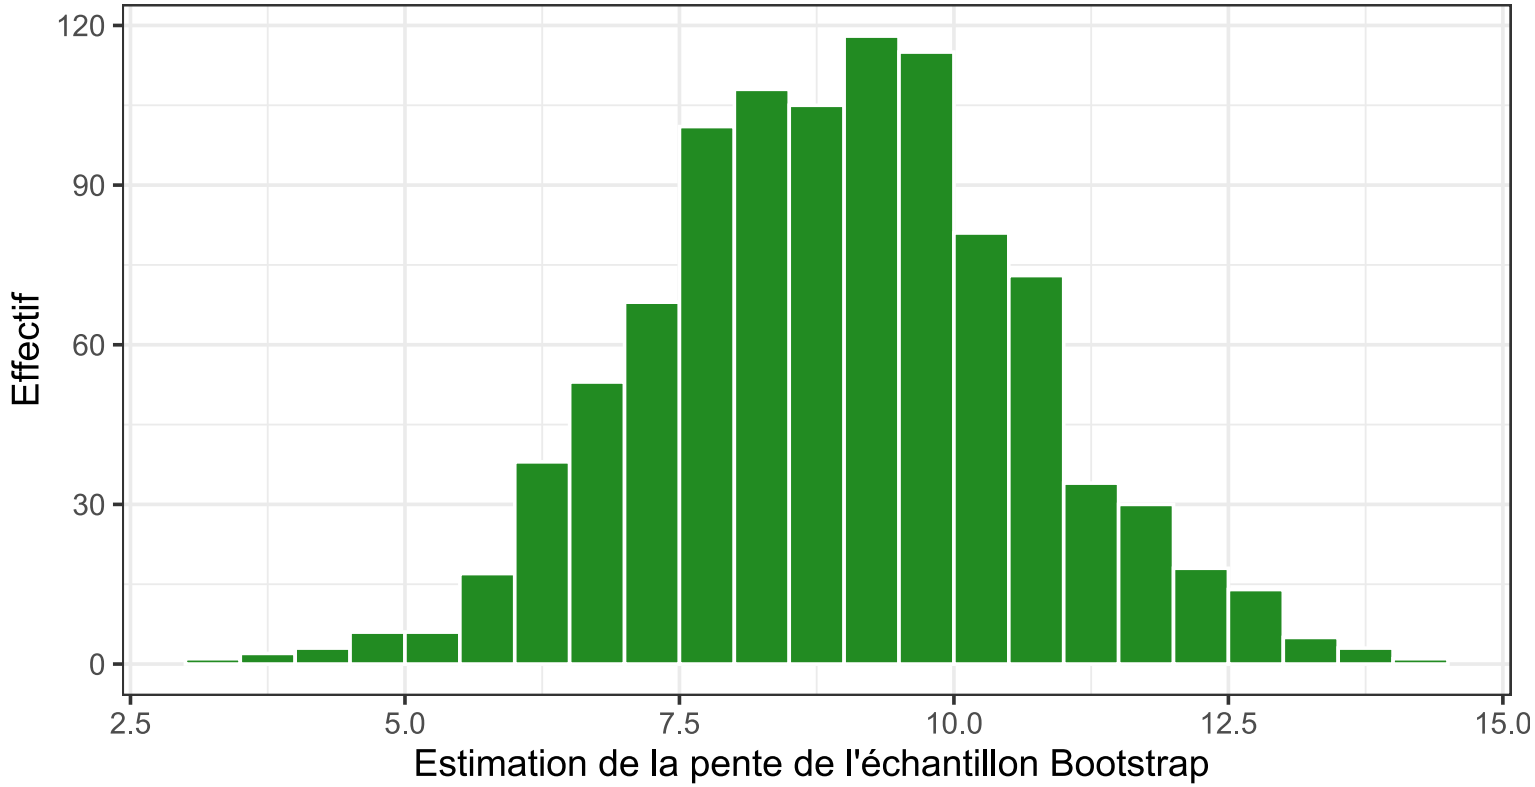
1. Représentez graphiquement cette distribution d'échantillonnage simulée et calculez la moyenne et l'erreur type de $\hat{\beta}_{\text{small}}$.



Distribution Bootstrap



Distribution Bootstrap



Erreur type: 1.7 $\rightarrow$ très proche de celle dans le tableau (1.68)!

Pas exactement égal, car on utilise le bootstrap à la place de l'approche théorique utilisée par R.

Revenons à nos moutons

```
library(fixest)
feols(math ~ small, star_df)
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 484.44638    1.15034 421.13285  < 2.2e-16 ***
## smallTRUE     8.89519    1.67833   5.30002 1.2327e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.5   Adj. R2: 0.008003
```

- On sait ce que la colonne `Std. Error` veut dire.
- Les 2 suivantes sont `t value` et `Pr(>|t|)`
- Cela ne vous dit rien ?
- A quelle hypothèse cela correspond ?



Tester $\beta_k = 0$ vs $\beta_k \neq 0$

Par défaut, le résultat de la régression vous fournira les résultats des tests suivants :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

Tester $\beta_k = 0$ vs $\beta_k \neq 0$

Par défaut, le résultat de la régression vous fournira les résultats des tests suivants :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Cela permet de tester statistiquement si il y a une relation entre nos variables dépendante et indépendante.



Tester $\beta_k = 0$ vs $\beta_k \neq 0$

Par défaut, le résultat de la régression vous fournira les résultats des tests suivants :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Cela permet de tester statistiquement si il y a une relation entre nos variables dépendante et indépendante.
- Si on ne rejette pas H_0, alors il **n'y a pas** de relation entre elles.
  - Dans ce cas observer $\beta_1 \neq 0$ était de la chance.

Tester $\beta_k = 0$ vs $\beta_k \neq 0$

Par défaut, le résultat de la régression vous fournira les résultats des tests suivants :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Cela permet de tester statistiquement si il y a une relation entre nos variables dépendante et indépendante.
- Si on ne rejette pas H_0, alors il **n'y a pas** de relation entre elles.
  - Dans ce cas observer $\beta_1 \neq 0$ était de la chance.
- Si on rejette H_0, alors **il y a** une relation entre elles.

Tester $\beta_k = 0$ vs $\beta_k \neq 0$

Par défaut, le résultat de la régression vous fournira les résultats des tests suivants :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Cela permet de tester statistiquement si il y a une relation entre nos variables dépendante et indépendante.
- Si on ne rejette pas H_0, alors il **n'y a pas** de relation entre elles.
  - Dans ce cas observer $\beta_1 \neq 0$ était de la chance.
- Si on rejette H_0, alors **il y a** une relation entre elles.
- ***Attention:*** C'est un ***test bilatéral*** !



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :

t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.
- Notre *t-statistique observée* (`statistic`) est égale à $t_{\hat{\beta}} \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}$.

t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.
- Notre *t-statistique observée* (`statistic`) est égale à $t_{\hat{\beta}} \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}$.

```
observed_stat = reg_star$coefficients[2]/sd(bootstrap_
round(observed_stat,2)
```

```
## smallTRUE
##      5.22
```



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.

- Notre *t-statistique observée* (`statistic`) est égale à $t_{\hat{\beta}} \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}$.

```
observed_stat = reg_star$coefficients[2]/sd(bootstrap_
round(observed_stat,2)
```

```
## smallTRUE
##      5.22
```

- Assez proche de la statistique de test observée obtenue dans le tableau : `statistic` = 5.3.



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.

- Notre *t-statistique observée* (`statistic`) est égale à $t_{\hat{\beta}} \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}$.

```
observed_stat = reg_star$coefficients[2]/sd(bootstrap_
round(observed_stat,2)
```

```
## smallTRUE
##      5.22
```

- Assez proche de la statistique de test observée obtenue dans le tableau : `statistic` = 5.3.

- La ***valeur-p*** (`Pr(>|t|)`) mesure l'aire à l'extérieur de $\pm$ *la t statistique de test observée* sous la *distribution nulle*.



t-statistique et valeur-p

- Comme nous l'avons vu au cours précédent, pour mener un tel test nous devons :
  - Dériver la distribution d'échantillonnage de notre ***t-statistique*** (`statistic`) en supposant que H_0 est vraie, c.-à-d. la *distribution nulle*.
  - Quantifier à quel point la ***statistique de test observée*** est extrême dans ce monde hypothétique.

- Notre *t-statistique observée* (`statistic`) est égale à $t_{\hat{\beta}} \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}$.

```
observed_stat = reg_star$coefficients[2]/sd(bootstrap_
round(observed_stat,2)
```

```
## smallTRUE
##      5.22
```

- Assez proche de la statistique de test observée obtenue dans le tableau : `statistic` = 5.3.

- La ***valeur-p*** (`Pr(>|t|)`) mesure l'aire à l'extérieur de $\pm$ *la t statistique de test observée* sous la *distribution nulle*.

- Enfin, nous vérifions si nous pouvons rejeter H_0 aux ***niveaux de signification*** usuels : α = 0.1, 0.05, 0.01

Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Nous allons approximer la distribution nulle de $\frac{\hat{\beta}_{\text{small}}}{\hat{SE}(\hat{\beta}_{\text{small}})}$ à travers un exercice de simulation.

Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Nous allons approximer la distribution nulle de $\frac{\hat{\beta}_{\text{small}}}{\hat{SE}(\hat{\beta}_{\text{small}})}$ à travers un exercice de simulation.
- S'il n'y a aucune relation entre le score en maths et la taille de la classe, c.-à-d. si H_0 est vraie et $\beta_{\text{small}} = 0$, alors *remélanger* / *permuter* les valeurs de `small` entre les étudiants ne devrait jouer aucun rôle.

Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Nous allons approximer la distribution nulle de $\frac{\hat{\beta}_{\text{small}}}{\hat{SE}(\hat{\beta}_{\text{small}})}$ à travers un exercice de simulation.
- S'il n'y a aucune relation entre le score en maths et la taille de la classe, c.-à-d. si H_0 est vraie et $\beta_{\text{small}} = 0$, alors *remélanger* / *permuter* les valeurs de `small` entre les étudiants ne devrait jouer aucun rôle.
  - Générons 1000 échantillons permutés et calculons $\hat{\beta}_{\text{small}}$ pour chacun.

```
null_distribution <- star_df %>%
mutate(small=as.numeric(small)) %>%
specify(formula = math ~ small) %>%
hypothesize(null = "independence") %>%
generate(reps = 1000, type = "permute") %>%
calculate(stat = "slope")
```



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Nous allons approximer la distribution nulle de $\frac{\hat{\beta}_{\text{small}}}{\hat{SE}(\hat{\beta}_{\text{small}})}$ à travers un exercice de simulation.
- S'il n'y a aucune relation entre le score en maths et la taille de la classe, c.-à-d. si H_0 est vraie et $\beta_{\text{small}} = 0$, alors *remélanger* / *permuter* les valeurs de `small` entre les étudiants ne devrait jouer aucun rôle.
  - Générons 1000 échantillons permutés et calculons $\hat{\beta}_{\text{small}}$ pour chacun.

```
null_distribution <- star_df %>%
mutate(small=as.numeric(small)) %>%
specify(formula = math ~ small) %>%
hypothesize(null = "independence") %>%
generate(reps = 1000, type = "permute") %>%
calculate(stat = "slope")
```

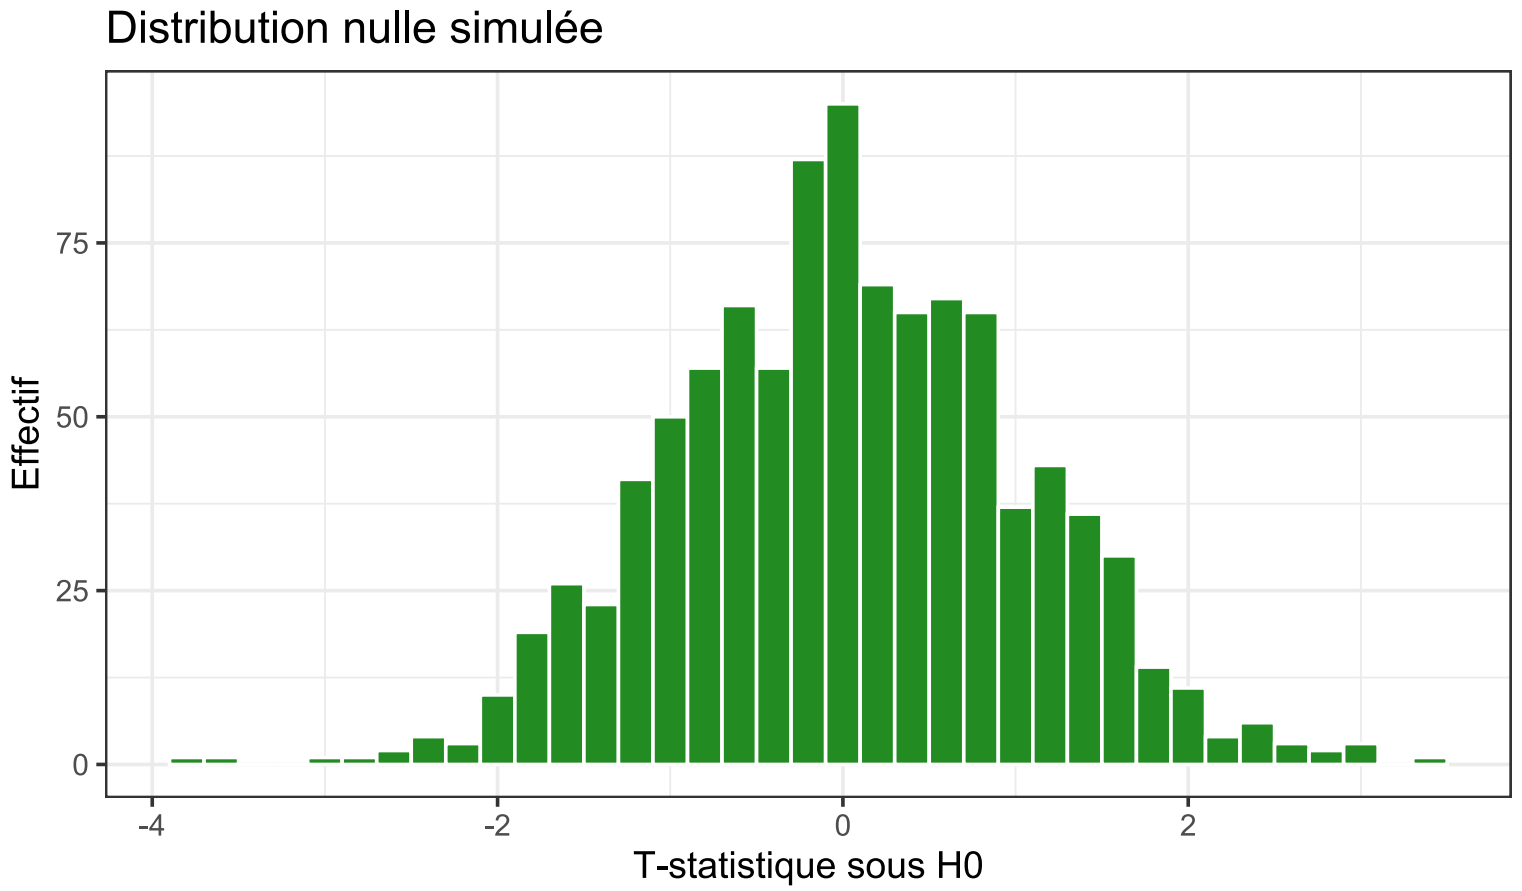
- Nous pouvons calculer la distribution de notre statistique de test $\frac{\hat{\beta}_{\text{small}}}{\hat{SE}(\hat{\beta}_{\text{small}})}$ sous l'hypothèse nulle :

```
null_distribution <- null_distribution %>%
  mutate(test_stat = stat/sd(bootstrap_distrib$stat))
```

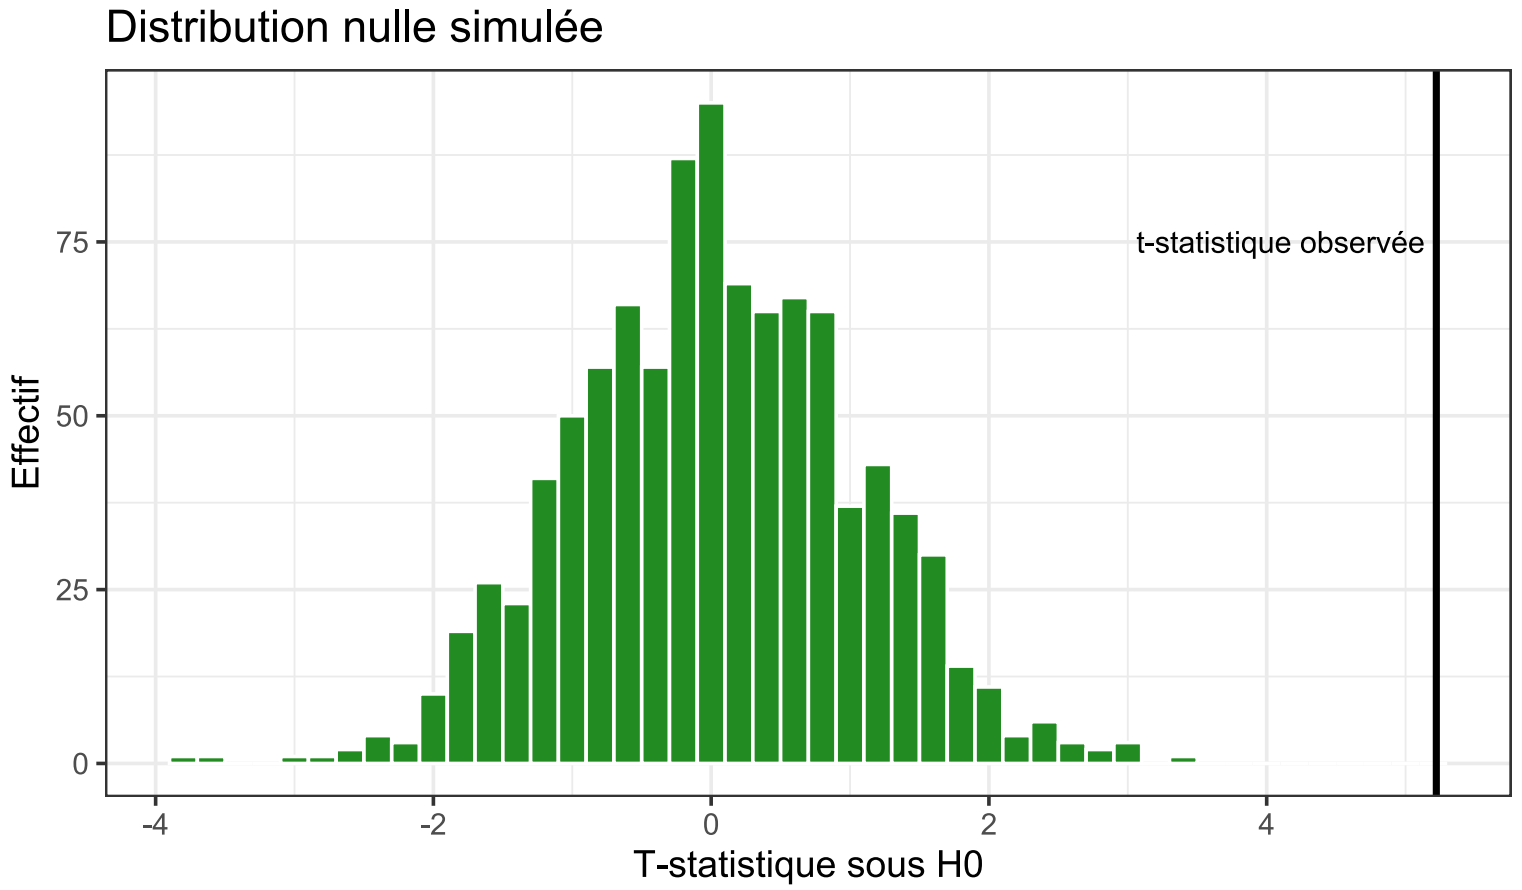
- Rappelez-vous que nous avons obtenu $\hat{SE}(\hat{\beta}_{\text{small}}) = 1.7$.



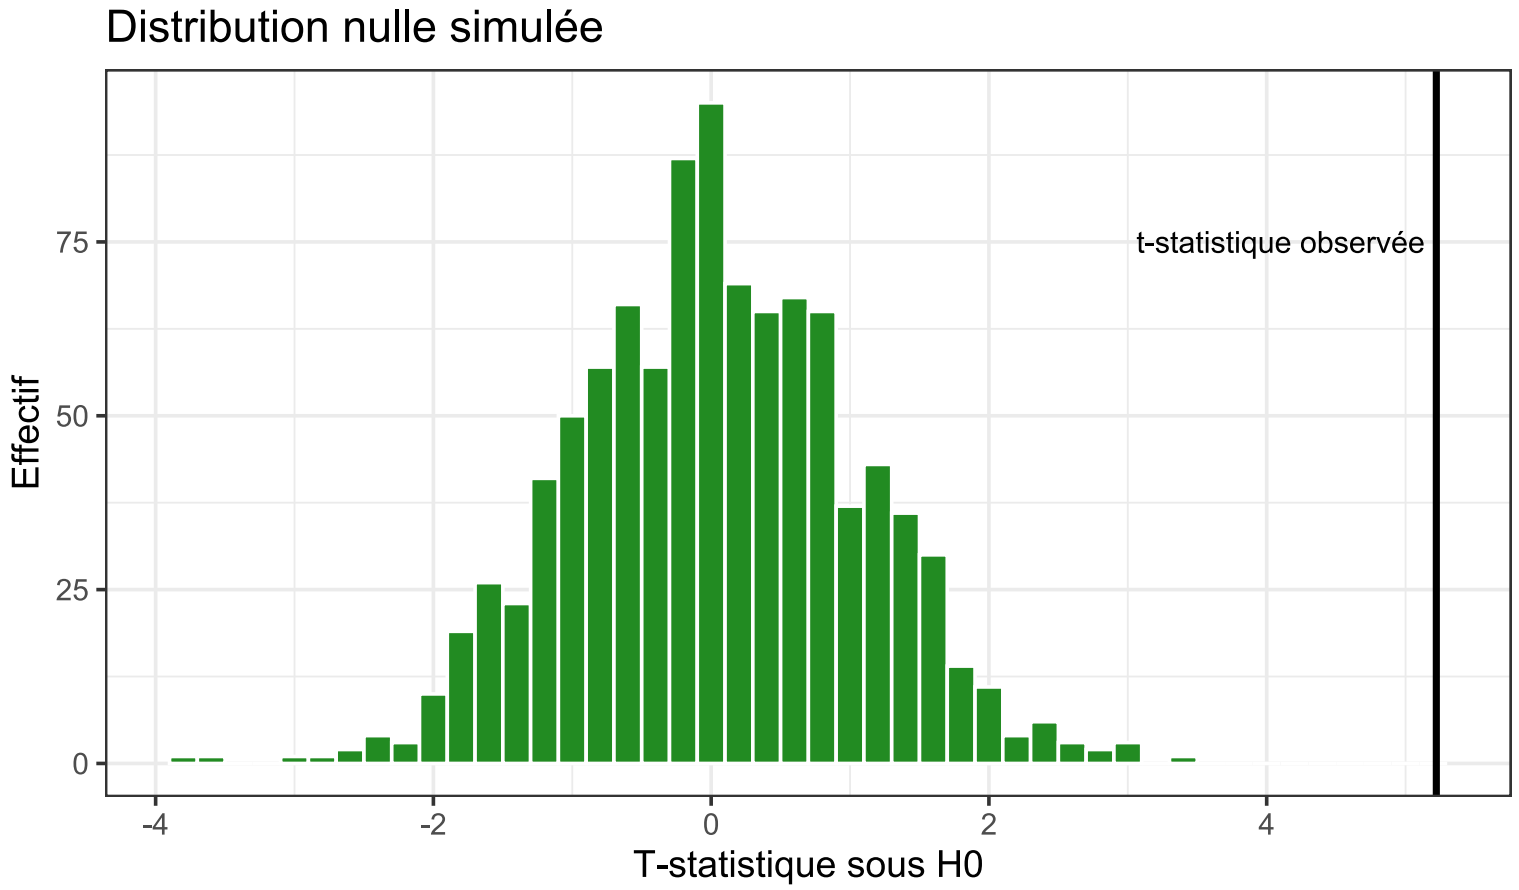
Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$



Très improbable d'obtenir β_{small} = 8.8951932 lorsque H_0 est vraie.

Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Pour décider si l'on rejette H_0, nous devons implémenter un **test bilatéral** avec ici : *plus extrême* signifiant inférieur à -5.22 **ou** supérieur 5.22.
- La *valeur p* égale à :

```
p_value = mean(abs(null_distribution$test_stat) >= observed_stat)
p_value
```

```
## [1] 0
```



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Pour décider si l'on rejette H_0, nous devons implémenter un **test bilatéral** avec ici : *plus extrême* signifiant inférieur à -5.22 **ou** supérieur 5.22.
- La *valeur p* égale à :

```
p_value = mean(abs(null_distribution$test_stat) >= observed_stat)
p_value
```

```
## [1] 0
```

- Même valeur que dans le tableau de régression.



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Pour décider si l'on rejette H_0, nous devons implémenter un **test bilatéral** avec ici : *plus extrême* signifiant inférieur à -5.22 **ou** supérieur 5.22.
- La *valeur p* égale à :

```
p_value = mean(abs(null_distribution$test_stat) >= observed_stat)
p_value
```

```
## [1] 0
```

- Même valeur que dans le tableau de régression.
- ***Question :*** Est-ce qu'on peut rejeter l'hypothèse nulle au seuil de 5% ?



Tester $\beta_{\text{small}} = 0$ contre $\beta_{\text{small}} \neq 0$

- Pour décider si l'on rejette H_0, nous devons implémenter un **test bilatéral** avec ici : *plus extrême* signifiant inférieur à -5.22 **ou** supérieur 5.22.
- La *valeur p* égale à :

```
p_value = mean(abs(null_distribution$test_stat) >= observed_stat)
p_value
```

```
## [1] 0
```

- Même valeur que dans le tableau de régression.
- ***Réponse :***
  - Puisque la *valeur p* est égale à 0, cela signifie que l'on peut rejeter H_0 à n'importe quel seuil de confiance : elle sera toujours inférieur à α.
  - En d'autres termes, on peut dire que β_{small} est **statistiquement différent de 0** à tout seuil de confiance.
  - On dit ausi que β_{small} est *significatif statistiquement* (à tout seuil de confiance).



D'un modèle linéaire uni à multivarié

- Jusqu'à présent, notre modèle n'expliquait le score en maths que par la *taille de la classe* (`small`).



D'un modèle linéaire uni à multivarié

- Jusqu'à présent, notre modèle n'expliquait le score en maths que par la ***taille de la classe*** (`small`).
- Mais on pourrait aussi se demander : le ***genre*** de l'élève joue-t-il un rôle sur le score en maths ?



D'un modèle linéaire uni à multivarié

- Jusqu'à présent, notre modèle n'expliquait le score en maths que par la ***taille de la classe*** (`small`).
- Mais on pourrait aussi se demander : le ***genre*** de l'élève joue-t-il un rôle sur le score en maths ?
- Ajoutons la variable `gender` à notre régression :

```
library(fixest)
reg_1var <- feols(math ~ small + gender, data = star_df)
reg_1var
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 488.85175    1.43274 341.20066  < 2.2e-16 ***
## smallTRUE     8.93597    1.67208   5.34424 9.6857e-08 ***
## gendermale   -8.55612    1.67000  -5.12343 3.1696e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.3   Adj. R2: 0.015408
```



D'un modèle linéaire uni à multivarié

- Jusqu'à présent, notre modèle n'expliquait le score en maths que par la ***taille de la classe*** (`small`).
- Mais on pourrait aussi se demander : le ***genre*** de l'élève joue-t-il un rôle sur le score en maths ?
- Ajoutons la variable `gender` à notre régression :

```
library(fixest)
reg_1var <- feols(math ~ small + gender, data = star_df)
reg_1var
```

```
## OLS estimation, Dep. Var.: math
## Observations: 3,359
## Standard-errors: IID
##              Estimate Std. Error   t value   Pr(>|t|)
## (Intercept) 488.85175    1.43274 341.20066  < 2.2e-16 ***
## smallTRUE     8.93597    1.67208   5.34424 9.6857e-08 ***
## gendermale   -8.55612    1.67000  -5.12343 3.1696e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 48.3   Adj. R2: 0.015408
```

- Nous avons maintenant ***deux*** coefficients à interpréter : $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$.

Que voulons-nous tester, intuitivement ?

- On voudrait savoir : *le genre a-t-il un effet sur le score en maths, une fois que l'on contrôle pour la taille de la classe ?*

Que voulons-nous tester, intuitivement ?

- On voudrait savoir : *le genre a-t-il un effet sur le score en maths, une fois que l'on contrôle pour la taille de la classe ?*
- C'est exactement le même raisonnement que pour `small` :
  - $H_0 : \beta_{\text{gender}} = 0$ (le genre n'a *aucun effet*)
  - $H_A : \beta_{\text{gender}} \neq 0$ (le genre a *un effet*)



Que voulons-nous tester, intuitivement ?

- On voudrait savoir : ***le genre a-t-il un effet sur le score en maths, une fois que l'on contrôle pour la taille de la classe ?***
- C'est exactement le même raisonnement que pour `small` :
  - H_0 : $\beta_{\text{gender}} = 0$ (le genre n'a ***aucun effet***)
  - H_A : $\beta_{\text{gender}} \neq 0$ (le genre a ***un effet***)
- On se demande : *si en réalité le genre n'avait aucun effet sur le score, quelle est la probabilité d'observer un coefficient aussi grand (en valeur absolue) que $\hat{\beta}_{\text{gender}}$ par pur hasard d'échantillonnage ?*

Que voulons-nous tester, intuitivement ?

- On voudrait savoir : ***le genre a-t-il un effet sur le score en maths, une fois que l'on contrôle pour la taille de la classe ?***
- C'est exactement le même raisonnement que pour `small` :
  - $H_0 : \beta_{\text{gender}} = 0$ (le genre n'a ***aucun effet***)
  - $H_A : \beta_{\text{gender}} \neq 0$ (le genre a ***un effet***)
- On se demande : *si en réalité le genre n'avait aucun effet sur le score, quelle est la probabilité d'observer un coefficient aussi grand (en valeur absolue) que $\hat{\beta}_{\text{gender}}$ par pur hasard d'échantillonnage ?*
- La logique est identique à celle de `small` : on compare la ***statistique de test observée*** $\frac{\hat{\beta}_{\text{gender}}}{\hat{SE}(\hat{\beta}_{\text{gender}})}$ à sa ***distribution nulle***.



Que voulons-nous tester, intuitivement ?

- On voudrait savoir : ***le genre a-t-il un effet sur le score en maths, une fois que l'on contrôle pour la taille de la classe ?***
- C'est exactement le même raisonnement que pour `small` :
  - $H_0 : \beta_{\text{gender}} = 0$ (le genre n'a ***aucun effet***)
  - $H_A : \beta_{\text{gender}} \neq 0$ (le genre a ***un effet***)
- On se demande : *si en réalité le genre n'avait aucun effet sur le score, quelle est la probabilité d'observer un coefficient aussi grand (en valeur absolue) que $\hat{\beta}_{\text{gender}}$ par pur hasard d'échantillonnage ?*
- La logique est identique à celle de `small` : on compare la ***statistique de test observée*** $\frac{\hat{\beta}_{\text{gender}}}{\hat{SE}(\hat{\beta}_{\text{gender}})}$ à sa ***distribution nulle***.
- Mais une nouvelle question se pose : et si on voulait tester ***plusieurs coefficients à la fois*** ?



Test de restriction linéaire multiple : le F-test?

- Imaginons que l'on se demande : `small` *et* `gender` *ont-ils, ensemble, un pouvoir explicatif sur le score en maths ?*

Test de restriction linéaire multiple : le F-test?

- Imaginons que l'on se demande : `small` *et* `gender` *ont-ils, ensemble, un pouvoir explicatif sur le score en maths ?*
- Intuitivement, c'est différent de tester chaque variable séparément !

Test de restriction linéaire multiple : le F-test?

- Imaginons que l'on se demande : `small` *et* `gender` *ont-ils, ensemble, un pouvoir explicatif sur le score en maths ?*
- Intuitivement, c'est différent de tester chaque variable séparément !
- On pourrait très bien avoir :
  - $\hat{\beta}_{\text{small}}$ pas significatif individuellement,
  - $\hat{\beta}_{\text{gender}}$ pas significatif individuellement,
  - mais les deux ***ensemble*** apportent quand même de l'information sur `math`.

Test de restriction linéaire multiple : le F-test?

- Imaginons que l'on se demande : `small` *et* `gender` *ont-ils, ensemble, un pouvoir explicatif sur le score en maths ?*
- Intuitivement, c'est différent de tester chaque variable séparément !
- On pourrait très bien avoir :
  - $\hat{\beta}_{\text{small}}$ pas significatif individuellement,
  - $\hat{\beta}_{\text{gender}}$ pas significatif individuellement,
  - mais les deux ***ensemble*** apportent quand même de l'information sur `math`.
- Pour répondre à cette question, on a besoin d'un test *conjoint* : le *test de Fisher (F-test)*.



Intuition du F-test

- L'idée : on compare ***deux modèles*** :
  - Le modèle ***complet*** : score $\text{math}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{gender}_i + u_i$
  - Le modèle ***restreint*** (sous H_0) : score $\text{math}_i = \beta_0 + u_i$



Intuition du F-test

- L'idée : on compare ***deux modèles*** :
  - Le modèle ***complet*** : score $\text{math}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{gender}_i + u_i$
  - Le modèle ***restreint*** (sous H_0) : score $\text{math}_i = \beta_0 + u_i$
- ***Hypothèses*** du test :

$$H_0 : \beta_{\text{small}} = \beta_{\text{gender}} = 0$$
$$H_A : \text{au moins un des deux } \beta_k \neq 0$$



Intuition du F-test

- L'idée : on compare ***deux modèles*** :
  - Le modèle ***complet*** : score $\text{math}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{gender}_i + u_i$
  - Le modèle ***restreint*** (sous H_0) : score $\text{math}_i = \beta_0 + u_i$
- ***Hypothèses*** du test :

$$H_0 : \beta_{\text{small}} = \beta_{\text{gender}} = 0$$
$$H_A : \text{au moins un des deux } \beta_k \neq 0$$

- Intuition : si le modèle complet n'explique ***pas mieux*** `math` que le modèle restreint (sans variables), alors les deux variables ***n'apportent rien*** ensemble.

Intuition du F-test

- L'idée : on compare ***deux modèles*** :
  - Le modèle ***complet*** : score $\text{math}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{gender}_i + u_i$
  - Le modèle ***restreint*** (sous H_0) : score $\text{math}_i = \beta_0 + u_i$
- ***Hypothèses*** du test :

$$H_0 : \beta_{\text{small}} = \beta_{\text{gender}} = 0$$
$$H_A : \text{au moins un des deux } \beta_k \neq 0$$

- Intuition : si le modèle complet n'explique ***pas mieux*** `math` que le modèle restreint (sans variables), alors les deux variables ***n'apportent rien*** ensemble.
- Le F-test compare la ***réduction de la variance résiduelle*** obtenue en ajoutant nos variables, par rapport à ce que l'on attendrait ***par hasard***.



Intuition du F-test

- L'idée : on compare ***deux modèles*** :
  - Le modèle ***complet*** : score $\text{math}_i = \beta_0 + \beta_1 \text{small}_i + \beta_2 \text{gender}_i + u_i$
  - Le modèle ***restreint*** (sous H_0) : score $\text{math}_i = \beta_0 + u_i$
- ***Hypothèses*** du test :

$$H_0 : \beta_{\text{small}} = \beta_{\text{gender}} = 0$$
$$H_A : \text{au moins un des deux } \beta_k \neq 0$$

- Intuition : si le modèle complet n'explique ***pas mieux*** `math` que le modèle restreint (sans variables), alors les deux variables ***n'apportent rien*** ensemble.
- Le F-test compare la ***réduction de la variance résiduelle*** obtenue en ajoutant nos variables, par rapport à ce que l'on attendrait ***par hasard***.
- Plus la statistique F est ***grande***, plus il est improbable d'observer un tel gain d'ajustement ***si H_0 était vraie***.



Le F-test en pratique

```
fitstat(reg_1var, type = "f")
```

```
## F-test: stat = 27.276, p = 1.777e-12, on 2 and 3,356 DoF.
```



Le F-test en pratique

```
fitstat(reg_1var, type = "f")
```

```
## F-test: stat = 27.276, p = 1.777e-12, on 2 and 3,356 DoF.
```

- ***Décision*** : si la valeur-p est ***inférieure*** à notre seuil α (par exemple 0.05), on ***rejette*** H_0.



Le F-test en pratique

```
fitstat(reg_1var, type = "f")
```

```
## F-test: stat = 27.276, p = 1.777e-12, on 2 and 3,356 DoF.
```

- ***Décision*** : si la valeur-p est ***inférieure*** à notre seuil α (par exemple 0.05), on ***rejette*** H_0.
  - Cela signifie que `small` et `gender`, ***pris ensemble***, ont un pouvoir explicatif ***statistiquement significatif*** sur le score en maths.



Le F-test en pratique

```
fitstat(reg_1var, type = "f")
```

```
## F-test: stat = 27.276, p = 1.777e-12, on 2 and 3,356 DoF.
```

- ***Décision*** : si la valeur-p est ***inférieure*** à notre seuil α (par exemple 0.05), on ***rejette*** H_0.
  - Cela signifie que `small` et `gender`, ***pris ensemble***, ont un pouvoir explicatif ***statistiquement significatif*** sur le score en maths.
- ⚠️ : rejeter H_0 dans un F-test ***ne nous dit pas laquelle*** des deux variables est responsable de cet effet, pour cela, il faut revenir aux tests individuels (t-tests) vus précédemment !

$$ F = \dfrac{(R^2{c} - R^2{r})/q}{R^2_{c}/(n-k-1)} $$ avec q = nombres de restrictions;
$n - k - 1$: degrés de liberté dans modèle complet (c)

Et si on voulait comparer deux coefficients entre eux ?

- Une autre question intéressante : est-ce que l'effet de `small` sur `math` est du même ***ordre de grandeur*** que celui de `gender` : $\beta_{\text{small}} = \beta_{\text{gender}}$?

Et si on voulait comparer deux coefficients entre eux ?

- Une autre question intéressante : est-ce que l'effet de `small` sur `math` est du même ***ordre de grandeur*** que celui de `gender` : $\beta_{\text{small}} = \beta_{\text{gender}}$?

- ⚠️ Ce n'est ***pas la même chose*** que de tester si chacun est égal à zéro séparément !

  - On pourrait très bien avoir $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ tous les deux ***significativement différents de zéro***, mais ***très proches l'un de l'autre*** (donc $\beta_{\text{small}} = \beta_{\text{gender}}$ plausible).

Et si on voulait comparer deux coefficients entre eux ?

- Une autre question intéressante : est-ce que l'effet de `small` sur `math` est du même ***ordre de grandeur*** que celui de `gender` : $\beta_{\text{small}} = \beta_{\text{gender}}$?

- ⚠️ Ce n'est ***pas la même chose*** que de tester si chacun est égal à zéro séparément !

  - On pourrait très bien avoir $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ tous les deux ***significativement différents de zéro***, mais ***très proches l'un de l'autre*** (donc $\beta_{\text{small}} = \beta_{\text{gender}}$ plausible).

  - Ou inversement, tous les deux significatifs, mais ***très différents*** l'un de l'autre.



Et si on voulait comparer deux coefficients entre eux ?

- Une autre question intéressante : est-ce que l'effet de `small` sur `math` est du même ***ordre de grandeur*** que celui de `gender` : $\beta_{\text{small}} = \beta_{\text{gender}}$?
- ⚠️ Ce n'est ***pas la même chose*** que de tester si chacun est égal à zéro séparément !
  - On pourrait très bien avoir $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ tous les deux ***significativement différents de zéro***, mais ***très proches l'un de l'autre*** (donc $\beta_{\text{small}} = \beta_{\text{gender}}$ plausible).
  - Ou inversement, tous les deux significatifs, mais ***très différents*** l'un de l'autre.
- ***Hypothèses*** de ce nouveau test :

$$H_0 : \beta_{\text{small}} - \beta_{\text{gender}} = 0$$
$$H_A : \beta_{\text{small}} - \beta_{\text{gender}} \neq 0$$



Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.

Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.
- Idée : on construit une nouvelle ***statistique de test*** basée sur $\hat{\beta}_{\text{small}} - \hat{\beta}_{\text{gender}}$.

Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.
- Idée : on construit une nouvelle ***statistique de test*** basée sur $\hat{\beta}_{\text{small}} - \hat{\beta}_{\text{gender}}$.
- Comme toujours, il nous faut une ***erreur type*** pour cette différence, mais ce n'est ***pas simplement*** $\hat{SE}(\hat{\beta}_{\text{small}}) - \hat{SE}(\hat{\beta}_{\text{gender}})$!

Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.
- Idée : on construit une nouvelle ***statistique de test*** basée sur $\hat{\beta}_{\text{small}} - \hat{\beta}_{\text{gender}}$.
- Comme toujours, il nous faut une ***erreur type*** pour cette différence, mais ce n'est ***pas simplement*** $\hat{SE}(\hat{\beta}_{\text{small}}) - \hat{SE}(\hat{\beta}_{\text{gender}})$!
  - $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ sont estimés ***simultanément*** dans le même modèle, ils peuvent être ***corrélés*** entre eux.

Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.
- Idée : on construit une nouvelle ***statistique de test*** basée sur $\hat{\beta}_{\text{small}} - \hat{\beta}_{\text{gender}}$.
- Comme toujours, il nous faut une ***erreur type*** pour cette différence, mais ce n'est ***pas simplement*** $\hat{SE}(\hat{\beta}_{\text{small}}) - \hat{SE}(\hat{\beta}_{\text{gender}})$!
  - $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ sont estimés ***simultanément*** dans le même modèle, ils peuvent être ***corrélés*** entre eux.
  - L'erreur type correcte doit tenir compte de cette ***covariance*** entre les deux estimateurs.



Intuition : tester une combinaison linéaire de coefficients

- On ne teste plus un seul coefficient, mais une ***différence*** entre deux coefficients.
- Idée : on construit une nouvelle ***statistique de test*** basée sur $\hat{\beta}_{\text{small}} - \hat{\beta}_{\text{gender}}$.
- Comme toujours, il nous faut une ***erreur type*** pour cette différence, mais ce n'est ***pas simplement*** $\hat{SE}(\hat{\beta}_{\text{small}}) - \hat{SE}(\hat{\beta}_{\text{gender}})$!
  - $\hat{\beta}_{\text{small}}$ et $\hat{\beta}_{\text{gender}}$ sont estimés ***simultanément*** dans le même modèle, ils peuvent être ***corrélés*** entre eux.
  - L'erreur type correcte doit tenir compte de cette ***covariance*** entre les deux estimateurs.
- Heureusement, R calcule cela automatiquement pour nous !



Tester $\beta_{\text{small}} = \beta_{\text{gender}}$ en pratique

```r
library(car)
linearHypothesis(reg_1var, "smallTRUE = gendermale")
```

```
##
## Linear hypothesis test:
## smallTRUE - gendermale = 0
##
## Model 1: restricted model
## Model 2: math ~ small + gender
##
##   Res.Df Df  Chisq Pr(>Chisq)
## 1   3357
## 2   3356  1 54.528  1.533e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Tester $\beta_{\text{small}} = \beta_{\text{gender}}$ en pratique

```
library(car)
linearHypothesis(reg_1var, "smallTRUE = gendermale")
```

```
##
## Linear hypothesis test:
## smallTRUE - gendermale = 0
##
## Model 1: restricted model
## Model 2: math ~ small + gender
##
##   Res.Df Df  Chisq Pr(>Chisq)
## 1   3357
## 2   3356  1 54.528  1.533e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- On retrouve une structure familière : une ***statistique de test*** (ici un F, car ce test peut aussi être vu comme un cas particulier de F-test à ***une seule contrainte***) et une ***valeur-p***.



Tester $\beta_{\text{small}} = \beta_{\text{gender}}$ en pratique

```r
library(car)
linearHypothesis(reg_1var, "smallTRUE = gendermale")
```

```
##
## Linear hypothesis test:
## smallTRUE - gendermale = 0
##
## Model 1: restricted model
## Model 2: math ~ small + gender
##
##   Res.Df Df  Chisq Pr(>Chisq)
## 1   3357
## 2   3356  1 54.528  1.533e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- On retrouve une structure familière : une ***statistique de test*** (ici un F, car ce test peut aussi être vu comme un cas particulier de F-test à ***une seule contrainte***) et une ***valeur-p***.
- ***Décision*** : si la valeur-p est ***inférieure*** à α, on ***rejette*** H_0, c'est-à-dire que l'on conclut que les effets de `small` et `gender` sur `math` sont ***statistiquement différents***.



Tester $\beta_{\text{small}} = \beta_{\text{gender}}$ en pratique

```r
library(car)
linearHypothesis(reg_1var, "smallTRUE = gendermale")
```

```
##
## Linear hypothesis test:
## smallTRUE - gendermale = 0
##
## Model 1: restricted model
## Model 2: math ~ small + gender
##
##   Res.Df Df  Chisq Pr(>Chisq)
## 1   3357
## 2   3356  1 54.528  1.533e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- On retrouve une structure familière : une ***statistique de test*** (ici un F, car ce test peut aussi être vu comme un cas particulier de F-test à ***une seule contrainte***) et une ***valeur-p***.
- ***Décision*** : si la valeur-p est ***inférieure*** à α, on ***rejette*** H_0, c'est-à-dire que l'on conclut que les effets de `small` et `gender` sur `math` sont ***statistiquement différents***.
- Sinon, on ***ne peut pas rejeter*** l'hypothèse que ces deux effets sont ***du même ordre de grandeur***.

Tester $\beta_{\text{small}} = \beta_{\text{gender}}$ en pratique

```r
library(car)
linearHypothesis(reg_1var, "smallTRUE = gendermale")
```

```
##
## Linear hypothesis test:
## smallTRUE - gendermale = 0
##
## Model 1: restricted model
## Model 2: math ~ small + gender
##
##   Res.Df Df  Chisq Pr(>Chisq)
## 1   3357
## 2   3356  1 54.528  1.533e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- On retrouve une structure familière : une ***statistique de test*** (ici un F, car ce test peut aussi être vu comme un cas particulier de F-test à ***une seule contrainte***) et une ***valeur-p***.
- ***Décision*** : si la valeur-p est ***inférieure*** à α, on ***rejette*** H_0, c'est-à-dire que l'on conclut que les effets de `small` et `gender` sur `math` sont ***statistiquement différents***.
- Sinon, on ***ne peut pas rejeter*** l'hypothèse que ces deux effets sont ***du même ordre de grandeur***.

Des tests aux intervalles de confiance

- Rappelez-vous : un test d'hypothèse et un intervalle de confiance sont ***deux faces d'une même pièce***.



Des tests aux intervalles de confiance

- Rappelez-vous : un test d'hypothèse et un intervalle de confiance sont ***deux faces d'une même pièce***.
- Plutôt que de se demander *"est-ce que* $\beta_{\text{gender}} = 0$ *?"*, on peut se demander : ***"quelle est la plage de valeurs plausibles pour*** β_{gender} ***?"***

Des tests aux intervalles de confiance

- Rappelez-vous : un test d'hypothèse et un intervalle de confiance sont ***deux faces d'une même pièce***.
- Plutôt que de se demander *"est-ce que* $\beta_{\text{gender}} = 0$ *?"*, on peut se demander : ***"quelle est la plage de valeurs plausibles pour*** β_{gender} ***?"***
- Un ***intervalle de confiance à 95%*** pour β_k répond à la question :

> *Si l'on répétait l'échantillonnage un grand nombre de fois, dans 95% des cas, l'intervalle obtenu contiendrait la vraie valeur de* β_k.



Des tests aux intervalles de confiance

- Rappelez-vous : un test d'hypothèse et un intervalle de confiance sont ***deux faces d'une même pièce***.
- Plutôt que de se demander *"est-ce que $\beta_{\text{gender}} = 0$?"*, on peut se demander : ***"quelle est la plage de valeurs plausibles pour β_{gender} ?"***
- Un ***intervalle de confiance à 95%*** pour β_k répond à la question :

> *Si l'on répétait l'échantillonnage un grand nombre de fois, dans 95% des cas, l'intervalle obtenu contiendrait la vraie valeur de β_k.*

- Lien avec le test d'hypothèse : si 0 ***n'est pas*** dans l'intervalle de confiance à 95% de β_k, alors on ***rejette*** $H_0 : \beta_k = 0$ au seuil de 5%.



Intervalles de confiance en pratique

```
confint(reg_1var)
```

```
##                 2.5 %     97.5 %
## (Intercept) 486.04262 491.660879
## smallTRUE     5.65758  12.214360
## gendermale  -11.83044  -5.281803
```



Intervalles de confiance en pratique

```
confint(reg_1var)
```

```
##                 2.5 %     97.5 %
## (Intercept) 486.04262 491.660879
## smallTRUE     5.65758  12.214360
## gendermale  -11.83044  -5.281803
```

- Pour chaque coefficient, on obtient une borne ***inférieure*** et une borne ***supérieure***.



Intervalles de confiance en pratique

```
confint(reg_1var)
```

```
##                 2.5 %     97.5 %
## (Intercept) 486.04262 491.660879
## smallTRUE     5.65758  12.214360
## gendermale  -11.83044  -5.281803
```

- Pour chaque coefficient, on obtient une borne ***inférieure*** et une borne ***supérieure***.
- ***Interprétation*** : on est "confiant à 95%" que la vraie valeur de β_{small} (respectivement β_{gender}) se situe dans cet intervalle.



Intervalles de confiance en pratique

```
confint(reg_1var)
```

```
##                 2.5 %     97.5 %
## (Intercept) 486.04262 491.660879
## smallTRUE     5.65758  12.214360
## gendermale  -11.83044  -5.281803
```

- Pour chaque coefficient, on obtient une borne ***inférieure*** et une borne ***supérieure***.
- ***Interprétation*** : on est "confiant à 95%" que la vraie valeur de β_{small} (respectivement β_{gender}) se situe dans cet intervalle.
- ***Question*** : est-ce que 0 est contenu dans l'intervalle de confiance de `gender` ? Qu'est-ce que cela implique pour notre test d'hypothèse ?



Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.

Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.
- ***Problème*** : le R^2 ***augmente mécaniquement*** à chaque fois que l'on ajoute une variable, même si elle n'a ***aucun lien réel*** avec `math` !



Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.
- ***Problème*** : le R^2 ***augmente mécaniquement*** à chaque fois que l'on ajoute une variable, même si elle n'a ***aucun lien réel*** avec `math` !
- On a donc besoin d'une mesure qui ***pénalise*** l'ajout de variables inutiles : le ***R^2 ajusté***.



Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.
- ***Problème*** : le R^2 ***augmente mécaniquement*** à chaque fois que l'on ajoute une variable, même si elle n'a ***aucun lien réel*** avec `math` !
- On a donc besoin d'une mesure qui ***pénalise*** l'ajout de variables inutiles : le ***R^2 ajusté***.

$$\bar{R}^2 = 1 - (1 - R^2) \times \frac{n - 1}{n - k - 1}$$

où n est le nombre d'observations et k le nombre de variables explicatives.

Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.
- ***Problème*** : le R^2 ***augmente mécaniquement*** à chaque fois que l'on ajoute une variable, même si elle n'a ***aucun lien réel*** avec `math` !
- On a donc besoin d'une mesure qui ***pénalise*** l'ajout de variables inutiles : le ***R^2 ajusté***.

$$\bar{R}^2 = 1 - (1 - R^2) \times \frac{n - 1}{n - k - 1}$$

où n est le nombre d'observations et k le nombre de variables explicatives.

- ***Intuition*** : le R^2 ajusté n'augmente que si la ***nouvelle variable*** améliore l'ajustement ***plus*** que ce que l'on attendrait par pur hasard.



Ajouter des variables améliore-t-il toujours le modèle ?

- Le R^2 mesure la part de variance de `math` expliquée par le modèle.
- ***Problème*** : le R^2 ***augmente mécaniquement*** à chaque fois que l'on ajoute une variable, même si elle n'a ***aucun lien réel*** avec `math` !
- On a donc besoin d'une mesure qui ***pénalise*** l'ajout de variables inutiles : le ***R^2 ajusté***.

$$\bar{R}^2 = 1 - (1 - R^2) \times \frac{n - 1}{n - k - 1}$$

où n est le nombre d'observations et k le nombre de variables explicatives.

- ***Intuition*** : le R^2 ajusté n'augmente que si la ***nouvelle variable*** améliore l'ajustement ***plus*** que ce que l'on attendrait par pur hasard.
- ***Règle pratique*** : pour comparer deux modèles avec un nombre de variables différent, on préfère toujours regarder le R^2 ***ajusté*** plutôt que le R^2 brut.



Inférence en Régression: Théorie

Inférence en régression : la théorie

- Jusqu'à présent, nous avons présenté l'inférence basée sur la ***simulation***.

Inférence en régression : la théorie

- Jusqu'à présent, nous avons présenté l'inférence basée sur la ***simulation***.
- Les valeurs rapportées par les packages statistiques dans `R` sont en réalité obtenues à partir de la ***théorie***.

Inférence en régression : la théorie

- Jusqu'à présent, nous avons présenté l'inférence basée sur la ***simulation***.
- Les valeurs rapportées par les packages statistiques dans `R` sont en réalité obtenues à partir de la ***théorie***.
- L'inférence basée sur la théorie repose sur des ***approximations en grand échantillon***.
  - On peut montrer que les distributions d'échantillonnage ***convergent*** vers des distributions adéquates $\rightarrow$ ***théorème central limite***



Inférence en régression : la théorie

- Jusqu'à présent, nous avons présenté l'inférence basée sur la ***simulation***.
- Les valeurs rapportées par les packages statistiques dans `R` sont en réalité obtenues à partir de la ***théorie***.
- L'inférence basée sur la théorie repose sur des ***approximations en grand échantillon***.
  - On peut montrer que les distributions d'échantillonnage ***convergent*** vers des distributions adéquates $\rightarrow$ ***théorème central limite***
- Regardons brièvement l'approche théorique.



Inférence en régression : la théorie

- Repose sur : la distribution d'échantillonnage de la statistique $\frac{\hat{\beta}-\beta}{\hat{\mathrm{SE}}(\hat{\beta})}$ ***converge*** vers une ***distribution normale centrée réduite*** à mesure que la taille de l'échantillon augmente.
  - $\hat{\mathrm{SE}}(\hat{\beta})$ est l'estimation d'échantillon de l'écart-type de $\hat{\beta}$.
  - Elle est elle aussi obtenue par une formule théorique (voir ici) mais nous la laisserons de côté.

Inférence en régression : la théorie

- Repose sur : la distribution d'échantillonnage de la statistique $\frac{\hat{\beta}-\beta}{\hat{\mathrm{SE}}(\hat{\beta})}$ ***converge*** vers une ***distribution normale centrée réduite*** à mesure que la taille de l'échantillon augmente.
  - $\hat{\mathrm{SE}}(\hat{\beta})$ est l'estimation d'échantillon de l'écart-type de $\hat{\beta}$.
  - Elle est elle aussi obtenue par une formule théorique (voir ici) mais nous la laisserons de côté.
- Une ***distribution normale centrée réduite*** est une *distribution normale* de *moyenne* 0 et d'***écart-type*** 1.

Inférence en régression : la théorie

- Repose sur : la distribution d'échantillonnage de la statistique $\frac{\hat{\beta}-\beta}{\hat{\text{SE}}(\hat{\beta})}$ ***converge*** vers une ***distribution normale centrée réduite*** à mesure que la taille de l'échantillon augmente.
  - $\hat{\text{SE}}(\hat{\beta})$ est l'estimation d'échantillon de l'écart-type de $\hat{\beta}$.
  - Elle est elle aussi obtenue par une formule théorique (voir ici) mais nous la laisserons de côté.
- Une ***distribution normale centrée réduite*** est une *distribution normale* de *moyenne* 0 et d'***écart-type*** 1.
- Nous dérivons de la théorie la distribution d'échantillonnage et l'utilisons pour construire des IC ou mener des tests d'hypothèses.

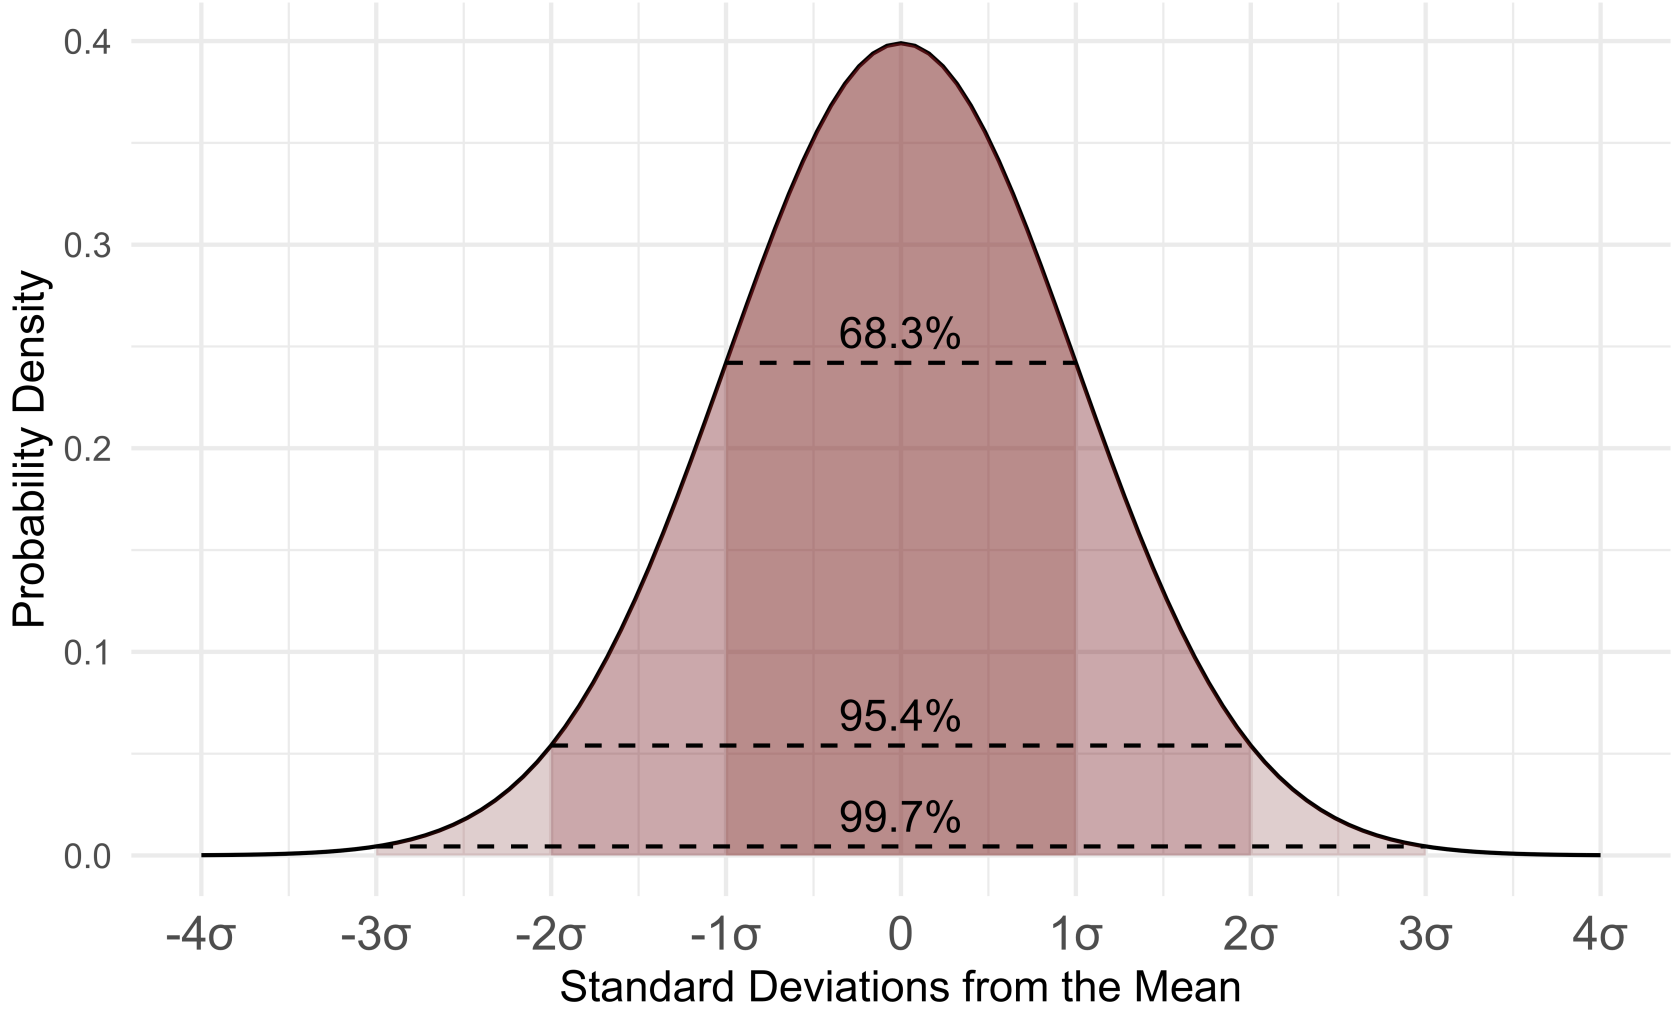


Inférence en régression : la théorie

- Repose sur : la distribution d'échantillonnage de la statistique $\frac{\hat{\beta}-\beta}{\hat{\text{SE}}(\hat{\beta})}$ ***converge*** vers une ***distribution normale centrée réduite*** à mesure que la taille de l'échantillon augmente.
  - $\hat{\text{SE}}(\hat{\beta})$ est l'estimation d'échantillon de l'écart-type de $\hat{\beta}$.
  - Elle est elle aussi obtenue par une formule théorique (voir ici) mais nous la laisserons de côté.
- Une ***distribution normale centrée réduite*** est une *distribution normale* de *moyenne* 0 et d'***écart-type*** 1.
- Nous dérivons de la théorie la distribution d'échantillonnage et l'utilisons pour construire des IC ou mener des tests d'hypothèses.
- Notez que si $\frac{\hat{\beta}-\beta}{\hat{\text{SE}}(\hat{\beta})}$ ***converge*** vers une ***distribution normale centrée réduite***, alors $\hat{\beta}$ converge vers une ***distribution normale*** de moyenne β et d'écart-type $\hat{\text{SE}}(\hat{\beta})$.



Distribution Normal : Rappel



Inférence basée sur la théorie : intervalle de confiance

- Prenons l'exemple d'un intervalle de confiance à 95%.

Inférence basée sur la théorie : intervalle de confiance

- Prenons l'exemple d'un intervalle de confiance à 95%.
- Puisque la distribution d'échantillonnage de $\hat{\beta}$ est supposée avoir une forme normale, nous pouvons utiliser la ***règle empirique des 95%*** relative aux distributions normales.

Inférence basée sur la théorie : intervalle de confiance

- Prenons l'exemple d'un intervalle de confiance à 95%.
- Puisque la distribution d'échantillonnage de $\hat{\beta}$ est supposée avoir une forme normale, nous pouvons utiliser la ***règle empirique des 95%*** relative aux distributions normales.
- Nous savons en effet que 95% des valeurs d'une distribution normale se situent à environ 2 écarts-types de la moyenne (exactement 1,96).



Inférence basée sur la théorie : intervalle de confiance

- Prenons l'exemple d'un intervalle de confiance à 95%.
- Puisque la distribution d'échantillonnage de $\hat{\beta}$ est supposée avoir une forme normale, nous pouvons utiliser la ***règle empirique des 95%*** relative aux distributions normales.
- Nous savons en effet que 95% des valeurs d'une distribution normale se situent à environ 2 écarts-types de la moyenne (exactement 1,96).
- On peut donc calculer un IC à 95% pour β comme : $\mathrm{CI}_{95\%} = [\hat{\beta} \pm 1{,}96 * \hat{\mathrm{SE}}(\hat{\beta})]$



IC à 95% : théorie vs bootstrap

```
tidy(lm(math ~ small, star_df),
     conf.int = TRUE, conf.level = 0.95) %>%
  filter(term == "smallTRUE") %>%
  select(term, conf.low, conf.high)
```

```
## # A tibble: 1 × 3
##   term      conf.low conf.high
##   <chr>        <dbl>     <dbl>
## 1 smallTRUE     5.60      12.2
```



IC à 95% : théorie vs bootstrap

```
tidy(lm(math ~ small, star_df),
     conf.int = TRUE, conf.level = 0.95) %>%
  filter(term == "smallTRUE") %>%
  select(term, conf.low, conf.high)
```

```
## # A tibble: 1 × 3
##   term      conf.low conf.high
##   <chr>        <dbl>     <dbl>
## 1 smallTRUE     5.60      12.2
```

```
bootstrap_distrib %>%
  summarise(
    lower_bound = 8.895 - 1.96*sd(stat),
    upper_bound = 8.895 + 1.96*sd(stat))
```

```
## # A tibble: 1 × 2
##   lower_bound upper_bound
##         <dbl>       <dbl>
## 1        5.56        12.2
```



IC à 95% : théorie vs bootstrap

```
tidy(lm(math ~ small, star_df),
     conf.int = TRUE, conf.level = 0.95) %>%
  filter(term == "smallTRUE") %>%
  select(term, conf.low, conf.high)
```

```
## # A tibble: 1 × 3
##   term      conf.low conf.high
##   <chr>        <dbl>     <dbl>
## 1 smallTRUE     5.60      12.2
```

```
bootstrap_distrib %>%
  summarise(
    lower_bound = 8.895 - 1.96*sd(stat),
    upper_bound = 8.895 + 1.96*sd(stat))
```

```
## # A tibble: 1 × 2
##   lower_bound upper_bound
##         <dbl>       <dbl>
## 1        5.56        12.2
```

- Généralisable pour tout seuil de confiance en prenant le quantile correspondant de la distribution normale.



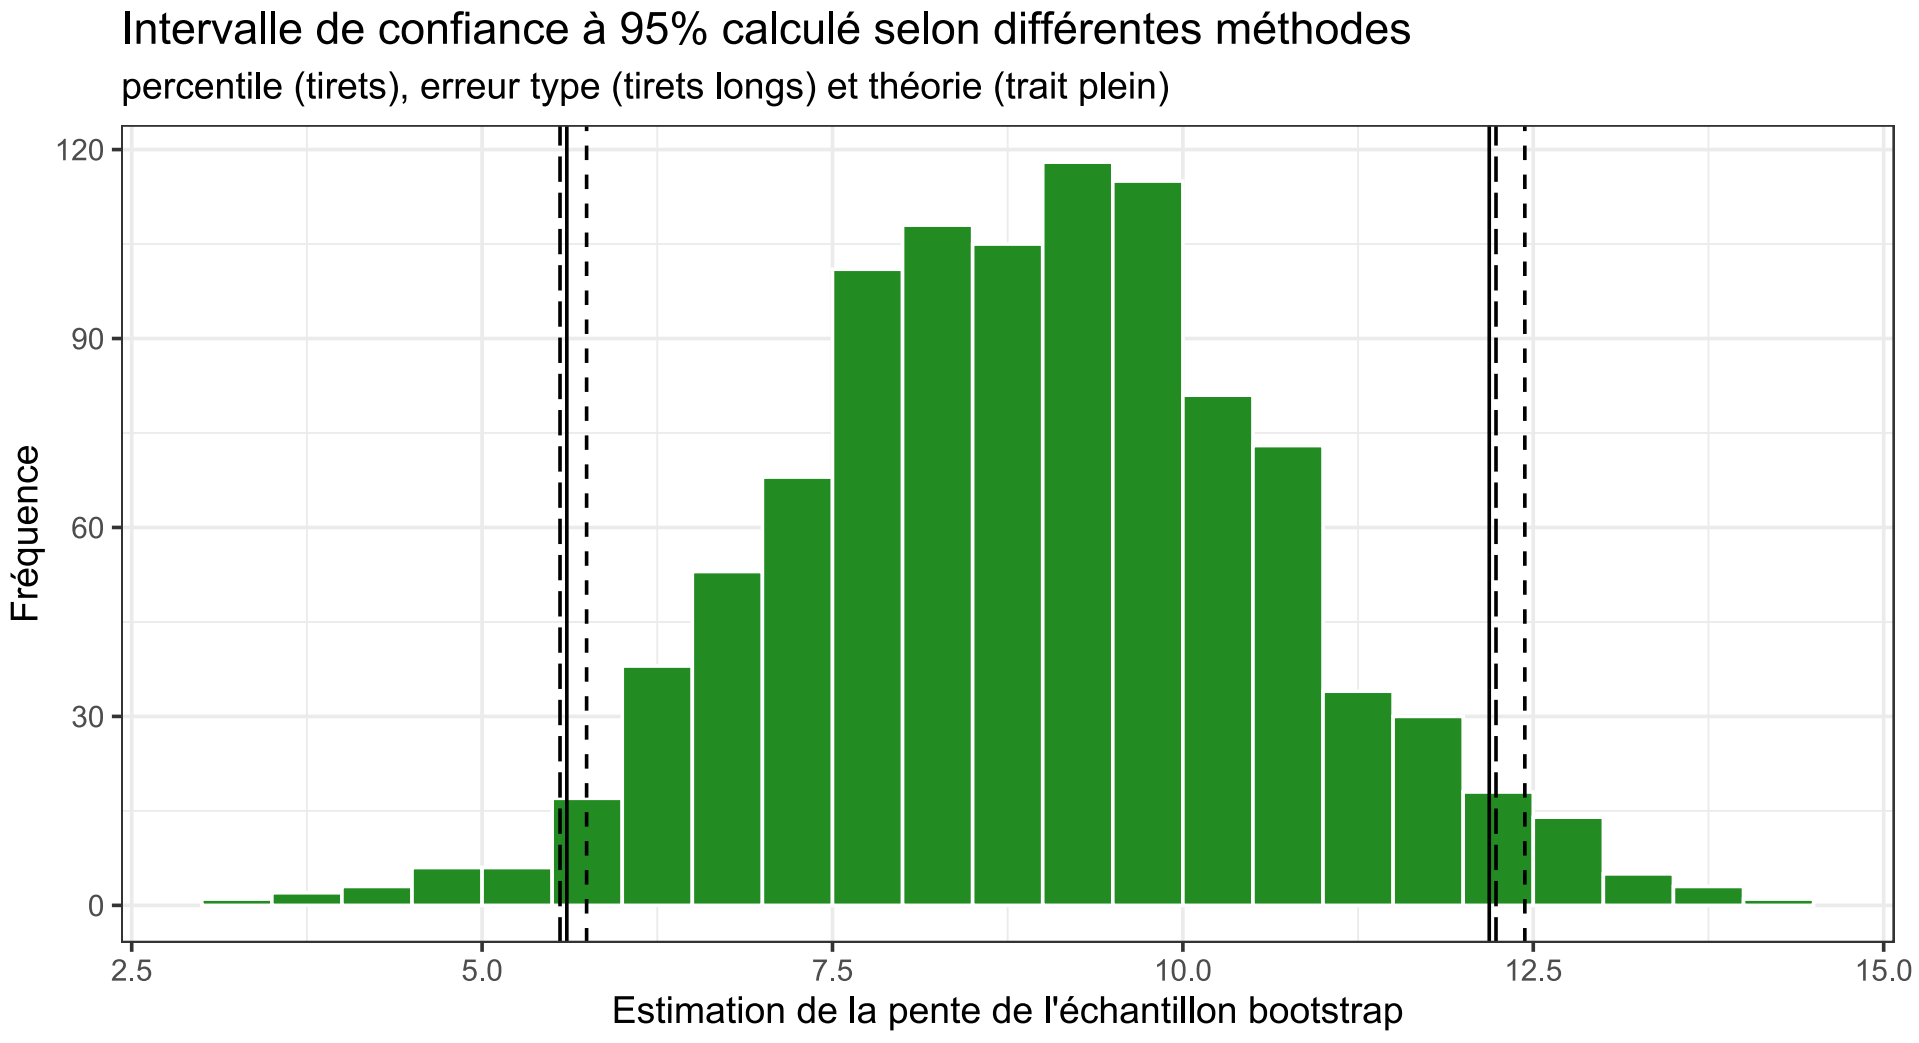
Tâche 2

05:00

1. En uilisant la distribution bottstrap générée au 1er exercise, calculer les IC à 95% en utilisant la *méthode des percentiles*.

2. Dans quelle mesure ces IC sont proches de ceux de la diapo précédente ?

Intervalle de Confiance : Visuellement



Inférence basée sur la théorie : test d'hypothèse

- La théorie nous dit que $\frac{\hat{\beta}-\beta_k}{\hat{\mathrm{SE}}(\hat{\beta})}$ converge vers une distribution normale centrée réduite
- Comme nous l'avons déjà mentionné, le test par défaut effectué par tout logiciel statistique est :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

Inférence basée sur la théorie : test d'hypothèse

- La théorie nous dit que $\frac{\hat{\beta}-\beta_k}{\hat{\text{SE}}(\hat{\beta})}$ converge vers une distribution normale centrée réduite
- Comme nous l'avons déjà mentionné, le test par défaut effectué par tout logiciel statistique est :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Ainsi, ***sous l'hypothèse nulle***, $\beta_k = 0$, et la théorie nous disent que la distribution d'échantillonnage de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$ sera une distribution normale centrée réduite.

Inférence basée sur la théorie : test d'hypothèse

- La théorie nous dit que $\frac{\hat{\beta}-\beta_k}{\hat{\text{SE}}(\hat{\beta})}$ converge vers une distribution normale centrée réduite
- Comme nous l'avons déjà mentionné, le test par défaut effectué par tout logiciel statistique est :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Ainsi, ***sous l'hypothèse nulle***, $\beta_k = 0$, et la théorie nous disent que la distribution d'échantillonnage de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$ sera une distribution normale centrée réduite.
- La ***distribution normale centrée réduite*** est donc la ***distribution nulle*** de notre statistique de test.



Inférence basée sur la théorie : test d'hypothèse

- La théorie nous dit que $\frac{\hat{\beta}-\beta_k}{\hat{\text{SE}}(\hat{\beta})}$ converge vers une distribution normale centrée réduite
- Comme nous l'avons déjà mentionné, le test par défaut effectué par tout logiciel statistique est :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Ainsi, ***sous l'hypothèse nulle***, $\beta_k = 0$, et la théorie nous disent que la distribution d'échantillonnage de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$ sera une distribution normale centrée réduite.
- La ***distribution normale centrée réduite*** est donc la ***distribution nulle*** de notre statistique de test.
- La ***valeur-p*** associée à notre test est alors égale à l'aire de la *distribution normale centrée réduite* à l'extérieur de $\pm$ la valeur observée de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$.



Inférence basée sur la théorie : test d'hypothèse

- La théorie nous dit que $\frac{\hat{\beta}-\beta_k}{\hat{\text{SE}}(\hat{\beta})}$ converge vers une distribution normale centrée réduite
- Comme nous l'avons déjà mentionné, le test par défaut effectué par tout logiciel statistique est :

$$H_0 : \beta_k = 0$$
$$H_A : \beta_k \neq 0$$

- Ainsi, ***sous l'hypothèse nulle***, $\beta_k = 0$, et la théorie nous disent que la distribution d'échantillonnage de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$ sera une distribution normale centrée réduite.
- La ***distribution normale centrée réduite*** est donc la ***distribution nulle*** de notre statistique de test.
- La ***valeur-p*** associée à notre test est alors égale à l'aire de la *distribution normale centrée réduite* à l'extérieur de $\pm$ la valeur observée de $\frac{\hat{\beta}}{\hat{\text{SE}}(\hat{\beta})}$.



Mise en forme d'un tableau de régression

- Maintenant que nous avons vu tous les éléments d'un tableau de régression, apprenons enfin à en créer et en lire un !

```
library(fixest)
reg_simple_math <- feols(math ~ small, data = star_df)
reg_gender_math <- feols(math ~ small + gender, data = star_df)
reg_simple_read <- feols(read ~ small, data = star_df)
reg_gender_read <- feols(read ~ small + gender, data = star_df)

etable(reg_simple_math, reg_gender_math, reg_simple_read,reg_gender_read,
  headers = c("Math score", "Math score",
              "Reading score", "Reading score"),
  dict = c(
    "(Intercept)" = "Intercept",
    "smallTRUE"   = "Small class",
    "gendermale"  = "Male gender"
  ),
  keep = c("Intercept", "Small class", "Male gender"),
  fitstat = ~n + r2,
  digits = 2,
  fixef_sizes = FALSE,
  se.below = TRUE,
  depvar = FALSE,
  tex = FALSE
)
```



Lire une table de régression

	Math score	Math score	Reading score	Reading score
Intercept	484.4***	488.9***	435.8***	439.6***
	(1.2)	(1.4)	(0.75)	(0.93)
Small class	8.9***	8.9***	5.4***	5.4***
	(1.7)	(1.7)	(1.1)	(1.1)
Male gender		-8.6***		-7.5***
		(1.7)		(1.1)
S.E. type	IID	IID	IID	IID
Observations	3,359	3,359	3,359	3,359
R2	0.00830	0.01599	0.00712	0.02099
*** p < 0.001; ** p < 0.01; * p < 0.05				

- Chaque colonne correspond à une régression. Pour la 1ère on a :
  - le **nom de l'outcome** en bleu
  - la **valeur estimée** $\hat{\beta}_{\text{small}}$ en vert
  - l'**estimation de l'écart type** en yellow
  - le **nombre d'observations** en purple
  - le **R^2** en red

Modèle de régression classique

Modèle de régression classique

- Que l'inférence soit basée sur la théorie ou sur des simulations, certaines hypothèses doivent être respectées pour que cette inférence soit valide.
- L'ensemble des hypothèses nécessaires définit le *Modèle de Régression Classique* (MRC).

Modèle de régression classique

- Que l'inférence soit basée sur la théorie ou sur des simulations, certaines hypothèses doivent être respectées pour que cette inférence soit valide.
- L'ensemble des hypothèses nécessaires définit le *Modèle de Régression Classique* (MRC).
- Nous avons déjà mentionné la distinction entre l'estimation d'échantillon $\hat{\beta}_k$ et le paramètre de population β_k.

Modèle de régression classique

- Que l'inférence soit basée sur la théorie ou sur des simulations, certaines hypothèses doivent être respectées pour que cette inférence soit valide.
- L'ensemble des hypothèses nécessaires définit le *Modèle de Régression Classique* (MRC).
- Nous avons déjà mentionné la distinction entre l'estimation d'échantillon $\hat{\beta}_k$ et le paramètre de population β_k.
- De la même manière, nous distinguons u, l'erreur d'échantillon (*résidu*), de ε, le terme d'erreur du véritable modèle de population :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \ldots + \beta_k x_{k,i} + \varepsilon_i$$

Modèle de régression classique

- Que l'inférence soit basée sur la théorie ou sur des simulations, certaines hypothèses doivent être respectées pour que cette inférence soit valide.
- L'ensemble des hypothèses nécessaires définit le *Modèle de Régression Classique* (MRC).
- Nous avons déjà mentionné la distinction entre l'estimation d'échantillon $\hat{\beta}_k$ et le paramètre de population β_k.
- De la même manière, nous distinguons u, l'erreur d'échantillon (*résidu*), de ε, le terme d'erreur du véritable modèle de population :

$$y_i = \beta_0 + \beta_1 x_{1,i} + \ldots + \beta_k x_{k,i} + \varepsilon_i$$

- Le modèle de régression classique s'applique aux **régressions linéaires correctement spécifiées** : le modèle doit être linéaire en paramètres, inclure toutes les variables pertinentes, et les variables ne doivent pas être colinéaires.

Hypothèses du MRC

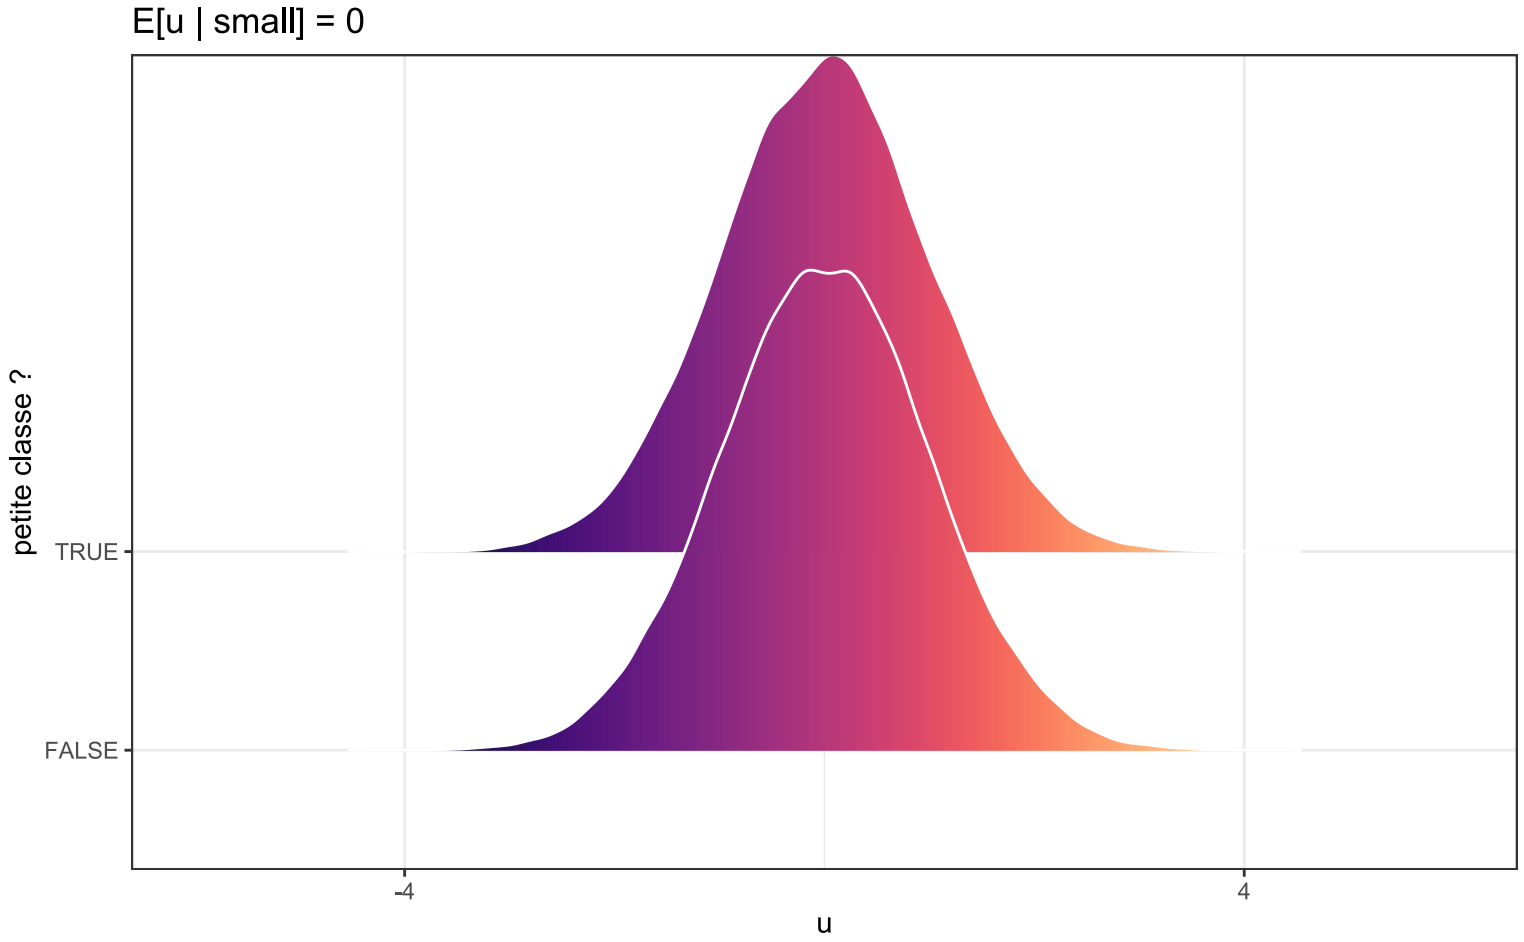
1. ***Indépendance en moyenne :*** la moyenne des résidus conditionnelle à x doit être nulle, $E[\varepsilon|x] = 0$. Remarquez que cela implique également que $Cov(\varepsilon, x) = 0$, c'est-à-dire que les erreurs et notre/nos variable(s) explicative(s) doivent être *non corrélées*.

Hypothèses du MRC

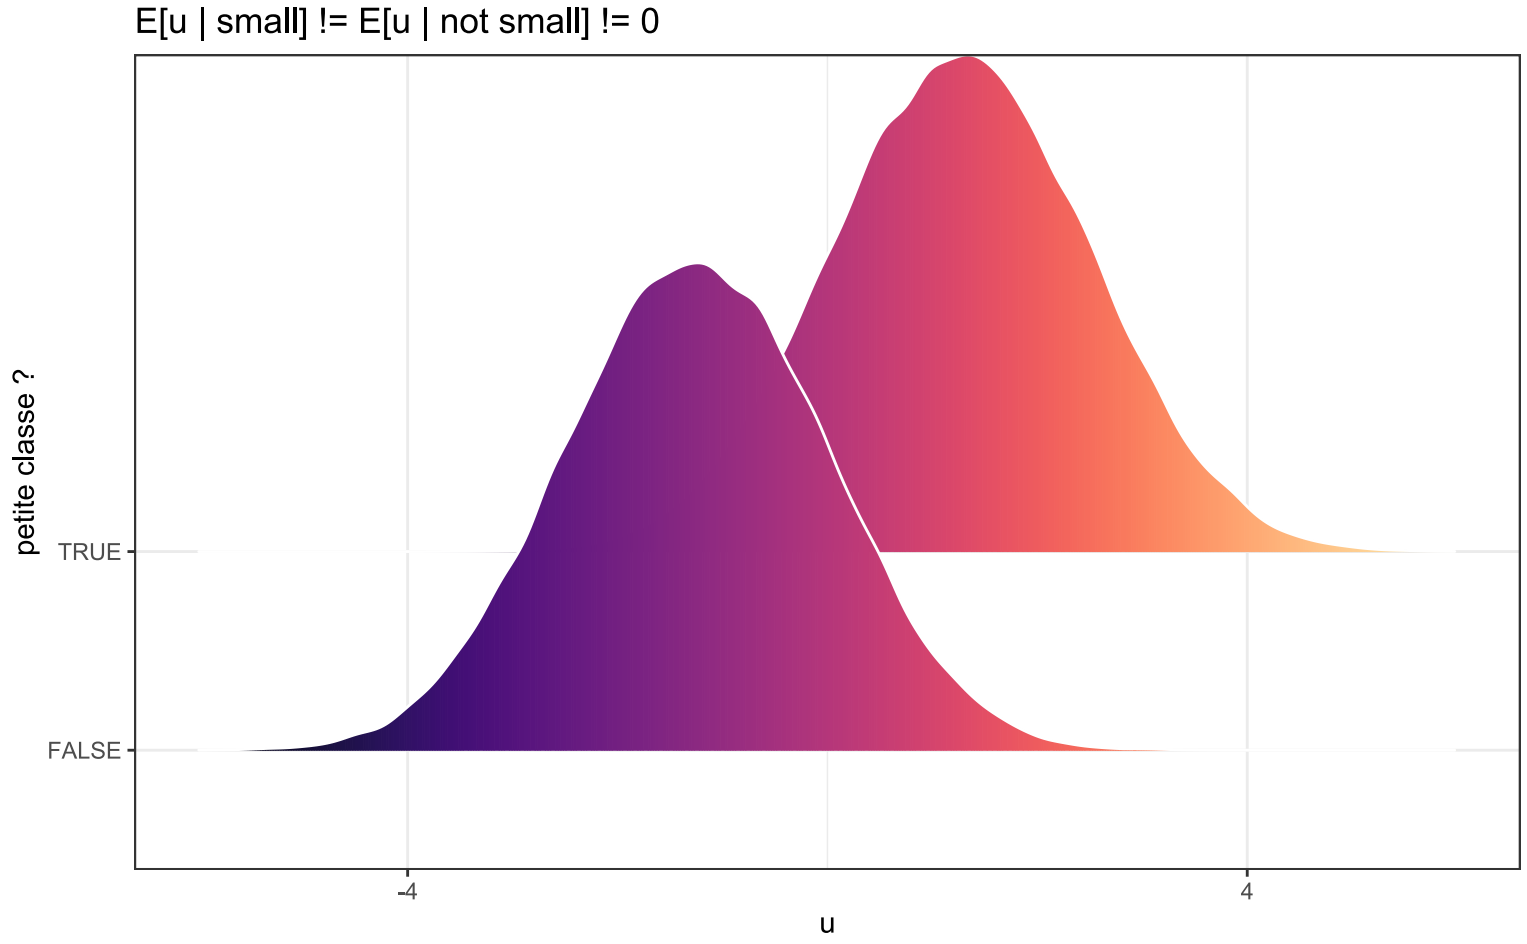
1. ***Indépendance en moyenne :*** la moyenne des résidus conditionnelle à x doit être nulle, $E[\varepsilon|x] = 0$. Remarquez que cela implique également que $Cov(\varepsilon, x) = 0$, c'est-à-dire que les erreurs et notre/nos variable(s) explicative(s) doivent être *non corrélées*.

- Violer cette hypothèse conduira à des estimations **biaisées** de β_k.

Indépendance en moyenne de l'erreur : E[u | small] = ?



Indépendance en moyenne de l'erreur : E[u | small] = ?



Hypothèse d'exogénéité

L'hypothèse #1 du MRC est aussi connue sous le nom d'**hypothèse d'exogénéité** (stricte).

- Lorsque cette hypothèse est violée, notre estimation b sera une estimation ***biaisée*** de β, c.-à-d. $\mathbb{E}[b] \neq \beta$

Hypothèse d'exogénéité

L'hypothèse #1 du MRC est aussi connue sous le nom d'**hypothèse d'exogénéité** (stricte).

- Lorsque cette hypothèse est violée, notre estimation b sera une estimation ***biaisée*** de β, c.-à-d. $\mathbb{E}[b] \neq \beta$
- Par exemple, imaginez que vous vous intéressiez à l'effet de l'éducation sur le salaire

$$\text{salaire}_i = \beta_0 + \beta_1 \text{éducation}_i + \varepsilon_i$$

  - Sous l'hypothèse d'exogénéité, β_1 désigne l'effet causal de l'éducation dans la population.

Hypothèse d'exogénéité

L'hypothèse #1 du MRC est aussi connue sous le nom d'**hypothèse d'exogénéité** (stricte).

- Lorsque cette hypothèse est violée, notre estimation b sera une estimation ***biaisée*** de β, c.-à-d. $\mathbb{E}[b] \neq \beta$
- Par exemple, imaginez que vous vous intéressiez à l'effet de l'éducation sur le salaire

$$\text{salaire}_i = \beta_0 + \beta_1 \text{éducation}_i + \varepsilon_i$$

  - Sous l'hypothèse d'exogénéité, β_1 désigne l'effet causal de l'éducation dans la population.

- Supposons qu'il existe une capacité *non observée* a_i.

  - Une capacité élevée signifie un salaire plus élevé.
  - Cela signifie *aussi* que l'école est plus facile, et donc que i choisit de faire plus d'études.

Hypothèse d'exogénéité

- Étant donné que la capacité est *non observée*, a_i se retrouve dans l'erreur ε_i

Hypothèse d'exogénéité

- Étant donné que la capacité est *non observée*, a_i se retrouve dans l'erreur ε_i
- Notre hypothèse *ceteris paribus* (toutes choses égales par ailleurs) n'est plus respectée.

Hypothèse d'exogénéité

- Étant donné que la capacité est *non observée*, a_i se retrouve dans l'erreur ε_i
- Notre hypothèse *ceteris paribus* (toutes choses égales par ailleurs) n'est plus respectée.
- En régressant alors le salaire sur l'éducation, nous attribuerons à `education` une partie de l'effet sur les salaires qui est en réalité *causée* par la capacité a_i !

Hypothèse d'exogénéité

- Étant donné que la capacité est *non observée*, a_i se retrouve dans l'erreur ε_i
- Notre hypothèse *ceteris paribus* (toutes choses égales par ailleurs) n'est plus respectée.
- En régressant alors le salaire sur l'éducation, nous attribuerons à `education` une partie de l'effet sur les salaires qui est en réalité *causée* par la capacité a_i !
  - Rappelez-vous la formule du **biais de variable omise** :

$$\text{Bias} = \text{coef de la régression multiple sur la VO} \times \frac{Cov(x, z)}{Var(x)}$$

Hypothèse d'exogénéité

- Étant donné que la capacité est *non observée*, a_i se retrouve dans l'erreur ε_i
- Notre hypothèse *ceteris paribus* (toutes choses égales par ailleurs) n'est plus respectée.
- En régressant alors le salaire sur l'éducation, nous attribuerons à `education` une partie de l'effet sur les salaires qui est en réalité *causée* par la capacité a_i !
  - Rappelez-vous la formule du **biais de variable omise** :

$$\text{Bias} = \text{coef de la régression multiple sur la VO} \times \frac{Cov(x, z)}{Var(x)}$$

  - Ainsi, nous avons :

$$\mathbb{E}(b_1) = \beta_1 + \text{Biais de variable omise} > \beta_1$$

- *Interprétation* : en prenant des échantillons répétés de la population et en calculant $\widehat{\beta}_1$ à chaque fois, nous ***surestimerions systématiquement*** l'effet de l'éducation sur le salaire.

Hypothèses du MRC

1. ***Indépendance en moyenne :*** la moyenne des résidus conditionnelle à x doit être nulle, $E[\varepsilon|x] = 0$. Remarquez que cela implique également que $Cov(\varepsilon, x) = 0$, c'est-à-dire que les erreurs et notre/nos variable(s) explicative(s) doivent être *non corrélées*.

- Violer cette hypothèse conduira à des estimations **biaisées** de β_k.

Hypothèses du MRC

1. ***Indépendance en moyenne :*** la moyenne des résidus conditionnelle à x doit être nulle, $E[\varepsilon|x] = 0$. Remarquez que cela implique également que $Cov(\varepsilon, x) = 0$, c'est-à-dire que les erreurs et notre/nos variable(s) explicative(s) doivent être *non corrélées*.

- Violer cette hypothèse conduira à des estimations **biaisées** de β_k.

2. ***Indépendamment et identiquement distribuées :*** les données sont tirées d'un **échantillon aléatoire** de taille n : l'observation (x_i, y_i) provient exactement de la même distribution, et est **indépendante** de l'observation (x_j, y_j), pour tout $i \neq j$.

Hypothèses du MRC

1. ***Indépendance en moyenne :*** la moyenne des résidus conditionnelle à x doit être nulle, $E[\varepsilon|x] = 0$. Remarquez que cela implique également que $Cov(\varepsilon, x) = 0$, c'est-à-dire que les erreurs et notre/nos variable(s) explicative(s) doivent être *non corrélées*.

- Violer cette hypothèse conduira à des estimations **biaisées** de β_k.

2. ***Indépendamment et identiquement distribuées :*** les données sont tirées d'un **échantillon aléatoire** de taille n : l'observation (x_i, y_i) provient exactement de la même distribution, et est **indépendante** de l'observation (x_j, y_j), pour tout $i \neq j$.

- Violer cette hypothèse rendrait votre échantillon moins représentatif de la population sous-jacente. Cela conduira à des estimations **biaisées** de β_k.

Hypothèses du MRC

3. ***Homoscédasticité :*** la variance du terme d'erreur ε est la même pour chaque valeur de x : $Var(\varepsilon|x) = \sigma^2$.

Hypothèses du MRC

3. ***Homoscédasticité :*** la variance du terme d'erreur ε est la même pour chaque valeur de x : $Var(\varepsilon|x) = \sigma^2$.

- Si cette hypothèse est violée, vous pouvez tout de même obtenir des estimations non biaisées de β_k. Cependant, votre estimation de $\hat{\mathrm{SE}}(b_k)$ sera biaisée, ce qui affectera votre statistique de test et votre valeur-p.

Hypothèses du MRC

3. ***Homoscédasticité :*** la variance du terme d'erreur ε est la même pour chaque valeur de x : $Var(\varepsilon|x) = \sigma^2$.

- Si cette hypothèse est violée, vous pouvez tout de même obtenir des estimations non biaisées de β_k. Cependant, votre estimation de $\hat{\mathrm{SE}}(b_k)$ sera biaisée, ce qui affectera votre statistique de test et votre valeur-p.

4. ***Erreurs normalement distribuées :*** le terme d'erreur est distribué normalement, c.-à-d. $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

Hypothèses du MRC

3. ***Homoscédasticité :*** la variance du terme d'erreur ε est la même pour chaque valeur de x : $Var(\varepsilon|x) = \sigma^2$.

- Si cette hypothèse est violée, vous pouvez tout de même obtenir des estimations non biaisées de β_k. Cependant, votre estimation de $\hat{\mathrm{SE}}(b_k)$ sera biaisée, ce qui affectera votre statistique de test et votre valeur-p.

4. ***Erreurs normalement distribuées :*** le terme d'erreur est distribué normalement, c.-à-d. $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

- Pas strictement nécessaire, mais rend l'inférence possible même avec de petits échantillons.

Hypothèses du MRC

3. ***Homoscédasticité :*** la variance du terme d'erreur ε est la même pour chaque valeur de x : $Var(\varepsilon|x) = \sigma^2$.

- Si cette hypothèse est violée, vous pouvez tout de même obtenir des estimations non biaisées de β_k. Cependant, votre estimation de $\hat{\mathrm{SE}}(b_k)$ sera biaisée, ce qui affectera votre statistique de test et votre valeur-p.

4. ***Erreurs normalement distribuées :*** le terme d'erreur est distribué normalement, c.-à-d. $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

- Pas strictement nécessaire, mais rend l'inférence possible même avec de petits échantillons.

👉 À retenir : **si les hypothèses sont violées, l'inférence n'est pas valide !**

Exercice 3.1

10:00

Revenons à notre question des retours à l'éducation et du genre

1. Télécharger les données `CPS1985` du package `AER` et regarder le fichier `help` pour avoir les définitions : `?CPS1985`
2. Créer la variable `log_wage` qui est le log du `wage`.
3. Regresser `log_wage` sur le `gender` et `education`, et sauvegarder le comme `reg1`.
   - Interpréter chaque coefficient.
   - Sont ils statistiquement significatifs ? A quel seuil ?
4. Régresser le `log_wage` sur le `gender`, `education` et leur intéraction `gender*education`, sauvegarder la dans `reg2`.
   - Interprétation du coeffcient associé à $female * education$?
   - Est ce que l'on peut rejet l'hypothèse nulle de ce coefficient au seuil de 5% level ? 10%?

Exercice 3.2

10:00

1. Faites un nuage de points de la relatio nentre `log wage` et `education`
2. Ajouter la *droite de régression* avec `geom_smooth`. Qu'est-ce qu'elle représente ?

UNIVERSITÉ DE NAMUR

Bonne journée!

	jeremy.donascimento@unamur.be
.Namurgreen	Discord
	Slides