UNIVERSITÉ DE NAMUR

Econométrie

Echantillonage

Jérémy Do Nascimento Miguel
Université de Namur
2026-09-16

Aujourd'hui - Sampling[1]

- Découvrir ce qu'est l'échantillonnage, sa variation, et sa distribution.
- Lexique : population, échantillon, paramètre de population, point d'estimation, etc.
- Rappel d'un ***estimateur non biaisé***.
- Découverte d'un théorème statistique essentiel : ***Théorème central limite***.



[1]: Ce chapitre est basé en partie sur le chapitre d'échantillonnage de ModernDive

Quelle est la proportion de pâtes vertes ?



Quelle est la proportion de pâtes vertes ?



On pourrait tout compter, mais cela serait long et fastidieux ! Quelles alternatives avons-nous ?

Echantillonnage

- Prenons un échantillon de 20 pâtes.
- Que l'on sélectionne de manière **aléatoire**.
- Voici ce que l'on trouve .

Couleurr	Nombre	Proportion
Vert	14	0.70
Rouge	5	0.25
Jaune	1	0.05

- 0.70 peut être pensé comme notre estimation de la proportion de pâtes vertes dans le bol.



Variation d'échantillonnage

- Que se passerait-il si nous prenions un *nouvel* échantillon (en remettant les 20 pâtes précédentes dans le bol) ? Obtiendrions-nous aussi 14 *vertes* comme avant ?

Variation d'échantillonnage

- Que se passerait-il si nous prenions un *nouvel* échantillon (en remettant les 20 pâtes précédentes dans le bol) ? Obtiendrions-nous aussi 14 *vertes* comme avant ?
- Probablement pas. Les échantillons varieront d'un tirage à l'autre.



Variation d'échantillonnage

- Que se passerait-il si nous prenions un *nouvel* échantillon (en remettant les 20 pâtes précédentes dans le bol) ? Obtiendrions-nous aussi 14 *vertes* comme avant ?
- Probablement pas. Les échantillons varieront d'un tirage à l'autre.
- Que se passerait-il si nous répétions cette activité plusieurs fois ?



Variation d'échantillonnage

- Que se passerait-il si nous prenions un *nouvel* échantillon (en remettant les 20 pâtes précédentes dans le bol) ? Obtiendrions-nous aussi 14 *vertes* comme avant ?
- Probablement pas. Les échantillons varieront d'un tirage à l'autre.
- Que se passerait-il si nous répétions cette activité plusieurs fois ?
- Élément clé de cette observation : il s'agit d'échantillons tirés *aléatoirement*.

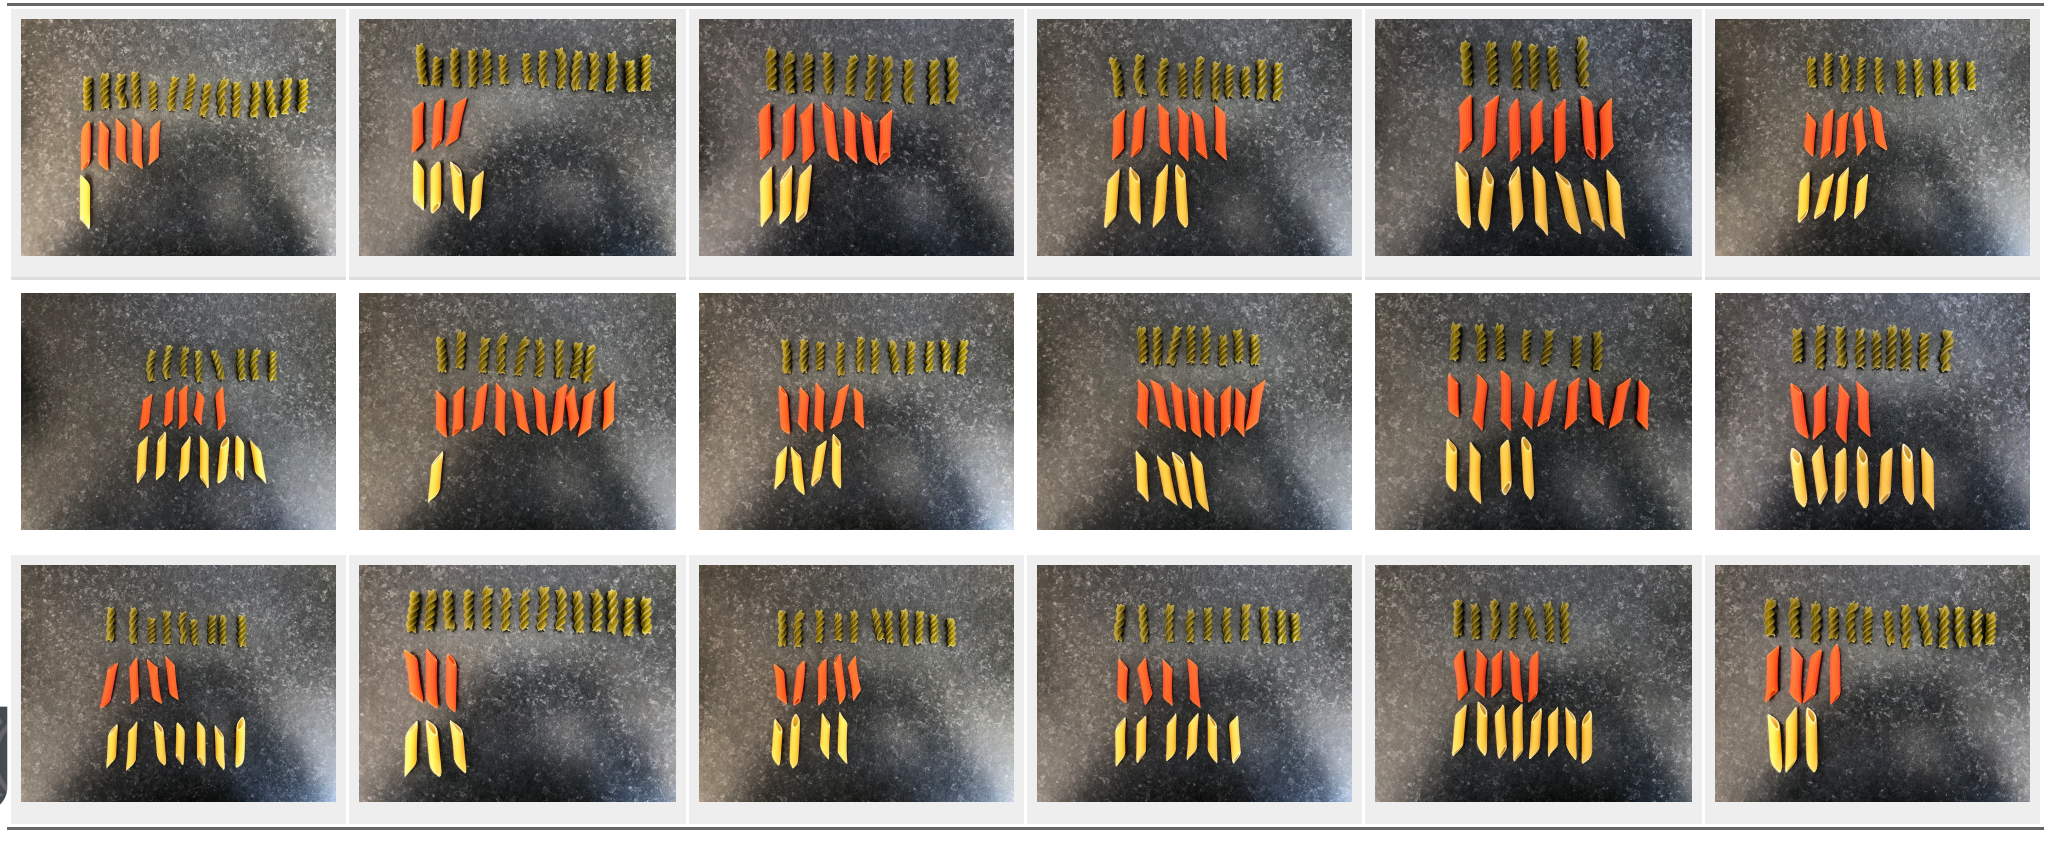


Prélèvement de 18 échantillons (un par étudiant)

- Comme nous n'avons pas de pâtes avec nous en classe, nous avons tiré 18 échantillons de 20 pâtes (avec remise) à la maison.

Prélèvement de 18 échantillons (un par étudiant)

- Comme nous n'avons pas de pâtes avec nous en classe, nous avons tiré 18 échantillons de 20 pâtes (avec remise) à la maison.
- Voici le résultat :



Tiré 18 échantillions (One per Student)

- Comme nous n'avons pas de pâtes avec nous en classe, nous avons tiré 18 échantillons de 20 pâtes (avec remise) à la maison.
- Pour chaque échantillon, nous pouvons caculer la proportion de pâtes vertes.

Echantillon #	Nombre	Proportion
1	14	0.70
2	14	0.70
3	10	0.50
4	10	0.50
5	6	0.30
6	10	0.50
7	8	0.40
8	9	0.45
9	11	0.55

Sample #	Count	Proportion
10	8	0.40
11	7	0.35
12	9	0.45
13	9	0.45
14	14	0.70
15	11	0.55
16	10	0.50
17	7	0.35
18	13	0.65

Tâche 1

05:00

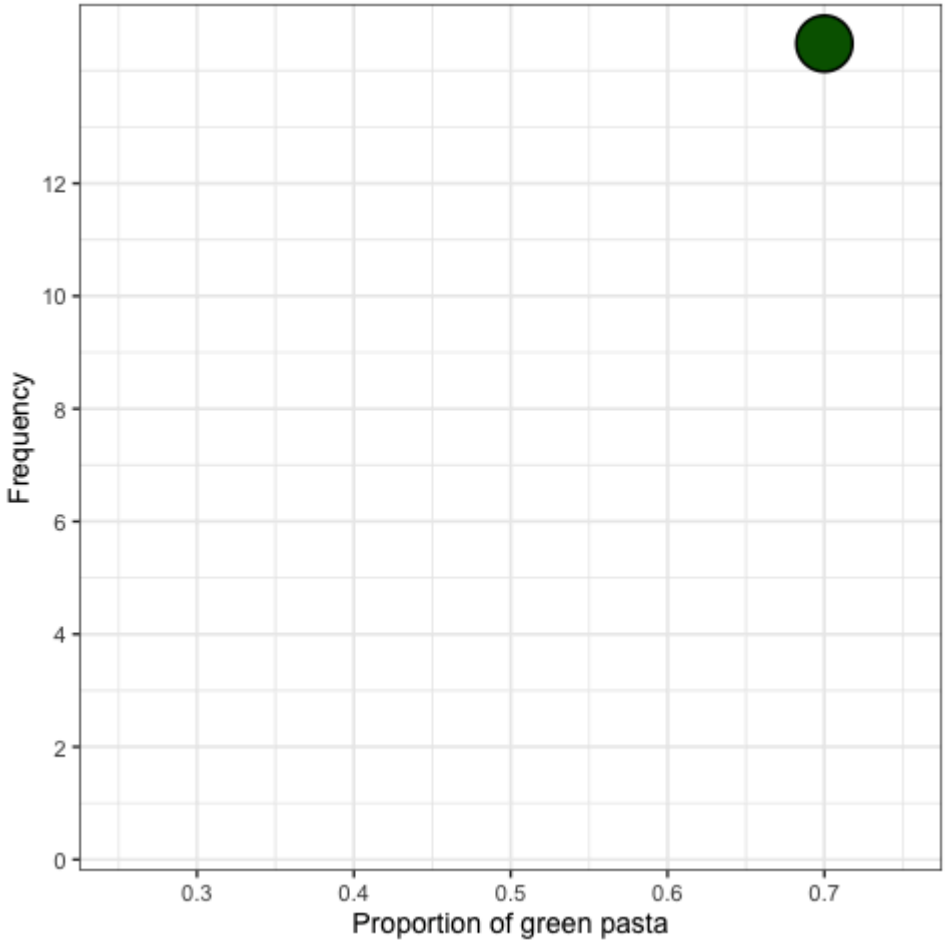
1. Créez un data.frame contenant les proportions de pâtes vertes de la diapositive précédente. Nommez-le `pasta` et nommez la variable contenant les proportions `prop_green`. (Indice : pour créer un data.frame, vous devez utiliser la fonction `data.frame()`.) Les proportions sont les suivantes : `(0.7,0.7,0.5,0.5,0.3,0.5,0.4,0.45,0.55,0.4,0.35,0.45,0.45,0.7,0.55,0.5,0.35,0.65)`

2. Créez un histogramme de ces proportions à l'aide de `ggplot2`. Utilisez ces paramètres dans `geom_histogram()` : `boundary = 0.325, binwidth = 0.05`.

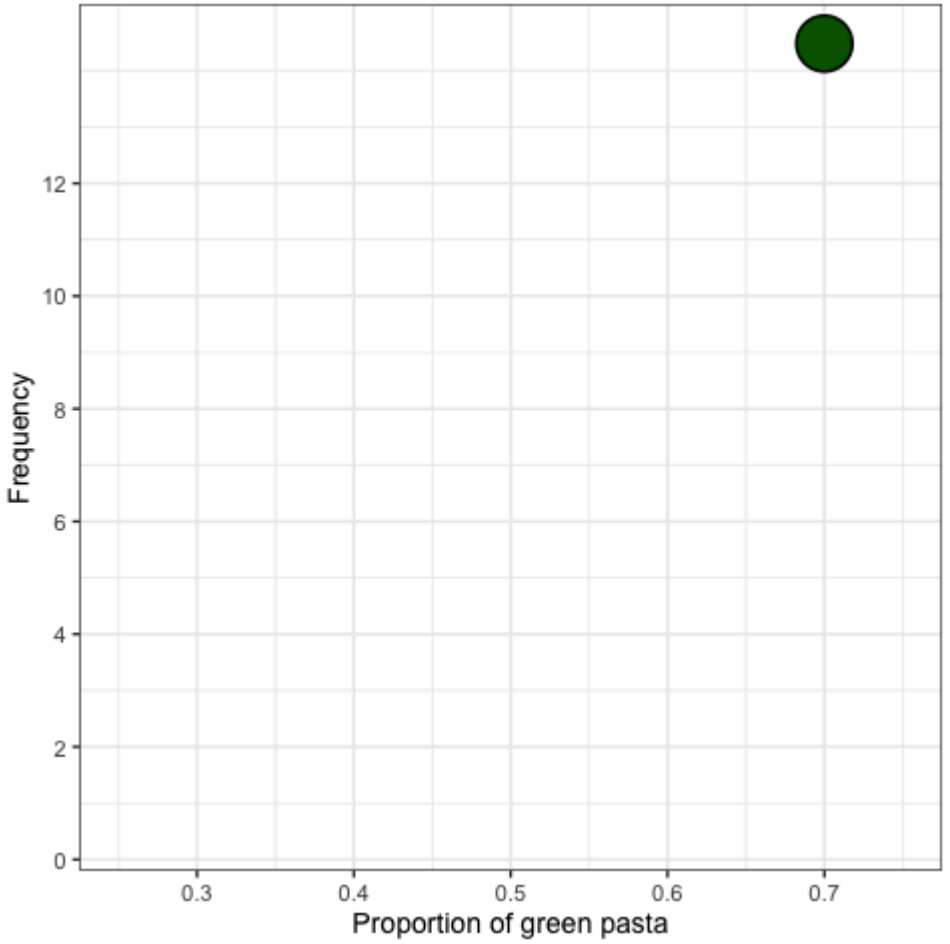
3. Qu'observez-vous ?

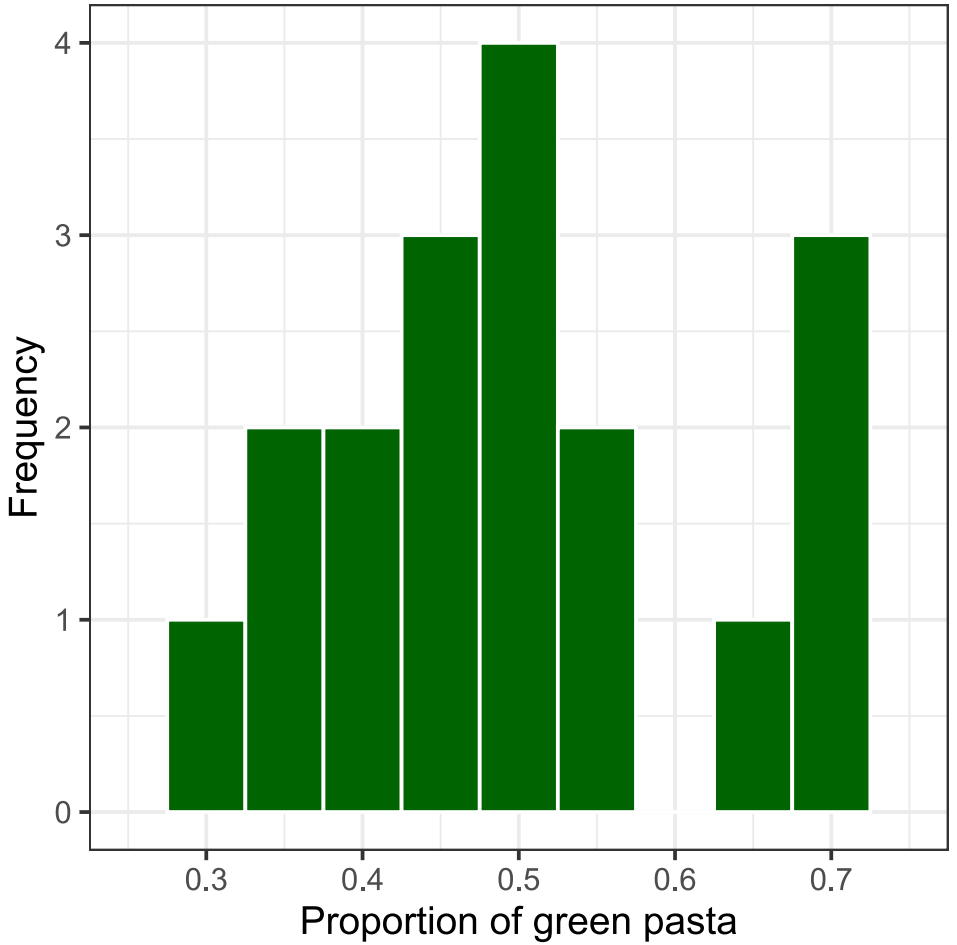


Distribution d'échantillon : Histogramme



Distribution d'échantillon : Histogramme





Qu'avons-nous fait ?



Qu'avons-nous fait ?

- Démontrer le concept statistique d'***échantillonnage***.

Qu'avons-nous fait ?

- Démontrer le concept statistique d'***échantillonnage***.
- *Objectif* : connaître la proportion de pâtes vertes

Méthodes :

1. **Recensement** : prend beaucoup de temps (et dans de nombreux cas très coûteux) ;

Qu'avons-nous fait ?

- Démontrer le concept statistique d'***échantillonnage***.
- *Objectif* : connaître la proportion de pâtes vertes

Méthodes :

1. **Recensement** : prend beaucoup de temps (et dans de nombreux cas très coûteux) ;
2. **Échantillonnage** : extraire un *échantillon* de 20 pâtes du bol pour obtenir une ***estimation***.
   Notre première ***estimation*** de la proportion de pâtes vertes était de 0,70, mais elle était en réalité supérieure à la plupart des autres ***estimations***.

Qu'avons-nous fait ?

- Démontrer le concept statistique d'***échantillonnage***.
- *Objectif* : connaître la proportion de pâtes vertes

Méthodes :

1. **Recensement** : prend beaucoup de temps (et dans de nombreux cas très coûteux) ;
2. **Échantillonnage** : extraire un *échantillon* de 20 pâtes du bol pour obtenir une ***estimation***.
   Notre première ***estimation*** de la proportion de pâtes vertes était de 0,70, mais elle était en réalité supérieure à la plupart des autres ***estimations***.

- *Important* : chaque *échantillon* a été tiré de façon ***aléatoire*** → les échantillons sont différents les uns des autres ! → des proportions différentes 👉 ***variation d'échantillonnage***

Prenons des échantillons virtuels

- Nous avons compté le nombre exact de pâtes vertes, rouges, et jaunes dans le bol
- Toutes les pâtes sont sauvegardés dans ce fichier csv here.

```
bowl <- read.csv("https://www.dropbox.com/s/qpjsk0rfg

head(bowl)
```

```
##   pasta_ID  color
## 1        1 yellow
## 2        2    red
## 3        3  green
## 4        4 yellow
## 5        5    red
## 6        6  green
```



Prenons des échantillons virtuels

- Nous avons compté le nombre exact de pâtes vertes, rouges, et jaunes dans le bol
- Toutes les pâtes sont sauvegardés dans ce fichier csv here.

```
bowl <- read.csv("https://www.dropbox.com/s/qpjsk0rfg

head(bowl)
```

```
##   pasta_ID  color
## 1        1 yellow
## 2        2    red
## 3        3  green
## 4        4 yellow
## 5        5    red
## 6        6  green
```

- `pasta_ID`: identifiant des pâtes
- `color` : couleur des pâtes

```
nrow(bowl)
```

```
## [1] 713
```

- Au lieu de sélectionner les pâtes avec nos mains, nous faisons des échantillons *virtuels* depuis le bol.
- Utilisons la *pelle virtuelle* pour prendre un échantillon de 50 pâtes depuis notre bol.



Utilisons une pelle virtuelle une fois

- Prenons un premier échantillon de taille 50, en utilisant la fonction `rep_sample_n` du package `moderndive`.



Utilisons une pelle virtuelle une fois

- Prenons un premier échantillon de taille 50, en utilisant la fonction `rep_sample_n` du package `moderndive`.

```
#Lancer le package moderndive
library(moderndive)

virtual_shovel <- bowl %>% #  les fonctions de moderndive peuvent être "pipper"
  rep_sample_n(size = 50) # échantillon de 50 pâtes
```

```
# montre les 6ères lignes
head(virtual_shovel)
```

```
## # A tibble: 6 × 3
## # Groups:   replicate [1]
##   replicate pasta_ID color
##       <int>    <int> <chr>
## 1         1      284 green
## 2         1      101 green
## 3         1      623 yellow
## 4         1      645 green
## 5         1      400 red
## 6         1       98 yellow
```



- La colonne `replicate` nous dit l'ID de l'échantillon. Ici : `1`.

Utilisons une pelle virtuelle une fois

- Prenons un premier échantillon de taille 50, en utilisant la fonction `rep_sample_n` du package `moderndive`.

```
#Lancer le package moderndive
library(moderndive)

virtual_shovel <- bowl %>% #  les fonctions de moderndive peuvent être "pipper"
  rep_sample_n(size = 50) # échantillon de 50 pâtes
```

```
# montre les 6ères lignes
head(virtual_shovel)
```

```
## # A tibble: 6 × 3
## # Groups:   replicate [1]
##   replicate pasta_ID color
##       <int>    <int> <chr>
## 1         1      284 green
## 2         1      101 green
## 3         1      623 yellow
## 4         1      645 green
## 5         1      400 red
## 6         1       98 yellow
```

```
# nombre d'observations dans l'échantillon
nrow(virtual_shovel)
```

```
## [1] 50
```



- La colonne `replicate` nous dit l'ID de l'échantillon. Ici : `1`.

% de pâtes vertes

```
sample_1 <- virtual_shovel %>%
  summarize(
    # nombre de pâtes vertes dans l'échantillon
    num_green = sum(color == "green"),
    # nombre d'observations dans l'échantillon
    sample_n = n()) %>%
  mutate(
    # % de pâtes vertes dans l'échantillon
    prop_green = num_green / sample_n)
sample_1
```

```
## # A tibble: 1 × 4
##   replicate num_green sample_n prop_green
##       <int>     <int>    <int>      <dbl>
## 1         1        23       50       0.46
```

1. Calculons :
    - somme des pâtes vertes dans l'échantillon,
    - nombre d'obs dans l'échantillon (i.e., 50 ici)
2. Calculons la % de pâtes vertes

👉 0.46 sont vertes ! C'est une ***estimation*** de la proportion de pâtes vertes dans le bol. Que se passe-t-il si on essaie encore ?

Et si on essaie encore de nombreuses fois, comme 50 ?



Utilisons la pelle virtuelle 50 fois

50 échantillons de taille 50.

```
virtual_samples <- bowl %>%
  # obtenir 50 échantillons de taille 50
  rep_sample_n(size = 50, reps = 50)
virtual_samples
```

```
## # A tibble: 2,500 × 3
## # Groups:   replicate [50]
##    replicate pasta_ID color
##        <int>    <int> <chr>
##  1         1      495 yellow
##  2         1      534 green
##  3         1      297 yellow
##  4         1      208 green
##  5         1      131 green
##  6         1      569 red
##  7         1      522 yellow
##  8         1      248 green
##  9         1      365 red
## 10         1      665 yellow
## # ℹ 2,490 more rows
```



Utilisons la pelle virtuelle 50 fois

50 échantillons de taille 50.

```
virtual_samples <- bowl %>%
  # obtenir 50 échantillons de taille 50
  rep_sample_n(size = 50, reps = 50)
virtual_samples
```

```
## # A tibble: 2,500 × 3
## # Groups:   replicate [50]
##    replicate pasta_ID color
##        <int>    <int> <chr>
##  1         1      495 yellow
##  2         1      534 green
##  3         1      297 yellow
##  4         1      208 green
##  5         1      131 green
##  6         1      569 red
##  7         1      522 yellow
##  8         1      248 green
##  9         1      365 red
## 10         1      665 yellow
## # ℹ 2,490 more rows
```

Calculons la proportion de pâtes vertes

```
virtual_prop_green <- virtual_samples %>%
  group_by(replicate) %>% # calcule la stat par échan
  summarize(
    num_green = sum(color == "green"),
    sample_n = n()) %>%
  mutate(prop_green = num_green / sample_n)
virtual_prop_green
```

```
## # A tibble: 50 × 4
##    replicate num_green sample_n prop_green
##        <int>     <int>    <int>      <dbl>
##  1         1        24       50       0.48
##  2         2        25       50       0.5
##  3         3        27       50       0.54
##  4         4        23       50       0.46
##  5         5        25       50       0.5
##  6         6        22       50       0.44
##  7         7        18       50       0.36
##  8         8        30       50       0.6
##  9         9        29       50       0.58
## 10        10        18       50       0.36
## # ℹ 40 more rows
```



Variation d'échantillonnage (virtuelle)

- Comme en réalité, l'échantillonnage virtuelle crée aussi des échantillons aléatoires.
- La colonne `prop_green` dans le data.frame `virtual_prop_green` est différent entre les échantillons.
- On peut encore visualiser la ***distribution d'échantillonnage***:

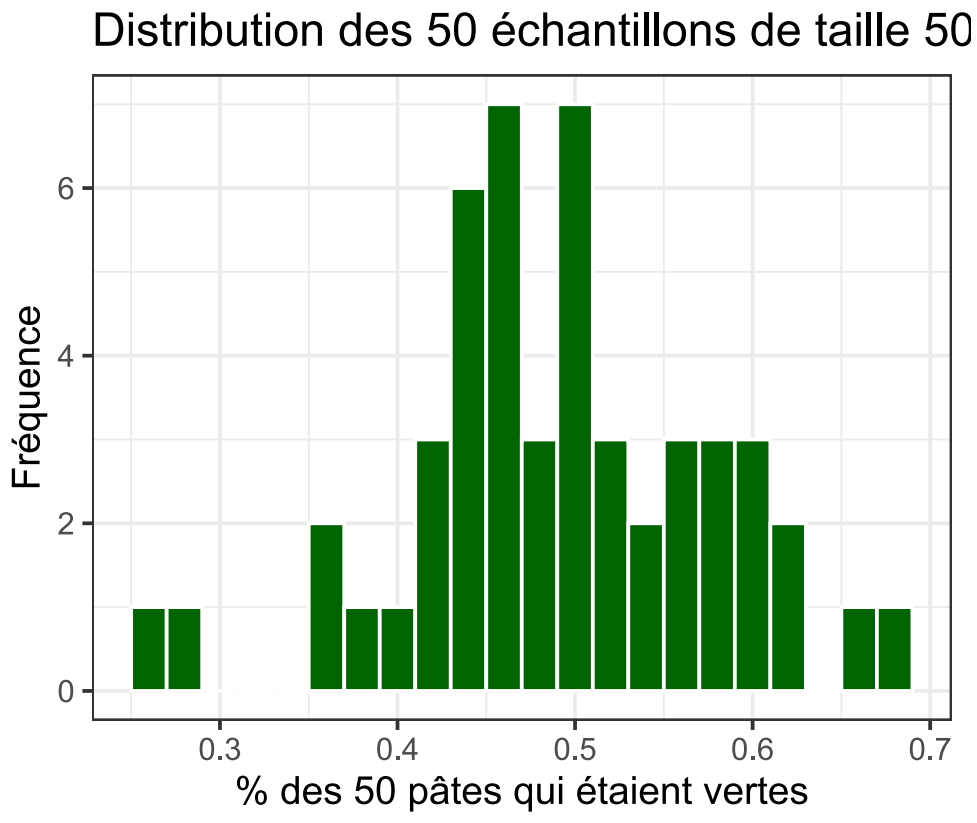
```
ggplot(virtual_prop_green, aes(x = prop_green)) +
  geom_histogram(binwidth = 0.02,
                 boundary = 0.51,
                 color = "white",
                 fill = "darkgreen") +
  scale_y_continuous(breaks = seq(0, 12, by = 2)) +
  labs(x = "% des 50 pâtes qui étaient vertes",
       y = "Fréquence",
       title = "Distribution des 50 échantillons de ta
  theme_bw(base_size = 20)
```



Variation d'échantillonnage (virtuelle)

- Comme en réalité, l'échantillonnage virtuelle crée aussi des échantillons aléatoires.
- La colonne `prop_green` dans le data.frame `virtual_prop_green` est différent entre les échantillons.
- On peut encore visualiser la ***distribution d'échantillonnage***:

```
ggplot(virtual_prop_green, aes(x = prop_green)) +
  geom_histogram(binwidth = 0.02,
                 boundary = 0.51,
                 color = "white",
                 fill = "darkgreen") +
  scale_y_continuous(breaks = seq(0, 12, by = 2)) +
  labs(x = "% des 50 pâtes qui étaient vertes",
       y = "Fréquence",
       title = "Distribution des 50 échantillons de ta
  theme_bw(base_size = 20)
```



Tâche 2

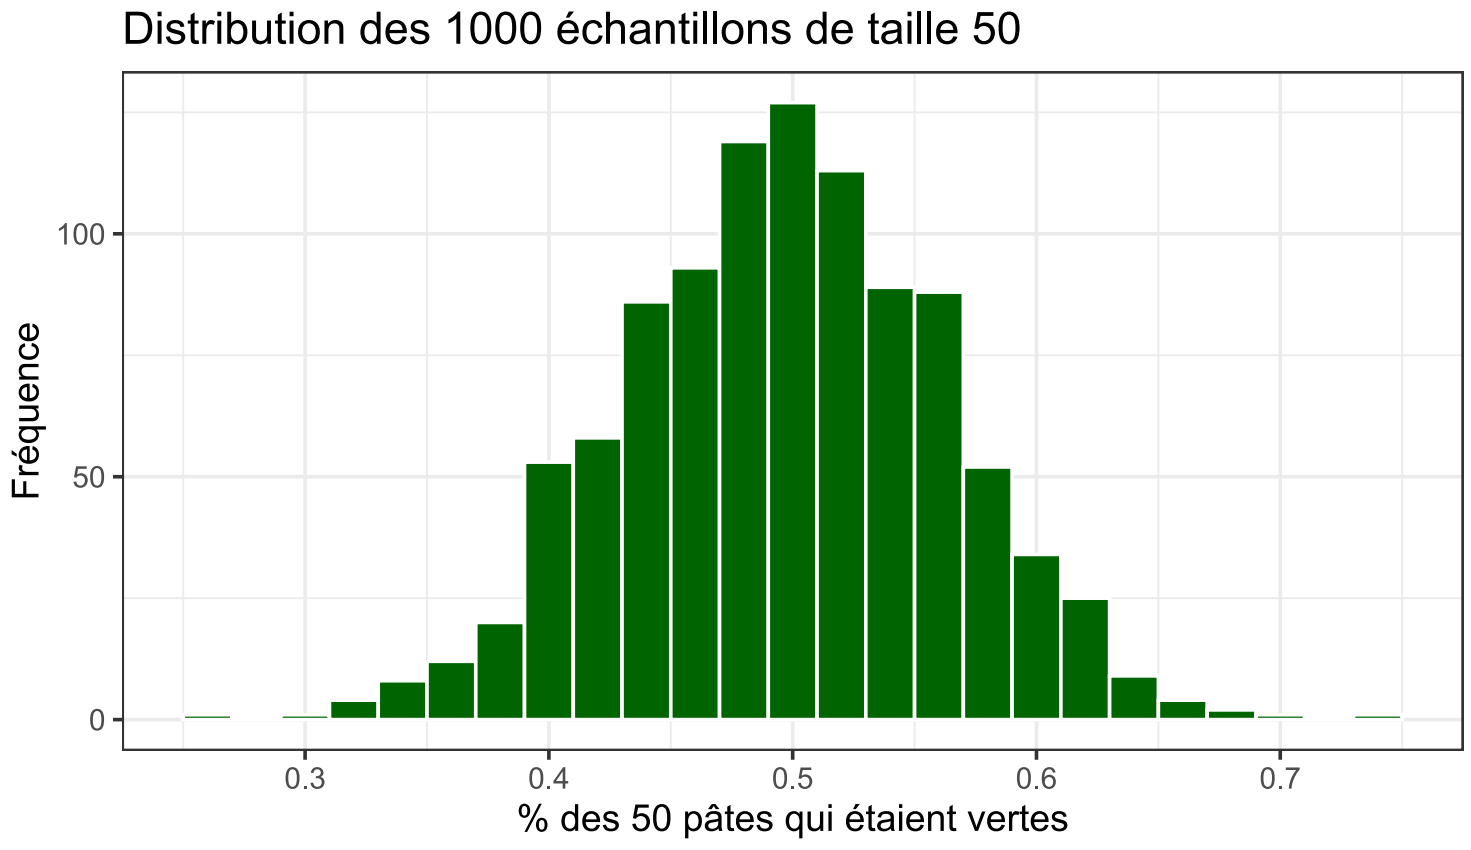
10:00

Au lieu de 18 échantillons, prenons en ***1000*** !

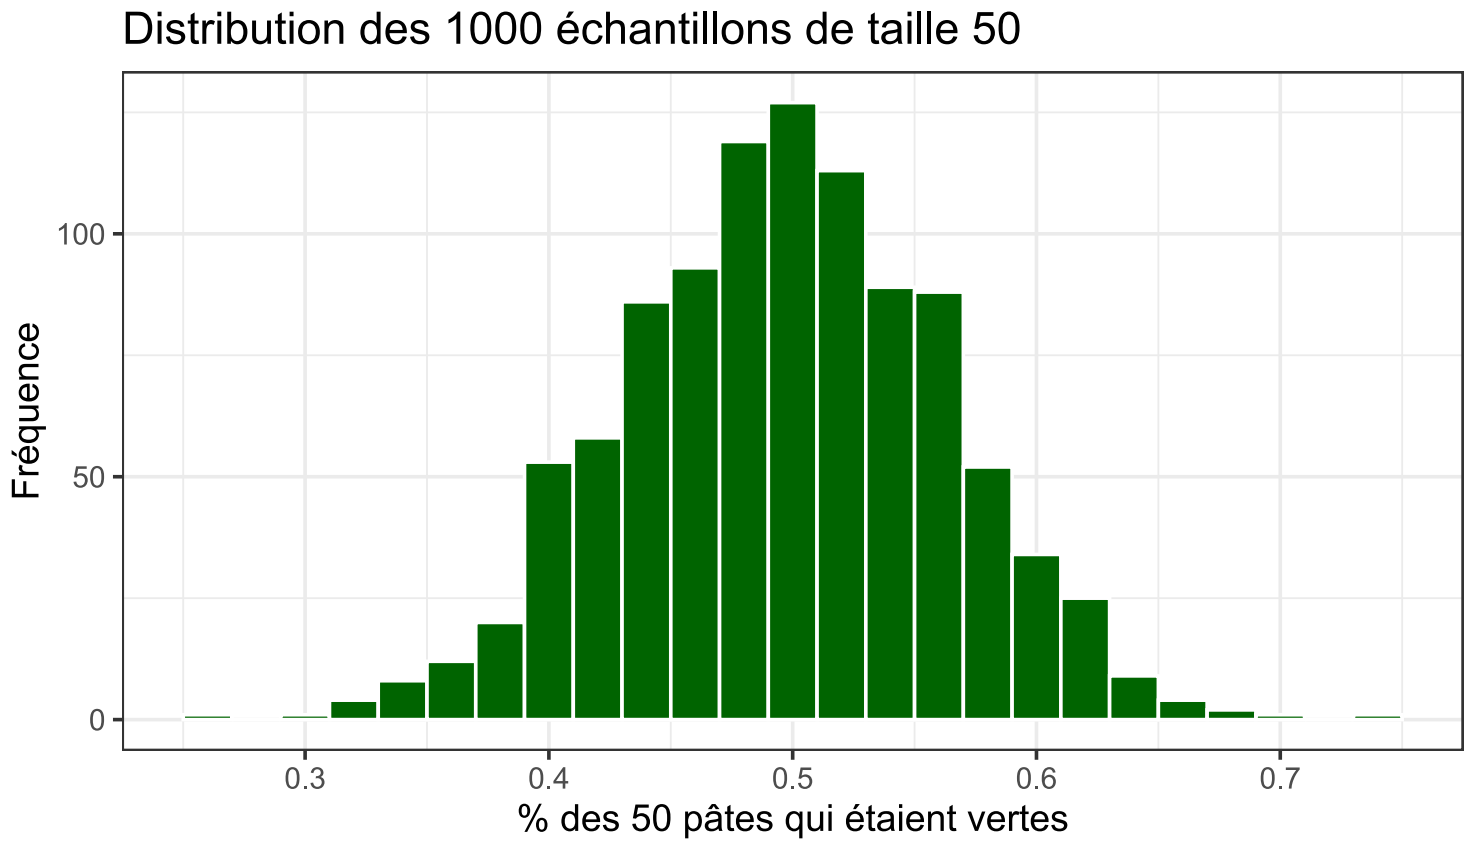
1. Pourquoi ne pas prendre les 1000 à la main ?
2. Télécharger les données dans un objet `pasta`.
3. Obtenez 1000 échantillons de taille 50 en utilisant la fonction `rep_sample_n()` du package `moderndive`.
4. Calculez la proportion de pâtes vertes dans chaque échantillon.
5. Faîtes un histogramme de la proportion de pâtes vertes dans chaque échantillon.
6. Qu'observez vous ? Quelles proportions est la plus fréquente ? Comment la forme de l'histogramme est par rapport à celle avec 18 échantillons ?
7. Quelle est la probabilité d'échantillonner 50 pâtes dont moins de 20 % sont vertes ?



Distribution d'échantillonnage de 1000 échantillon



Distribution d'échantillonnage de 1000 échantillon



Ressemble remarquablement à une ***distribution normale*** → plus nous prenons d'échantillons, plus leur ***distribution d'échantillonnage*** ressemblera à une ***distribution normale***.

Rôle de la taille de l'échantillon

Imaginez que vous puissiez changer la taille de vos échantillons et que vous ayez le choix entre les tailles suivantes : 25, 50 et 100.

Si votre objectif est toujours d'estimer la proportion de pâtes vertes dans le bol, quelle pelle choisiriez-vous ?

Rôle de la taille de l'échantillon

- Répétons ce que nous avons fait précédemment mais pour différentes tailles d'échantillon.
- Prenons 1000 échantillons chacun pour $n = 25, n = 50, n = 100$.

Rôle de la taille de l'échantillon

- Répétons ce que nous avons fait précédemment mais pour différentes tailles d'échantillon.
- Prenons 1000 échantillons chacun pour $n = 25, n = 50, n = 100$.
- Nous utiliserons à nouveau `rep_sample_n()`.



Rôle de la taille de l'échantillon

- Répétons ce que nous avons fait précédemment mais pour différentes tailles d'échantillon.
- Prenons 1000 échantillons chacun pour $n = 25, n = 50, n = 100$.
- Nous utiliserons à nouveau `rep_sample_n()`.

Générons des échantillons de tailles différentes

```
# Taille : 25
virtual_samples_25 <- bowl %>%
rep_sample_n(size = 25, reps = 1000)
```

Taille : 50

```
virtual_samples_50 <- bowl %>% rep_sample_n(size = 50, reps = 1000)
```

Taille : 100

Rôle de la taille de l'échantillon

- Répétons ce que nous avons fait précédemment mais pour différentes tailles d'échantillon.
- Prenons 1000 échantillons chacun pour $n = 25, n = 50, n = 100$.
- Nous utiliserons à nouveau `rep_sample_n()`.

Générons des échantillons de tailles différentes

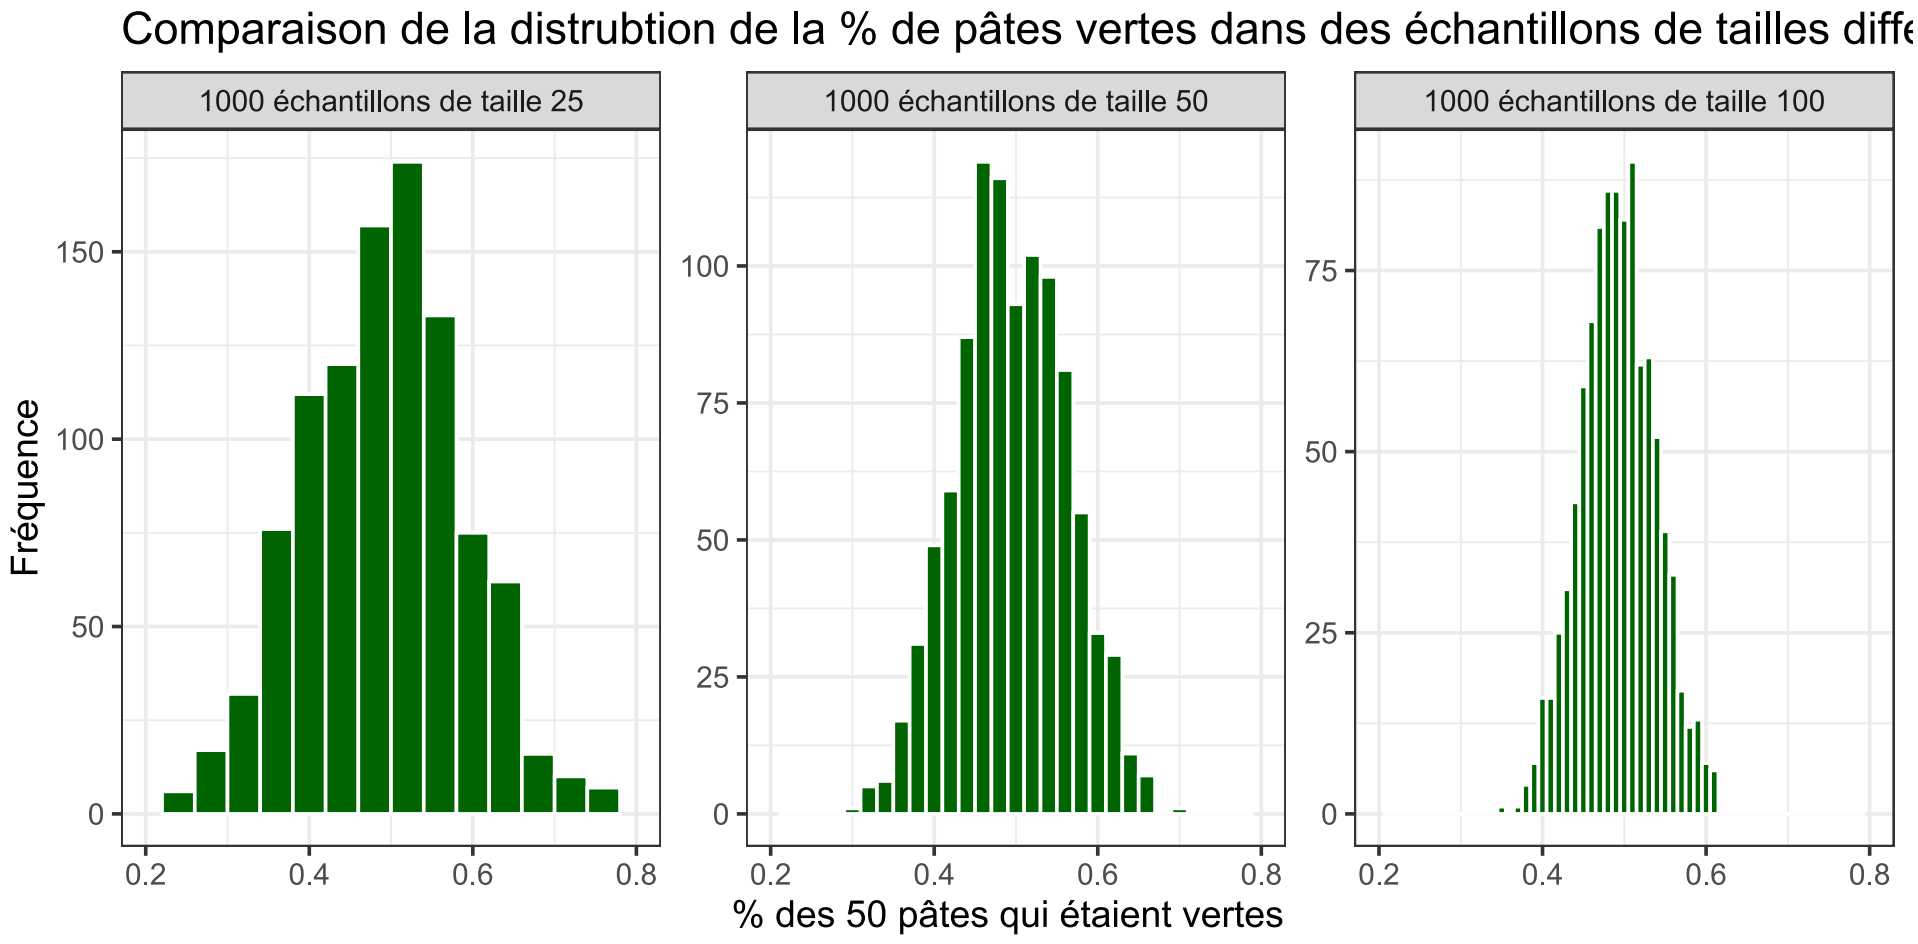
```
# Taille : 25
virtual_samples_25 <- bowl %>%
rep_sample_n(size = 25, reps = 1000)
```

Taille : 50

```
virtual_samples_50 <- bowl %>% rep_sample_n(size = 50, reps = 1000)
```

Taille : 100

Rôle de la taille de l'échantillon



Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.

Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.
- En d'autres termes, il y a moins de différences dues à la ***variation d'échantillonnage***.



Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.
- En d'autres termes, il y a moins de différences dues à la ***variation d'échantillonnage***.
- En maintenant constant le nombre de réplications (1000 dans notre cas), des ***échantillons plus grands*** produiront des *distributions normales* avec des ***écarts-types plus petits***.



Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.
- En d'autres termes, il y a moins de différences dues à la ***variation d'échantillonnage***.
- En maintenant constant le nombre de réplications (1000 dans notre cas), des ***échantillons plus grands*** produiront des *distributions normales* avec des ***écarts-types plus petits***.

Taille échantillon	Erreur standard
25	0.10
50	0.07
100	0.05



Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.
- En d'autres termes, il y a moins de différences dues à la ***variation d'échantillonnage***.
- En maintenant constant le nombre de réplications (1000 dans notre cas), des ***échantillons plus grands*** produiront des *distributions normales* avec des ***écarts-types plus petits***.

Taille échantillon	Erreur standard
25	0.10
50	0.07
100	0.05

- Rappelez vous que l'***erreur standard*** measure la *dispertion* d'une variable autour de sa moyenne.



Taille de l'échantillon et distrubtion de l'échantillon

- Plus la taille de l'échantillon est grande, plus la ***distribution d'échantillonnage*** résultante est *étroite*.
- En d'autres termes, il y a moins de différences dues à la ***variation d'échantillonnage***.
- En maintenant constant le nombre de réplications (1000 dans notre cas), des ***échantillons plus grands*** produiront des *distributions normales* avec des ***écarts-types plus petits***.

Taille échantillon	Erreur standard
25	0.10
50	0.07
100	0.05

- Rappelez vous que l'***erreur standard*** measure la *dispertion* d'une variable autour de sa moyenne.
- Donc à mesure que la taille de l'échantillon augmente, nos ***estimations*** de la proporiton *réelle* de pâtes vertes dans le bol devient *précise*.



Résumé sur l'échantillonnage

- Nous avons utilisé l'échantillonnage dans un but d'***estimation***.



Résumé sur l'échantillonnage

- Nous avons utilisé l'échantillonnage dans un but d'***estimation***.
- Nous avons extrait des échantillons afin d'***estimer*** la proportion de pâtes vertes dans le bol.

Résumé sur l'échantillonnage

- Nous avons utilisé l'échantillonnage dans un but d'***estimation***.
- Nous avons extrait des échantillons afin d'***estimer*** la proportion de pâtes vertes dans le bol.
- 2 concepts clés liés à l'échantillonnage à des fins d'estimation :

  1. L'effet de la ***variation d'échantillonnage*** sur nos estimations : des échantillons différents donnent des estimations différentes.

  2. L'effet de la taille de l'échantillon sur la ***variation d'échantillonnage*** : plus la taille de notre échantillon est grande, plus notre estimation devrait être proche de la valeur réelle.



Sampling Glossary 📖

Population : ensemble des individus ou observations qui nous intéressent.
$N = 713$ pâtes.

Paramètre de population : quantité numérique résumant la population, qui est inconnue mais que nous souhaitons connaître.
Exemples : moyenne de la population (μ), proportion de pâtes vertes (p).

Recensement : énumération ou dénombrement exhaustif de tous les N individus ou observations de la population afin de calculer *exactement* la valeur du paramètre de population.

Échantillonnage : collecte d'échantillon(s) de

Sampling Glossary 📖

Population : ensemble des individus ou observations qui nous intéressent.
$N = 713$ pâtes.

Paramètre de population : quantité numérique résumant la population, qui est inconnue mais que nous souhaitons connaître.
Exemples : moyenne de la population (μ), proportion de pâtes vertes (p).

Recensement : énumération ou dénombrement exhaustif de tous les N individus ou observations de la population afin de calculer *exactement* la valeur du paramètre de population.

Échantillonnage : collecte d'échantillon(s) de

- *Estimation ponctuelle* ou *Statistique d'échantillon :* statistique résumée calculée à partir d'un échantillon qui estime un paramètre de population inconnu.
  Exemple : la *proportion d'échantillon* de pâtes vertes $(\hat{p})$. Le « chapeau » au-dessus du p indique qu'il s'agit d'une *estimation* de la proportion de population p.
- *Échantillonnage représentatif :* l'échantillon *ressemble-t-il* à la population ?
- *Échantillonnage biaisé :* toutes les pâtes avaient-elles une chance égale d'être incluses dans un échantillon ?

Définition statistique

- Nous avons estimer $\hat{p}$ tout au long du cours.

Définition statistique

- Nous avons estimer $\hat{p}$ tout au long du cours.
- On a montré graphiquement *la distribution de l'échantillon* pour mettre en évidence la *variation d'échantillonnage* de la *proportion de l'échantillon* $\hat{p}$.



Définition statistique

- Nous avons estimer $\hat{p}$ tout au long du cours.
- On a montré graphiquement *la distribution de l'échantillon* pour mettre en évidence la *variation d'échantillonnage* de la *proportion de l'échantillon* $\hat{p}$.
- Nous avons calculé l'*écart-type* de la *distribution d'échantillonnage* de $\hat{p}$. Cet écart-type porte un nom particulier : ***erreur type*** de l'*estimation ponctuelle* $\hat{p}$.



Définition statistique

- Nous avons estimer $\hat{p}$ tout au long du cours.
- On a montré graphiquement *la distribution de l'échantillon* pour mettre en évidence la *variation d'échantillonnage* de la *proportion de l'échantillon* $\hat{p}$.
- Nous avons calculé l'*écart-type* de la *distribution d'échantillonnage* de $\hat{p}$. Cet écart-type porte un nom particulier : ***erreur type*** de l'*estimation ponctuelle* $\hat{p}$.
- Reproduisons le tableau récapitulatif avec les libellés appropriés :

Taille échantillon (n)	**Erreur type** $\hat{p}$
25	0.10
50	0.07
100	0.05



- Point clé à retenir : à mesure que la *taille de l'échantillon* n augmente, l'erreur "typique" de votre *estimation ponctuelle* diminue, telle que quantifiée par l'*erreur type*.

Tout mettre ensemble

- Les ***estimations ponctuelles*** issues d'***échantillons aléatoires*** fournissent une *bonne estimation* du véritable ***paramètre de population*** inconnu.

Tout mettre ensemble

- Les ***estimations ponctuelles*** issues d'***échantillons aléatoires*** fournissent une *bonne estimation* du véritable ***paramètre de population*** inconnu.
- À quel point est-elle bonne ? Parfois $\hat{p}$ sera loin de p, parfois proche. Il y a de la ***variation d'échantillonnage***.

Tout mettre ensemble

- Les ***estimations ponctuelles*** issues d'***échantillons aléatoires*** fournissent une *bonne estimation* du véritable ***paramètre de population*** inconnu.
- À quel point est-elle bonne ? Parfois $\hat{p}$ sera loin de p, parfois proche. Il y a de la ***variation d'échantillonnage***.
- ***En moyenne***, nos estimations seront correctes. C'est grâce à l'échantillonnage aléatoire. On dit que :

> $\hat{p}$ est un ***estimateur sans biais*** de p, c.-à-d. $\mathbb{E}[\hat{p}] = p$

Tout mettre ensemble

- Les ***estimations ponctuelles*** issues d'***échantillons aléatoires*** fournissent une *bonne estimation* du véritable ***paramètre de population*** inconnu.
- À quel point est-elle bonne ? Parfois $\hat{p}$ sera loin de p, parfois proche. Il y a de la ***variation d'échantillonnage***.
- ***En moyenne***, nos estimations seront correctes. C'est grâce à l'échantillonnage aléatoire. On dit que :

> $\hat{p}$ est un ***estimateur sans biais*** de p, c.-à-d. $\mathbb{E}[\hat{p}] = p$

- Quelle est la véritable proportion de population p de pâtes vertes dans la population de $N = 713$ pâtes ?

Tout mettre ensemble

- Les ***estimations ponctuelles*** issues d'***échantillons aléatoires*** fournissent une *bonne estimation* du véritable ***paramètre de population*** inconnu.
- À quel point est-elle bonne ? Parfois $\hat{p}$ sera loin de p, parfois proche. Il y a de la ***variation d'échantillonnage***.
- ***En moyenne***, nos estimations seront correctes. C'est grâce à l'échantillonnage aléatoire. On dit que :

> $\hat{p}$ est un ***estimateur sans biais*** de p, c.-à-d. $\mathbb{E}[\hat{p}] = p$

- Quelle est la véritable proportion de population p de pâtes vertes dans la population de $N = 713$ pâtes ?

```
sum(bowl$color == "green")/nrow(bowl)
```

```
## [1] 0.4936886
```



Tout mettre ensemble

- Les *estimations ponctuelles* issues d'*échantillons aléatoires* fournissent une *bonne estimation* du véritable *paramètre de population* inconnu.
- À quel point est-elle bonne ? Parfois $\hat{p}$ sera loin de p, parfois proche. Il y a de la *variation d'échantillonnage*.
- *En moyenne*, nos estimations seront correctes. C'est grâce à l'échantillonnage aléatoire. On dit que :

> $\hat{p}$ est un *estimateur sans biais* de p, c.-à-d. $\mathbb{E}[\hat{p}] = p$

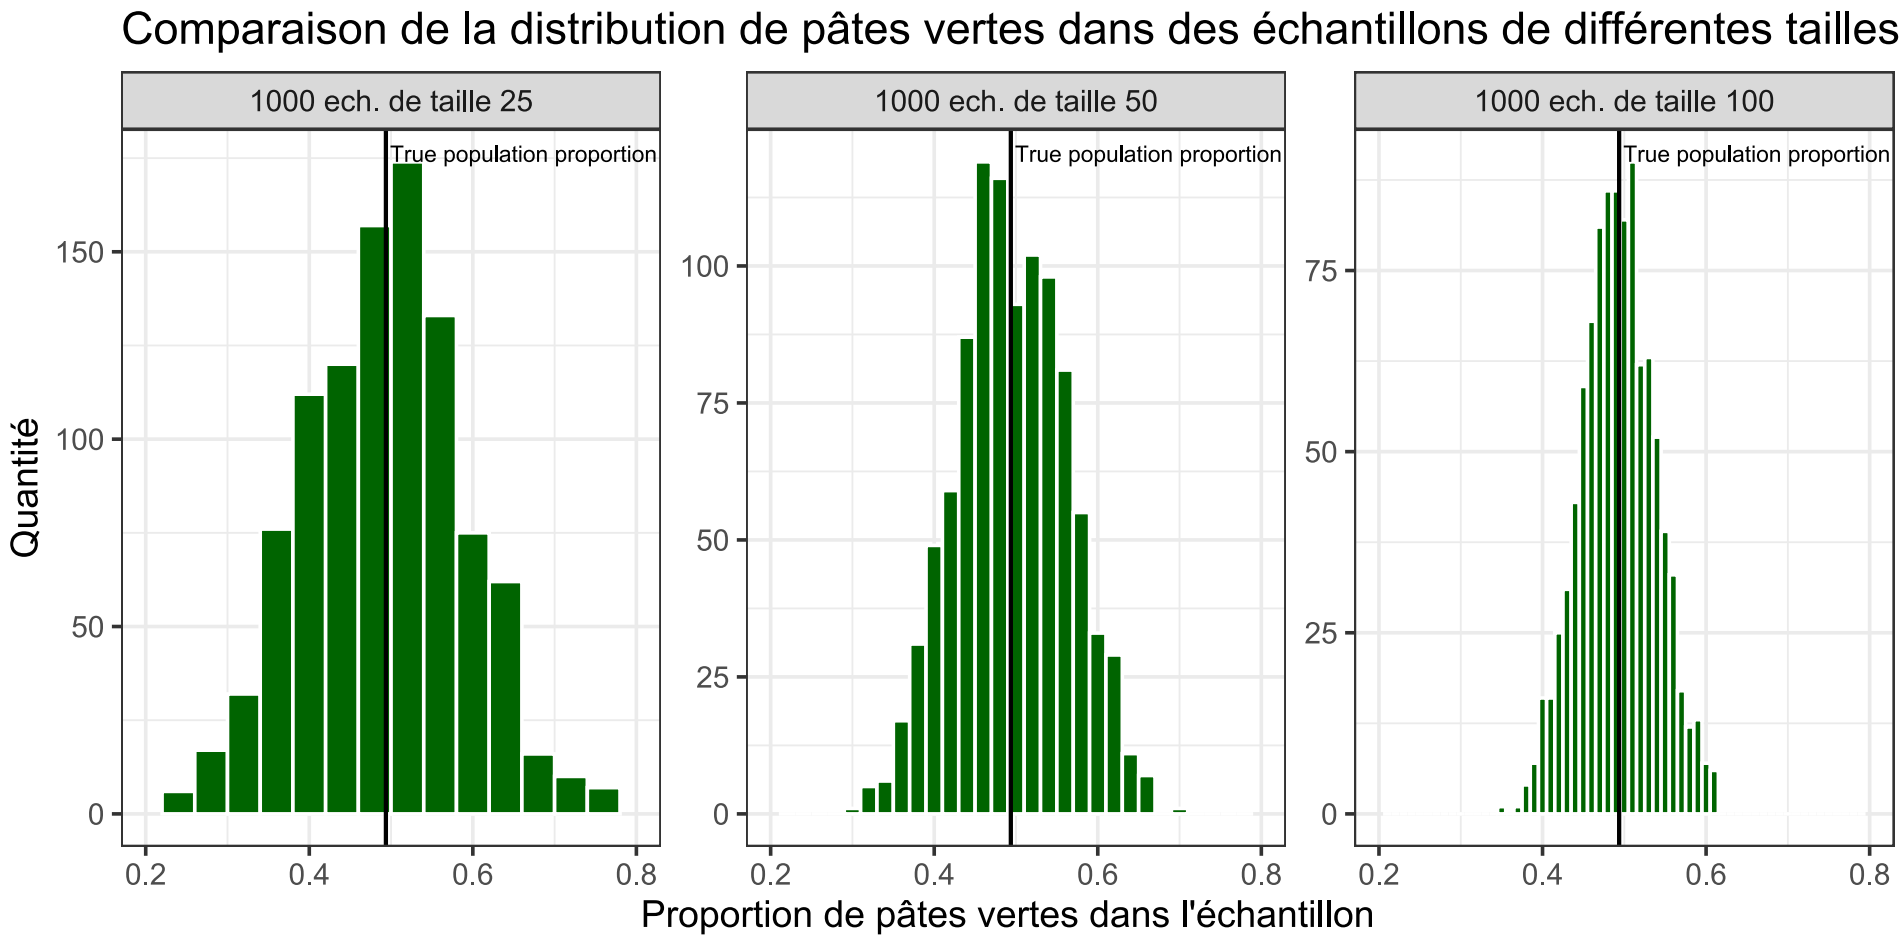
- Quelle est la véritable proportion de population p de pâtes vertes dans la population de $N = 713$ pâtes ?

```
sum(bowl$color == "green")/nrow(bowl)
```

```
## [1] 0.4936886
```

- Insérons la *véritable proportion de population* $p = 0.49$ dans nos graphiques précédents !

Visualiser l'absence de biais et la variation d'échantillonnage



Quelques scénarios d'échantillonnage

Scénario	Paramètre de population	Notation	Estimation ponctuelle	Symbole(s)
1	Proportion de population	p	Proportion d'échantillon	$\hat{p}$
2	Moyenne de population	μ	Moyenne d'échantillon	$\overline{x}$ ou $\widehat{\mu}$
3	Différence de proportions de population	$p_1 - p_2$	Différence de proportions d'échantillon	$\hat{p}_1 - \hat{p}_2$
4	Différence de moyennes de population	$\mu_1 - \mu_2$	Différence de moyennes d'échantillon	$\overline{x}_1 - \overline{x}_2$
5	Pente de régression de population	β_1	Pente de régression ajustée	b_1 ou $\widehat{\beta}_1$
6	Ordonnée à l'origine de régression de population	β_0	Ordonnée à l'origine de régression ajustée	b_0 ou $\widehat{\beta}_0$

Le théorème central limite (TCL)

- Le fait que nos statistiques d'échantillon ***convergent*** vers une *limite centrale* est bien connu en statistique.



Le théorème central limite (TCL)

- Le fait que nos statistiques d'échantillon ***convergent*** vers une *limite centrale* est bien connu en statistique.
- C'est le résultat d'un résultat connu sous le nom de ***théorème centrale limite***.

Le théorème central limite (TCL)

- Le fait que nos statistiques d'échantillon ***convergent*** vers une *limite centrale* est bien connu en statistique.
- C'est le résultat d'un résultat connu sous le nom de ***théorème centrale limite***.

> **Théorème central limite :** quelle que soit l'allure de la distribution de population sous-jacente, lorsque les *moyennes* d'échantillon sont basées sur des tailles d'échantillon de plus en plus grandes, la distribution d'échantillonnage de ces *moyennes* d'échantillon devient à la fois de plus en plus normale et de plus en plus étroite.



Le théorème central limite (TCL)

- Le fait que nos statistiques d'échantillon ***convergent*** vers une *limite centrale* est bien connu en statistique.
- C'est le résultat d'un résultat connu sous le nom de ***théorème centrale limite***.

> **Théorème central limite :** quelle que soit l'allure de la distribution de population sous-jacente, lorsque les *moyennes* d'échantillon sont basées sur des tailles d'échantillon de plus en plus grandes, la distribution d'échantillonnage de ces *moyennes* d'échantillon devient à la fois de plus en plus normale et de plus en plus étroite.

- En d'autres termes, leur distribution d'échantillonnage suit de plus en plus une ***distribution normale*** et la *variation de ces distributions d'échantillonnage diminue*, telle que quantifiée par leurs ***erreurs types***.



Théorème centrale limite - La statistique expliquée à mon chat



UNIVERSITÉ DE NAMUR

BONNE JOURNÉE !

	jeremy.donascimento@unamur.be
	Discord
	Slides