UNIVERSITÉ DE NAMUR

Econométrie

Regression Linéaire Simple

Jérémy Do Nascimento Miguel
Université de Namur
2026-09-16

Aujourd'hui - Real 'metrics finally

- Introduction aux ***Modèles de Régression Linéaire Simple*** et *estimation* ***Ordinary Least Squares (OLS)***.
- Application empirique : *absentéisme* et *santé des élèves*
- L'objectif est d'étudier l'existence d'une relation **causale** entre ces deux variables



Etat de santé des élèves et présence à l'école

- Quelles politiques peuvent *causer* une réduction de l'absentéisme des élèves ?
- Différentes options mise en place : transferts sociaux conditionnels, construction d'écoles, accompagnement de santé.

Etat de santé des élèves et présence à l'école

- Quelles politiques peuvent *causer* une réduction de l'absentéisme des élèves ?
- Différentes options mise en place : transferts sociaux conditionnels, construction d'écoles, accompagnement de santé.
- Nous allons utiliser les données d'un papier économique célèbre écrit par Michael Kremer et Edward Miguel (2004).
- Les données donnent des informations sur des caractéristiques de santé et abstésime d'étudiant.e.s entre 6 et 8 ans dans 75 écoles Kényanes en 1998 et 1999.
- Nous utiliserons principalement les *données anthropométriques* (rapport poids pour âge) et *l'absentéisme* mesuré par le nombre de jours d'école manqué lors des 4 dernière semaines.



Exo 1: Connaitre les données

07:00

1. Télécharger les données depuis ici comme `data`. *Indice : Utiliser la fonction `read_dta` de la librairie `haven` pour importer les données, qui est en format .dta.* (FYI: *.dta* est une extension utilisée pour les fichiers utilisés dans *Stata*)

2. Décrire les données :

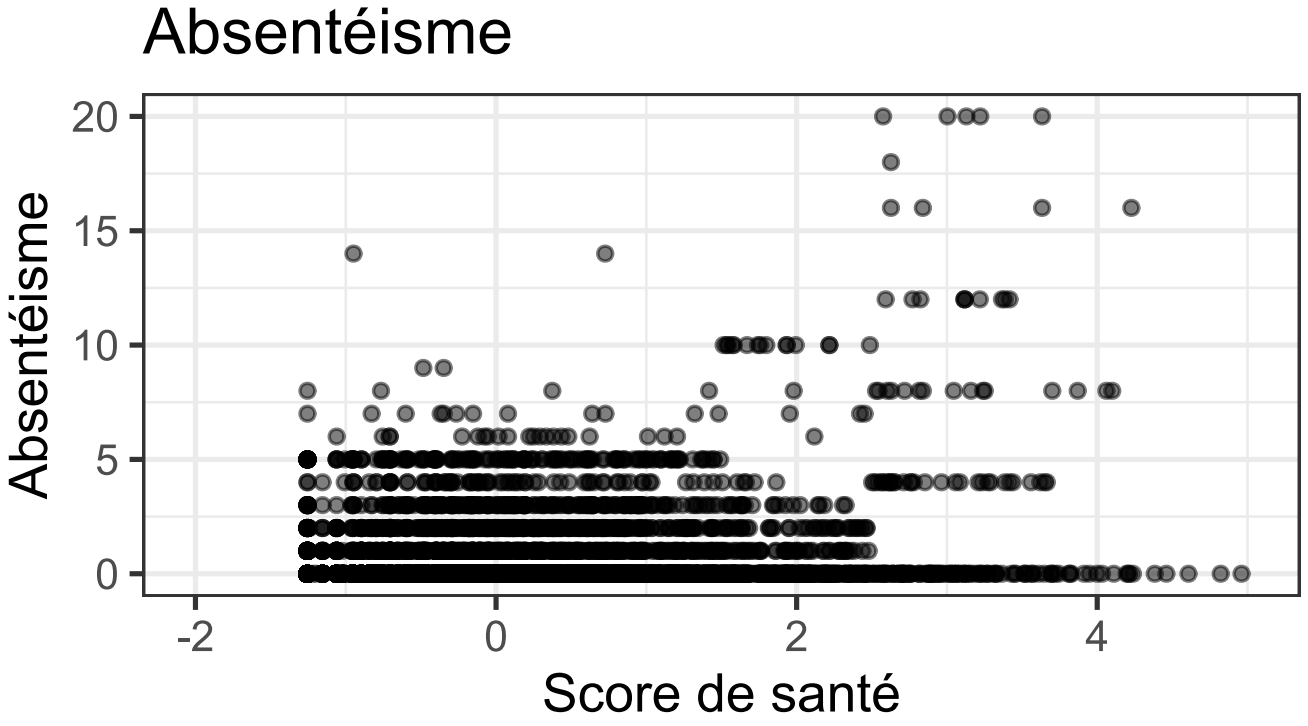
   - Quelle est l'unité d'observation, i.e., à quoi correspond une ligne ?
   - Combien d'observations avons-nous ?
   - Regarder les donnéest. Quelles variables avons-nous ? A quoi correspondent les variables `absdays` et `haz` ?
   - Utiliser la fonction `skim` du package `skimr` pour avoir des statistiques basiques pour les variables `absdays`, `haz` et `waz`. (*Indice: utiliser `dplyr` pour `select` les variables et ensuite utiliser (`%>%`) `skim()`.*)

3. Avez vous une idée sur la relation entre l'état de santé des élèves et leur absentéisme ? Qu'est ce que vous ferez pour étudier cela ?

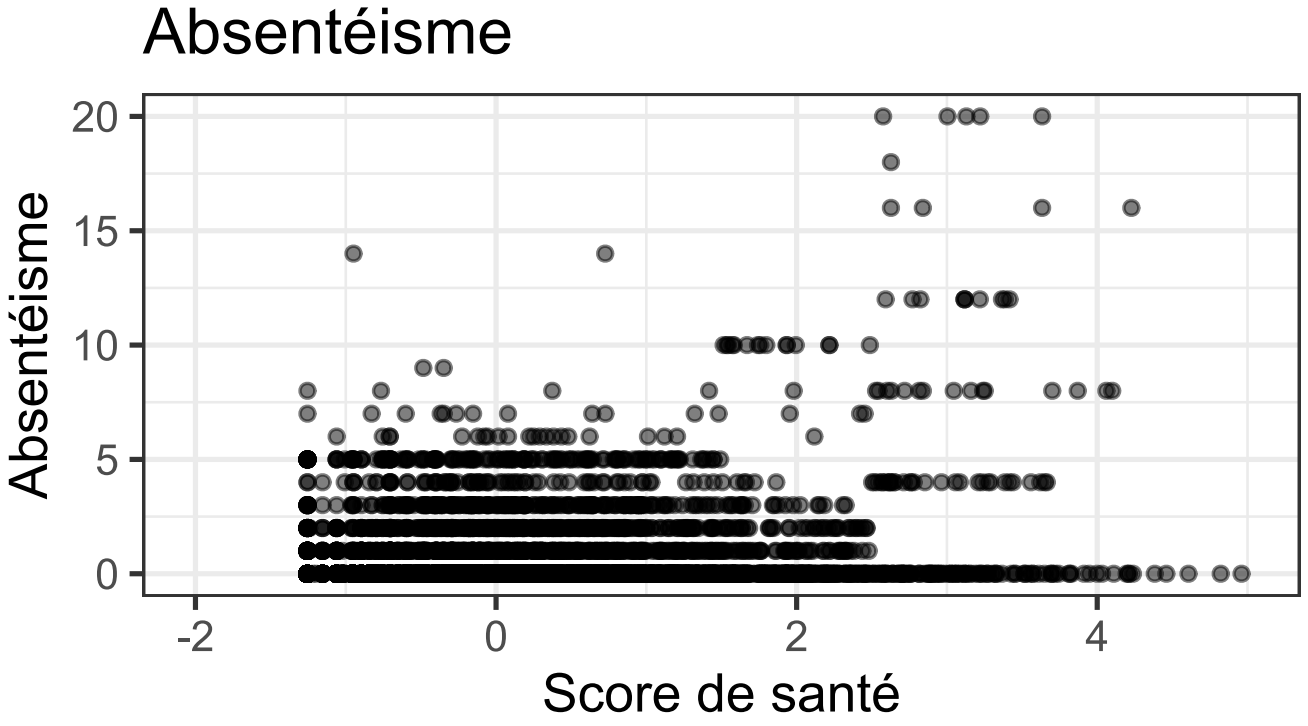
4. Calculer la corrélation entre ces deux variables. Est-ce que cette relation est positive/négative, forte/faible?



Santé des élèves et absentéisme: Nuage de points

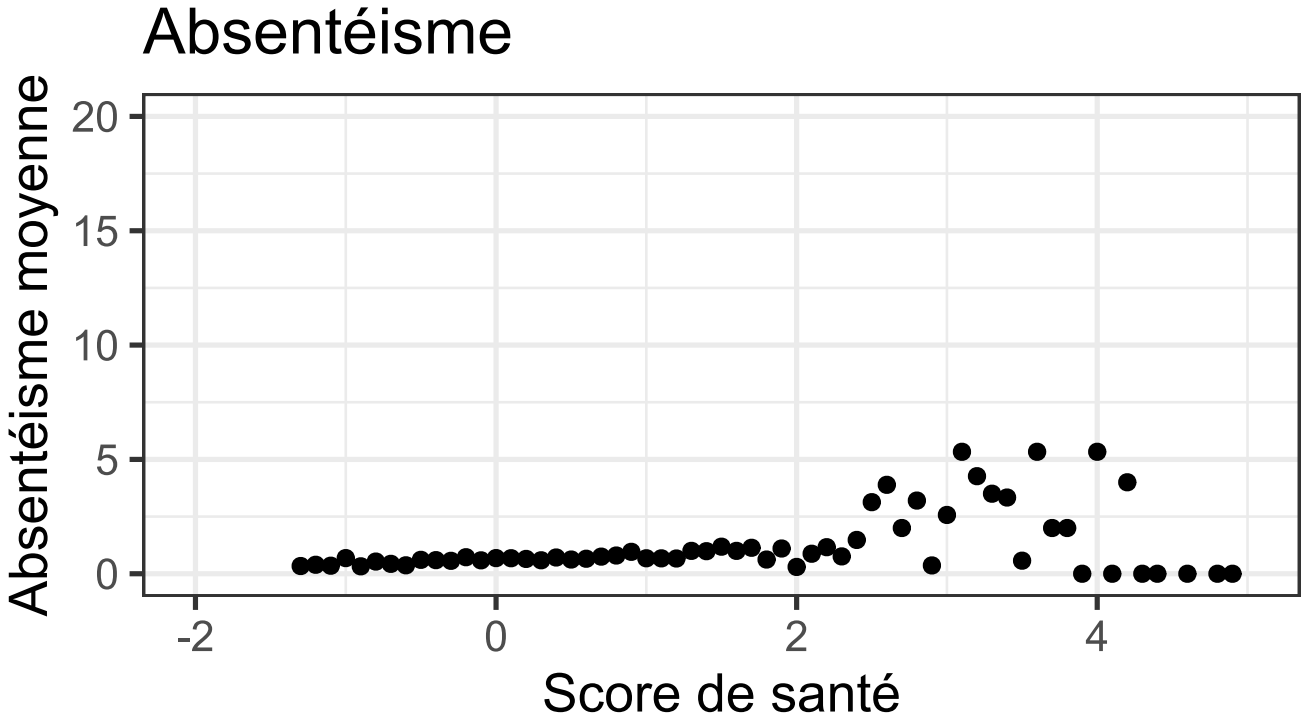


Santé des élèves et absentéisme: Nuage de points



- La relation semble positive, mais calculons l'absentéisme moyen par score de santé pour y voir plus clair !

Santé des élèves et absentéisme: Nuage de points

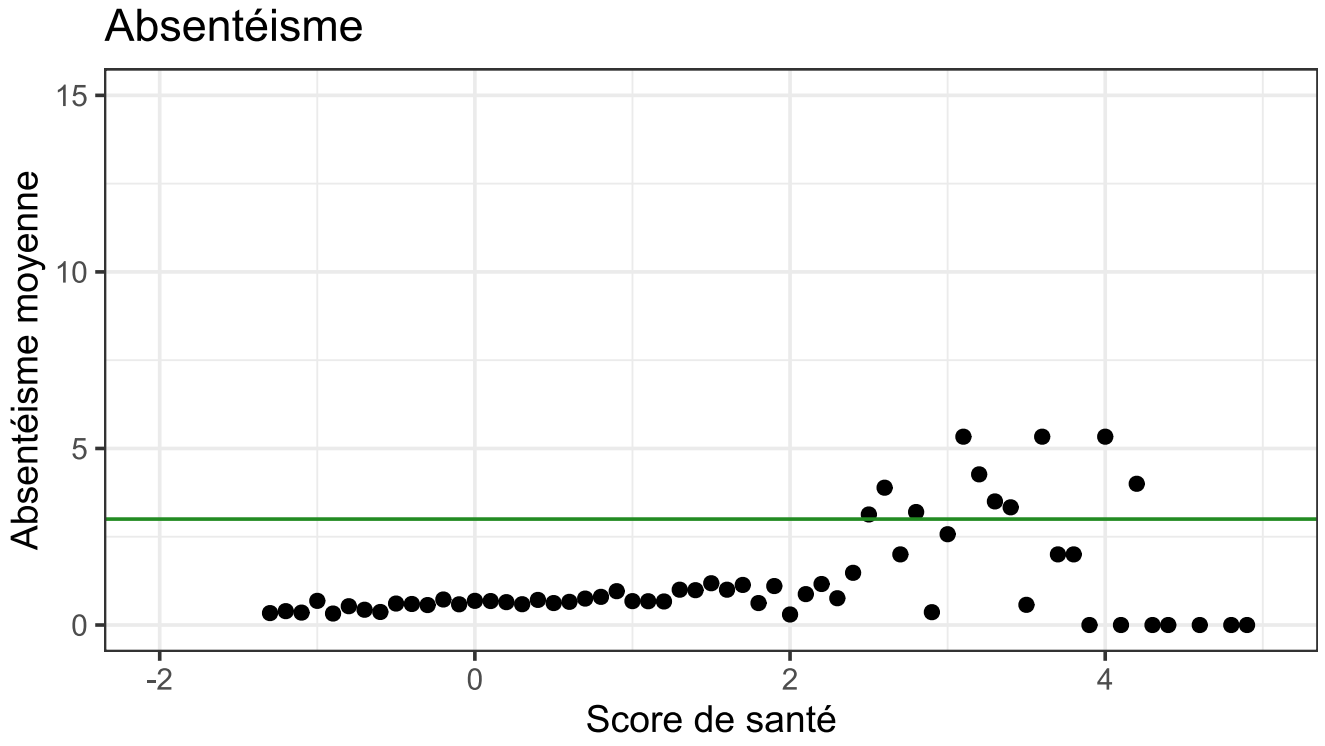


Santé des élèves et absentéisme: ligne de régression

Comment résumer visuellement cette relation ? On utilise le plus souvent une **droite de régression**

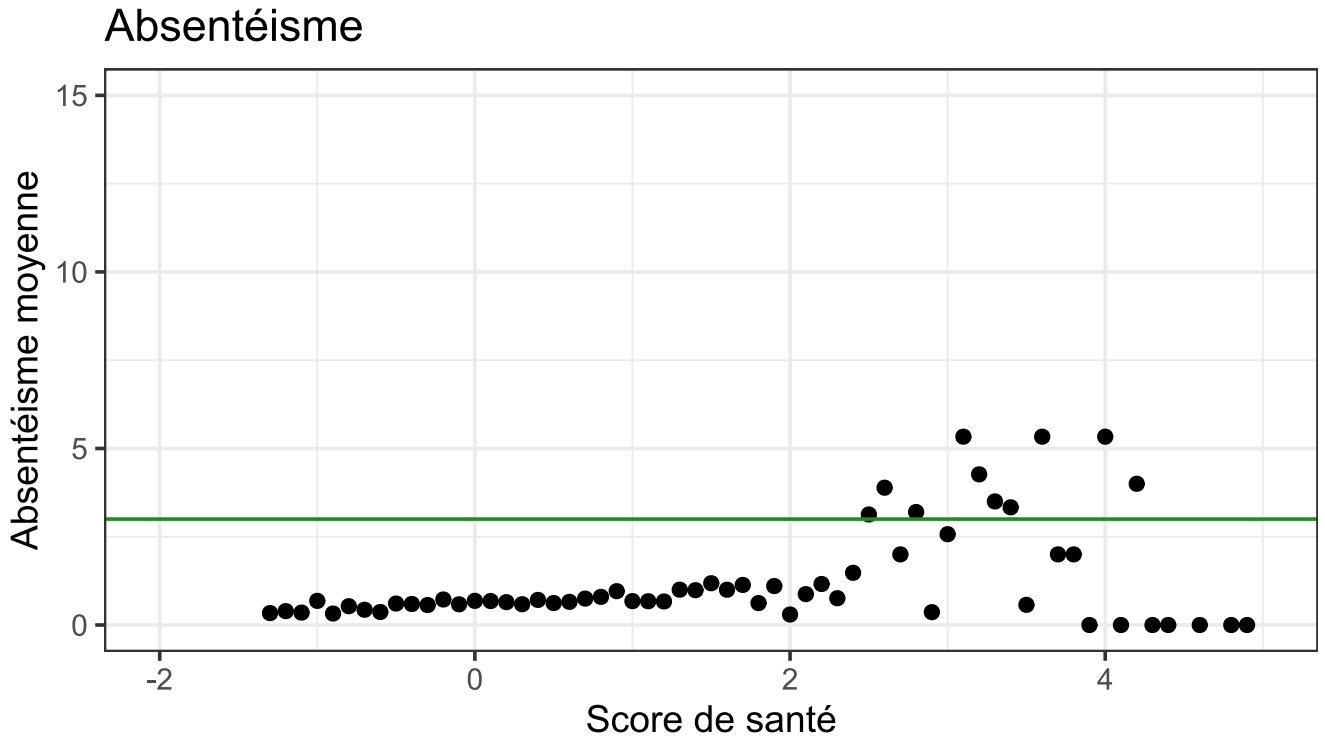
Santé des élèves et absentéisme: ligne de régression

Comment résumer visuellement cette relation ? On utilise le plus souvent une **droite de régression**



Santé des élèves et absentéisme: ligne de régression

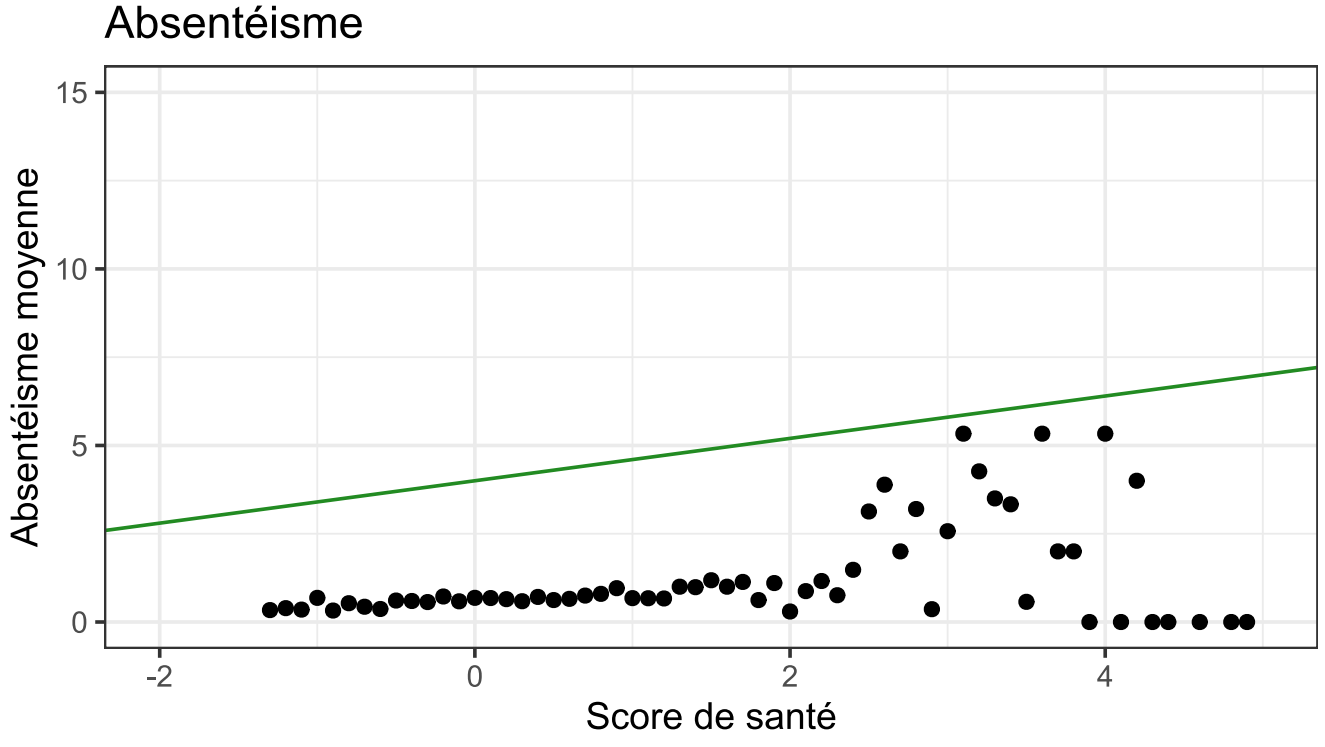
Comment résumer visuellement cette relation ? On utilise le plus souvent une **droite de régression**



- Une *droite* ! MAIS **laquelle** ? Celle-ci ?
- La droite est relativement *plate* mais l'absentéisme *augmente* modestement lorsque les élèves sont en plus mauvaise santé

Santé des élèves et absentéisme: ligne de régression

Comment résumer visuellement cette relation ? On utilise le plus souvent une **droite de régression**



- **Celle-ci** ?
- Légèrement mieux ! Il y a une **pente** et une **intersection**
- Nous avons besoin d'une règle formelle de décision.

Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :



Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :
  - une **variable dépendante** (ou **prédite, expliquée**):
    absentéisme à l'école (y)

Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :
  - une **variable dépendante** (ou **prédite, expliquée**):
    absentéisme à l'école (y)
  - une **variable explicative** (**dépendante, controle, predicteur, régresseur**) :
    état de santé de l'élève (x)

Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :
  - une **variable dépendante** (ou **prédite, expliquée**):
    absentéisme à l'école (y)
  - une **variable explicative** (**dépendante, controle, predicteur, régresseur**) :
    état de santé de l'élève (x)
- Pour chaque classe i, nous observons x_i et y_i, et par conséquent pouvons étudier la *distribution jointe* de la taille de la classe et du score moyen en math.

Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :
  - une **variable dépendante** (ou **prédite, expliquée**):
    absentéisme à l'école (y)
  - une **variable explicative** (**dépendante, controle, predicteur, régresseur**) :
    état de santé de l'élève (x)
- Pour chaque classe i, nous observons x_i et y_i, et par conséquent pouvons étudier la *distribution jointe* de la taille de la classe et du score moyen en math.
- On peut résumer cette relation avec une droite L'équation s'écrit de telle sorte qu'il a une intersection à l'ordonnée β_0 et la pente β_1 :

$$\hat{y}_i = \beta_0 + \beta_1 x_i + u_i$$

Régression Linéaire Simple

Formalisons ce que l'on est entrain de faire. Nous sommes intéressé.e.s dans l'étude de la relation entre deux variables

- L'analyse économétrique a pour objectif d'expliquer y par rapport à x :
  - une **variable dépendante** (ou **prédite, expliquée**):
    absentéisme à l'école (y)
  - une **variable explicative** (**dépendante, controle, predicteur, régresseur**) :
    état de santé de l'élève (x)
- Pour chaque classe i, nous observons x_i et y_i, et par conséquent pouvons étudier la *distribution jointe* de la taille de la classe et du score moyen en math.
- On peut résumer cette relation avec une droite L'équation s'écrit de telle sorte qu'il a une intersection à l'ordonnée β_0 et la pente β_1 :

$$\hat{y}_i = \beta_0 + \beta_1 x_i + u_i$$

- $\hat{y}_i$: *prédiction* pour y à notre observation i (y_i) en utilisant notre modèle (la droite).

Qu'est ce qu'une droite ?

```
## Error in parse(text = input): <text>:1:2: symbole inattendu
## 1: \beta_0
##      ^
```



Qu'est ce qu'une droite ?

```
## Error in parse(text = input): <text>:2:6: '\\' inattendu(e)
## 1: library('latex2exp')
## 2: plot_\
##         ^
```

Qu'est ce qu'une droite ?

```
## Error in parse(text = input): <text>:1:6: '\\' inattendu(e)
## 1: plot_\
##          ^
```

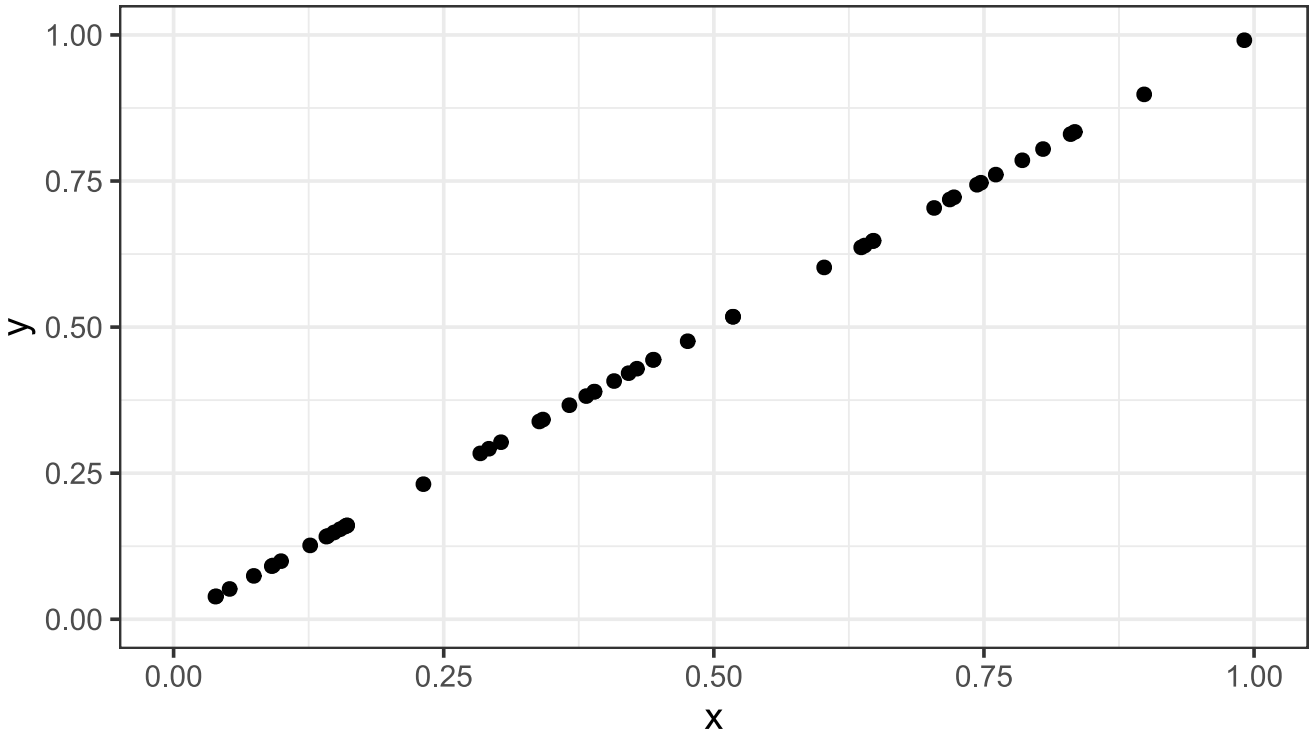


Résidus

- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.

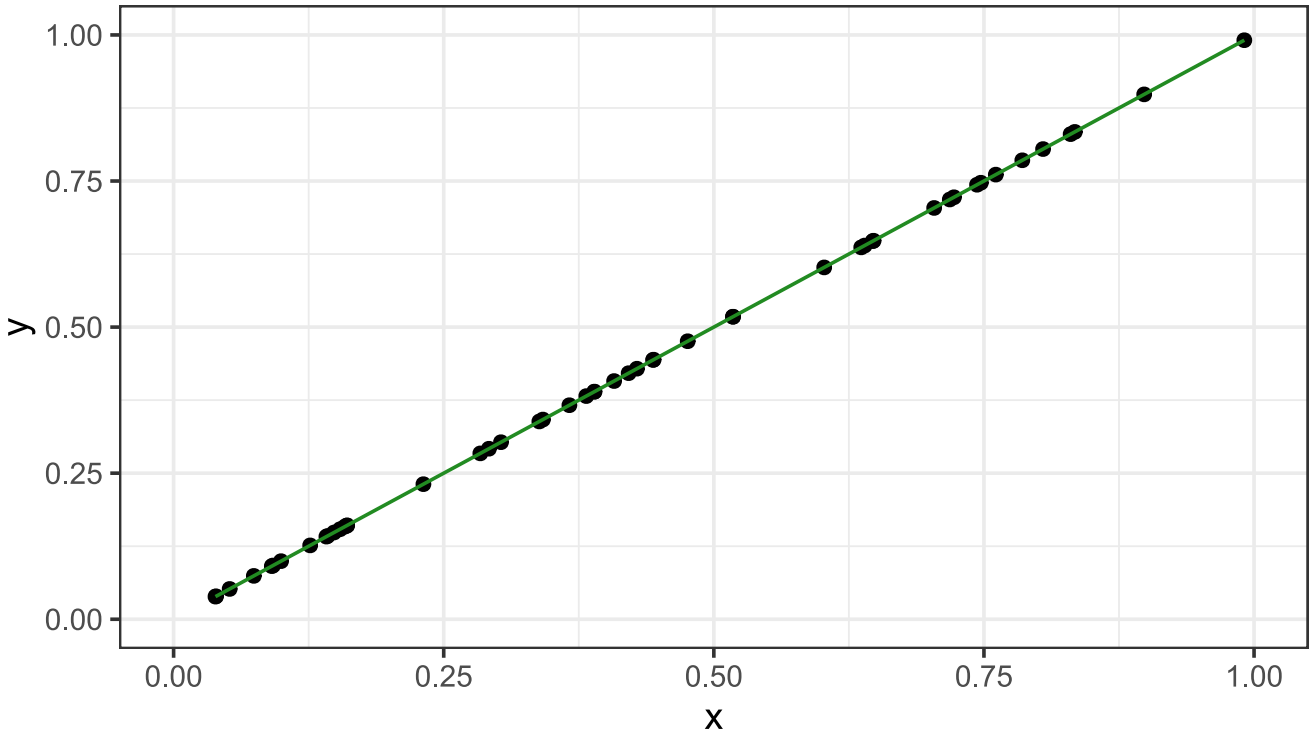
Résidus

- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.



Résidus

- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.



Résidus

- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.
- Cependant, dans la majorité des cas la *variable dépendante* (y) n'est pas *uniquement* expliquée par notre *variable indépendante* (x), $\hat{y}_i \neq y_i$, i.e., on fait une **erreur**.
  Cette **erreur** est appelée le **résidu**.



Résidus

- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.
- Cependant, dans la majorité des cas la *variable dépendante* (y) n'est pas *uniquement* expliquée par notre *variable indépendante* (x), $\hat{y}_i \neq y_i$, i.e., on fait une **erreur**.
  Cette **erreur** est appelée le **résidu**.
- Au point (x_i, y_i), on le note u_i.

Résidus

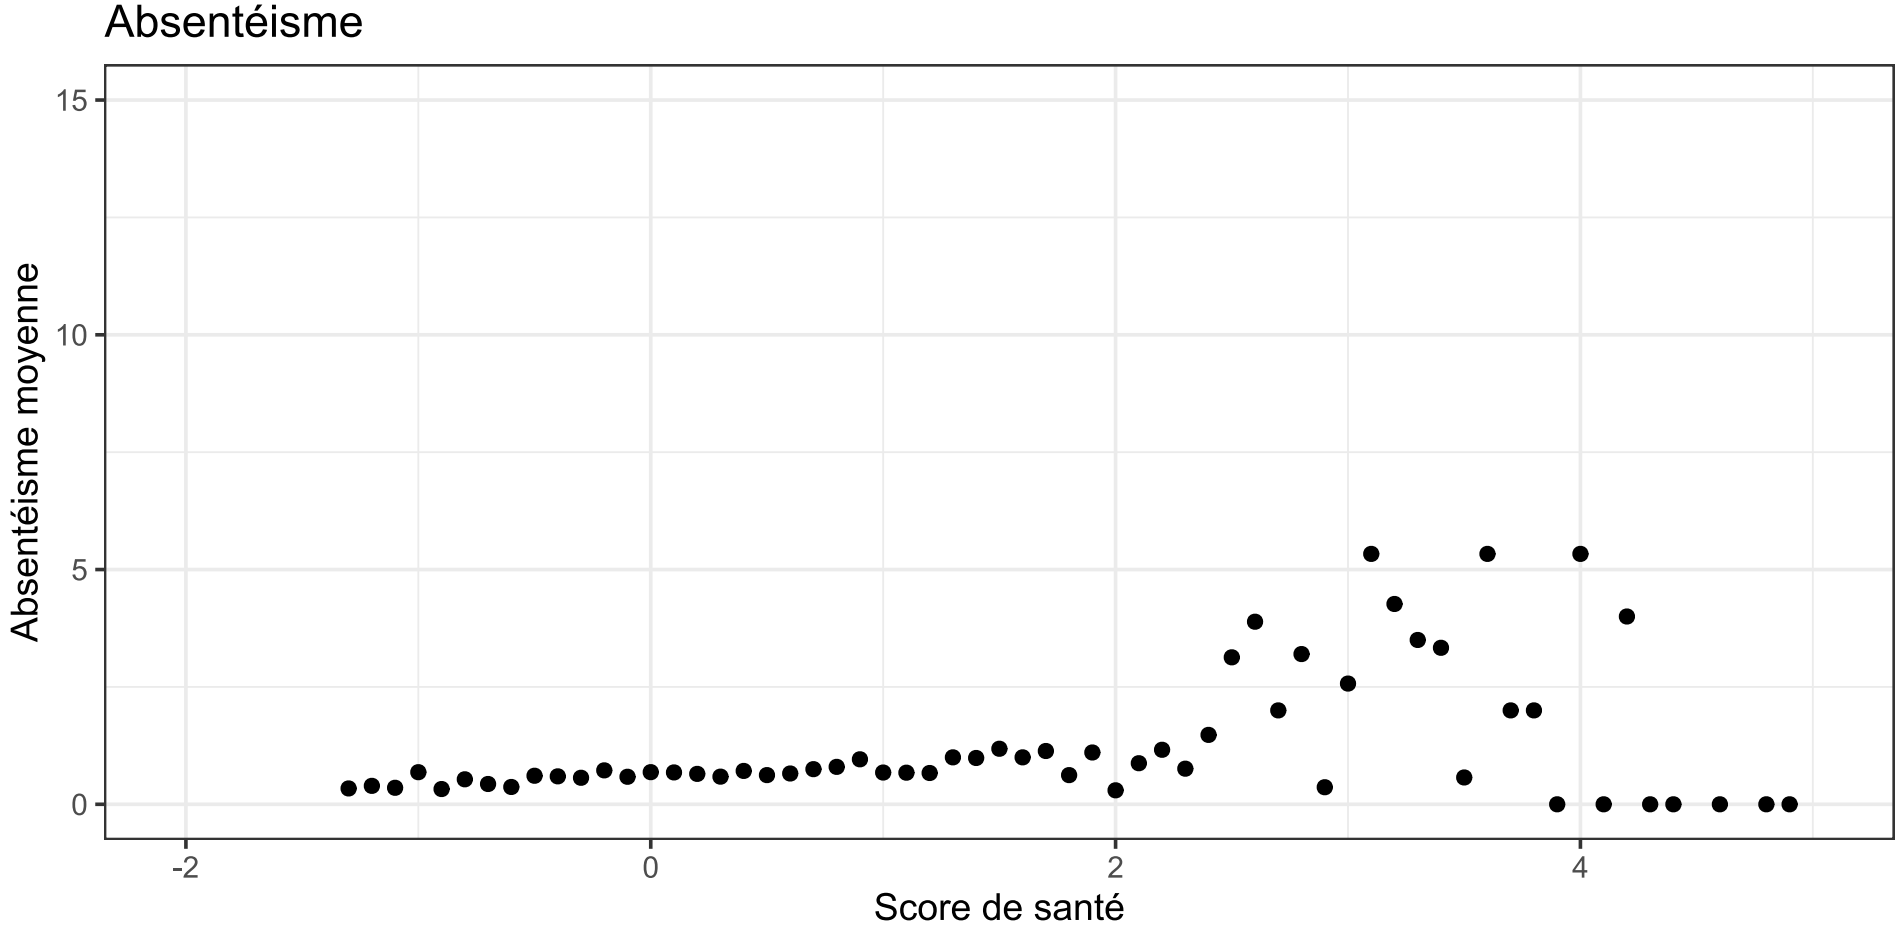
- Si l'ensemble des points étaient **sur** la droite, alors $\hat{y}_i = y_i$.
- Cependant, dans la majorité des cas la *variable dépendante* (y) n'est pas *uniquement* expliquée par notre *variable indépendante* (x), $\hat{y}_i \neq y_i$, i.e., on fait une **erreur**.
  Cette **erreur** est appelée le **résidu**.
- Au point (x_i, y_i), on le note u_i.
- Les *données réelles* (x_i, y_i) peuvent être réecrite telle que *prédiction* + *residu*:

$$\hat{y}_i = \beta_0 + \beta_1 x_i + u_i$$



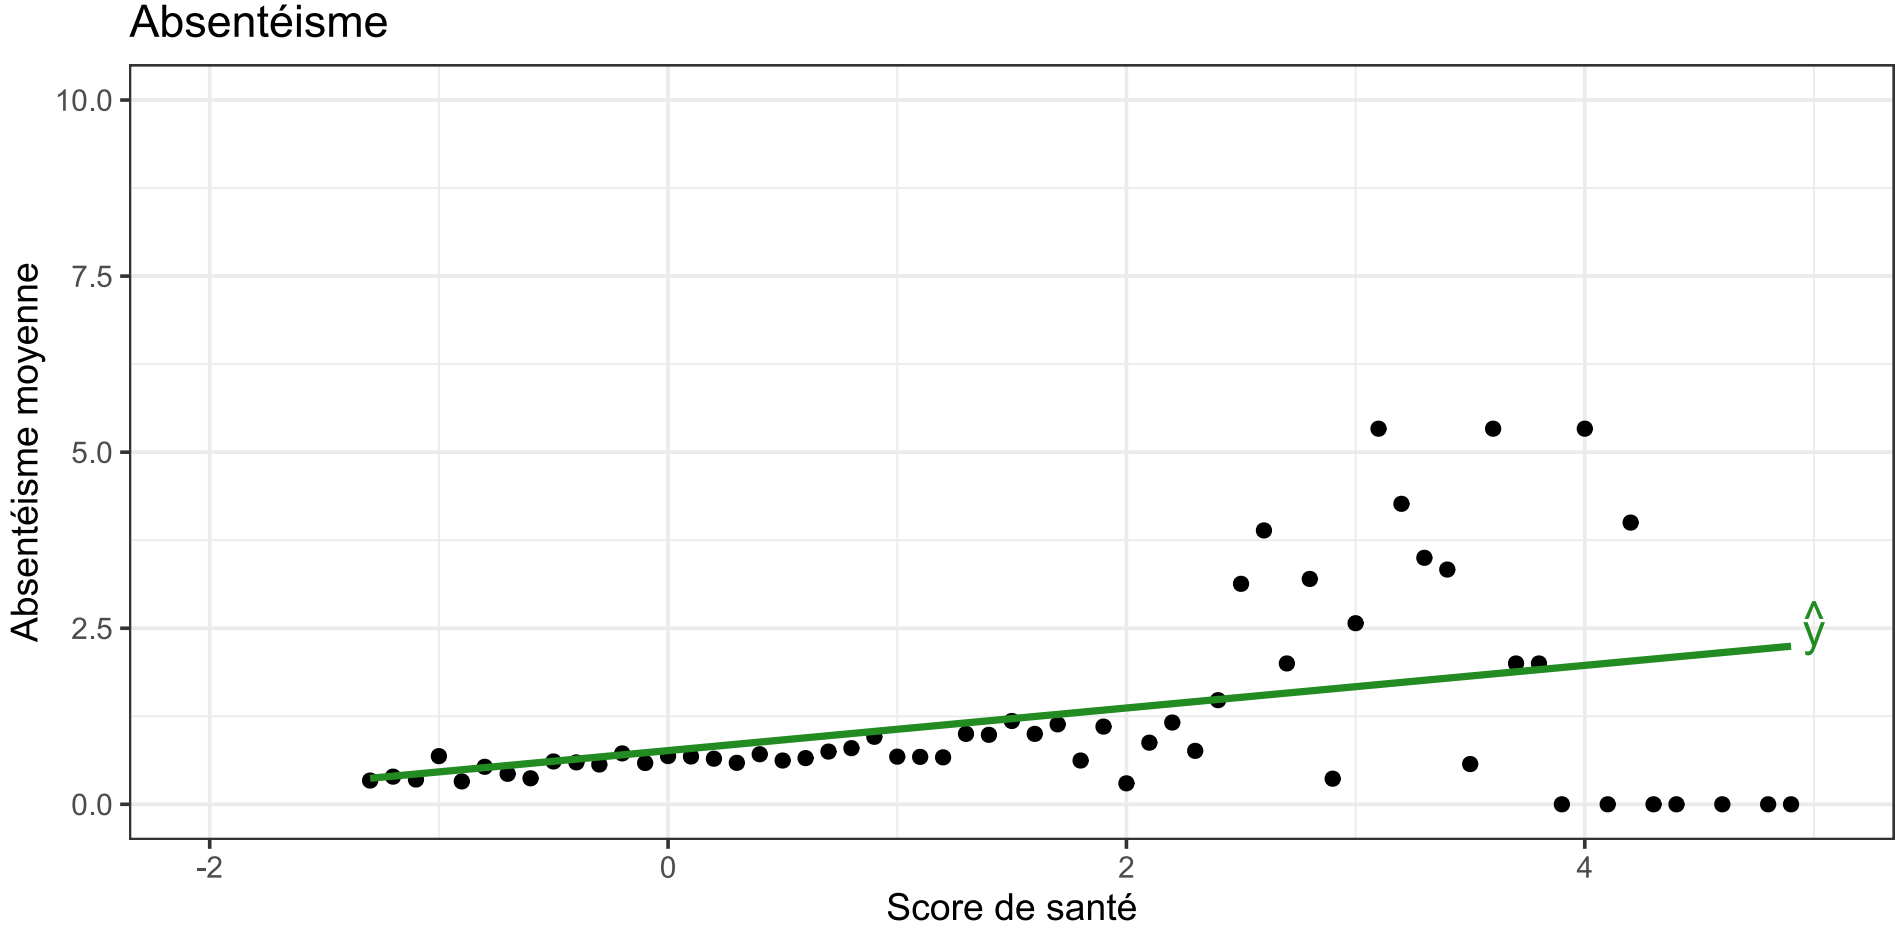
Régression linéaire simple : graphiquement

Regardons la distribution jointe de nos deux variables



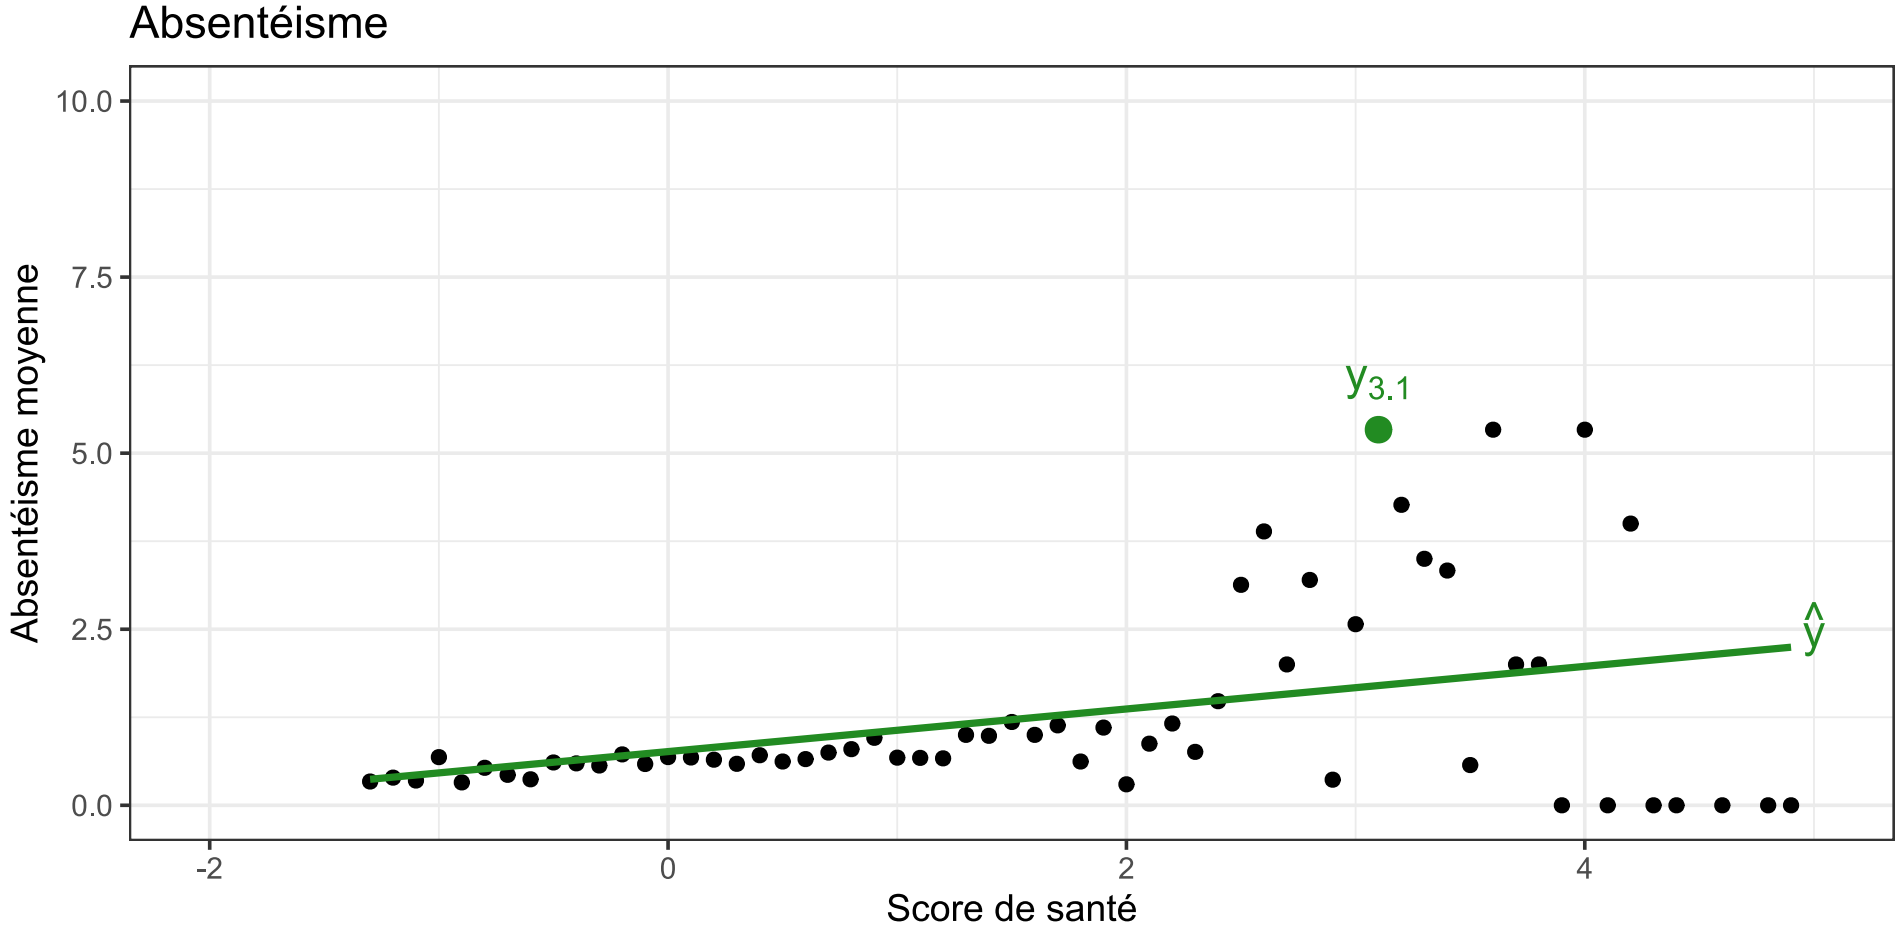
Régression linéaire simple : graphiquement

Ajoutons la droite de régression linéaire



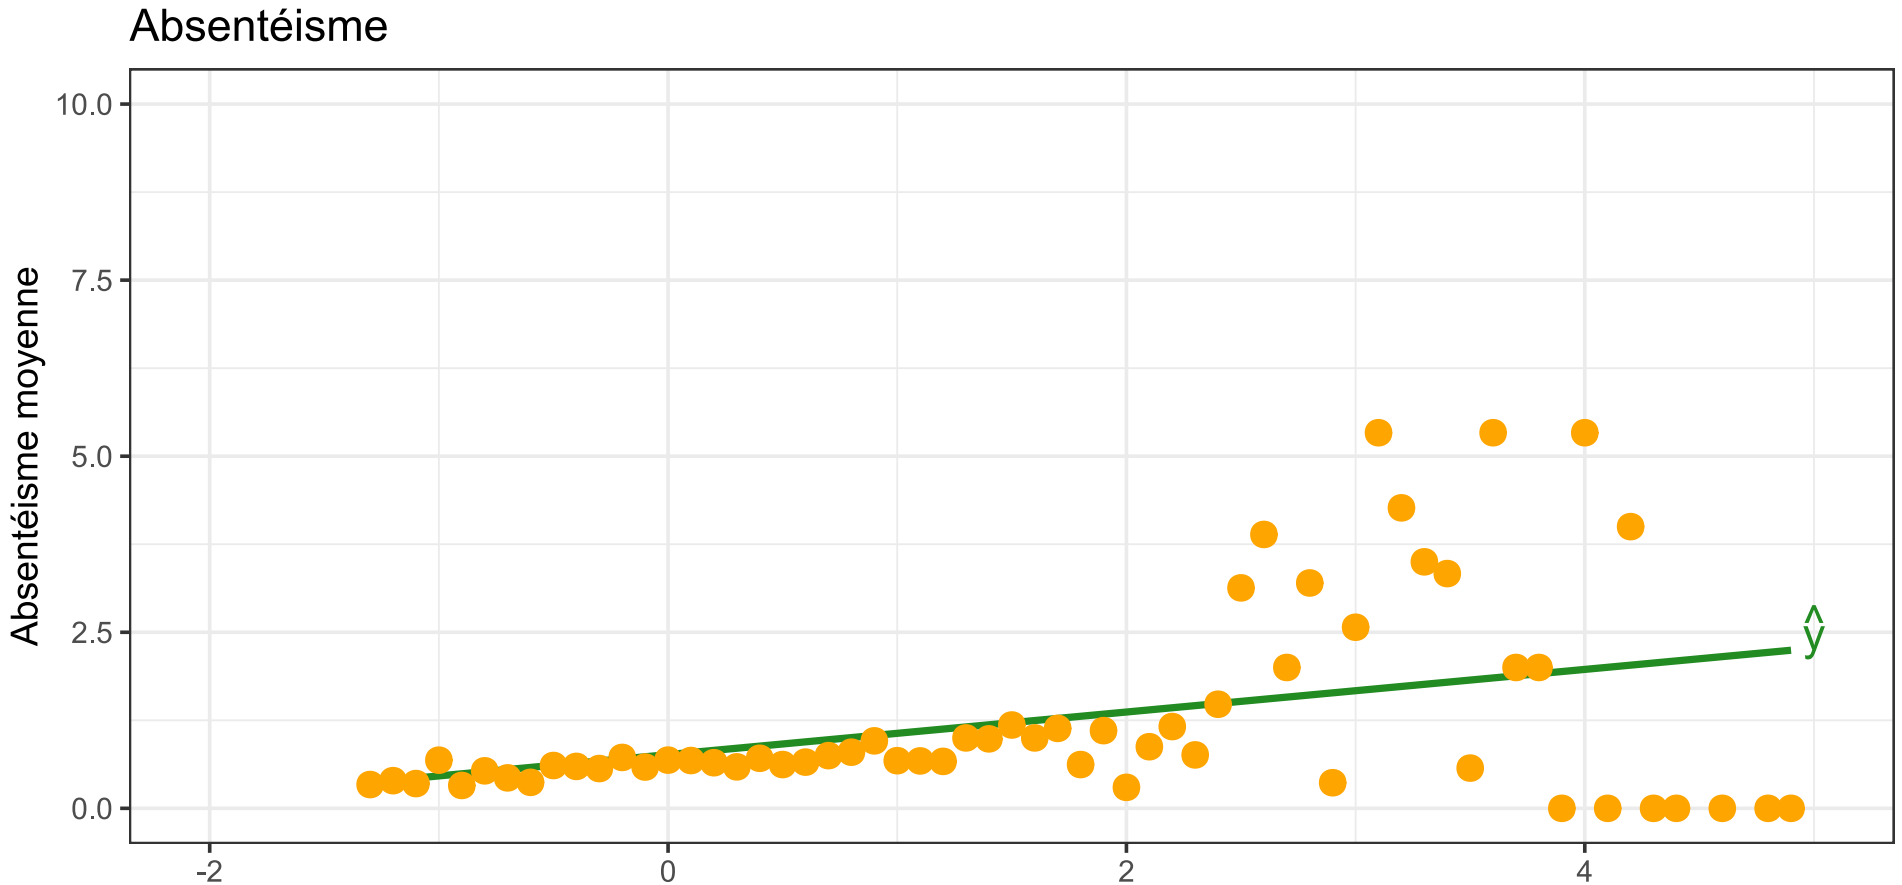
Régression linéaire simple : graphiquement

Concentrons nous sur les observations avec un score = 2

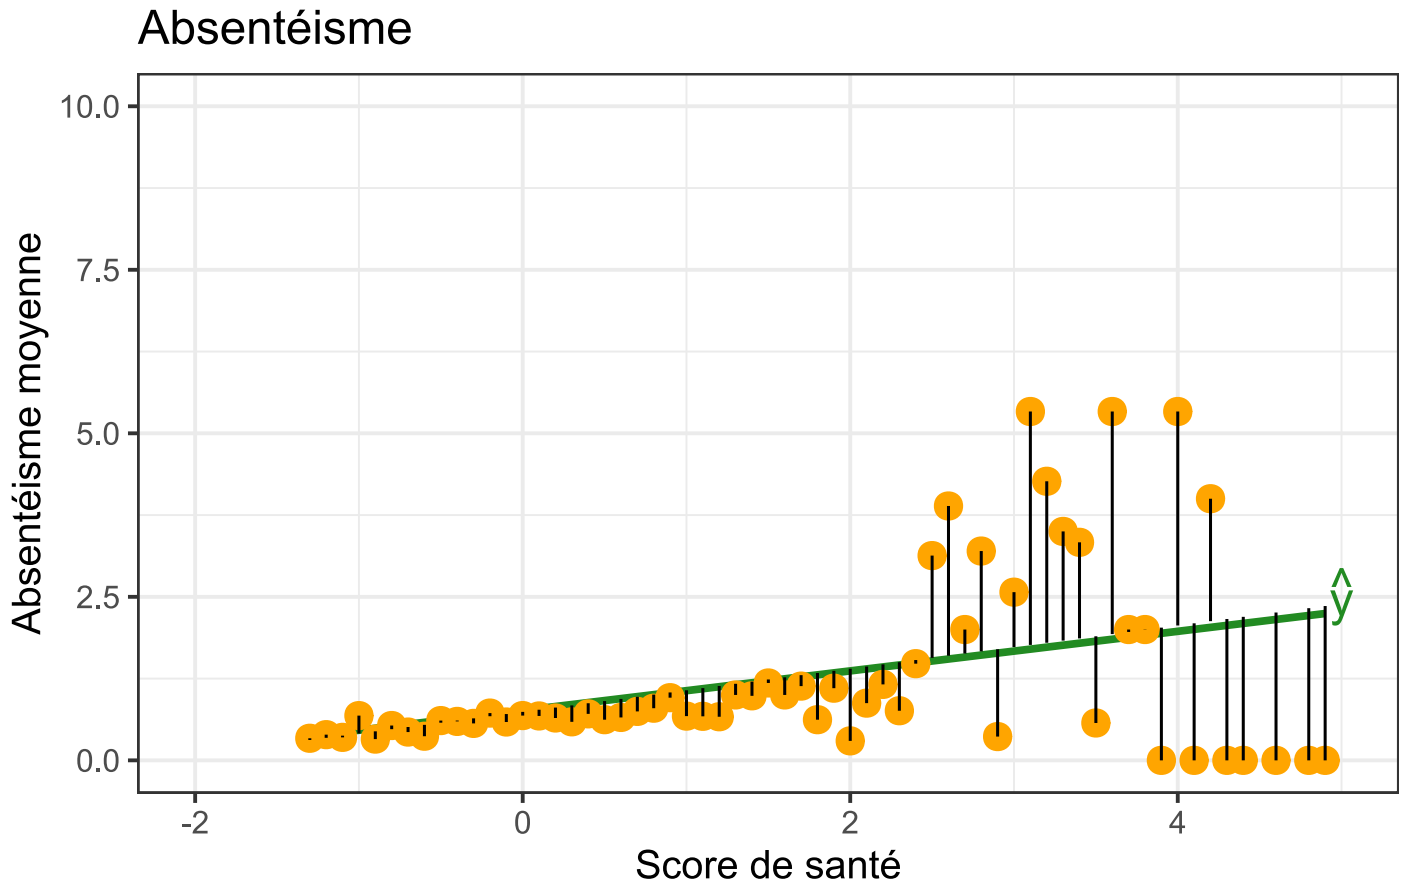


Régression linéaire simple : graphiquement

On trouve la même chose lorsque l'on se concentre sur l'ensemble de notre base de données. Notre nouvel objectif est de minimiser la distance entre la droite ($\widehat{y_i}$) et les valeurs réelles (y_i), cad les erreurs



Régression linéaire simple : graphiquement



Quel critère de *minimisation* devons nous utiliser?

Quelle est la relation entre x et u ?

L'objectif est d'esitmer l'effet **ceteris paribus** : tous les autres éléments sont maintenus constant pour isoler l'effet unique de notre variable indépendante sur la variable dépendante.

Quelle est la relation entre x et u ?

L'objectif est d'esitmer l'effet **ceteris paribus** : tous les autres éléments sont maintenus constant pour isoler l'effet unique de notre variable indépendante sur la variable dépendante.

Hypothèse centrale sur la distribution des facteurs inobservables :

(a) $E(u) = 0$

- Sachant que x et u sont deux variables aléatoires, on peut définir la distribution conditionnelle de u pour toute valeur de x

$\Rightarrow$ (b) $E(u|x) = E(u) \iff$ En moyenne, les résidus sont indépendants des x

Quelle est la relation entre x et u ?

En combinant (a) et (b), on obtient l'hypothèse de moyenne conditionnelle nulle :
$E(u|x) = 0$

On obtient la fonction de regression de la population $ E(y|x) = \beta_0 + \beta_1 x $

- Fonction linéaire de x, linéaire car la *variation* d'une unité de x change la valeur espérée de y par β_1

Estimation Ordinary Least Squares (OLS)

- Comment choisir (β_0 et β_1) sachant que l'on a un échantillon aléatoire de taille n : $\{(x_i, y_i) : i = 1, 2, \ldots, n\}$

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

pour l'individu i

On sait que :

- $E[u|x] = 0$, cela signifie donc que $\text{cov}(x, u) = 0$
- (1) $E(u) = 0$

On a donc : (2) $cov(x, u) = E(xu) = 0$

En utilisant (1) et (2) ainsi que la définition de y_i, on peut trouver $\widehat{\beta_0}$ et $\widehat{\beta_1}$ qui résoud :

- (1) $E(y - \beta_0 - \beta_1 x) = 0$
- (2) $E(x[y - \beta_0 - \beta_1 x)] = 0$

Estimation Ordinary Least Squares (OLS)

En utilisant (1) et (2) ainsi que la définition de y_i, on peut trouver $\widehat{\beta_0}$ et $\widehat{\beta_1}$ qui résoud :

- (1) $E(y - \beta_0 - \beta_1 x) = 0$
- (2) $E(x[y - \beta_0 - \beta_1 x)] = 0$

> **Pente:** $\beta_1^{OLS} = \frac{cov(x,y)}{var(x)}$ **Intersection:** $\beta_0^{OLS} = \bar{y} - \beta_1 \bar{x}$

- Note que $\beta_1 \geq 0$ si $cov(x, y) \geq 0$ et $\beta_1 \leq 0$ si $cov(x, y) \leq 0$
- Ces formules s'obtiennent en résolvant la minimisation du carré des erreurs. Dérivons-les ensemble, étape par étape.



Dérivation : la fonction à minimiser

- Pour des valeurs candidates β_0, β_1, le résidu associé à l'observation i est :

$$\widehat{u}_i = y_i - \beta_0 - \beta_1 x_i$$

Dérivation : la fonction à minimiser

- Pour des valeurs candidates β_0, β_1, le résidu associé à l'observation i est :

$$\widehat{u}_i = y_i - \beta_0 - \beta_1 x_i$$

- La **somme des carrés des résidus (SCR)** est donc une fonction de β_0 et β_1 :

$$SCR(\beta_0, \beta_1) = \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i)^2$$

Dérivation : la fonction à minimiser

- Pour des valeurs candidates β_0, β_1, le résidu associé à l'observation i est :

$$\widehat{u}_i = y_i - \beta_0 - \beta_1 x_i$$

- La **somme des carrés des résidus (SCR)** est donc une fonction de β_0 et β_1 :

$$SCR(\beta_0, \beta_1) = \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i)^2$$

- On cherche $(\widehat{\beta}_0, \widehat{\beta}_1)$ tel que :

$$(\widehat{\beta}_0, \widehat{\beta}_1) = \underset{\beta_0,\, \beta_1}{\arg\min}\ SCR(\beta_0, \beta_1)$$



Dérivation : la fonction à minimiser

- Pour des valeurs candidates β_0, β_1, le résidu associé à l'observation i est :

$$\widehat{u}_i = y_i - \beta_0 - \beta_1 x_i$$

- La **somme des carrés des résidus (SCR)** est donc une fonction de β_0 et β_1 :

$$SCR(\beta_0, \beta_1) = \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i)^2$$

- On cherche $(\widehat{\beta}_0, \widehat{\beta}_1)$ tel que :

$$(\widehat{\beta}_0, \widehat{\beta}_1) = \underset{\beta_0,\, \beta_1}{\arg\min}\ SCR(\beta_0, \beta_1)$$

- **Condition nécessaire :** les dérivées partielles de SCR par rapport à β_0 et β_1 doivent être nulles en $(\widehat{\beta}_0, \widehat{\beta}_1)$.



Dérivation : condition de premier ordre en β_0

- On dérive SCR par rapport à β_0 et on annule :

$$\frac{\partial SCR}{\partial \beta_0} = -2 \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i) = 0$$

Dérivation : condition de premier ordre en β_0

- On dérive SCR par rapport à β_0 et on annule :

$$\frac{\partial SCR}{\partial \beta_0} = -2 \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i) = 0$$

- En divisant par -2 puis en distribuant la somme :

$$\sum_{i=1}^{N} y_i \; - \; N\beta_0 \; - \; \beta_1 \sum_{i=1}^{N} x_i = 0$$

Dérivation : condition de premier ordre en β_0

- On dérive SCR par rapport à β_0 et on annule :

$$\frac{\partial SCR}{\partial \beta_0} = -2 \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i) = 0$$

- En divisant par -2 puis en distribuant la somme :

$$\sum_{i=1}^{N} y_i \; - \; N\beta_0 \; - \; \beta_1 \sum_{i=1}^{N} x_i = 0$$

- En divisant chaque terme par N, on fait apparaître les moyennes $\bar{y}$ et $\bar{x}$:

$$\bar{y} - \beta_0 - \beta_1 \bar{x} = 0$$

Dérivation : condition de premier ordre en β_0

- On dérive SCR par rapport à β_0 et on annule :

$$\frac{\partial SCR}{\partial \beta_0} = -2 \sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i) = 0$$

- En divisant par -2 puis en distribuant la somme :

$$\sum_{i=1}^{N} y_i \; - \; N\beta_0 \; - \; \beta_1 \sum_{i=1}^{N} x_i = 0$$

- En divisant chaque terme par N, on fait apparaître les moyennes $\bar{y}$ et $\bar{x}$:

$$\bar{y} - \beta_0 - \beta_1 \bar{x} = 0$$

On isole directement `(\beta_0)` : $\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}$

Dérivation : condition de premier ordre en β_1

- On dérive SCR par rapport à β_1 et on annule :

$$\frac{\partial SCR}{\partial \beta_1} = -2 \sum_{i=1}^{N} x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Dérivation : condition de premier ordre en β_1

- On dérive SCR par rapport à β_1 et on annule :

$$\frac{\partial SCR}{\partial \beta_1} = -2 \sum_{i=1}^{N} x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

- En divisant par -2 et en distribuant :

$$\sum_{i=1}^{N} x_i y_i \; - \; \beta_0 \sum_{i=1}^{N} x_i \; - \; \beta_1 \sum_{i=1}^{N} x_i^2 = 0$$

Dérivation : condition de premier ordre en β_1

- On dérive SCR par rapport à β_1 et on annule :

$$\frac{\partial SCR}{\partial \beta_1} = -2 \sum_{i=1}^{N} x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

- En divisant par -2 et en distribuant :

$$\sum_{i=1}^{N} x_i y_i \; - \; \beta_0 \sum_{i=1}^{N} x_i \; - \; \beta_1 \sum_{i=1}^{N} x_i^2 = 0$$

- On y substitue $\beta_0 = \bar{y} - \beta_1 \bar{x}$ (trouvé à l'étape précédente) :

$$\sum_{i=1}^{N} x_i y_i \; - \; (\bar{y} - \beta_1 \bar{x}) \sum_{i=1}^{N} x_i \; - \; \beta_1 \sum_{i=1}^{N} x_i^2 = 0$$



Dérivation : condition de premier ordre en β_1

- En développant et en regroupant les termes en β_1 :

$$\sum_{i=1}^{N} x_i y_i - \bar{y} \sum_{i=1}^{N} x_i = \beta_1 \left(\sum_{i=1}^{N} x_i^2 - \bar{x} \sum_{i=1}^{N} x_i \right)$$

Dérivation : formule finale de $\widehat{\beta}_1$

- En isolant β_1 :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} x_i y_i - N\bar{x}\bar{y}}{\sum_{i=1}^{N} x_i^2 - N\bar{x}^2}$$

Dérivation : formule finale de $\widehat{\beta}_1$

- En isolant β_1 :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} x_i y_i - N\bar{x}\bar{y}}{\sum_{i=1}^{N} x_i^2 - N\bar{x}^2}$$

- Cette expression est **algébriquement identique** à :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N} (x_i - \bar{x})^2}$$



Dérivation : formule finale de $\widehat{\beta}_1$

- En isolant β_1 :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} x_i y_i - N\bar{x}\bar{y}}{\sum_{i=1}^{N} x_i^2 - N\bar{x}^2}$$

- Cette expression est **algébriquement identique** à :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N} (x_i - \bar{x})^2}$$



Dérivation : formule finale de $\widehat{\beta}_1$

- En isolant β_1 :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} x_i y_i - N\bar{x}\bar{y}}{\sum_{i=1}^{N} x_i^2 - N\bar{x}^2}$$

- Cette expression est **algébriquement identique** à :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{N} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N} (x_i - \bar{x})^2}$$



Estimation Ordinary Least Squares (OLS)

- Erreurs de différents signes $(+/-)$ s'annulent, donc on considère **le carré des résidus**

$$\forall i \in [1, N], u_i^2 = (y_i - \hat{y}_i)^2 = (y_i - \beta_0 - \beta_1 x_i)^2$$

- Donc on choisi (β_0, β_1) tel que $\sum_{i=1}^{N} u_1^2 + \cdots + u_N^2$ est aussi **petite que possible**.

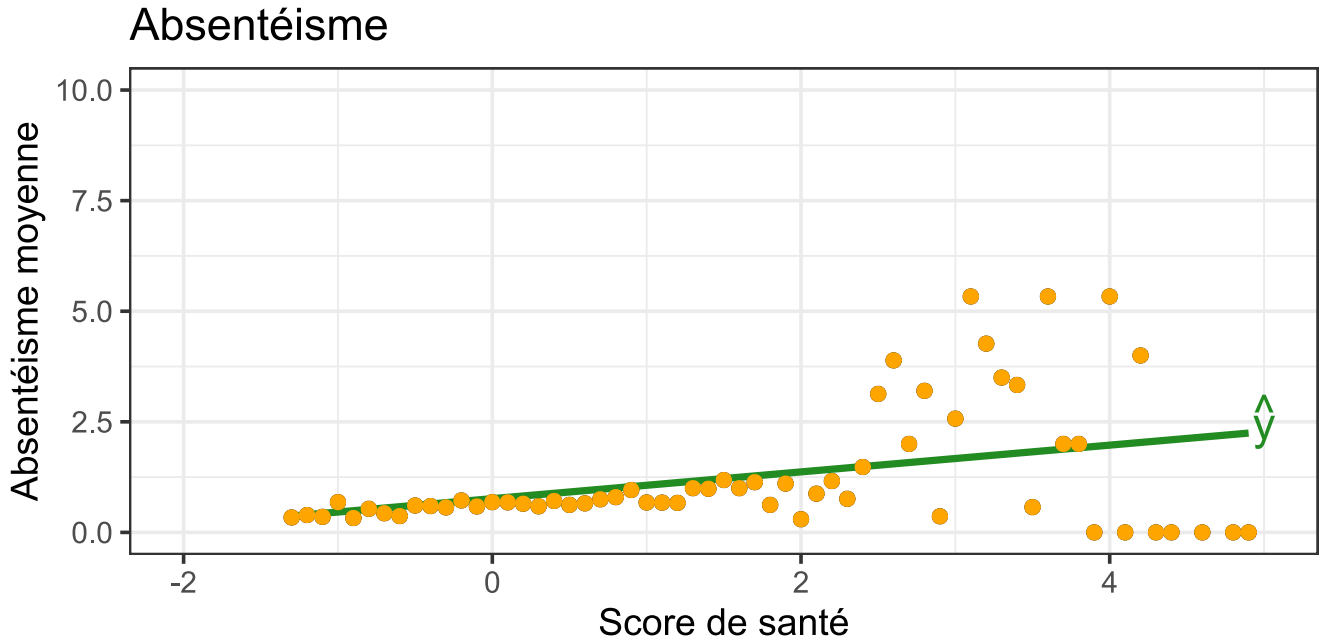


Estimation Ordinary Least Squares (OLS)

- Erreurs de différents signes $(+/-)$ s'annulent, donc on considère **le carré des résidus**

$$\forall i \in [1, N], u_i^2 = (y_i - \hat{y}_i)^2 = (y_i - \beta_0 - \beta_1 x_i)^2$$

- Donc on choisi (β_0, β_1) tel que $\sum_{i=1}^{N} u_1^2 + \cdots + u_N^2$ est aussi **petite que possible**.

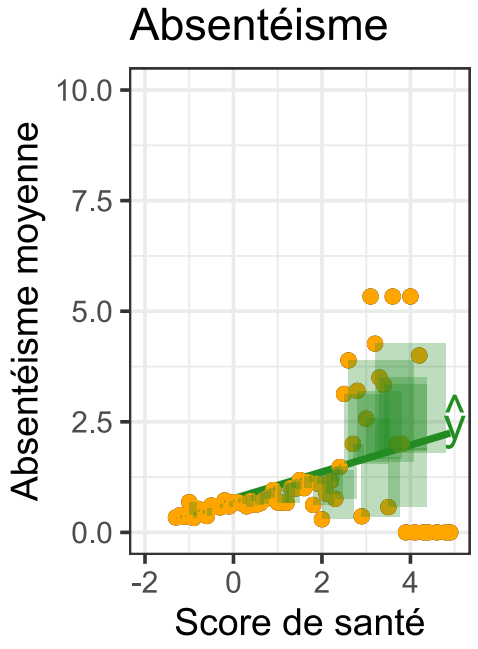


Ordinary Least Squares (OLS) Estimation

- Erreurs de différents signes $(+/-)$ s'annulent, donc on considère **le carré des résidus**

$$\forall i \in [1, N], u_i^2 = (y_i - \hat{y}_i)^2 = (y_i - \beta_0 - \beta_1 x_i)^2$$

- Donc on choisi (β_0, β_1) tel que $\sum_{i=1}^{N} u_1^2 + \cdots + u_N^2$ est aussi **petite que possible**.



Ordinary Least Squares (OLS): Formule des coefs

- **OLS**: méthode d'*estimation* consiste à minimiser la somme des carrés des erreur.
- Résulte en une **unique** solution à ce problème de minimisation



Ordinary Least Squares (OLS): Formule des coefs

- **OLS**: méthode d'*estimation* consiste à minimiser la somme des carrés des erreur.
- Résulte en une **unique** solution à ce problème de minimisation
- Dans notre cas avec une seule variable indépendante :

> **Pente:** $\beta_1^{OLS} = \frac{cov(x,y)}{var(x)}$ **Intersection:** $\beta_0^{OLS} = \bar{y} - \beta_1 \bar{x}$



Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.



Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.

> Intersection (β_0): **La valeur prédite de y $(\hat{y})$ si $x = 0$.**



Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.

> Intersection (β_0): **La valeur prédite de y $(\hat{y})$ si $x = 0$.**
>
> Pente (β_1): **Le changement prédit, en moyenne, dans la valeur de y *associé* à une hasse de une unité de x.**

Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.

> Intersection (β_0): **La valeur prédite de y $(\hat{y})$ si $x = 0$.**
>
> Pente (β_1): **Le changement prédit, en moyenne, dans la valeur de y *associé* à une hasse de une unité de x.**

- ⚠️ Notez que l'on utilise ici le termé *associé*, **car pour le moment on évite d'interpréter β_1 comme l'effet causal de x sur y**. Pour pouvoir mettre une interprétation causale, nous avons besoin que certaines conditions soient validées. (Plus tard dans le cours)

Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.

> Intersection (β_0): **La valeur prédite de y $(\hat{y})$ si $x = 0$.**
>
> Pente (β_1): **Le changement prédit, en moyenne, dans la valeur de y *associé* à une hasse de une unité de x.**

- ⚠️ Notez que l'on utilise ici le termé *associé*, **car pour le moment on évite d'interpréter β_1 comme l'effet causal de x sur y**. Pour pouvoir mettre une interprétation causale, nous avons besoin que certaines conditions soient validées. (Plus tard dans le cours)
- Un autre facteur importante dans l'interprétation de β_1 réside dans l'unité de x.



Ordinary Least Squares (OLS) : Interpretation

Pour le moment, faisons l'hypothèse que nos variables dépendante (y) et indépendante (x) sont numériques.

> Intersection (β_0): **La valeur prédite de y $(\hat{y})$ si $x = 0$.**
>
> Pente (β_1): **Le changement prédit, en moyenne, dans la valeur de y *associé* à une hasse de une unité de x.**

- ⚠️ Notez que l'on utilise ici le termé *associé*, **car pour le moment on évite d'interpréter β_1 comme l'effet causal de x sur y**. Pour pouvoir mettre une interprétation causale, nous avons besoin que certaines conditions soient validées. (Plus tard dans le cours)
- Un autre facteur importante dans l'interprétation de β_1 réside dans l'unité de x.
- **Lors de l'intreprétation vous devrez être explicite sur l'unité de x !**



OLS dans R

- Dans `R`, les régressions OLS sont estimées grâce à la fonction `lm`.
- Concrètement, voici à quoi ressemble le code :

```
lm(formula = y ~  x, data = data.frame avec vos données)
```



OLS dans R

- Dans R, les régressions OLS sont estimées grâce à la fonction lm.
- Concrètement, voici à quoi ressemble le code :

```
lm(formula = y ~  x, data = data.frame avec vos données)
```

Santé des élèves et absentéisme

Estimons le modèle suivant par OLS : $\text{absentéisme}_i = \beta_0 + \beta_1 \text{score santé}_i + u_i$

```
# Régression OLS du score de santé sur l'absentéisme
lm(avg_abs ~ score_bin, data = g_abs)
```

```
##
## Call:
## lm(formula = avg_abs ~ score_bin, data = g_abs)
##
## Coefficients:
## (Intercept)    score_bin
##      0.7409       0.3303
```

Ordinary Least Squares (OLS): Prediction

```
##
## Call:
## lm(formula = avg_abs ~ score_bin, data = g_abs)
##
## Coefficients:
## (Intercept)    score_bin
##      0.7409       0.3303
```



Ordinary Least Squares (OLS): Prediction

```
##
## Call:
## lm(formula = avg_abs ~ score_bin, data = g_abs)
##
## Coefficients:
## (Intercept)    score_bin
##      0.7409       0.3303
```

Cela implique (on simplifie en omettant le subscript $_i$):

$$\hat{y} = \beta_0 + \beta_1 x$$

$$\widehat{\text{absentéisme}}\ \text{moyen} = \beta_0 + \beta_1 \cdot \text{score santé}$$

$$\widehat{\text{absentéisme}}\ \text{moyen} = 0.74 + 0.33 \cdot \text{score santé}$$



Ordinary Least Squares (OLS): Prediction

```
##
## Call:
## lm(formula = avg_abs ~ score_bin, data = g_abs)
##
## Coefficients:
## (Intercept)    score_bin
##      0.7409       0.3303
```

Cela implique (on simplifie en omettant le subscript $_i$):

$$\hat{y} = \beta_0 + \beta_1 x$$

$$\widehat{\text{absentéisme}}\ \text{moyen} = \beta_0 + \beta_1 \cdot \text{score santé}$$

$$\widehat{\text{absentéisme}}\ \text{moyen} = 0.74 + 0.33 \cdot \text{score santé}$$

Quel est l'absentéisme prédit pour un score de santé égal à 3 ? (En se basant sur les coefficients)

$$\widehat{\text{absentéisme}}\ \text{moyen} = 0.74 + 0.33 \cdot 3$$

$$\widehat{\text{absentéisme}}\ \text{moyen} = 1.73$$



Tâche 2 : Régression OLS

10:00

1. Régressez l'absentéisme (variable dépendante) sur le score de santé (variable indépendante). Interprétez les coefficients.

2. Calculez les coefficients OLS β_0 et β_1 de la régression précédente en utilisant les formules de la diapositive 27. (*Indice :* vous devez utiliser les fonctions `cov`, `var`, et `mean`.)

3. Quel est l'absentéisme moyen prédit lorsque le score de santé est égale à 0 ?

4. Quel est l'absentéisme moyen prédit lorsque le score de santé est égale à 4 ?



Propriété des OLS: Pedictions et Residus

Valeurs prédites correspondent à tout valeur de $\hat{y}_i$ qui se trouve sur la droite OLS.

- **La moyenne de $\hat{y}_i$ est égale à $\bar{y}$.**

$$\begin{aligned}\frac{1}{N}\sum_{i=1}^{N}\hat{y}_i &= \frac{1}{N}\sum_{i=1}^{N}\beta_0 + \beta_1 x_i \\ &= \beta_0 + \beta_1 \bar{x} = \bar{y}\end{aligned}$$

- **La moyenne (ou la somme) des résidus est 0.**

$$\begin{aligned}\frac{1}{N}\sum_{i=1}^{N}u_i &= \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i) \\ &= \bar{y} - \frac{1}{N}\sum_{i=1}^{N}\hat{y}_i\end{aligned}$$

Propriété des OLS: Pedictions et Residus

Valeurs prédites correspondent à tout valeur de $\hat{y}_i$ qui se trouve sur la droite OLS.

- **La moyenne de $\hat{y}_i$ est égale à $\bar{y}$.**

$$\begin{aligned}\frac{1}{N}\sum_{i=1}^{N}\hat{y}_i &= \frac{1}{N}\sum_{i=1}^{N}\beta_0 + \beta_1 x_i \\ &= \beta_0 + \beta_1 \bar{x} = \bar{y}\end{aligned}$$

- **La moyenne (ou la somme) des résidus est 0.**

$$\begin{aligned}\frac{1}{N}\sum_{i=1}^{N}u_i &= \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i) \\ &= \bar{y} - \frac{1}{N}\sum_{i=1}^{N}\hat{y}_i\end{aligned}$$

- **Les régresseurs et les résidus ne sont pas corrélés.**

$$Cov(x_i, u_i) = 0$$

- **Les valeurs prédites et les résidus ne sont pas corrélés.**

$$\begin{aligned}Cov(\hat{y}_i, u_i) &= Cov(\beta_0 + \beta_1 x_i, u_i) \\ &= \beta_1 Cov(x_i, u_i) \\ &= 0\end{aligned}$$

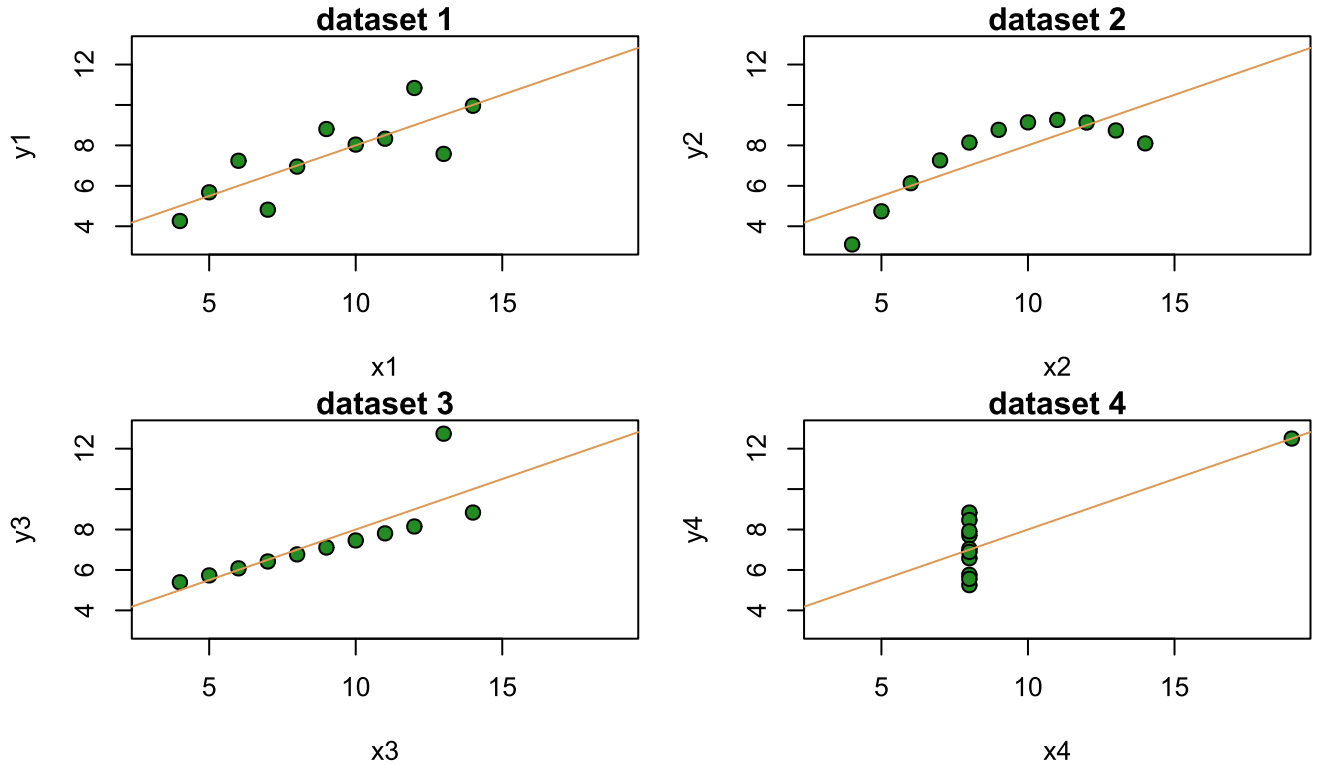
En se basant sur
$Cov(a + bx, y) = bCov(x, y)$.

Un conseil, toujours visualiser ces données !

- ⚠️ La covariance, coefficient de corrélation, et régression OLS univarié ne mesurent qu'une **relation linéaire** entre deux variables.
- On peut avoir deux bases de données avec ces statistiques *identiques* mais qui sont *très* différentes.

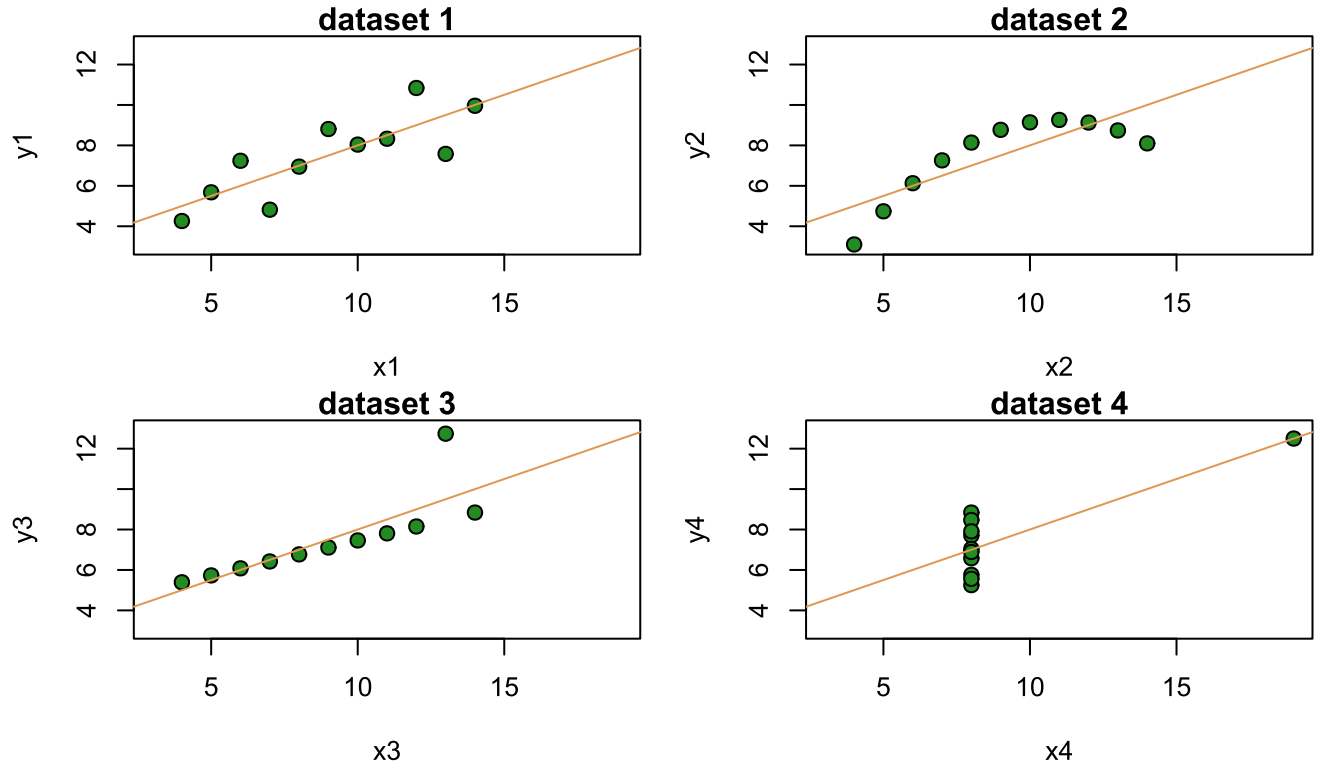
Hypothèse de linéaire : l'exemple Anscombe

- Francis Anscombe (1973) montre 4 base de données avec les mêmes statistiques. Néanmoins, celles-ci semblent bien différentes !



Hypothèse de linéaire : l'exemple Anscombe

- Francis Anscombe (1973) montre 4 base de données avec les mêmes statistiques. Néanmoins, celles-ci semblent bien différentes !



dataset	cov	var(y)	var(x)
1	5.501	4.127	11
2	5.500	4.128	11
3	5.497	4.123	11
4	5.499	4.123	11

Présence de relation non-linéaire ?

- Il est très facile de prendre en compte des relations non-linéaire dans des régressions.
- Il suffit d'ajouter un terme *d'ordre plus élevé* :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + u_i$$

- C'est **une régression multivarié** (patience on verra ça bientôt)

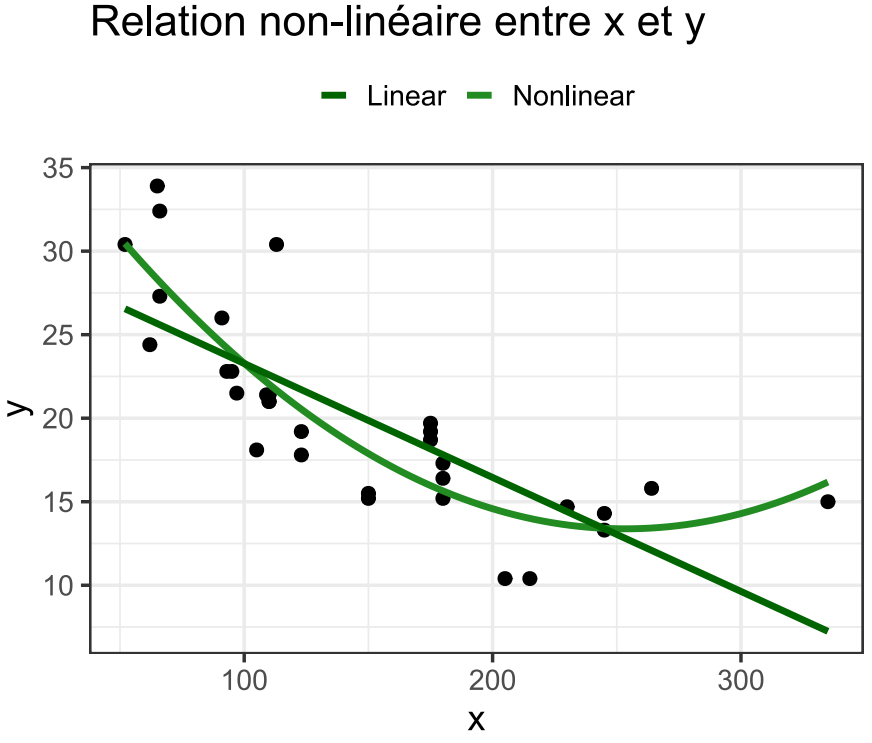
Présence de relation non-linéaire ?

- Il est très facile de prendre en compte des relations non-linéaire dans des régressions.
- Il suffit d'ajouter un terme *d'ordre plus élevé* :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + u_i$$

- C'est **une régression multivarié** (patience on verra ça bientôt)

- Par exemple, imaginons que nous avons ces données, on peut estimer ces modèles :



Analyse de la variance

- Rappel : $y_i = \hat{y}_i + u_i$. En décomposant, on obtient :

$$\begin{aligned} Var(y) &= Var(\hat{y} + u) \\ &= Var(\hat{y}) + Var(u) + 2Cov(\hat{y}, u) \\ &= Var(\hat{y}) + Var(u) \end{aligned}$$

- Car:
  - $Var(x + y) = Var(x) + Var(y) + 2Cov(x, y)$
  - $Cov(\hat{y}, u) = 0$

Analyse de la variance

- **Somme totale des carrés (SST) = Somme des carrés (SSE) + Somme des carrés résiduelles (SSR)**
  - $SST = \sum_i^N (y_i - \bar{y})^2$ = variation totale dans les valeurs actuelles (y_i)
  - $SSE = \sum_i^N (\widehat{y_i} - \bar{y})^2$ = variation de l'échantillon dans les valeurs prédites ($\widehat{y_i}$)
  - $SSR = \sum_i^N \hat{u_i}^2$ = variation de l'échantillon dans les résidus ($\widehat{u_i}$)

Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.



Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totlae}} = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totlae}} = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

- R^2 proche de 1 indique un **pouvoir explicatif très *fort*** du modèle.
- R^2 proche to 0 indique un **pouvoir explicatif très *faible*** du modèle.

Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totlae}} = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

- R^2 proche de 1 indique un **pouvoir explicatif très *fort*** du modèle.
- R^2 proche to 0 indique un **pouvoir explicatif très *faible*** du modèle.
- *Interpretation:* un R^2 de 0.3, par exemple, signifie que la variation dans les x "explique" 30% de la variatoin totale dans y.

Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totlae}} = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

- R^2 proche de 1 indique un **pouvoir explicatif très *fort*** du modèle.
- R^2 proche to 0 indique un **pouvoir explicatif très *faible*** du modèle.
- *Interpretation:* un R^2 de 0.3, par exemple, signifie que la variation dans les x "explique" 30% de la variatoin totale dans y.
- ⚠️ Faible R^2 ne **SIGNIFIE PAS** que le modèle est inutile ! Rappel du premier cours, on est intéressé.e dans les relations causales, pas la prédiction (cours de Machine Learning) !



Pouvoir prédictif du modèle

- Mesurer à quel point x explique bien y, i.e., le pouvoir prédictif du modèle
- Le R^2 mesure à quel point le **modèle estime bien les données**.

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totlae}} = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

- R^2 proche de 1 indique un **pouvoir explicatif très *fort*** du modèle.
- R^2 proche to 0 indique un **pouvoir explicatif très *faible*** du modèle.
- *Interpretation:* un R^2 de 0.3, par exemple, signifie que la variation dans les x "explique" 30% de la variatoin totale dans y.
- ⚠️ Faible R^2 ne **SIGNIFIE PAS** que le modèle est inutile ! Rappel du premier cours, on est intéressé.e dans les relations causales, pas la prédiction (cours de Machine Learning) !
- ⚠️ Le R^2 n'est **PAS** un indicateur de causalité entre deux relations. On verra ça plus tard dans le cours !



Tâche 3 : R^2 et qualité de l'ajustement

10:00

1. Régressez `score` sur `avg_abs`. Assignez le résultat à un objet `abs_reg`.

2. Passez `abs_reg` dans la fonction `summary()`. Quel est le R^2 (multiple) pour cette régression ? Comment pouvez-vous l'interpréter ?

3. Calculez la corrélation au carré entre ces deux variables. Que vous apprend cela sur la relation entre le R^2 et la corrélation dans une régression à un seul régresseur ?



UNIVERSITÉ DE NAMUR

Bonne journée !

	jeremy.donascimento@unamur.be
	Discord
	Slides